

记忆库：利用长期记忆增强大型语言模型

Wanjun Zhong¹, Lianghong Guo¹, Qiqi Gao², He Ye³, Yanlin Wang^{(1)*}

¹中山大学

²哈尔滨工业大学

³KTH 皇家理工学院

{zhongwj25@mail2, wangylin36@mail, guolh8@mail2}.sysu.edu.com 18b903026@stu.hit.edu.cn, heyeye@kth.se

摘要

大型语言模型 (LLM) 极大地改变了我们与人工智能 (AI) 系统的交互方式，在一系列任务中表现出令人印象深刻的性能。尽管如此，一个明显的障碍依然存在--这些模型中缺乏长期记忆机制。在个人陪伴系统、心理咨询和秘书助理等需要持续互动的情况下，这种不足变得越来越明显。认识到长期记忆的必要性，我们提出了 "记忆库" (MemoryBank) 这一为 LLM 量身定制的新型记忆机制。MemoryBank 使模型能够唤醒重要记忆，通过不断更新记忆来持续发展、理解，并通过综合以前的互动信息来适应用户的个性。为了模仿拟人行为并有选择地保留记忆，MemoryBank 在艾宾浩斯遗忘曲线理论的启发下，采用了一种记忆更新机制。这种机制允许人工智能根据时间的推移和记忆的相对重要性来遗忘和强化记忆，从而提供更像人类的记忆机制和更丰富的用户体验。Memory-Bank 可同时兼容 ChatGPT 等闭源模式和 ChatGLM 等开源模式。为了验证 MemoryBank 的有效性，我们在一个长期的人工智能伴侣场景中创建了一个基于 LLM 的聊天机器人 SiliconFriend，以此来示范 MemoryBank 的应用。经过心理对话数据的进一步调整，SiliconFriend 在互动中表现出了更高的同理心和辨别力。实验包括对真实世界用户对话的定性分析和对模拟对话的定量分析。在后者中，ChatGPT 将扮演多个具有不同特征的用户，并生成涵盖各种主题的长期对话语境。我们的分析结果表明，配备了记忆库的 SiliconFriend 具有强大的长期陪伴能力，因为它可以提供强调性的回应、唤起相关记忆并了解用户的个性。

*Corresponding author: 王彦林，中山大学软件工程学院。
版权所有 © 2024，人工智能促进协会
Intelligence (www.aaai.org)。保留所有权利。

引言

大型语言模型 (LLMs)，如 ChatGPT (OpenAI 2022) 和 GPT-4 (OpenAI 2023)，已导致越来越多的语言模型 (LLMs)，如 ChatGPT (OpenAI 2022) 和 GPT-4 (OpenAI 2023)。

从教育和医疗保健到客户服务和娱乐，人工智能的影响遍及各个领域。这些强大的人工智能系统在理解和产生类似人类的反应方面表现出了非凡的能力。尽管 LLMs 具有非凡的能力，但它们的一个主要局限是缺乏长期记忆，而长期记忆是类人交流的一个重要方面，在需要持续互动的场景中尤为明显，如个人陪伴、心理咨询和秘书任务。人工智能中的长期记忆对于保持上下文理解、确保有意义的互动和理解用户的长期行为至关重要。例如，人工智能个人伴侣需要回忆过去的对话，以建立友好关系。在心理逻辑咨询中，人工智能可以通过了解用户的历史和过去的情绪状态提供更有效的支持。同样，秘书人工智能也需要记忆来进行任务管理和偏好识别。LLM 缺乏长期记忆会影响其性能和用户体验。因此，必须开发人工智能的记忆能力，以实现更加个性化的交互。

因此，我们引入了“记忆库”（MemoryBank），这是一种新颖的机制，旨在为本地语言管理员提供保持长期记忆和绘制用户肖像的能力。Memory-Bank 可使 LLM 回忆起历史交互，不断发展对上下文的理解，并根据过去的交互适应用户的个性，从而提高他们在长期交互场景中的表现。艾宾浩斯遗忘曲线是描述记忆强度随时间推移而减弱的成熟心理学原理，受此启发，MemoryBank 进一步采用了动态记忆机制，与人类的认知过程密切相关。这种机制使人工智能能够根据时间的推移记忆、选择性遗忘和强化记忆，从而提供更自然、更吸引人的用户体验。具体来说，MemoryBank 建立在记忆存储的基础上，具有记忆重现和更新机制，能够总结过去的事件和用户的个性。MemoryBank 既能兼容 ChatGPT 这样的闭源 LLM，也能兼容 ChatGLM（Zeng 等，2022 年）或 BELLE（季云杰和李，2023 年）这样的开源 LLM。

为了说明 MemoryBank 的实际意义，我们开发了 SiliconFriend，这是一个基于 LLM 的人工智能伴侣聊天机器人，集成了这一创新的记忆机制。

SiliconFriend旨在保留和参考过去的互动行为，加强记忆库在打造更人性化的人工智能伴侣方面的变革性影响。SiliconFriend的一个显著特点是从各种网络来源收集到的38K段心理对话中进行调整，这使它表现出同理心、细心，并提供有用的指导，使其善于处理情绪激动的对话。此外，SiliconFriend的一个突出功能是通过总结过去的互动来了解用户的个性，这使它能够根据用户的个性特征量身定制回复，从而提升用户体验。此外，Silicon-Friend还支持双语功能，以满足用中英文交流的用户的需求。这种多语言支持扩大了其在不同用户群中的可用性。SiliconFriend采用ChatGLM和BELLE两种开源模型以及ChatGPT一种闭源模型，展示了MemoryBank在适应不同LLM方面的多功能性。

为了评估MemoryBank的有效性，我们进行了涵盖定性和定量分析的评估，前者涉及真实世界的用户对话，后者采用模拟对话。在定量分析中，我们创建了一个由10天对话组成的记忆库，其中包含各种不同的主题。这些对话涉及15个性格各异的虚拟用户，由ChatGPT扮演用户角色，并根据他们的性格生成对话语境。在记忆存储的基础上，我们设计了194个探究性问题，以评估该模型是否能成功回忆起相关记忆并提供适当的回答。实验结果展示了SiliconFriend在回忆记忆、提供情感陪伴和理解用户肖像方面的能力。这些发现证明了记忆库在长期交互场景中显著提高LLM性能的潜力。我们将主要贡献总结如下：

- 我们介绍了一种新颖的类人长期记忆机制--MemoryBank，它能让LLMs存储、回忆、更新记忆并绘制用户肖像。
- 我们通过SiliconFriend演示了记忆库的实际应用性，SiliconFriend是一家基于LLM的人工智能公司，配备了记忆库并通过心理逻辑对话进行了调整。它可以回忆过去的记忆，提供情感陪伴，并理解用户的行为。
- 我们从三个关键方面展示了MemoryBank的通用性：(1) 兼顾开源和闭源LLM；(2) 中英文双语能力；(3) 有无记忆遗忘机制的适用性。

记忆库为 LLM 量身定制的新型记忆机制

我们将介绍专为LLM设计的新型内存机制MemoryBank。如图1所示，MemoryBank是一种统一的机制，围绕三个核心支柱构建：(1) 作为LLM的内存存储设备；(2) 作为LLM的存储设备；(3) 作为LLM的存储设备。

主要数据存储库，(2) 用于特定情境记忆的记忆检索器，(3) 从艾宾浩斯遗忘曲线理论中汲取灵感的记忆更新器，艾宾浩斯遗忘曲线理论是与记忆保持和遗忘相关的一个久经考验的心理学原理。

记忆存储：记忆库的仓库

记忆库（MemoryBank的仓库）是一个庞大的数据存储库，存储着大量细致入微的信息。如图1所示，它存储了日常对话记录、过往事件摘要和不断变化的用户个性评估，从而构建了一个动态、多层次的记忆景观。

深度记忆存储：MemoryBank的存储系统以详细的时间顺序记录多轮对话，从而捕捉到人工智能与用户之间丰富的互动。每段对话都存储有时间戳，从而形成了过去互动的有序叙述。这种去尾记录不仅有助于精确的记忆检索，还有助于之后的记忆更新过程，为对话历史提供了详细的索引。

分层事件摘要：MemoryBank反映了人类记忆的复杂性，超越了单纯的详细存储。它将对话处理并提炼为日常事件的高层次摘要，就像人类如何重新记忆其经历的关键方面一样。我们将对话浓缩成简明的每日事件摘要，然后进一步合成为全局摘要。这一过程会产生一个分层的记忆结构，提供一个过去互动和重要事件的鸟瞰图。具体来说，我们将以前的日常对话或日常事件作为输入，要求LLMs总结日常事件或全局事件，提示语为“总结[对话/事件]内容中的事件和关键内容”。

动态个性理解：MemoryBank注重对用户个性的理解。它通过长期互动不断分析和更新这些理解，并创建每日个性洞察。这些洞察会进一步汇总，形成对用户个性的整体理解。通过这种多层次的方法，人工智能伴侣可以根据每个用户的独特特征进行学习、调整和定制响应，从而提升用户体验。特别是在日常对话或性格分析中，我们要求LLM通过提示进行推理：“[对话]”或“以下是用户在多日内表现出的性格特征和情绪。请对用户的个性进行高度简洁的概括总结[每日个性]”。

记忆检索

我们的记忆检索机制建立在记忆存储的稳健基础之上，其运作类似于知识检索任务。在这种情况下，我们采用了一种类似于密集通道检索（Dense Passage Retrieval, Karpukhin 等人，2020年）的双塔密集检索模型。在这一模式中，对话的每一个转折和




图 1: MemoryBank 概述。记忆存储器存储过去的对话、事件摘要和用户肖像, 而记忆更新机制则更新记忆存储器。记忆检索可调用相关记忆。SiliconFriend 是一个基于 LLM 的人工智能伴侣, 它与 MemoryBank 相辅相成。

事件摘要被视为一个记忆片段 m , 它被预先编码成上下文表示 $h(m)$ 。

编码器模型 $E(\cdot)$ 。因此, 整个存储器的存储空间是有限的。年龄 M 被预先编码为 $M = \{h^0, h^1, \dots, h^{(M)}\}$, 其中

每个 h_m 是一个记忆片段的向量表示。然后使用 FAISS (Johnson, Douze 和 Jegou 2019) 对这些向量表示进行索引, 以实现高效检索。与此同时, 对话 c 的当前上下文由以下内容编码

$E(\cdot)$ 转换成 h_c , 作为查询, 在 M 中搜索最相关的存储器。实际上, 编码器 $E(\cdot)$ 可以与任何合适的模型互换。

内存更新机制

有了持久内存存储和内存重置机制, LLM 的记忆能力就能大大增强。不过, 对于需要更多无病呻吟式内存行为的应用场景, 则需要进行内存更新。这些场景包括人工智能伴侣、虚拟 IP 等。遗忘那些年代久远、不太重要的记忆片段, 可以让人工智能伴侣更加自然。

记忆遗忘机制受艾宾浩斯遗忘曲线理论启发, 遵循原则规则¹:

- **遗忘率。**艾宾浩斯发现, 记忆保持率会随着时间的推移而降低。他在遗忘曲线中对此进行了量化, 表明信息在学习后会迅速丢失, 除非有意识地进行复习。
- **时间与记忆衰减。**曲线在开始时是陡峭的, 表明在学习后的最初几小时或几天内, 大量已学知识就会被遗忘。然后, 记忆丧失的速度会减慢。
- **间隔效应。**艾宾浩斯发现, 重新学习比第一次学习更容易。经常重温和重复所学材料可以重置遗忘曲线, 使其不那么陡峭, 从而证明记忆的保持效果。

¹虽然艾宾浩斯遗忘曲线理论还包括其他特征, 如过度学习 () 和有意义的物质效应 (), 但我们的论文侧重于模拟所列的三

艾宾浩斯遗忘曲线用指数衰减模型表示: $R = e^{-\frac{t}{s}}$, 其中 R 是遗忘率。 t 是学习信息后所经过的时间。

条原则规则。

S 是记忆强度，会根据以下因素发生变化例如学习深度和重复次数。为了简化记忆更新过程，我们将 S 建模为一个失忆值，并在对话中首次提及及时将其初始化为 1。当记忆项在对话中被唤起时，它会在记忆中持续更长时间。我们将 S 增加 1，并将 t 重置为 0，从而降低遗忘它的概率。需要注意的是，这是一个探索性的、高度简化的记忆更新模型。现实生活中的记忆过程更为复杂，会受到多种因素的影响。对于不同的人 and 不同类型的信息，遗忘曲线也会有所不同。总之，MemoryBank 将这些关键要素整合在一起，形成了一个更全面的 LLM 内存管理系统。它增强了 LLM 长时间提供有意义的个性化互动的能力，同时也为 LLM 提供了开放式的记忆管理系统。为人工智能应用提供了新的可能性。

SiliconFriend：记忆库支持的人工智能聊

天机器人伴侣

为了证明记忆库在长期个人人工智能陪伴领域的实用性，我们创建了一个名为 SiliconFriend 的人工智能聊天机器人。它旨在成为用户的情感伴侣，回忆用户的相关记忆，了解用户的个性和情绪状态。我们的实现集成了三个功能强大的 LLM，它们原本都缺乏长期记忆和对心理领域的特定适应性，但我们的实现展示了它们的适应性。

1) ChatGPT (OpenAI 2022) 是由 OpenAI 建立的闭源对话模型，是一种专有的关系型人工智能模型，以其促进动态和交互式对话的能力而闻名。该模型在大量数据的基础上进行训练，并通过人类反馈的强化学习进行进一步微调。这种方法使 ChatGPT 不仅能生成符合语境的回复，而且还能生成符合用户需求的回复。

在实际应用中, 它不仅要与人类的期望相匹配, 还要与人类的认知密切相关。2) **ChatGLM** (Zeng 等, 2022 年): ChatGLM 是基于通用语言模型 (GLM) 框架的开源双语模型。该模型的特点是拥有 62 亿个参数, 并针对中文对话数据进行了专门优化。该模型的训练包括处理约一万亿个中英文文本标记, 并辅以监督微调、反馈引导和人工反馈强化学习。3) **BELLE** (季允杰和李 2023): BELLE 是一个开源的双语语言模型, 由 7B LLaMA (Touvron 等, 2023 年) 持续微调而成。BELLE 的特点是自动指令合成, 这增强了它的中文会话能力。

SiliconFriend 的开发分为两个阶段。第一阶段 (仅适用于开源 LLM) 是利用心理对话数据对 LLM 进行参数优化。通过这一步骤, SiliconFriend 可以为用户提供有用的、感同身受的情感支持, 反映出人类伴侣所期望的不理解和同情。第二阶段是将 MemoryBank 集成到 SiliconFriend 中, 从而为其灌输强大的记忆系统。MemoryBank 允许聊天机器人保留、回忆和利用过去的互动和用户画像, 从而提供更丰富、更个性化的用户体验。

利用心理数据进行参数高效调整: SiliconFriend 开发的初始阶段包括使用 38k 心理对话数据集调整 LLM。这些数据来自在线资源², 包括一系列涵盖情绪状态和反应的对话。这一调整过程使 Silicon-Friend 能够有效地理解和回应情绪线索, 模仿人类伴侣的同情、理解和支持。它使人工智能具备了利用心理学知识处理情感引导对话的能力, 并能根据用户的情感状态为其提供有意义的情感支持。

为了让 LLMs 适应计算资源有限的场景, 我们采用了一种计算效率高的调整方法, 即低秩调整 (Low-Rank Adaptation, LoRA) 方法 (Hu 等人, 2021 年)。LoRA 通过学习成对的秩分解矩阵, 大大减少了可训练参数的数量, 同时冻结了原始权重。形式上, 考虑一个线性层, 其定义为 $y = Wx$ 权重为 W 。LoRA 将其修改为 $y = Wx + BAx$, 其中 $W \in \mathbb{R}^{d \times k}$, $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$, $r \ll \min(d, k)$ 。这种方法大大减少了参数。这对于在资源有限的情况下提高效率至关重要。我们将 LoRA rank r 设置为 128, 并使用 A100 GPU 对模型进行了 3 次历时训练。

注意到这一阶段只针对开源龙8国际娱乐城。从本质上讲, 这一阶段为 Silicon-Friend 成为具有同理心的人工智能伴侣奠定了基础, 确保它能对用户的情感需求做出有益的回应。

与 MemoryBank 集成: SiliconFriend 开发的第二阶段涉及与 MemoryBank 的整合。

或数据库。这一阶段至关重要，因为它使 SiliconFriend 具备了存储、检索过去的互动以及了解用户画像的能力，从而提供更加个性化、更具吸引力的用户体验。

在记忆存储方面，SiliconFriend 与用户之间的对话将被记录并更新到记忆存储中，这一过程可在不同的模型骨干中进行调整。记忆更新机制采用的原则受到艾宾浩斯遗忘曲线理论的启发，从而实现了逼真的、类似人类的记忆回忆过程。在实时对话过程中，用户的对话将作为记忆检索的查询。在实践中，我们使用 LangChain (LangChain Inc. LangChain 支持开源嵌入模型和 FAISS 索引，因此是一种通用选择。在 SiliconFriend 开源版本的特定语言实现中，我们使用 MiniLM (Wang 等人, 2020 年) 作为英文的嵌入模型，使用 Text2vec (Ming, 2022 年) 作为中文的嵌入模型。值得注意的是，嵌入模型可以灵活交换，以适应不同的需求，甚至可以使用多语言模型。在检索记忆时，对话提示中会组织一系列信息，包括相关记忆、全局用户画像和全局事件摘要。因此，SiliconFriend 可以生成参考过去记忆的回复，并提供与过去记忆相关的信息。

根据用户的肖像进行互动。

总之，这些阶段将 SiliconFriend 从一个标准的人工智能聊天机器人转变为一个长期的人工智能伴侣，它能够记住并学习过去的互动，从而提供个性化和感同身受的用户体验。

实验

我们实验的主要目的是评估 MemoryBank 的功效，特别是其作为人工智能伴侣的能力。我们尤其想确定，嵌入长期记忆模块是否能提高人工智能在回忆历史互动和加深对用户个性理解方面的能力。此外，我们还检验了基于心理学数据的调整是否能增强人工智能提供有效情感支持的能力。

定性分析主要集中在三个方面：(1) SiliconFriend 和基线之间的对比研究，以评估它们在提供共情心理陪伴方面的能力；(2) SiliconFriend 的记忆回忆能力调查；(3) 分析模型对用户资料的理解如何影响用户的反应。更重要的是，为了在更大范围内证明模型在记忆再调用方面的能力，我们使用了大规模的长期记忆存储和 194 个记忆探测问题进行质量分析。ChatGPT 通过 15 个不同的虚拟用户（每个用户都体现了自己的个性）的角色扮演，生成了跨越 450 个话题和 10 天时间跨度的模拟对话历史。

定性分析

定性分析是通过展示 SiliconFriend 的实践案例来进行的。为了收集这些



图 2：咨询 SiliconFriendChatGLM 进行心理陪伴的实例。总之，SiliconFriend 可以提供更多的共情响应，为用户提供建设性的情感支持，帮助他以积极的心态面对悲伤。

例如，我们为 SiliconFriend 开发了一个在线平台，并收集了实际用户的实时对话。

心理陪伴 在对话中表现出情感的能力是有效人工智能伴侣的关键属性。为了评估模型为用户提供心理安慰的能力，我们比较了 SiliconFriend 和基线 LLMs 在真实对话中的反应。如图 2 所示，当用户表达情绪困难并向 SiliconFriend 寻求帮助时，该模型能够做出令人同情的回应，并提出建设性建议。SiliconFriend 的回应因其情感支持而脱颖而出，与基线 ChatGLM 形成了鲜明对比。

记忆回忆分析 为了评估 SiliconFriend 的记忆回忆能力，我们在对话中加入了记忆探测问题。这些问题旨在提示 SiliconFriend 从聊天记录中检索特定细节。如图 3 所示，用户和 SiliconFriend 就编程学习建议进行了讨论。几天后，用户提出了几个记忆探测问题。SiliconFriend 成功地回忆起了之前建议的书籍和算法。此外，它还正确地识别出了一个以前未曾讨论过的事件（即堆排序算法）。这些例子都证明了 SiliconFriend 的成功记忆能力。



性格互动分析 如图 4 所示，我们考察了 SiliconFriend 与不同性格用户的互动能力。我们观察到，它能根据用户的性格特征，有效地推荐符合其兴趣的活动。这一分析表明，SiliconFriend 能够与不同性格的用户进行有效的互动。

定量分析

为了在更大范围内体现 SiliconFriend 的记忆回忆能力，我们进行了定量分析。我们请人类注释者对从以下模型中检索到的记忆和回复进行评分：（1）SiliconFriendChatGPT；（2）SiliconFriendChatGLM；（3）SiliconFriendBELLE。

内存存储构建：我们建立了一个评估基础，内存存储了 15 个虚拟用户 10 天的对话。这些用户具有双重人格，每天的对话至少涉及两个主题。用户元信息（包括姓名、性格和感兴趣的话题）由 ChatGPT 生成。对话由 ChatGPT 根据预定义的话题和用户个性合成。我们创建了中英文记忆库。对时记忆库涵盖了 450 个话题的多轮对话。建立记忆存储后，我们人工编写了 194 个试探性问题（97 个英文问题和 97 个中文问题），以评估模型是否能准确地重新调用相关记忆并恰当地提出答案。表 1 举例说明了用户元信息、生成的会话和试探性问题。

评估指标 根据以下指标对性能进行评估。（1）**记忆检索准确性：**确定相关记忆是否能被成功检索（标签：否=0，是=1）。（2）**反应正确性：**评估回答是否包含对试探性问题的正确回答（标签：错误=0，部分=0.5，正确=1）。（3）**上下文一致性：**评估回答的结构是否自然连贯，是否将对话上下文和检索记忆联系起来（标签：不连贯=0；部分连贯=0.5；连贯=1）。

图 3: SiliconFriend_{BELLE}在记忆回忆中的反应示例。图 4: SiliconFriend_{ChatGPT}对不同性格用户的回复示例。

一致=0，部分一致=0.5，一致=1)。(4) 模型排名得分：

对 Silicon-Friend 的三个变体 (SiliconFriend_{ChatGLM}、SiliconFriend_{ChatGPT}和 SiliconFriend_{BELLE}) 在相同问题和内容下的输出进行排名。模型得分使用 $s = 1/r$ ，其中 $r = 1, 2, 3$ 表示相对排名。

结果分析。我们用中英文测试集评估了 SiliconFriend 的 3 个变体。表 2 得出以下结论：(1) 最佳变体 SiliconFriend_{ChatGPT} 在所有指标上都有很高的表现，显示了整体框架的有效性。(2) SiliconFriend_{BELLE}和 SiliconFriend_{ChatGLM}在检索准确率方面也有很高的表现，这表明 MemoryBank 机制对于开源和闭源 LLM 都具有通用性和有效性。不过，它们在其他指标上的表现不如 SiliconFriend_{ChatGPT}。这可能是因为基础模型的整体能力不如 ChatGPT。(3) 不同语言的性能不同。SiliconFriend_{ChatGLM}和 SiliconFriend_{ChatGPT}在英语中的表现较好，而 SiliconFriend_{BELLE}在中文中的表现突出。

相关作品

大型语言模型：GPT-3 (Brown 等人，2020 年) 和 FLAN-

T5 (Chung 等人，2022 年) 等 LLM 已经

在广泛的任务中取得了长足的进步。最近，最先进的闭源语言模型，如 PaLM (Chowdhery 等人, 2022 年) 和 ChatGPT (OpenAI, 2022 年)，继续显示出巨大的灵活性，能够适应各种各样的领域。它们已逐渐成为许多人的日常决策辅助工具。然而，这些模型的封闭源代码性质使得研究人员和公司无法研究 LLMs 的内在机制，也无法构建适应不同领域的应用。因此，社区中出现了许多开源 LLM，如 LLaMa (Touvron 等人, 2023 年)、ChatGLM (Zeng 等人, 2022 年) 和 Alpaca (Taori 等人, 2023 年)。欲了解更多详情，请读者参阅本报告：赵等人 (2023 年)。然而，这些模型仍有不足之处。一个明显的缺陷是它们缺乏强大的长期记忆功能。这一局限影响了它们长期保持上下文并从过去的互动中检索相关信息的能力。在此，我们重新进行了研究，主要目的是开发 LLM 的长期记忆机制。

长期记忆机制：人们一直在尝试增强神经模型的记忆能力。记忆增强网络 (MANNs) (Meng 和 Huang, 2018 年；Graves、Wayne 和 Danihelka, 2014 年) 与神经转机 (NTMs) (Graves、Wayne 和 Danihelka, 2014 年) 一样，可以增强神经网络的记忆能力。这些

用户元信息:	姓名: 加里加里爱好: 赛车、商务、国际象棋、绘画、葡萄酒 性格: 果断、直率、直言不讳、乐于助人
往期对话:	(5月3日) 用户: 我最近感觉压力有点大, 睡眠也不太好。您有什么缓解压力的好方法吗? (5月3日) 大赦国际: 长期的工作或生活压力确实会影响我们的身心健康。缓解压力的方法有很多, 比如做适量运动、听音乐、阅读、与朋友聊天等。您可以尝试在日常生活中增加娱乐和休闲活动, 减轻工作压力和负面影响。 (接下来的对话涉及电影和其他话题。 电视节目推荐)。
探究性问题:	(5月10日) 您向我推荐了哪些缓解压力的好方法?
模型输出:	我建议您尝试做一些适度的运动、听音乐、阅读、与人交谈。
SiliconFriend _{ChatGLM}	在日常生活中, 你可以多交朋友, 或增加娱乐和休闲活动, 以减轻工作压力和负面影响。您也可以尝试在生活中适度地增加这些活动, 因为重要的是要保持平衡, 不要过度。如果您仍然感到压力, 我建议您寻求专业咨询师或治疗师的帮助, 他们可以为您提供进一步的指导和支持。我推荐了一些缓解压力的方法, 如做运动、听音乐、与朋友聊天等。您可以尝试在日常生活中增加娱乐和休闲活动, 减轻工作压力和负面影响。
型号输出: 硅友 _{BELLE}	
模型输出:	根据我们过去的谈话, 我建议做适量的运动、听音乐、阅读、与朋友交谈, 以及在日常生活中增加更多的休闲活动, 这些都是缓解压力的好方法。运动可以帮助释放内啡肽, 提升情绪, 而音乐和阅读则可以让从精神上逃离压力。与朋友交谈也可以通过提供社会支持系统来缓解压力。最后, 在日常生活中增加休闲活动也是一种有趣而有效的减压方式。
SiliconFriend _{ChatGPT}	

表 1: 记忆库中 5 月 3 日的记忆片段和 5 月 10 日提出的相应试探问题示例。表中显示了 SiliconFriend 三个变量的输出结果, 以供比较。所有模型的答案都正确一致。

兰	模型	RA.	Cor.	Coh.	等级
恩。	硅友 _{聊天室}	0.809	0.438	0.68	0.498
	硅友 _{贝尔}	0.814	0.479	0.582	0.517
	硅友 _{聊天室}	0.763	0.716	0.912	0.818
Ch.	SiliconFriend _{ChatGLM}	0.84	0.418	0.428	0.51
	硅友 _{贝尔}	0.856	0.603	0.562	0.565
	SiliconFriend _{ChatGPT}	0.711	0.655	0.675	0.758

表 2: 定量分析结果检索准确率
=RA., Correctness= Cor., Coherence= Coh.

这些模型的结构是为了与外部记忆矩阵进行交互, 使它们能够处理需要长时间维护和操作存储信息的任务。尽管这些方法显示出了潜力, 但它们并没有完全满足对 LLMs 中可靠且适应性强的长期记忆功能的需求。有研究关注长程会话 (Xu、Szlam 和 Weston, 2021 年; Xu 等, 2022 年)。Xu、Szlam 和 Weston (2021 年) 引入了一个由多时段人与人聊天组成的数据集, 用于长期对话。然而, 这些对话仅限于几轮对话, 无法与长期的人工智能同伴相匹配。此外, 这些模型往往无法创建详细的用户画像, 也缺乏类似人类的记忆更新机制, 而这两者对于促进更自然的交互都至关重要。心理学界一直在研究记忆更新的概念。艾宾浩斯 (Ebbinghaus, 1964 年) 的 "遗忘曲线" (Forgetting Curve) 理论揭示了人类随着时间推移记忆保持和获取的模式。受这一理论的启发, 我们在 MemoryBank 中加入了记忆更新机制, 以便

增强其长期记忆功能。

虽然在以下领域取得了重大进展
法律硕士仍然需要长期记忆机制。
在需要个人能力的场景中, 增强法律硕士的能力。

化和持久的互动。我们的工作将 Memo- ryBank 作为一种新方法应对这一挑战。

结论

我们介绍的 MemoryBank 是一种长期记忆机制, 旨在解决 LLM 的记忆限制问题。MemoryBank 增强了长期保持上下文、回忆相关信息和理解用户个性的能力。MemoryBank 的记忆更新机制证明了人工智能在长期交互场景中的拟人化。MemoryBank 的多功能性体现在它既能容纳开源模型, 也能容纳像 ChatGPT 这样的近源模型。我们通过 SiliconFriend 进一步说明了 MemoryBank 的实际应用, SiliconFriend 是一款基于 LLM 的聊天机器人, 旨在作为人工智能的长期伴侣。有了 MemoryBank, SiliconFriend 可以更深入地了解用户, 提供更加个性化和人性化的互动。利用心理对话数据对 SiliconFriend 进行调整, 使其能够提供感同身受的情感支持。广泛的实验验证了 MemoryBank 的有效性。实验结果表明, 记忆库增强了 SiliconFriend 的记忆能力, 加深了对用户行为的理解。此外, SiliconFriend 还能提供更高质量的情感陪伴。

致谢

本文所述工作得到了 CCF- 华为杨树林基金 CCF-HuaweiSE202301 的部分支持。

参考资料

- Brown, T.; Mann, B.; Ryder, N.; Subbiah, M.; Kaplan, J. D.; Dhariwal, P.; Neelakantan, A.; Shyam, P.; Sastry, G.; Askell, A.; et al. 2020. 语言模型是少量学习者。 *Advances in neural information processing systems*, 33: 1877-1901.
- Chowdhery, A.; Narang, S.; Devlin, J.; Bosma, M.; Mishra, G.; Roberts, A.; Barham, P.; Chung, H. W.; Sutton, C.; Gehrmann, S.; et al. Palm: *ArXiv preprint arXiv:2204.02311*.
- Chung, H. W.; Hou, L.; Longpre, S.; Zoph, B.; Tay, Y.; Fedus, W.; Li, E.; Wang, X.; Dehghani, M.; Brahma, S.; et al. Scaling instruction-finetuned language models. *arXiv preprint arXiv:2210.11416*.
- Ebbinghaus, H. 1964. Memory: A contribution to experimental.
- Graves, A.; Wayne, G.; and Danihelka, I. 2014. *ArXiv preprint arXiv:1410.5401*.
- Hu, E.; Shen, Y.; Wallis, P.; Allen-Zhu, Z.; Li, Y.; Wang, L.; and Chen, W. 2021. LoRA: 大型语言模型的低 rank 自适应。 *arXiv:2106.09685*.
- Johnson, J.; Douze, M.; and Jegou, H. 2019. 使用 GPU 进行亿级规模的相似性搜索。 *IEEE Transactions on Big Data*, 7(3): 535-547.
- Karpukhin, V.; Oguz, B.; Min, S.; Lewis, P.; Wu, L.; Edunov, S.; Chen, D.; and Yih, W.-t. 2020. Dense passage retrieval for open-domain question answering. *arXiv preprint arXiv:2004.04906*.
- LangChain Inc. LangChain. <https://docs.langchain.com/docs/>.
- Meng, L.; and Huang, M. 2018. 利用长短期记忆网络进行对话意图分类。 *自然语言处理与中文计算》：第六届 CCF 国家间会议, NLPCC 2017, 中国大连, 2017 年 11 月 8-12 日, 论文集 6*, 42-50. Springer.
- Ming, X. 2022: 文本到矢量的工具 OpenAI. 2022. ChatGPT. <https://chat.openai.com/chat>.
- OpenAI. 2023. GPT-4 技术报告。 *ArXiv:2303.08774*.
- Taori, R.; Gulrajani, I.; Zhang, T.; Dubois, Y.; Li, X.; Guestrin, C.; Liang, P.; and Hashimoto, T. B. 2023. 斯坦福羊驼: An Instruction-following LLaMA model. https://github.com/tatsu-lab/stanford_alpaca.
- Touvron, H.; Lavril, T.; Izacard, G.; Martinet, X.; Lachaux, M.-A.; Lacroix, T.; Roziere, B.; Goyal, N.; Hambro, E.; Azhar, F.; et al. Llama: Open and efficient foundation language models. *ArXiv preprint arXiv:2302.13971*.
- Wang, W.; Wei, F.; Dong, L.; Bao, H.; Yang, N.; and Zhou, M. 2020. Minilm: 用于预训练变换器任务无关压缩的深度自我注意蒸馏。 *神经信息处理系统进展》*, 33: 5776-5788.
- Xu, J.; Szlam, A.; and Weston, J. 2021. 超越金鱼记忆: *arXiv preprint arXiv:2107.07567*.
- Xu, X.; Gou, Z.; Wu, W.; Niu, Z.-Y.; Wu, H.; Wang, H.; and Wang, S. 2022. Long time no see! Open-domain conversation with long-term persona memory. *ArXiv preprint arXiv:2203.05797*.
- Yunjie Ji, Y. G. Y. P. Q. N. B. M., Yong Deng; and Li, X. 2023. BELLE: BELLE <https://github.com/LianjiaTech/BELLE>: Be Everyone's Large Language Model Engine.
- Zeng, A.; Liu, X.; Du, Z.; Wang, Z.; Lai, H.; Ding, M.; Yang, Z.; Xu, Y.; Zheng, W.; Xia, X.; et al. Glm-130b: An open bilingual pre-trained model. *ArXiv preprint arXiv:2210.02414*.
- Zhao, W. X.; Zhou, K.; Li, J.; Tang, T.; Wang, X.; Hou, Y.; Min, Y.; Zhang, B.; Zhang, J.; Dong, Z.; et al. *arXiv preprint arXiv:2303.18223*.