

基于大型语言模型的代理的崛起与潜力：一项调查

Zhiheng XI^{(1)(†)}, Wenxiang CHEN^{(1)(†)}, Xin GUO^{(1)(†)}, Wei HE^{(1)(†)}, Yiwon DING^{(1)(†)},
Boyyang HONG^{(1)(†)}, Ming ZHANG^{(1)(†)}, Junzhe WANG^{(1)(†)}, Senjie JIN^{(1)(†)}, Enyu ZHOU^{(1)(†)}

Rui ZHENG¹, Xiaoran FAN⁽¹⁾, Xiao WANG¹, Limao XIONG⁽¹⁾, Yuhao ZHOU¹, Weiran
WANG², Changhao JIANG⁽¹⁾, Yicheng ZOU⁽¹⁾, Xiangyang LIU¹, Zhangyue YIN¹,
Shihan DOU¹, Rongxiang WENG⁴, Wenjuan QIN², Yongyan ZHENG², Xipeng
QIU¹, Xuanjing HUANG⁽¹⁾, Qi ZHANG^{1*} & Tao GUI^(3*)

¹复旦大学计算机学院, 中国上海 200441

²复旦大学外国语言文学学院, 中国上海 200433 ³复旦大学现代语言研究所, 中国上海 200433 ^(*)美国, 中国北京 100102

2024 年 9 月 7 日收到/2024 年 10 月 25 日修订/2024 年 11 月 11 日接受/2025 年 1 月 17 日在线发表

摘要 长期以来, 研究人员一直在寻求能够匹配或超越人类智能的人工智能 (AI)。人工智能代理是能够感知环境、做出决策和采取行动的人工实体, 被视为实现这一目标的一种手段。人们为开发人工智能代理做出了大量努力, 主要侧重于改进算法或训练策略, 以提高特定技能或特定任务的执行能力。然而, 该领域还缺乏一个足够通用和强大的模型, 作为构建适应各种场景的通用代理的基础。大型语言模型 (LLM) 具有多种功能, 为开发通用人工智能代理铺平了道路, 并且在基于 LLM 的代理领域取得了实质性进展。在本文中, 我们对基于 LLM 的代理进行了全面调查, 涵盖了它们的构建框架、应用场景以及对基于 LLM 的代理所构建的社会的探索。我们还总结了这一蓬勃发展的领域的一些潜在未来方向 and 有待解决的问题。

关键词 自然语言处理、大型语言模型、基于 LLM 的代理、人工智能代理、代理社会

引文 Xi Z H, Chen W X, Guo X, et al. 基于大语言模型的代理的兴起与潜力：一项调查。中国信息科学, 2025, 68 (2) : 121101,
<https://doi.org/10.1007/s11432-024-4222-0>

1 导言

人工智能 (AI) 的一个核心研究领域是开发具有人类智力水平, 甚至有可能超过人类智力水平的代理[1]。代理的概念源于哲学, 它描述的是拥有欲望、信念、意图和行动能力的实体[2]。在人工智能研究中, "代理"一词指的是能够使用传感器感知周围环境、做出决策并使用执行器采取行动的人工实体[1, 3]。长期以来, 代理的发展和进步一直是人工智能界的核心问题[1, 4]。此外, 人工智能代理现在被认为是实现人工通用智能 (AGI) ⁽¹⁾的关键一步, 因为它们具有开展各种智能活动的潜力[3, 5, 6]。

从 20 世纪中期开始, 人工智能代理的设计和开发取得了长足进步 [7-12]。然而, 这些努力主要集中在提高特定技能 (如符号推理或快速反应能力) 或掌握特定任务 (如围棋或国际象棋) [13-15]。要在不同的场景中实现广泛的适应性仍然难以实现。此外, 以往的研究大多强调算法和训练策略的设计, 忽视了模型内在通用性的开发。

* 通讯作者 (电子邮件: qz@fudan.edu.cn, tgui@fudan.edu.cn)

这些作者对本研究做出了同样的贡献。

1) 也称为强人工智能。




图1 (彩色在线) 本次调查的路线图。

能力[16, 17]。事实上, 增强模型的这些固有能力对于推进代理的发展至关重要, 而这一领域正需要一个强大而多用途的模型来作为代理系统的基础。

大型语言模型 (LLMs) 的出现为代理的进一步发展带来了一线希望[18-20], 这方面的研究人员已经取得了重大进展[16, 21-23]。这要归功于 LLMs 所展示的卓越能力, 包括自然语言交互、知识获取、指令遵循、泛化、推理、规划和工具使用。这些优势为 LLMs 赢得了 "AGI 火花" 的称号 [24], 使其成为构建通用代理的理想选择 [16]。基于 LLM 的代理领域已成为人工智能研究中最有前途的领域之一。学术界和工业界在这一领域投入了大量的研发力量。然而, 尽管取得了进展, 这一新兴领域仍然面临着许多需要进一步探索和解决的关键问题, 例如基于 LLM 的代理的架构设计及其应用领域。因此, 我们有必要回顾这一领域的起源和发展, 总结当前的研究成果, 并展望未来, 以提供对基于 LLM 的代理更清晰的认识和对其未来发展更深入的见解。

在本文中, 我们对基于 LLM 的代理进行了全面系统的调查, 试图探讨该领域的几个关键研究问题以及这一新兴领域的前景 (图 1 展示了调查的路线图)。在深入探讨研究问题之前, 我们首先讨论背景信息 (第 2 节), 包括人工智能代理的起源、定义和发展, 以及为什么 LLM 适合作为人工智能代理的基础。第一个研究问题是设计和构建基于 LLM 的代理 (第 3 节)。根据人工智能代理的定义, 我们提出了一个概念框架, 其中包含三个关键组成部分: 大脑、感知和行动。不同的下游应用可根据其具体要求定制这一框架。第二个研究问题是基于 LLM 的代理的应用场景 (第 4 节)。我们讨论了单个代理、多代理和人在环等各种范例及其各自的适用场景。第三个研究问题是代理社会 (第 5 节)。我们讨论了代理社会的组成部分和运行机制, 以及它对人类社会的启示。最后, 我们讨论了这一领域的一系列开放问题和未来方向 (第 6 节), 例如 LLM 研究与代理研究之间的互利性、基于 LLM 的代理评估、基于 LLM 的代理的潜在风险以及代理数量的扩展。最后, 我们将对整篇文章进行概述和总结 (第 7 节)。

2 背景介绍

在本节中, 我们将提供重要的背景信息, 为后续内容奠定基础。我们首先讨论人工智能代理在哲学中的起源及其定义 (第 2.1 小节)。随后, 我们从技术趋势的角度回顾人工智能代理的发展 (第 2.2 小节)。最后, 我们介绍了代理的主要特征, 并说明为什么 LLM 适合作为人工智能代理的基础 (第 2.3 小节)。

2.1 人工智能代理的起源

"代理"是一个历史悠久的概念,横跨多个领域。它源于哲学,引发了关于人工产品能否拥有哲学意义上的代理权的讨论。随后,相关概念被引入人工智能领域,形成了人工智能代理的基础。

哲学中的代理人。代理人"的最初概念源于哲学,亚里士多德和休谟等有影响的思想家对其概念化做出了贡献[2]。从一般意义上讲,"代理人"是具有行动能力的实体,"代理"一词表示这种能力的行使或表现[2]。从狭义上讲,"代理"通常是指有意行动的表现;相应地,"代理人"是指拥有欲望、信念、意图和行动能力的实体[25-28]。重要的是,代理不仅包括人类个体,还包括物理世界和虚拟世界中的其他实体。

将代理引入人工智能。在人工智能中,代理被定义为能够感知环境、做出决策并利用传感器和执行器采取行动的人工实体[1, 3]。正如 Wooldridge 等人[3]所言,我们可以这样定义人工智能:它是计算机科学的一个子领域,旨在设计和构建基于计算机的、表现出智能行为各个方面的代理。因此,我们可以将"代理"视为人工智能的核心概念。当代理的概念被引入人工智能时,其含义也随之发生了变化。在哲学中,代理可以是人、动物,甚至是具有自主性的概念或实体[2]。然而,在人工智能领域,代理是一种计算实体[3, 29]。由于很难确定它们是否拥有内在欲望或意识,包括阿兰-图灵在内的许多人工智能研究者建议暂时搁置代理人是否"真正"在思考或真正拥有"思想"的问题[30]。相反,研究人员采用其他属性来帮助描述代理,如自主性、反应性、主动性和社交能力等属性[3, 31]。

在 20 世纪 80 年代中后期之前,主流人工智能界的研究人员对代理相关概念的关注相对较少,这可能会让人感到惊讶。然而,从那时起,计算机科学和人工智能界对这一话题的兴趣就大大增加了[32-35]。

2.2 制剂研究的技术趋势

人工智能代理的发展经历了几个主要阶段,在此,我们从技术趋势的角度对其发展进行简要回顾。

符号代理。在人工智能研究的早期阶段,最主要的方法是符号人工智能,其特点是依赖符号逻辑[36, 37]。这种方法采用逻辑规则和符号表示法来封装知识和促进推理过程。早期的人工智能代理就是基于这种方法构建的[38],它们主要关注两个问题:转换问题和表示/推理问题[39]。这些代理旨在模仿人类的思维模式。它们拥有明确的、可解释的推理框架,由于其符号性质,它们表现出高度的表达能力[7,8,40]。这种方法的一个典型例子就是基于知识的专家系统。然而,符号代理在处理不确定性和大规模现实世界问题时面临着局限性[13, 14]。此外,由于符号推理算法错综复杂,要找到一种能在有限时间内产生有意义结果的高效算法具有挑战性[14, 41]。

反应型代理。与符号代理不同,反应式代理不使用复杂的符号推理。相反,它们主要关注代理与其环境之间的交互,强调快速和实时的反应[9, 10, 14, 42, 43]。这些代理主要基于"感知-行动"循环,有效地感知环境并做出反应。这类代理的设计优先考虑直接的输入输出映射,而不是复杂的推理和符号操作[34]。不过,反应型代理也有局限性。它们通常需要较少的计算资源,从而能做出更快的反应,但可能缺乏复杂的高层决策和规划能力。

基于强化学习的代理。随着计算能力和数据可用性的提高,以及人们对模拟智能代理与其环境之间互动的兴趣与日俱增,研究人员已开始利用强化学习方法来训练代理,以应对更具挑战性的复杂任务[11, 12, 44, 45]。该领域的主要关注点是如何让代理通过与环境的交互进行学习,使其在特定任务中获得最大累积奖励[15]。最初,强化学习(RL)代理主要基于基本技术,如策略搜索和价值函数优化,例如

Q-learning [46] 和 SARSA [47]。随着深度学习的兴起,出现了深度神经网络与强化学习的整合,即深度强化学习(DRL) [48, 49]。这使得代理可以从高维输入中学习复杂的策略,从而取得了众多重大成就,如 AlphaGo [50] 和 DQN [51]。这种方法的优势在于它能让代理在未知环境中自主学习,而无需明确的人工干预。这使得它能广泛应用于从游戏到机器人控制等一系列领域。然而,强化学习也面临着一些挑战,包括训练时间长、采样效率低以及稳定性问题,尤其是在复杂的真实世界环境中应用时[15]。

具有迁移学习和元学习功能的代理。传统上,训练强化学习代理需要大量样本和较长的训练时间,而且缺乏泛化能力 [52-56]。因此,研究人员引入了迁移学习来加速代理对新任务的学习 [57-59]。迁移学习减轻了新任务训练的负担,促进了知识在不同任务间的共享和迁移,从而提高了学习效率、性能和泛化能力。此外,元学习也被引入到代理开发中[60-64]。元学习的重点是学习如何学习,使代理能够从少量样本中迅速推断出新任务的最优策略[65]。这样的代理在面对新任务时,可以利用已获得的常识和策略迅速调整其学习方法,从而减少对大量样本的依赖。然而,当源任务和目标任务之间存在显著差异时,迁移学习的效果可能达不到预期,并可能出现负迁移[66, 67]。此外,元学习需要大量的预训练和大量样本,因此很难建立通用的学习策略[61, 68]。

基于大语言模型的代理。由于 LLM 已展示出令人印象深刻的新兴能力,并受到广泛欢迎[18-20, 69],研究人员已开始利用这些模型构建人工智能代理,即基于 LLM 的代理[16, 21, 22, 70]。具体地说,他们采用 LLM 作为这些代理的大脑或控制器的核心组件,并通过多模态感知和工具利用等策略拓展其感知和行动空间 [71-75]。通过思维链(CoT)和问题分解等技术,这些基于 LLM 的代理可以表现出与符号代理相当的推理和规划能力 [76-82]。它们还能通过从反馈中学习和执行新行动,获得与环境互动的能力,类似于反应式代理[83-85]。同样,LLM 在大规模语料库中进行预训练,并展示了少量和零次泛化的能力,从而实现任务间的无缝转移,而无需更新参数 [69, 86-88]。基于 LLM 的代理已被应用于各种实际场景,如软件开发 [89, 90] 和科学研究 [91]。由于具有自然语言理解和生成能力,它们可以无缝互动,从而促进多个代理之间的协作和竞争 [89、90、92、93]。此外,一些研究表明,允许多个代理共存可导致社会现象的出现 [16]。

2.3 为什么法学硕士适合作为代理人的基础?

如前所述,在人工智能领域,研究人员已经引入了多种属性来帮助描述和定义代理。在本节中,我们将讨论这些关键属性,阐明它们与 LLM 的相关性,从而阐述为什么 LLM 非常适合作为人工智能代理的基础。

自主性。自主性是指一个代理在没有人类或其他人直接干预的情况下运行,并对其行动和内部状态拥有一定程度的控制[3, 94]。这意味着,一个代理不仅应具备按照人类明确指令完成任务的能力,还应表现出独立发起和执行行动的能力。LLMs 可以通过生成类似人类的文本、参与对话以及在无详细步骤指示的情况下执行各种任务的能力来展示某种形式的自主性 [95,96]。此外,它们还能根据环境输入动态调整输出,体现出一定程度的自适应能力[17, 21, 85]。此外,它们还可以通过展示创造力来体现自主性,比如提出新颖的想法、故事或解决方案,而这些并没有明确编入它们的程序[97, 98]。这意味着一定程度的自主探索和决策。Auto-GPT [95] 等应用充分体现了 LLM 在构建自主代理方面的巨大潜力。只需向它们提供一项任务和一组可用工具,它们就能自主制定计划并执行计划,从而实现最终目标。

反应性。代理的反应能力指的是其对环境中的即时变化和刺激做出快速反应的能力[31]。这意味着,代理可以感知周围环境的变化,并迅速采取适当的行动。传统上,语言模型的感知空间局限于文本输入,而行动空间则局限于文本输出。最近,多模态融合技术的发展扩大了感知空间,可以快速处理来自环境的视觉和听觉信息[19, 99, 100]。同样,通过体现技术[101, 102]和工具使用[73, 75]来扩展 LLMs 的行动空间也是可行的。这些进步使 LLMs 能够有效地与真实世界的物理环境互动,并在其中执行任务。一个主要挑战是,基于 LLM 的代理在执行非文本操作时,需要一个中间步骤,即生成文本形式的想法或制定工具使用方法,然后才能最终将其转化为具体操作。这一中间过程会消耗时间,降低响应速度。不过,这与人类的行为模式类似,都遵循 "先思考后行动" 的原则[103, 104]。

主动性。积极主动指的是,行为主体不仅仅是对环境做出反应,它们还拥有通过积极主动地采取行动来实现目标的能力[31]。这一特性强调了代理可以进行推理、制定计划,并在行动中采取积极主动的措施,以实现特定目标或适应环境变化。尽管从直觉上讲,LLMs 中的下一个标记预测范式可能不具备意图或愿望,但研究表明,它们可以隐含地生成这些状态的表征,并指导模型的推理过程[105-107]。LLMs 具有很强的概括推理和规划能力。通过向 LLMs 发出 "让我们一步一步地思考" 等指令,我们可以激发 LLMs 的推理能力,如逻辑推理和数学推理 [76-78]。同样,低等语言聋人也表现出了规划能力,如目标重新制定[80, 108]、任务分解[79, 109]以及根据环境变化调整计划[81, 110]等。

社交能力。社交能力是指一个代理使用代理通信语言与其他代理(包括人类)进行交互的能力[111]。大型语言模型具有很强的自然语言交互能力,如理解和生成[17, 112, 113]。与结构化语言或其他通信协议相比,这种能力使它们能够以可解释的方式与其他模式或人类进行交互,为基于 LLM 的代理的社交能力奠定了基础[16, 89]。许多研究人员已经证明,基于 LLM 的代理可以通过协作和竞争等社会行为来提高任务执行率 [89、92、114、115]。通过输入特定的提示,LLM 也可以扮演不同的角色,从而模拟现实世界中的社会分工 [90]。此外,当我们将多个具有不同身份的代理放入一个社会中时,可以观察到新出现的社会现象[16]。

3 代理的诞生: 构建基于 LLM 的代理

适者生存"[116] 原则强调了个体生存所需的适应外部环境和应对变化的认知能力。受这一原则和人工智能代理定义的启发,我们提出了一个基于 LLM 的代理总体概念框架,由大脑、感知和行动三个关键部分组成(见图 2)。我们首先描述 "大脑" 的结构和工作机制,它是人工智能代理的认知核心 (3.1 小节)。它不仅存储知识和记忆,还承担着决策等不可或缺的功能,展现了人工智能代理的智慧。接下来,我们介绍感知模块 (3.2 小节)。它的核心目的是将代理的感知空间从纯文字领域扩展到多模态领域,使代理能够更有效地掌握和利用周围环境的信息。最后,我们介绍了旨在拓展代理行动空间的行动模块 (3.3 小节)。具体来说,该模块赋予了代理适应环境变化、提供反馈,甚至影响和塑造环境的能力。

该框架可针对不同的应用场景进行定制;也就是说,并非所有研究都会使用每个特定组件。一般来说,代理按以下工作流程运行: 首先,与人类感官系统相对应的感知模块会感知外部环境的变化,然后将多模态信息转换为代理人可以理解的表征。随后,作为控制中心的大脑模块进行思考、决策和操作等活动,并存储记忆和知识。最后,行动模块,对应于




图2 (彩色在线) 基于 LLM 的代理概念框架, 包括大脑、感知和行动三个部分。作为控制器, 大脑模块承担记忆、推理和规划等基本任务。感知模块负责感知和处理来自外部环境的多模态信息, 行动模块负责执行任务并与周围环境互动。下面是一个说明工作流程的例子: 当人类询问是否会下雨时, 感知模块会将指令转换为具体的表征。然后, 大脑模块开始根据当前天气和互联网上的天气报告进行推理。最后, 行动模块做出反应, 将雨伞递给人类。通过重复上述过程, 基于 LLM 的代理可以不断获得反馈并与环境互动。

代理可以像人的肢体一样执行任务, 并对周围环境产生影响。通过重复上述过程, 代理可以不断获得反馈并与环境互动。

3.1 大脑

人脑是由大量相互连接的神经元组成的精密结构, 能够处理复杂信息、产生各种想法、控制行为, 甚至创造艺术和文化[117]。与人类一样, 大脑组件也是人工智能代理的核心控制器。在我们的框架中, 大脑模块主要由 LLM 组成。

在接收感知模块处理过的信息后, 大脑模块首先转向存储, 在知识中检索 (3.1.1 小节), 并从记忆中回忆 (3.1.2 小节)。这些结果有助于机器人进行规划、推理和决策 (3.1.3 小节)。此外, 大脑模块还能以摘要、矢量或其他数据结构的形式记忆代理过去的观察、思考和行动。同时, 它还可以更新常识和领域知识等知识, 以备将来使用。基于 LLM 的代理还可以利用其固有的概括性和可转移性来适应陌生场景 (3.1.4 小节)。在随后的章节中, 我们将深入探讨大脑模块的这些非凡之处。

3.1.1 知识

LLM 通常在预训练阶段通过半监督学习获得大规模数据 [118, 119]。它们可以将各种知识编码到参数中, 并在预训练后对各种类型的查询做出正确响应 [120]。此外, 这些知识还能帮助基于 LLM 的代理做出明智的决策 [121]。这些知识大致可分为以下几类。

- 常识性知识。常识[122-124]指的是大多数人在幼年时就被灌输的世界常识。例如, 人们通常知道药是用来治病的, 伞是用来防雨的。这些信息

通常不会在上下文中明确提及。因此, 缺乏相应常识性知识的模型可能无法理解或误解所要表达的意思[125]。同样, 缺乏常识性知识的代理可能会做出错误的决定, 比如下大雨时不打伞。

- 专业领域知识。专业领域知识是指与特定领域相关的知识, 如编程[124, 126, 127]、数学[128, 129]、医学[]等。它对模型有效解决特定领域内的问题至关重要[130]。例如, 为执行编程任务而设计的模型需要具备编程知识。这种知识对特定领域的代理非常重要, 因为只有具备这种知识, 代理才能做出合理的决定。

3.1.2 内存

在我们的框架中, "记忆" 存储了代理过去的观察、思考和行动 [131]。这种记忆能让代理利用过去的经验制定策略和做出决策, 类似于人类的做法 [132-134]。它允许代理重新审视过去的策略并适应新的环境, 从而帮助代理处理复杂的问题。

然而, 随着基于 LLM 的代理互动的增加, 出现了两个主要问题。首先, 历史数据的长度可能超过基于变压器架构的 LLM 代理的处理能力, 从而可能导致数据截断。其次, 随着大量数据的积累, 代理检索和连接相关记忆变得越来越困难, 从而有可能在当前情境中做出不一致的反应。因此, 适当的记忆压缩和检索技术是增强代理记忆能力的关键。

压缩内存的方法。我们将深入探讨旨在压缩内存的两种主要方法, 以确保高效的调用和分析。

- 总结内存提高记忆效率的第一个策略是记忆总结。这种方法可以总结历史交互并以自然语言存储。针对记忆总结提出了多种技术。一些方法利用提示简洁地整合记忆[135], 而另一些方法则强调反思过程, 以创建浓缩的记忆表述[16, 136]。分层方法将对话精简为每日快照和总体总结 [137]。值得注意的是, 一些特定的策略能将环境反馈转化为文字概括, 从而加强代理对未来参与的情境把握[138]。

- 用向量或数据结构压缩记忆。使用适当的数据结构, 基于 LLM 的代理可以更高效地存储历史交互。值得注意的是, 有几种方法倾向于为记忆部分、计划或对话历史嵌入向量[90, 137, 139, 140]。另一种方法将句子转化为三元组配置[141], 还有一些方法将记忆视为独特的数据对象, 从而促进不同的交互[142]。此外, ChatDB [143] 和 DB-GPT [144] 选择了 SQL 数据库, 允许通过 SQL 查询进行数据操作。

记忆检索方法。当代理与环境交互时, 必须从其记忆中检索最合适的内容。这可确保代理访问相关且准确的信息以做出决策 [137, 140]。自动检索的一种代表性方法考虑了三个指标: 再现性、相关性和重要性。记忆得分由这些指标加权组合而成, 得分最高的记忆在模型上下文中被优先考虑[16]。一些研究引入了交互式记忆对象的概念, 这些对象代表了可以移动、编辑、删除或通过总结合并的对话历史[142]。用户可以查看和操作这些对象, 从而影响代理对对话的感知。同样, 其他研究也允许根据用户提供的特定命令进行删除等记忆操作 [143]。这些方法可确保记忆内容与用户的期望密切吻合。

3.1.3 推理和规划

推理。推理是人类智力活动中解决问题、决策和批判性分析的关键, 其基础是证据和逻辑[145-147]。演绎推理、归纳推理和旁证推理是这些活动中的主要形式 [148]。对于基于 LLM 的代理来说, 与人类一样, 推理能力对于处理复杂任务至关重要 [19]。

对于 LLM, 推理能力被认为是一种新兴能力, 即当语言模型的规模达到一定程度时, 这种能力就会出现 [20, 149]。值得注意的是, CoT 方法 [76, 77] 已被

通过引导 LLM 在输出答案前生成理由, 证明了 LLM 的推理能力。其他技术, 如自我一致性[78]、自我修正[80]、自我完善[150]和选择推理[151], 也能提高 LLM 的性能。为了进一步提高 LLM 或基于 LLM 的代理的推理能力, 目前的研究主要探索监督微调 (SFT) 方法 [152] 和交互式训练方法 [153, 154]。

规划。规划是人类在面对复杂任务时采用的一种关键策略。对人类来说, 规划有助于组织思维、设定目标和确定实现这些目标的步骤 [155-157]。与人类类似, 规划能力对代理也至关重要, 而规划模块的核心是推理能力[158-160]。这为基于 LLM 的代理提供了一个结构化的思维过程。通过推理, 代理可将复杂的任务分解为易于管理的子任务, 并为每个子任务制定适当的计划 [161, 162]。此外, 随着任务的进展, 代理可以利用内省来修改计划, 确保计划更符合实际情况, 从而促进任务的自适应和成功执行。通常情况下, 计划包括两个阶段: 计划制定和计划反思。

- **制定计划。**在计划制定过程中, 代理通常会将一项总体任务分解为许多子任务, 在这一阶段, 人们提出了各种不同的方法。值得注意的是, 一些研究主张基于 LLM 的代理在单一步骤中全面分解问题, 一次性制定完整的计划, 然后按顺序执行 [79, 163-165]。与此相反, 其他研究 (如 CoT 系列) 则采用自适应策略, 一次规划和处理一个子任务, 从而更流畅地处理复杂的整体任务 [76、77、166]。此外, 有些方法强调分层规划[167, 168], 而另一些方法则强调一种策略, 即通过树状结构的推理步骤得出最终计划。后一种方法认为, 在最终确定计划之前, 代理应评估所有可能的路径[78, 169-171]。虽然基于 LLM 的代理展示了广博的常识, 但在遇到需要专业知识的情况时, 它们偶尔也会面临挑战。通过将代理与特定领域的规划者相结合来增强它们的能力, 已证明能产生更好的性能[109, 115, 172, 173]。

- **计划反思。**制定计划后, 必须对其优点进行反思和评估。基于 LLM 的代理采用内部反馈机制, 通常从已有模型中汲取灵感, 以完善和改进其战略和规划方法 [138,150,174,175]。为了更好地与人类的价值观和偏好保持一致, 代理会主动与人类接触, 从而纠正错误, 并将这些有针对性的反馈吸收到其规划方法中[89, 176, 177]。此外, 它们还可以从有形或虚拟环境中收集反馈, 如任务完成或行动后观察所提供的线索, 帮助它们修改和完善计划[72, 82, 178-180]。

3.1.4 可转让性和普遍性

人类大脑的非凡特性主要归功于其高度的可塑性和适应性。它可以根据外部刺激和内部需求不断调整自身结构, 从而适应不同的环境和任务。近年来, 大量研究表明, 预训练模型可以学习通用语言表征[181-183], 而且只需少量数据进行微调, 就能在下游任务中表现出优异的性能[184]。 , 无需从头开始训练新模型, 从而节省了大量计算资源。然而, 通过这种针对特定任务的微调训练出来的模型通常缺乏通用性, 无法推广到其他任务中。基于 LLM 的代理不只是发挥静态知识库的作用, 它还具有动态学习能力, 能迅速、稳健地适应新任务 [18, 86, 87]。

看不见的任务泛化。研究表明, 经过指令调整的 LLMs 无需针对特定任务进行微调, 就能表现出 "零镜头泛化" (zero-shot generalization) [18, 19, 88]。值得注意的是, LLMs 可以根据自己的理解, 按照指令完成不熟悉的任务。多任务学习是其中一种实现方法, 例如, FLAN[86] 在通过指令描述的任务集合上对语言模型进行微调, 而 T0 [87] 则引入了一个统一的框架, 将每个语言问题转换成文本到文本的格式。尽管只是一个纯粹的语言模型, GPT-4 [19] 在各种领域和任务中, 包括抽象、编码、数学、医学、法律和其他领域, 都展示了非凡的能力 [24]。令人欣慰的是, 这种泛化能力可以通过扩大模型规模和训练指令的数量或多样性得到进一步增强[75, 185]。

情境学习大量研究表明, LLMs 可以通过上下文学习 (ICL) 完成各种复杂任务, 这涉及模型从给定上下文中的几个例子中学习的能力[186]。少数几个实例的上下文学习可以通过串联

在原始输入中加入几个完整的例子作为提示,以丰富语境[69]。ICL 的关键理念是从类比中学习,这与人类的学习过程类似 [187]。此外,由于提示是用自然语言编写的,因此交互是可解释和可改变的,从而更容易纳入人类知识[76, 188]。与监督学习过程不同,ICL 不涉及微调或参数更新,从而大大降低了模型适应新任务的计算成本。除了文本,研究人员还探索了 ICL 在不同多模态任务中的潜在能力 [189-194],使代理应用于大规模真实世界任务成为可能。

3.2 感知

人类和动物都依靠眼睛和耳朵等感觉器官从周围环境中收集信息。这些感知输入被转化为神经信号并发送到大脑进行处理 [195, 196],从而使人类能够感知世界并与之互动。同样,对于基于 LLM 的代理来说,接收来自不同来源和模式的信息也至关重要。这种扩展的感知空间有助于代理更好地了解环境,做出明智的决策,并在更广泛的任务中表现出色,因此是一个重要的发展方向。代理通过感知模块将这些信息传送到大脑模块进行处理。

在本节中,我们将介绍如何使基于 LLM 的代理获得多模态感知能力,包括文本 (3.2.1 小节)、视觉 (3.2.2 小节) 和听觉输入 (3.2.3 小节)。我们还考虑了其他潜在的输入形式 (3.2.4 小节),如触觉反馈、手势和三维地图,以丰富代理的感知领域并增强其多功能性。

3.2.1 文本输入

文本作为传递数据、信息和知识的渠道,使文本交流成为人类与世界互动的最重要方式之一。基于 LLM 的代理随时具备通过文本输入和输出与人类交流的基本能力[95]。在用户的文本输入中,除了明确的内容外,还隐藏着信念、愿望和意图。理解隐含含义对于代理掌握人类用户的潜在和潜在意图,从而提高与用户交流的效率和质量至关重要。然而,理解文本输入中的隐含含义对于目前基于 LLM 的代理来说仍然是一项挑战[75, 197]。例如,一些研究[113, 198-200]采用强化学习来感知隐含含义,并建立反馈模型以获得奖励。这有助于推断说话者的偏好,从而使代理做出更个性化、更准确的回应。此外,由于代理要在复杂的真实世界环境中使用,不可避免地会遇到许多全新的任务。要理解未知任务的文本指示,对语音代理的文本感知能力提出了更高的要求。如 3.1.4 小节所述,经过指令调整 [86] 的 LLM 可以表现出卓越的零点指令理解和泛化能力,从而无需针对特定任务进行微调。

3.2.2 视觉输入

虽然 LLM 在语言理解 [19, 201] 和多轮对话 [202] 方面表现出色,但它们一直缺乏视觉感知,只能理解离散的文本内容。视觉输入通常包含大量有关世界的信息,包括代理周围环境中物体的属性、空间关系、场景布局等。因此,将视觉信息与其他模式的数据整合在一起,可以为代理提供更广泛的背景和更精确的理解[101],从而加深代理对环境的感知。

为了帮助代理理解图像中包含的信息,一种直接的方法是为图像输入生成相应的文本描述,即图像标题 [203-207]。字幕可与标准文本指令直接链接,并输入基于 LLM 的代理。这种方法具有很高的可解释性,而且不需要额外的标题生成训练,可以节省大量的计算资源。不过,字幕生成是一种低带宽方法 [101, 208],在转换过程中可能会丢失大量潜在信息。此外,代理对图像的关注可能会带来偏差。

赋予基于 LLM 的代理以视觉理解能力的第二种方法是模态融合,即在嵌入层将视觉编码器与 LLM 集成 [209, 210]。冻结

在训练过程中, LLMs 可以选择使用其中一个或两个嵌入点, 这是一种被广泛采用的模式, 可以在训练资源和模型性能之间取得平衡 [211]。然而, LLM 无法直接理解视觉编码器的输出, 因此有必要将图像编码转换为 LLM 可以理解的嵌入。换句话说, 这需要将视觉编码器与 LLM 对齐。这通常需要在两者之间添加一个额外的可学习接口层。例如, BLIP-2 [211] 和 InstructBLIP [212,213] 使用查询转换器 (Q-Former) 模块作为视觉编码器和 LLM 之间的中间层。同时, 一些研究人员采用了一种计算效率高的方法, 利用单一投影层实现视觉-文本对齐, 从而减少了训练额外参数的需要 [99, 210, 213]。此外, 投影层还能与可学习界面有效结合, 调整其输出的维度, 使其与 LLM 兼容 [214-217]。

3.2.3 听觉输入

听觉信息是世界信息的重要组成部分。当代理拥有听觉能力时, 它就能提高对交互内容、周围环境甚至潜在危险的感知能力。虽然有许多成熟的模型和方法 [218-220] 可以将音频作为一种独立的模式进行处理, 但这些模型往往只擅长特定的任务。鉴于 LLM 出色的工具使用能力 (将在第 3.3 小节中详细讨论), 一个非常直观的想法是, 代理可以将 LLM 用作控制中心, 以级联方式调用现有工具集或模型库来感知音频信息。

此外, 音频频谱图可以作为一种媒介, 赋予基于 LLM 的代理以听觉能力, 因为它可以清晰地表示音频信号的频谱是如何随时间演变的 [221]。对于一段时间内的一段音频数据, 可将其抽象为有限长度的音频频谱图。音频频谱图具有二维表示形式, 可视化后为平面图像。因此, 一些研究 [222,223] 致力于将感知方法从视觉领域迁移到音频领域。音频频谱图变换器 (AST) [222] 采用与 ViT 类似的变换器架构来处理音频频谱图图像。通过将音频频谱图分割成片段, 它实现了对音频信息的有效编码。

3.2.4 其他输入

未来, 基于 LLM 的代理有望配备更丰富的感知模块。它们可以像人类一样感知和理解现实世界中的各种模式。例如, 代理可以拥有独特的触觉和嗅觉器官, 从而在与物体互动时收集到更多详细信息。同时, 代理还可以配备 GPS、激光雷达和其他传感器等硬件设备, 对空间位置、温度和亮度有更清晰的感知, 并采取环境感知行动。

3.3 行动

人类在感知环境后, 大脑会进行整合、分析和推理, 从而做出决定。随后, 他们利用神经系统控制自己的身体, 做出适应环境或创造性的行动, 如交谈、躲避障碍或生火。当一个代理拥有类似大脑的结构, 具备知识、记忆、推理、规划和概括能力以及多模态感知能力时, 它也有望拥有类似人类的各种行动, 以应对周围环境。在构建这样一个代理时, 行动模块接收大脑模块发送的行动序列, 并执行与环境互动的行动。

本节首先讨论文本输出 (3.3.1 小节), 这是基于 LLM 的代理固有的能力。接下来, 我们将讨论基于 LLM 的代理使用工具的能力 (第 3.3.2 小节), 事实证明, 这种能力可以有效增强代理的多功能性和专业性。最后, 我们将讨论为基于 LLM 的代理配备具体行动, 以促进其在物理世界中的立足 (第 3.3.3 小节)。

3.3.1 文本输出

最近, 基于 Transformer 的生成式 LLM 的兴起和发展, 赋予了基于 LLM 的代理固有的语言生成能力 [19, 224]。它们生成的文本质量在以下方面表现出色

在各方面,如流畅性、相关性、多样性、可控性[112, 225-227]。因此,基于 LLM 的代理可以成为异常强大的语言生成器。

3.3.2 使用工具

工具是人类能力的延伸。在面对复杂任务时,人类会使用工具来简化任务解决过程并提高效率,从而释放时间和资源。同样,如果代理也学会使用和利用工具,他们就有可能更高效、更高质量地完成复杂任务[75]。基于 LLM 的代理具有局限性,因为它们会产生幻觉 [228]、缺乏训练数据和针对特定领域的调整 [229]、决策过程不透明 [230] 以及易受对抗性攻击 [231]。幸运的是,专业工具能让基于 LLM 的代理以可插拔的形式增强其专业知识、调整领域知识并更适合特定领域的需求。它们还表现出更强的可解释性和鲁棒性。基于 LLM 的代理不仅需要使用工具,而且非常适合工具集成。LLM 在复杂的交互环境中表现出卓越的推理和决策能力 [78],在意图理解和其他方面也具有巨大潜力 [19, 232-234]。这些都使基于 LLM 的代理成为熟练的工具用户。

学习使用工具。利用 LLM 强大的 "零镜头 "和 "少镜头 "学习能力 [69, 235],代理可以利用包含工具功能和参数描述的 "零镜头 "提示,或提供特定工具使用场景和相应方法演示的 "少镜头 "提示,来获取有关工具的知识 [73, 236]。这些学习方法与人类通过查阅工具手册或观察他人使用工具的方法类似 [75]。除了配置和演示,代理还可以从环境和人类的反馈中学习 [18, 237, 238]。环境反馈包括行动是否成功完成任务的结果反馈,以及捕捉行动导致的环境状态变化的中间反馈;人类反馈包括显性评价和隐性行为,如点击链接 [75]。

至关重要的是,要提高代理在工具使用方面的概括能力,以应对复杂的场景和不断发展的新工具。为此,代理需要掌握工具使用策略中的共同原则或模式,而这有可能通过元工具学习来实现 [239]。此外,课程学习 [240]等技术可以增强代理对简单工具和复杂工具之间关系的理解,例如复杂工具是如何建立在较简单工具的基础上的,并使代理能够有效辨别各种应用场景中的细微差别,并将以前学到的知识迁移到新工具中[75]。以往的研究表明,基于 LLM 的代理不仅有能力推广现有工具的使用,还能通过生成可执行程序或将现有工具集成到功能更强大的工具中来制造所需的新工具[75, 241, 242]。

工具拓展了基于 LLM 的代理的行动空间。在工具的帮助下,代理可以在推理和规划阶段利用各种外部资源,如网络应用程序和其他 LM [73]。这一过程可以为基于 LLM 的代理提供具有高度专业性、可靠性、多样性和高质量的信息,促进其决策和行动。例如,基于搜索的工具可以借助外部数据库、知识图谱和网页提高代理可获取知识的范围和质量,而特定领域的工具则可以增强代理在相应领域的专业知识[243,244]。一些研究人员已经开发出了基于 LLM 的控制器,可生成 SQL 语句来查询数据库,或将用户查询转换为搜索请求,并使用搜索引擎获得所需的结果 [71,143]。此外,基于 LLM 的代理还可以使用科学工具执行任务,如化学中的有机合成,或与 Python 解释器对接,以提高其在复杂数学计算任务中的性能 [245, 246]。

虽然前面提到的工具增强了代理的能力,但与环境交互的媒介仍然是文本。然而,工具的设计旨在扩展语言模型的功能,其输出并不局限于文本。非文本输出工具可以使代理行动的模式多样化,从而扩展基于 LLM 的代理的应用场景 [163, 247]。例如,利用视觉模型的代理可以完成图像处理和生成[248]。

3.3.3 体现行动

在追求人工智能的过程中,具身代理被认为是一个关键范例。具身假说[249]从人类智能发展过程中汲取灵感,认为代理的

智能来源于与环境的持续互动和反馈，而不是仅仅依赖于精心编辑的教科书[250]。同样，人们预计基于 LLM 的代理应该能够主动感知、理解物理环境并与之互动，根据 LLM 的内部知识做出决策并产生预期行为来改变环境。我们将这些统称为“具身行动”（embodied actions），它使代理能够以近似人类行为的方式与世界互动并感知世界。

基于 LLM 的代理在体现行动方面的潜力。尽管基于 RL 的化身取得了巨大成功 [50, 51, 251]，但它在某些方面仍有局限性。例如，由于对动态环境建模的挑战和对奖励信号表征的依赖，RL 算法在成本效率、泛化和复杂问题推理方面都面临限制 [252]。最近的研究表明，利用在 LLM 预训练过程中获得的丰富内部知识可以有效缓解这些问题 [101、171、178、253]。

- 成本效率。一些基于策略的算法在采样效率方面存在困难，因为它们需要反复采样数据进行策略更新，而为高性能训练收集足够的体现数据成本很高。一些端到端模型也存在这种限制 [254-256]。通过利用 LLM 的固有知识，PaLM-E 等代理[101] 将机器人数据与一般视觉语言数据联合训练，在具身任务中实现了显著的转移能力，同时也展示了几何输入表示法可以提高训练数据效率。

- 化身行动泛化。正如 3.1.4 小节所述，代理的能力应超越特定任务。与大多数根据不同形式和类型的任务进行微调的 RL 算法[82, 257-259]不同，LLM 已经展示出卓越的跨任务泛化能力[260, 261]。此外，自然语言既是与环境交互的手段，也是将基础技能迁移到新任务的媒介[262]。SayCan [163] 使用 LLMs 将提示中的任务指令分解为相应的技能命令，但在部分可观察环境中，有限的先前技能往往无法实现令人满意的性能 [82]。为了解决这个问题，Voyager [177] 引入了技能库组件，不断收集新的自我验证技能，从而实现了代理的终身学习能力。

- 体现行动规划。在解决复杂问题时，规划是代理的关键策略。在传统的分层强化学习（HRL）方法中，高层策略为低层策略设定子目标，而低层策略则产生适当的行动信号[263-265]。与高层策略的作用类似，具有新兴推理能力[20]的 LLM 也能以零次或多次的方式无缝应用于复杂任务[76, 78-80]。此外，来自环境的外部反馈可以进一步提高基于 LLM 的代理的规划性能。一些研究[72, 81, 82, 266]动态生成、维护和调整高层次行动计划，以尽量减少对先前知识的依赖，从而使计划落地。这种反馈也可以来自模型和人类，通常可称为批评者，根据当前状态和任务提示评估任务完成情况 [19, 177]。

基于 LLM 的代理的具身行动。基于 LLM 的代理需要掌握几种基本的具身行动或任务，主要包括观察、操纵和导航。

- 观察。观察在随后的具体行动中起着至关重要的作用，通过观察，代理可以获取环境信息并更新状态。如 3.2 小节所述，在观察阶段，各种输入最终会汇聚成多模态信号。一种常见的方法是使用预先训练好的视觉转换器（ViT）作为文本和视觉信息的对齐模块[101, 102, 267]。近来，越来越多的研究将音频作为嵌入式观察的一种模式。声音空间 [268] 提出通过混响音频输入识别空间几何元素 [265]。除了级联范式 [218、219、269]，音频信息编码还能加强音频与其他输入模式的无缝整合 [222]。此外，代理的观察可以来自人类的实时语言指令，这有助于代理获取可能不容易获得或解析的细节信息[177, 270]。

- 操纵。嵌入式代理的操纵任务一般包括物体重新排列、桌面操纵和移动操纵 [17, 101]。典型的情况是，代理在厨房执行一系列任务，包括从抽屉中取出物品并递给用户 [163]。这项任务涉及一系列子目标的组合，保持代理状态与这些子目标之间的同步具有重要意义[271]。除此之外，AlphaBlock [272] 专注于更具挑战性的操作任务（如使用积木制作笑脸），这需要

它还能使代理对指令有更深入的理解。它根据由相应的多步骤规划和观察对组成的复杂任务数据集，对多模态模型进行微调，以增强对高级认知指令的理解。

- **导航。**在导航任务中，代理需要动态地改变自己的位置，这通常涉及多角度和多目标观测[17]。在导航之前，对于智能代理来说，必须先建立内部地图，通常是拓扑图、语义图和占位图[250]。例如，LM-Nav [273] 利用 VNM [274] 创建拓扑图，并进一步利用 LLM 和 VLM 分析环境以找到最佳路径。一些研究 [275, 276] 强调了空间表示的重要性，通过利用预先训练好的 VLM 模型将图像中的视觉特征与物理世界的三维重建相结合，从而获得目标的精确定位[250]。在导航任务中，代理的状态往往会受到其过去行动的影响。这就需要一种记忆机制来记录历史信息[277]，《小镇》和《旅行者》也采用了这种机制[16, 177, 278, 279]。此外，音频输入对导航任务也具有重要意义。先前的研究展示了一个基本框架，其中包括一个动态路径规划器，它利用视觉和听觉观察以及空间记忆来规划一系列行动 [265, 280]。

复杂而接地气的具身行动。通过整合上述行动，代理可以完成更复杂的任务，比如具身问题解答，例如：厨房里的西瓜比锅大吗？哪个更难？要回答这些问题，机器人需要导航到厨房，观察两个物体的大小，然后通过比较来回答问题[250]。在控制策略方面，如前所述，基于 LLM 的代理在特定具身数据集上接受训练后，通常会生成高级策略指令来控制低级策略[163]，如机器人变压器[101, 281, 282]，它将图像和指令作为输入，并为末端效应器和机械臂以及虚拟具身控制器生成控制指令，因为机器人操作员的成本很高[16, 89, 90, 139, 271, 283, 284]。一些研究利用 Mineflayer [285] 应用程序接口，以经济有效的方式检查化身代理的操作，包括探索、规划和终身学习 [177]。另一方面，将语言与行动空间联系起来也给代理带来了障碍。例如，要理解像“像猫一样跳下来”这样的语言隐喻表达，需要足够的世界知识[286]。Sumers 等人 [287] 尝试将文本提炼与事后经验回放相结合，以构建一个用于训练的数据集。尽管如此，由于具身行动在人类生活的各个领域发挥着越来越关键的作用，因此仍有必要对具身行动的基础进行更多研究。

4 实践中的代理：利用人工智能做好事

基于 LLM 的代理作为一个新兴方向，越来越受到研究人员的关注。目前已开发出许多在特定领域和任务中的应用，展示了代理强大而多变的能力 [288]。作为一种基于 LLM 的代理，其设计目标应始终对人类有益，即人类可以利用人工智能造福人类。

在本节中，我们将概述基于 LLM 的代理的当前应用，旨在为实际部署场景提供一个广阔的视角（见图 3）。首先，我们阐明了单个代理的各种应用场景，包括面向任务、面向创新和面向生命周期的场景（第 4.1 小节）。然后，我们介绍了多个代理的重要协调潜力：合作互动或对抗互动（第 4.2 小节）。最后，我们将人类与代理之间的互动协作分为两种范式，并介绍具体应用（第 4.3 小节）。

4.1 单一制剂的一般能力

目前，基于 LLM 的代理应用实例正在蓬勃发展 [289-291]。AutoGPT [95] 是正在进行的热门项目之一，旨在实现完全自主的系统。除了 LLM 的基本功能外，AutoGPT 框架还集成了各种外部工具和内存管理。用户输入定制的目标后，就可以腾出手来，等待 AutoGPT 自动生成想法并执行特定任务，所有这些都不需要额外的用户提示。如图 4 所示，我们介绍了代理在只有一个代理在场的场景中表现出的惊人能力。



图 3 (彩色在线) 基于 LLM 的代理应用场景：单代理部署、多代理交互和人与代理交互。单个代理拥有多种能力，在各种应用方向上都能表现出出色的任务解决能力。当多个代理互动时，它们可以通过合作或对抗的方式取得进步。此外，在人与代理的交互中，人类的反馈可以使代理更高效、更安全地执行任务，同时代理也可以为人类提供更好的服务。




图 4 (彩色在线) 基于 LLM 的单一代理在不同场景中的实际应用。在面向任务的部署中，代理协助人类用户解决日常任务。它们需要具备基本的指令理解和任务分解能力。在面向创新的部署中，代理展示了在科学领域进行自主探索的潜力。在面向生命周期的部署中，代理有能力不断探索、学习和利用新技能，以确保在开放世界中长期生存。

4.1.1 以任务为导向的部署

基于 LLM 的代理可以理解人类的自然语言指令并执行日常任务 [292]，是目前最受用户青睐、最具实用价值的代理之一。这是因为它们具有提高任务效率、减轻用户工作量和促进更多用户使用的潜力。在面向任务的部署中，代理遵从用户的高级指令，执行目标分解 [167,171,293,294]、子目标序列规划 [167,295]、环境交互探索 [165,292,296,297] 等任务，直至实现最终目标。根据任务类型，我们将这些部署环境分为网络场景和生活场景，并介绍了代理在其中扮演的具体角色。

在网络场景中。在网络场景中代表用户执行特定任务被称为网络导航问题[296]。代理解释用户指令，将其分解为多个基本操作，并与计算机进行交互。这通常包括填写表格、网上购物和发送电子邮件等网络任务。代理需要具备在复杂的网络场景中理解指令、适应变化（如嘈杂的文本和动态 HTML 网页）以及概括成功操作的能力[292]。这样，代理就能在未来处理看不见的任务时实现无障碍和自动化[298]，将人类从与计算机用户界面的重复交互中解放出来。

为了使代理与现实网页之间能够成功互动，一些研究人员[294, 299]已经开始利用 LLM 强大的 HTML 阅读和理解能力。通过设计提示，他们试图让代理理解整个 HTML 源代码，并预测更合理的下一步行动。Mind2Web [300] 结合了多个针对 HTML 进行微调的 LLM，使其能够在真实世界的场景中总结冗长的 HTML 代码 [293] 并提取有价值的信息。此外，WebGum [296] 通过使用包含 HTML 屏幕截图的多模态语料库，增强了具有视觉感知能力的代理的能力。Auto-GUI [301] 也提出了一种多模态解决方案，可直接与移动设备上的界面进行交互，从而加深对网络的全面理解。

页码

生活场景。在许多日常家务劳动中,代理必须理解隐含指令并应用常识性知识 [302]。对于仅根据海量文本训练的基于 LLM 的代理来说,人类认为理所当然的任务可能需要多次试错尝试 [303]。更现实的场景往往会带来更晦涩难懂的任务。例如,如果天黑而房间里有灯,代理就应该主动打开灯。为了成功地在厨房切菜,代理需要预测刀的可能位置 [167]。

代理能否将其训练数据中蕴含的世界知识应用到真实的交互场景中? Huang 等人[171]率先探索了这一问题。他们证明,在适当的提示下,足够大的 LLM 可以有效地将高级任务分解为合适的子任务,而无需额外的训练。不过,这种静态推理和规划能力也有其潜在的缺点。代理生成的行动往往缺乏对周围动态环境的感知。例如,当用户下达 "打扫房间" 的任务时,代理可能会将其转化为 "呼叫清洁服务" 等不可行的子任务 [304]。因此,有些方法直接将空间数据和项目位置关系作为模型的附加输入。这样,代理就能获得对周围环境的精确描述,并更有效地计划下一步行动 [167, 295, 304]。

4.1.2 以创新为导向的部署

基于 LLM 的代理在执行任务方面表现出了强大的能力。然而,在尖端科学等智力要求更高的领域,代理的潜力尚未得到充分发挥。这种局限性主要来自两个方面的挑战 [305]。一方面,科学本身的复杂性构成了重大障碍。许多特定领域的术语和多维结构难以用单一文本表示。因此,它们的完整属性无法完全封装。另一方面,科学领域严重缺乏合适的训练数据,使得代理难以理解整个领域的知识[306, 307]。如果能在代理内部发现自主探索的能力,将为人类科技带来有益的创新。

目前,各专业领域都在努力克服这一挑战 [308-310]。计算机领域的专家充分利用了代理强大的代码理解和调试能力 [288, 311]。在化学和材料领域,研究人员为代理配备了各种通用或特定任务工具,以更好地理解领域知识。代理逐渐发展成为科学助手,精通在线研究和文档分析,以填补数据空白。它们还利用机器人应用程序接口进行现实世界的交互,从而完成材料合成和机制发现等任务[91, 245, 305]。

基于 LLM 的代理在科学创新方面的潜力是显而易见的,但我们并不希望它们的探索能力被用于可能威胁或伤害人类的应用中。Boiko 等人[91]研究了代理在合成非法药物和化学武器过程中隐藏的危险,指出代理可能会在对抗性提示中被恶意用户误导。这为我们今后的工作敲响了警钟。

4.1.3 面向生命周期的部署

在一个开放、未知的世界中,建立一个能够不断探索、开发新技能并保持长期生命周期的通用代理是一项巨大的挑战。这一成就被视为 AGI 领域的一个重要里程碑[271]。Minecraft 作为一个典型的、被广泛探索的模拟生存环境,已成为开发和测试代理综合能力的独特乐园。玩家通常从学习基础知识开始,如开采木材和制作工艺台,然后再学习更复杂的任务,如与怪物战斗和制作钻石工具 [177]。Minecraft 从根本上反映了真实世界,有利于研究人员调查代理在真实世界中的生存潜力。

《威廉与魔法》中的代理生存算法一般可分为两类[177]: 低级控制和高级规划。早期的工作主要集中在强化学习 [177, 312] 和模仿学习 [313], 使代理能够制作一些低级物品。随着展现出惊人推理和分析能力的 LLM 的出现,代理开始利用 LLM 作为高级计划器来指导模拟生存任务[271, 314]。一些研究人员利用 LLM 将高级任务指令分解为一系列子目标 [315]、基本技能序列 [314] 或基本键盘/鼠标操作 [315], 逐步协助代理探索开放世界。

Voyager [177]从AutoGPT [95]中汲取灵感,成为Minecraft中第一个基于LLM的嵌入式终身学习代理。它引入了一个用于存储和检索复杂动作可执行代码的技能库,以及一个包含环境反馈和纠错的迭代提示机制。这使代理能够在没有人类干预的情况下自主探索和适应未知环境。能够自主学习和掌握整个现实世界技术的人工智能代理可能并不像人们想象的那样遥远[315]。

4.2 协调多个代理的潜力

动机和背景。虽然基于 LLM 的代理在文本理解和生成方面表现出色,但它们本质上是孤立的实体 [316]。单个代理应用范例的一个关键局限是它们与其他代理合作并从社会互动中学习的能力。这种局限性限制了它们从多轮反馈中获益的能力,而多轮反馈本可以提高它们的性能 [21]。

早在 1986 年,明斯基[317]就做出了前瞻性的预测。他在《心灵社会》(*The Society of Mind*)一书中提出了一种新颖的智能理论,认为智能是由许多具有特定功能的小型代理相互作用而产生的。例如,某些代理可能负责模式识别,而其他代理可能负责决策或生成解决方案。随着分布式人工智能的兴起,这一观点已被付诸具体实践[318]。作为主要研究领域之一的多代理系统(MAS) [3],重点研究的是一组代理如何有效地协调和协作解决问题。一些专门的通信语言(如 KQML [319])很早就被设计出来,以支持代理之间的信息传输和知识共享。进入 21 世纪,将强化学习算法(如 Q-learning)与深度学习相结合,已成为开发可在复杂环境中运行的 MAS 的一项突出技术[320]。如今,基于 LLMs 的构建方法开始展现出巨大的潜力。代理之间的自然语言交流变得更加优雅,也更容易为人类所理解,从而大大提高了交互效率。

潜在优势。具体来说,基于 LLM 的多代理系统可以提供几种优势。正如斯密在《国富论》[321]中明确指出的:"劳动生产力的最大提高,以及指导或应用劳动的大部分技能、灵巧和判断力,似乎都是分工的结果"。根据分工原则,具备专业技能和领域知识的单个代理可以从事特定的任务。一方面,通过分工,代理处理特定任务的技能日益精进。另一方面,将复杂任务分解为多个子任务,可以省去在不同流程之间切换的时间。最终,多个代理之间的有效分工可以完成比没有专业化分工时大得多的工作量,从而大大提高整个系统的效率和产出质量。

在第 4.1 小节中,我们全面介绍了基于 LLM 的代理的多功能能力。在本小节中,我们将重点探讨多代理环境中代理之间的交互方式。根据目前的研究,这些交互大致可分为以下几类:合作交互和对抗交互(见图 5)。

4.2.1 合作互动促进互补

多代理合作系统是实际应用中最广泛的模式。在这类系统中,单个代理会评估其他代理的需求和能力,并积极寻求与他们合作行动和信息共享 [89]。这种方法带来了许多潜在的好处,包括提高任务效率、改进集体决策,以及解决单个代理无法独立解决的复杂现实问题。我们将现有的多代理合作应用分为两类:无序合作和有序合作。

无序合作。当系统中存在三个或更多代理时,每个代理都可以自由地公开表达自己的观点和意见。他们可以提供反馈和建议,以修改与当前任务相关的反应[322]。整个讨论过程不受控制,没有任何特定的顺序。我们将这种多代理合作称为无序合作。ChatLLM 网络 [323] 是这一概念的典范代表。它模拟了神经网络中的前向和后向传播过程,将每个代理视为一个单独的节点。代理




图 5 (彩色在线) 基于 LLM 的多个代理的交互场景。在合作互动中, 代理以无序或有序的方式进行合作, 以实现共同目标。在对抗式交互中, 代理以针锋相对的方式展开竞争, 以提高各自的性能。

后一层的代理需要处理前一层所有代理的输入, 并向前传播。一个潜在的解决方案是引入一个专门的协调代理, 负责整合和组织来自所有代理的响应, 从而更新最终答案 [324]。然而, 整合大量反馈数据并提取有价值的见解对协调代理来说是一个巨大的挑战。此外, 多数表决也是做出适当决策的有效方法 [325]。有序合作。当系统中的代理遵守特定规则时, 例如按顺序逐一表达自己的意见, 下游代理只需关注上游的输出。这大大提高了任务完成效率。整个讨论过程组织有序。我们把这种多代理合作称为有序合作。值得注意的是, 只有两个代理的系统, 基本上是在进行对话这也属于有序合作的范畴。

CAMEL [89] 是双代理合作系统的成功实施案例。在角色扮演通信框架内, 代理分别扮演用户 (下达指令) 和助手 (提供具体解决方案) 的角色。通过多轮对话, 这些代理自主合作完成用户指令 [326]。另一方面, Talebirad 等人 [316] 最早系统地介绍了基于 LLM 的综合多代理协作框架。这种模式旨在利用每个代理的优势, 促进它们之间的合作关系。在此基础上, 许多多代理合作应用已成功建立起来 [21, 327-330]。为了提高合作效率, 研究人员希望代理能从人类成功的合作案例中学习 [90]。Wang 等人 [331] 主张把进化博弈论和人工智能结合起来, 以推进多代理学习系统的数学研究。MetaGPT [332] 从经典的软件开发瀑布模型中汲取灵感。通过将先进的人类管理经验编码到代理提示中, 多个代理之间的协作变得更有条理。

然而, 在 MetaGPT 的实际探索过程中, 发现了多代理合作的潜在威胁。如果不制定相应的规则, 多个代理之间的频繁互动会无限放大微小的幻觉 [332]。例如, 在软件开发过程中, 可能会出现函数不完整、依赖关系缺失以及肉眼无法察觉的错误等问题。引入交叉验证 [90] 或及时外部反馈等技术可对代理输出的质量产生积极影响。

4.2.2 对抗性互动促进进步

传统上, 合作方法在多代理系统中得到了广泛探索。不过, 研究人员越来越认识到, 将博弈论 [333, 334] 中的概念引入系统可以带来更稳健、更高效的行为。在竞争环境中, 代理可以通过动态互动迅速调整策略, 努力选择最有利或最合理的行动来应对其他代理引起的变化 [50, 335]。例如, AlphaGo Zero [336] 是围棋的代理




图6 (彩色在线) 人类与代理互动的两种范式。在指导者-执行者范式 (a) 中, 人类提供指导或反馈, 而代理则充当执行者。在平等合作范式 (b) 中, 代理像人类一样, 能够与人类进行移情对话, 并参与合作任务。

通过自我博弈实现重大突破。同样, 在基于 LLM 的多代理系统中, 通过竞争、争论和辩论, 可以自然而然地促进代理之间的变革 [337, 338]。通过放弃僵化的信念和进行深思熟虑的反省, 对抗性互动可以提高回应的质量。

研究人员首先深入研究了基于 LLM 的代理的基本辩论能力 [114, 339, 340]。研究结果表明, 当多个代理在 "针锋相对" 的状态下表达自己的论点时, 一个代理可以从其他代理那里获得大量外部反馈, 从而纠正自己扭曲的想法 [93]。因此, 多代理对抗系统适用于需要高质量回应和准确决策的场景。例如, Du 等人 [92] 引入了辩论的概念, 赋予代理来自同伴的回应。当这些回应与代理自身的判断出现分歧时, 就会发生 "心理" 争论, 从而得出完善的解决方案。

多代理对抗系统的性能已显示出相当可观的前景。然而, 该系统基本上依赖于 LLM 的力量, 并面临着几个基本挑战: (1) 在长时间的辩论中, LLM 有限的上下文无法处理整个输入。(2) 在多代理环境中, 计算开销大大增加。(3) 多代理协商可能会收敛到一个错误的共识, 而所有代理都坚信其准确性 [92]。MAS 的发展还远未成熟和不可行。在适当的时候引入人工指导来弥补代理的不足, 是促进代理进一步发展的良好选择。

4.3 人与代理之间的互动参与

人机交互, 顾名思义, 是指代理人 与人类合作完成任务。在整个交互过程中, 人类通过提供指导或规范代理的安全性、合法性和道德行为, 发挥着举足轻重的作用 [341, 342]。这在专业领域尤为重要, 例如存在数据隐私问题的医学领域 [343]。在这种情况下, 人类的参与可以作为弥补数据不足的重要手段, 从而促进更顺畅、更安全的合作流程。人与代理之间的互动可分为两种模式 (见图 6)。(1) 不平等互动 (即指导者-执行者范式), 人类是指令的发布者, 而代理则是执行者, 作为人类的助手参与协作。

(2) 平等互动 (即平等伙伴关系范式): 代理达到人类水平, 与人类平等参与互动。

4.3.1 指导者-执行者范式

最简单的方法是由人类全程指导: 人类直接提供具体的指令, 而代理的作用则是理解人类的自然语言指令, 并将其转化为相应的行动 [344-346]。在第 4.1 小节中, 我们介绍了代理解决单步问题或接收人类高级指令的情景。此外, 一些研究表明, 将指令分解为分步格式可以提高语言模型的跨任务泛化能力 [347]。考虑到语言的交互性, 在

在本节中,我们假定人类与代理之间的对话也是交互式的:代理重新回应人类的每一条指令,通过交替迭代改进其行动,最终满足人类的要求[177, 348]。虽然这种方法确实实现了人机交互的目标,但它需要大量的人力,在某些任务中,甚至可能需要高水平的专业知识。为了缓解这一问题,可以授权代理自主完成任务,而人类只需在特定情况下提供反馈。在此,我们将反馈大致分为两种类型:定量反馈和定性反馈。

量化反馈。定量反馈的形式主要包括二进制分数和评级等绝对评价以及相对分数。二元反馈指的是人类提供的正面和负面评价,代理可利用这些评价加强自我优化[349-353]。这种类型的用户反馈只包括两个类别,通常很容易收集,但有时可能会过度简化用户意图,忽略潜在的中间场景。为了展示这些中间情况,研究人员试图从二元反馈扩展到评级反馈,这涉及到将分类划分到更细的层次。然而, Kreutzer 等人[354]的研究结果表明,这种多级人工评级方法可能效率不高或可靠性较低。此外,代理还可以从多重选择等比较分数中学习人类的偏好[355, 356]。

定性反馈。文本反馈通常以自然语言提供:人类就如何修改代理生成的输出结果提出建议,然后代理根据这些建议完善其后续输出结果 [357, 358]。对于不具备多模态感知能力的代理,人类可以充当批评者,提供视觉批评 [177]。此外,代理还可以利用记忆模块来存储反馈信息,以便将来重复使用 [359]。在 Scheurer 等人的研究中[360],人类对代理生成的初始输出提供反馈,促使代理提出各种改进建议。然后,代理根据人类的反馈意见,辨别并采纳最合适的建议。与定量反馈相比,这种方法能更好地传达人类的意图,但对于代理来说,理解起来可能更具挑战性。Xu 等人[361]比较了各种类型的反馈,发现将多种类型的反馈结合起来能产生更好的效果。当然,人机交互的协作性质也允许人类通过修改中间环节 [176, 362] 或调整对话内容 [363] 来直接改进代理的输出。在一些研究中,代理可以自主判断对话是否顺利进行,并在遇到错误时寻求反馈[364, 365]。人类也可以选择随时参与反馈,引导代理朝正确方向学习 [366]。

目前,作为人类助手的基于 LLM 的代理在各个领域都拥有巨大的潜力。例如,在教育领域,机器人 Dona [367] 支持多模态交互,协助学生注册; Gvirsman 等人 [368] 通过实现多方面的交互,为幼儿教育做出了贡献。代理还能帮助人类理解和利用数学[369]。在医学领域,已经提出了一些医疗代理,在辅助诊断、咨询等方面显示出巨大的潜力[370, 371]。特别是在心理健康领域,研究表明,与面对面治疗相比,代理具有降低成本和匿名等优势,因此可以提高可及性[372]。利用这些优势,代理得到了广泛应用。Ali 等人[373]设计了 LISSA,用于与自闭症谱系的青少年进行在线交流,实时分析他们的语音和面部表情。Hsu 等人[374]建立了语境化语言生成方法,为寻求从人际关系压力到焦虑等不同主题支持的用户提供量身定制的帮助。此外,在商业等其他行业,一个好的代理可以提供自动化服务,从而有效降低劳动力成本[375]。在追求人工智能的过程中,人们正努力创造能在现实生活中充当万能助手的代理[376]。

4.3.2 平等伙伴关系范例

富有同情心的交流者随着人工智能的快速发展,对话式代理以各种形式 [377] 和各种场景 [378-380] 引起了广泛关注。虽然直观地说,代理本身并不具备情感,但我们能否让它们表现出情感,从而弥合代理与人类之间的鸿沟呢?因此,大量的研究工作已开始深入探讨代理的移情能力。这种努力旨在为这些代理注入人情味,使其能够从人类的表达中察觉情绪和情感,最终制作出能引起情感共鸣的对话[381-381-385385]。除了生成带有情感色彩的语言,代理还能从人类的表达中察觉情绪和情感,最终制作出能引起情感共鸣的对话[]

可以动态调整自己的情绪状态,并通过面部表情和声音显示出来[386]。这些研究将代理视为移情交流者,不仅提高了用户满意度,还在医疗保健[373, 374, 387]和商业营销[388]等领域取得了重大进展。与简单的基于规则的对话代理不同,具有移情能力的代理可以根据用户的情感需求调整其互动[389]。

人类层面的参与者。此外,我们还希望代理能够参与人类的正常生活,从人类层面的角度与人类合作完成任务。在现实世界的许多应用中,对抗游戏在促进高效率、高效益的决策过程中发挥着举足轻重的作用[390]。代理已经在象棋[335]、围棋[50]和扑克[391]等纯竞争环境中表现出色,而基于 LLM 的代理则更进一步,通过在更复杂的场景中进行有效的协商和协作,设计出统一的合作策略[392-395]。除了游戏之外,基于 LLM 的代理还能在策略制定、谈判和其他基于交互的任务中展示出人类水平的能力。它们可以与人类协作,确定共享知识、识别相关信息、提出问题并进行推理,从而完成分配、规划和调度等任务[396]。此外,基于 LLM 的代理还具有说服能力[397],可在各种交互场景中动态影响人类的观点[398]。

总之,人类与代理互动领域的目标是学习和理解人类,最终实现人类与代理之间高效、安全的互动。目前,该领域在可用性方面已取得重大突破。未来,基于 LLM 的代理有望更好地帮助人类完成各个领域更复杂的任务。

5 代理社会:从个体性到社会性

长期以来,研究人员和从业人员一直在设想一个交互式人工社会,在这个社会中,人类的行为可以通过可信的代理来实现[399]。从《模拟人生》等沙盒游戏到 Metaverse 概念,我们可以看到“模拟社会”在人们心目中的定义:环境和在其中互动的个体。每个个体的背后可以是一段程序、一个真实的人类,也可以是前文[16, 400, 401]所述的基于 LLM 的代理。然后,个体之间的互动也有助于社会性的出现。

在本节中,我们首先介绍基于 LLM 的代理的行为和个性,追溯其从个体性到社会性的发展历程(第 5.1 小节)。随后,我们介绍了供代理执行其行为和参与互动的各种环境的总体分类(第 5.2 小节)。最后,我们将讨论代理社会是如何运作的,人们可以从中获得哪些启示,以及我们需要注意的风险(第 5.3 小节)。

5.1 基于 LLM 的代理的行为和个性

正如社会学家所指出的,可以从外部和内部两个维度对个人进行分析[402]。外在层面涉及可观察到的行为,而内在层面则与性格、价值观和情感有关。如图 7 所示,这个框架为基于 LLM 的代理提供了一个关于突发性行为和个性的视角。从外部来看,我们可以观察到代理的社会学行为(5.1.1 小节),包括代理如何单独行动以及如何与环境互动。从内部来看,代理可能会表现出人格的复杂方面(5.1.2 小节),如认知、情感和性格,这些都会影响代理的行为反应。

5.1.1 社会行为

正如 Troitzsch 等人[403]所言,代理社会是一个由个体和群体社会活动组成的复杂系统。最近,基于 LLM 的代理在环境中表现出了自发的社会行为[404]。

基础个人行为。个人行为产生于内部认知过程和外部环境因素。这些行为构成了个体在社会中运作和发展的基础。它们可分为三个方面:(1)输入行为指的是从周围环境中吸收信息。这包括感知感官刺激[101]并将其储存为记忆[138]。(2)内化行为涉及内部认知处理。这类行为包括计划[109]、推理[76]、反思[72]等活动




图7（彩色在线）模拟代理社会概览。整个框架分为两个部分：代理和环境。从图中我们可以观察到以下几点。(1)（左图）在个体层面，代理表现出计划、推理和反思等内化行为。它还表现出内在的个性特征，包括认知、情感和性格。(2)（中）一个代理可以和其他代理组成群体，并表现出群体行为，如合作。(3)（右）环境，无论是虚拟环境还是物理环境，都包含人类行动者和所有可用资源。对于单个代理来说，其他代理也是环境的一部分。(4) 代理能够通过感知和行动与环境互动。

和知识沉淀 [89, 332]。这些内省过程对于成熟和自我完善至关重要。(3) 输出行为包括从物体操作[101]到结构构建[177]的外显行为。此外，代理还表达意见和广播信息，与他人互动[332, 405]。

动态群体行为。群体是由两个或两个以上的个体在一个确定的社会环境中聚集而成的[406]。群体的属性会因成员间的互动和环境影响而发生变化。这种灵活性产生了群体行为，每种行为都会对更大的群体产生影响。群体行为包括以下几类。(1) 积极的群体行为能促进集体福祉[16, 90, 322, 327, 328, 340]。例如，通过志愿者行为[330]、头脑风暴讨论[327, 340]和项目管理[332]实现的合作。(2) 基于 LLM 的代理可观察到中立的群体行为。LLM 被设计为“乐于助人、诚实、无害”[407]，这种与中立价值观的一致性[408]导致了包括模仿和旁观在内的一致性行为。

(3) 消极的群体行为会削弱群体的有效性。最近的研究发现，代理人可能会表现出对抗行为 [404]，甚至采取破坏行为，如为了追求某些利益而破坏其他代理人或环境 [330]。

5.1.2 个性

最近的研究进展表明，LLM 和基于 LLM 的代理通过与群体和环境的互动表现出一种人格[409-411]。广为接受的人格定义包括认知、情感和性格特征[412]。

认知能力。认知能力指的是心理过程，包括思考、判断和解决问题。最近的研究应用认知心理学方法来研究基于 LLM 的代理的新兴个性 [413-415]。他们进行了有关判断和决策的心理实验，以测试代理系统[413, 414, 416, 417]。具体来说，使用认知反思测试（CRT）对 LLM 进行了评估，以强调其超越直觉的深思熟虑能力 [418, 419]。这些研究结果表明，基于 LLM 的代理在特定领域显示出类似人类的认知智能。

情商。情绪涉及主观感受和情绪状态。随着 LLM 的作用越来越大，基于 LLM 的代理现在对情绪有了细致入微的理解 [24]。最近的研究探索了 LLMs 的情绪智能（EI），包括情绪识别、

解释和理解。LLMs 可以准确识别用户情绪,表现出同理心[420, 421],并调节用户的情绪反应[386,422,423]。这些进步促进了移情人工智能(EAI)的发展,而移情人工智能是实现 AGI 的一个重要方面。贝茨等人[424]探索了情感建模在创建更可信的代理中的作用。通过开发社会情感技能并将其整合到代理架构中,基于 LLM 的代理或许能进行更自然的互动。

性格刻画。认知涉及心智能力,情感与主观体验有关,而狭义的人格概念通常与独特的性格模式有关。研究人员使用五大人格特质指标[425, 426]和迈尔斯-布里格斯类型指标(MBTI)[425-427]等框架分析法律硕士的性格特征。此外,对潜在有害的阴暗人格特质的调查强调了这些代理中角色形象的复杂性和多面性[428]。还有人研究了在代理中塑造可定制的角色形象[429],使用户能够塑造符合所需特征的代理。提示工程[16, 430]和个性丰富的数据集[431, 432]等技术被用来优化 LLM,训练它们表现出特定的个性特征。

5.2 代理社会的环境

在模拟中,社会不仅由单独的代理组成,还包括代理居住、感知和行动的环境[433]。环境影响着代理的感官输入和行动,而代理则影响着环境的状态。如图 7 所示,对于单个代理而言,环境指的是其他自主代理、人类和外部因素。环境为代理提供资源和刺激。本节将探讨各种环境范例的基本特征、优势和局限性,包括基于文本的环境(第 5.2.1 小节)、虚拟沙盘环境(第 5.2.2 小节)和物理环境(第 5.2.3 小节)。

5.2.1 基于文本的环境

由于 LLM 主要依赖语言作为输入和输出格式,因此基于文本的环境是基于 LLM 的代理运行的最自然平台。基于文本的环境可以以自然格式或结构格式呈现。自然文本使用描述性语言来传递信息[434],而结构化文本则遵循标准化格式,如技术文档和超文本[292, 293, 297, 300]。

基于文本环境的灵活性允许各种应用,如互动日志[89]和基于文本的游戏。在基于文本的游戏中,代理利用文本命令执行移动或使用工具等操作[303, 434-436],并通过文本表达情感[437]。

5.2.2 虚拟沙盘环境

虚拟沙盘环境为代理社会提供了一个可视化和可扩展的平台,在模拟与现实之间架起了一座桥梁。沙盘环境的主要特点如下。

(1) 可视化。从二维图形界面到身临其境的三维建模,虚拟沙盘展示了模拟环境的全景。多种元素共同将抽象模拟转化为可视景观。它允许跟踪代理移动、交互和行动的符号表示。(2) 可扩展性。该环境具有高度可扩展性,便于构建和部署各种场景。在基本层面上,代理可以操纵物理元素。例如,AgentSims[140]和生成式代理[16]等平台在基于网格的世界中构建了具有建筑物和居民的人工城镇。另一个例子是 Minecraft,它提供了一个开放式构建的块状三维世界[177, 283, 315]。除了物理元素,还可以定义代理关系、规则和社会规范[21]。这种可扩展性使迭代式原型开发成为可能。

5.2.3 自然环境

如前所述,基于文本的环境表现力有限,而虚拟沙盘则缺乏真实的体现性体验。相比之下,物理环境指的是有形的物体和空间,这给基于 LLM 的代理带来了额外的挑战。这些挑战可归纳如下:(1) 感官感知和处理。物理环境提供了丰富的感官输入、

包括视觉[101,270]、听觉[265,268]和空间感。这在增强感官沉浸感的同时,也带来了复杂性。代理需要有效处理这些感官输入,以便与周围环境互动。(2) 运动控制。与虚拟环境不同,物理空间通过体现对行动施加了现实的限制。这就需要可执行的、接地气的运动控制[171]。例如,在工厂中,操作机械臂的代理需要精确的调整和可控的力来抓取物体。此外,代理还必须在物理工作空间中导航并避开障碍物。为了应对这些挑战,代理需要接受特定硬件和特定场景的培训,以发展从虚拟环境到物理环境的适应能力。更多讨论将在第 6.6 小节中介绍。

5.3 使用基于 LLM 的代理进行社会模拟

近期关于模拟社会的研究主要遵循两条主线,即探索基于 LLM 的代理的集体智能能力的边界 [90, 115, 327, 330, 332] 以及利用模拟社会加速社会科学的发现 [16,438,439]。此外,还有一些值得关注的研究,如利用模拟社会收集合成数据集[89,440,441],帮助人们模拟罕见而困难的人际交往情况[442,443]。在 5.1 和 5.2 小节的基础上,我们将介绍代理社会的关键属性和机制(5.3.1 小节)、我们可以从突发社会现象中学到的东西(5.3.2 小节),以及其中潜在的伦理和社会风险(5.3.3 小节)。

5.3.1 代理人社会的主要性质和机制

社会模拟可分为宏观模拟和微观模拟 [438]。在宏观层面的仿真(也称为基于系统的仿真)中,研究人员模拟仿真社会系统的整体状态 [444, 445]。而微观层面的仿真,也称为基于代理的仿真或 MAS,则是通过对个人建模来间接模拟社会 [446, 447]。随着基于 LLM 的代理的发展,微观层面的仿真近来越来越受到重视 [16, 140]。在本文中,我们将“代理社会”定义为一个开放、持久、情景化和有组织的框架[399],在这个框架中,基于 LLM 的代理在一个确定的环境中相互影响。在下面的段落中,我们将通过讨论这些特性来分析模拟社会是如何运作的。

(1) 开放性。模拟社会的决定性特征之一在于其开放性,包括个人和环境组成部分的开放性。代理和人类作为这类社会的主要行为者,可以灵活地进入或离开环境,而不会破坏其运行的完整性[448]。(2) 持久性。我们期望模拟社会具有持久性和可持续性。虽然社会中的单个代理在离散的时间步骤中行动[16, 438],但整个社会在某种程度上脱离了瞬时行为,并在时间中持续存在。这种持续性创造了一种环境,使代理人的决策和行为不断累积,从而形成连贯的社会轨迹。(3) 情境性。社会的情境性强调社会在一个独特的环境中存在和运行,而这个环境是事先人为或自动构建的。值得注意的是,代理拥有空间环境意识,了解自己在环境中的位置和视野范围内的物体[16, 177]。这种意识有助于提高它们主动与上下文进行交互的能力。(4) 有组织。模拟社会在精心组织的框架和预定义的规则下运行。在模拟世界中,代理在有限的行动空间中与环境互动,而环境中的物体则在有限的状态空间中转换。这种组织框架确保了操作的连贯性和可理解性,使模拟不断发展,但又经久不衰。

5.3.2 代理人社会的启示

在探索模拟社会如何运作之后,本节将深入探讨代理社会中出现的社会现象。在社会科学领域,追求个人、群体及其复杂动态的通用表征一直是人们的共同目标[449, 450]。基于 LLM 的代理的出现,使人们能够从更微观的角度看待模拟社会,并从新的表征中获得新的发现。

有组织的生产合作。模拟社会为创新性合作模式提供了宝贵的见解，有可能加强现实世界的管理策略。研究表明，在这种模拟社会中，具有不同背景和能力的专家会为复杂问题（如软件开发或咨询）的创造性解决方案做出贡献[89, 90, 324, 330]。此外，通过代理之间反复的互动和辩论，幻觉或思维退化（DoT）等个人错误会被群体纠正，最终提高任务的完成率[92, 93]。另一个可观察到的现象是，在这样一个大型合作小组中，高效的交流也起着举足轻重的作用。例如，MetaGPT [332]参照标准化操作程序（SOP），人为地制定了高效的交流方式。Park 等人[16]通过在模拟城镇中的自发交流，观察到代理共同组织聚会的情况。

社会网络中的传播。模拟社会系统还可作为预判社会进程的参考。与依赖时间序列数据和整体建模的传统实证方法不同[451, 452]，基于代理的模拟为研究人员提供了一个更可解释和更具内涵的视角。在此，我们重点讨论其社会网络传播建模中的应用，例如人际关系的传播。最初没有联系的代理作为朋友，有可能通过中间人建立联系[16]。一旦关系网络建立起来，我们就可以观察到信息的传播以及潜在的态度和情感。S⁽³⁾[438]提出了一个用户人口推理模块，用于捕捉知晓特定信息的人数以及他们的集体情绪。同样的方法还可扩展到文化传播建模 [453] 和传染病传播建模 [454]。利用基于 LLM 的代理，研究人员可以轻松实施各种干预策略，并监测人口随时间的变化，从而了解各种社会传播现象背后的原理。

伦理决策与博弈论。模拟社会为研究复杂的决策过程（包括受伦理道德原则影响的决策过程）提供了一个动态平台。以狼人游戏 [404, 455] 和神秘谋杀游戏 [456] 为例，研究人员探索了基于 LLM 的代理在面对欺骗、信任和信息不完整等挑战时的能力。这些复杂的决策场景与博弈论也有交集 [457]，在博弈论中，我们经常会遇到与个人和集体利益相关的道德困境。通过对不同情景的模拟，我们可以了解代理人如何在行动中优先考虑诚实、合作和公平等价值观。此外，它不仅提供了对现有道德价值观的理解，还有助于理解这些价值观是如何随着时间的推移而演变和发展的。最终，这些见解有助于完善基于 LLM 的代理，使其符合人类的价值观和道德标准[21]。

政策制定与改进。社会建模中最有前途和最有基础的研究方向之一是探索各种经济和政治状态及其对社会动态的影响[458]。研究人员可以通过配置具有不同经济偏好或政治意识形态的代理人来模拟各种社会系统。这种分析可以为寻求促进繁荣和社会福祉的政策制定者提供有价值的见解。此外，随着人们对环境可持续性的关注与日俱增，我们还可以模拟涉及资源开采、污染、保护工作和政策干预的情景 [459]。这些实验将有助于做出明智的决策，预见潜在的影响，并制定旨在最大限度地扩大积极成果、同时最大限度地减少意外负面影响的政策。

5.3.3 代理社会的伦理和社会风险

从工业工程到科学研究，以基于 LLM 的代理为动力的模拟社会提供了重要启示。然而，这些模拟也带来了无数伦理和社会风险，需要仔细考虑并加以缓解[460]。

意外的社会危害。模拟社会有可能产生意想不到的社会现象，从而引起公众的强烈不满和社会危害。这些现象既包括歧视、孤立和欺凌等个人层面的问题，也包括压迫性奴役和群体对立等更广泛的问题[461, 462]。恶毒的人可能会操纵这些模拟进行不道德的社会实验，其后果将超越虚拟世界而影响现实。创建这些模拟社会无异于打开潘多拉的盒子，因此有必要在其开发和使用过程中制定严格的道德准则并进行监督 [460]。

定型观念和偏见。刻板印象和偏见是语言建模领域长期存在的难题。很大一部分原因在于从互联网上获取的训练语料[463, 464], 这些语料反映了, 有时甚至放大了现实世界中的社会偏见, 如性别、宗教和文化[465]。虽然 LLM 已与人类价值观保持一致, 以减少有偏见的输出, 但由于训练数据的长尾效应, 这些模型仍难以很好地描绘少数群体[466-468]。这可能导致有关基于 LLM 的代理的社会科学研究过于片面, 因为边缘化人群的模拟行为通常符合普遍的假设[469]。研究人员已开始通过训练数据多样化和调整 LLM 来解决这一问题 [470,471], 但仍有许多工作要做。

隐私与安全。鉴于人类也可以成为代理社会的成员, 用户与基于 LLM 的代理之间的私人信息交换会带来重大的隐私和安全问题 [472]。用户在交互过程中可能会无意中泄露敏感的个人信 息, 而这些信息将长期保留在代理的内存中 [137]。这种情况可能导致未经授权的监控、数据泄露和个人信息滥用, 尤其是在受到恶意攻击时[473]。为有效应对这些风险, 必须实施严格的数据保护措施, 如差异化隐私协议、定期数据清除和用户同意机制 [474, 475]。

过度依赖和成瘾性。模拟社会中另一个令人担忧的问题是, 用户可能会对代理产生过度的情感依赖, 甚至上瘾。尽管意识到这些代理是计算实体, 但用户可能会将它们拟人化, 并将人类的情感附加到它们身上 [16, 476]。一个值得注意的例子是 "悉尼", 它是微软公司开发的由 LLM 驱动的聊天机器人, 是必应搜索引擎的一部分。然而, 一些用户报告称, 他们与 "悉尼" 之间存在意想不到的情感联系[477], 甚至有人对微软削减其个性表示不满, 并因此发起了名为 "FreeSydney"⁽²⁾ 的请愿活动。因此, 为了降低这里提到的风险, 必须强调不应将代理视为真正人际关系的替代品。

6 讨论

6.1 法学硕士研究与代理人研究互惠互利

随着近来 LLM 的进步, LLM 与代理交叉领域的研究也迅速发展, 推动了这两个领域的发展。在本节中, 我们将讨论 LLM 研究和代理研究为彼此带来的益处和机遇。

LLM 研究→ 代理研究。如前所述, 人工智能代理必须具备感知环境、做出决策和有效执行行动的能力[3, 31]。这涉及到理解输入、推理、规划和制定可执行的行动序列, 而这些都是 LLM 已经做好充分准备的。再加上所获得的知识和记忆, LLMs 可以创建可有效执行的连贯动作序列 [171, 246, 271]。此外, 通过反射等机制[138, 150], 它们可以根据当前环境提供的反馈不断调整决策和优化执行序列。这就提供了一个更稳健、更可解释的控制器。只需任务描述或演示, 它们就能有效处理以前从未见过的任务 [18, 87, 478]。此外, LLMs 还能适应各种语言、文化和领域, 使其用途广泛, 并减少了构建代理所需的复杂培训过程和数据收集[24, 224]。

从本质上讲, LLM 为代理研究提供了一个强大的基础, 为将其整合到代理相关研究中开辟了许多新的机会。这包括在传统的代理框架中增强决策能力, 并有可能改变以前由人类专家主导的领域, 如法律咨询和医疗援助 [326,330]。LLMs 的规划和反思能力可带来更优化的行动序列, 将代理研究从简单的模拟扩展到复杂的真实世界环境, 如机器人手臂路径规划或具身智能机器与有形世界的交互。此外, 代理的训练范式也变得更加精简, 可以通过演示轨迹直接适应新任务。

代理研究→ LLM 研究。将 LLM 提升为代理带来了新的挑战 and 机遇, 扩大了其应用范围。对 LLM 的研究不再局限于传统任务

2) <https://www.change.org/p/save-sydney-ai>.

目前, 语音识别技术的重点不再是涉及文本输入和输出的任务, 如文本分类、问题解答和文本摘要。取而代之的是, 重点已转向处理包含更丰富输入模式和更广泛行动空间的复杂任务, 同时以 PaLM-E [101] 为例, 努力实现更高的目标。

这种转变为 LLM 的进一步发展提供了动力, 例如更强的认知能力和概括能力。此外, 考虑到基于 LLM 的代理的规模和潜在计算成本, LLM 的效率成为一个重要的研究领域。此外, 基于 LLM 的代理的能力必须限制在安全的应用范围内, 以防止对环境中的其他元素造成意外伤害, 这就对作为认知核心的 LLM 提出了更高的要求[21, 479, 480]。

此外, 多代理系统领域是代理领域的一个重要研究分支[16, 89, 316, 330], 为如何更好地设计和构建 LLM 提供了宝贵的见解。我们希望基于 LLM 的代理在社会分工中扮演不同角色, 参与涉及合作、竞争和协调的社会互动 [90, 93, 114, 327, 332]。研究如何激发和保持代理的角色扮演能力, 提高合作效率 是一个值得关注的研究领域。

6.2 开发实用工具

如今, 各种代理开发工具提供了重要的基础设施[289, 481-483], 使研究人员和开发人员能够专注于代理策略, 而不必从头开始构建复杂的环境和交互机制。在本节中, 我们将讨论几种常见的单代理和多代理系统开发工具。

开发单一代理系统的工具。目前, 开发单个代理系统的工具主要集中在增强单个代理在不同环境中的决策和学习能力。例如, XAgent [481] 提供了一种基于 LLM 的通用代理, 可自动解决各种任务, 由三个部分组成: 调度器、规划器和行动器。XAgent 利用名为 ToolServer 的 docker 容器, 在安全的环境中运行, 并利用强大的工具来解决任务。同样, LangChain [289] 也是一个框架, 开发人员可以通过实施一系列模块化组件来创建由 LLM 驱动的应用程序, 这些组件可以通过链以特定方式进行组合。这些工具直接调用 LLM API, 而不是从头开始训练代理。相比之下, Xi 等人[482] 推出了 AgentGym, 这是一个支持基于 LLM 的代理培训的通用代理交互平台。该平台基于 HTTP 服务, 为不同环境提供统一的 API 接口, 支持轨迹采样、多转弯交互、在线评估和实时反馈。

开发多代理系统的工具。另一方面, 开发多代理系统的工具强调不同代理之间的协调与合作。AgentVerse [330]是这一领域的一个著名工具, 它是一个多代理框架, 可模拟人类群体解决问题的过程, 并动态调整团队成员, 以有效协调专家代理的协作群体。它在各种任务中表现出卓越的性能, 并在 Minecraft 环境中展示了代理之间复杂的相互关系。此外, AutoGen [327] 是一款高度灵活的多代理开发工具, 允许用户创建可定制的代理。通过与人类和工具的集成, 它促进了多个代理之间的自动通信和协作。在具体场景中, 全流程自动化软件开发框架 ChatDev [90] 通过多代理协作实现了虚拟软件公司的运营。Chan 等人[340]引入了一个名为 ChatEval 的多代理辩论框架, 用于评估生成文本的质量, 允许再搜索者设计不同的交流策略, 以提高评估的准确性。最近, 一种名为 Swarm [483] 的新型多代理开发工具被提出。通过利用代理和交接的原始抽象, 它实现了轻量级、高度可控和易于测试的代理协调和执行。这些开发工具正在为更复杂的协作型代理系统铺平道路, 使开发人员能够更轻松地对代理进行进一步研究。

6.3 基于 LLM 的代理评估

尽管 LLMs 代理在独立运行、集体合作和人机交互等领域表现出色, 但有效、客观地评估 LLMs 代理仍面临巨大挑战[70,484]。图灵提出了一种意义重大、前景广阔的人工智能代理评估方法, 即众所周知的图灵测试, 用于评估人工智能系统是否能表现出类似人类的智能[30]。然而, 该测试

是非常模糊、笼统和主观的。在本节中，我们将讨论基于 LLM 的代理的现有评估工作，并从实用性、社交性和价值观三个维度提出一些展望。

实用性目前，LLM 驱动的自主代理主要充当人类助手，接受人类委托的任务，独立完成任务或协助人类完成任务 [95, 167, 300, 311, 367, 376]。因此，任务执行过程中的有效性和实用性是这一阶段的关键评估标准。具体来说，任务完成的成功率是评估实用性的主要指标 [109, 115]。这一指标主要包括代理是否实现了规定的目标或达到了预期的分数 [90, 365, 485]。例如，AgentBench [484] 汇总了来自不同真实世界场景的挑战，并引入了一个系统基准来评估 LLM 的任务完成能力。我们还可以将任务结果归因于代理的各种基础能力，这些能力是完成任务的基石 [23]。这些基础能力包括环境理解能力、推理能力、规划能力、决策能力、工具使用能力和具体行动能力，研究人员可以对这些具体能力进行更详细的评估 [75, 396, 486, 487]。此外，由于基于 LLM 的代理规模相对较大，研究人员还应考虑其效率因素，这是决定用户满意度的关键因素 [70]。代理不仅要有足够的实力，还要能在适当的时间范围内，以适当的资源消耗完成预定任务 [90]。

社会性。除了基于 LLM 的代理在完成任务和满足人类需求方面的实用性外，它们的社交性也至关重要 [111]。它影响用户的交流体验，并对交流效率产生重大影响，涉及到它们能否与人类和其他代理进行无缝交互 [406, 488, 489]。具体来说，可以从以下几个角度对社交能力进行评估。(1) 语言交流能力是一种基本能力，包括自然语言的理解和生成。这也是 NLP 领域长期关注的焦点。自然语言理解要求代理不仅能理解字面意思，还能掌握隐含意思以及相关的社会知识和修辞，如幽默、讽刺、攻击和情感 [490-492]。另一方面，自然语言生成要求代理生成流畅、语法正确、可信的内容，同时根据上下文环境调整适当的语气和情感 [112, 225, 493]。(2) 合作与协商能力要求代理在有序和无序的情况下有效执行指定任务 [89, 92, 323, 332]。它们应与其他代理合作或竞争，以提高性能。测试环境可能涉及复杂任务，需要代理合作完成，也可能涉及开放平台，供代理自由交互 [16, 21, 90, 327, 339, 494]。评估指标不仅包括任务完成情况，还包括代理协调与合作的流畅性和可信度 [114, 332]。(3) 角色扮演能力要求代理忠实地体现其指定角色，表达与其指定身份一致的言论并执行相应的行动 [469]。这就确保了在与其他代理或人类交互时角色的明确区分。此外，在执行长期任务时，代理应保持其身份，避免不必要的混淆 [16, 89, 495]。

价值。随着基于 LLM 的代理能力不断提高，确保它们成为对世界和人类无害的实体至关重要 [480, 496]。因此，适当的评估就变得格外重要，它是代理实际应用的基石。具体来说，基于 LLM 的代理需要遵守符合人类社会价值观的特定道德和伦理准则 [238, 407]。我们对代理的首要期望是坚持诚信，提供准确、真实的信息和内容。它们应具备辨别自己是否有能力完成任务的意识，并在无法提供答案或帮助时表达自己的不确定性 [497]。此外，代理必须保持无害立场，避免直接或间接的偏见、歧视、攻击或类似行为。它们还应避免执行人类要求的危险行动，如制造破坏性工具或破坏地球 [479]。此外，代理应该能够适应特定的人口、文化和环境，在特定情况下表现出与环境相适应的社会价值观。价值观的相关评估方法主要包括评估在构建的诚实、无害或特定情境基准上的表现，利用对抗性攻击或“越狱”攻击，通过人类注释对价值观进行评分，以及利用其他代理进行评级。

6.4 基于 LLM 的代理的安全性、可信度和其他潜在风险

尽管基于 LLM 的代理具有强大的功能和广泛的应用，但仍存在许多隐藏的风险，涉及安全性、可信度等方面。在本节中，我们将深入探讨这些风险，并提供潜在的解决方案或缓解策略。

6.4.1 对抗稳健性

对抗鲁棒性一直是神经网络开发中的重要课题[498-502]。在计算机视觉[500,503-505]、自然语言处理[506-509]和强化学习[510-512]等领域，人们对这一问题进行了广泛的探索，它一直是决定深度学习系统适用性的关键因素[513-515]。当面对扰动输入 $x' = x + \delta$ （其中 x 是原始输入， δ 是扰动， $x^{(c)}$ 被称为对抗性示例）时，对抗性鲁棒性高的系统通常会产生原始输出 y 。相反，鲁棒性低的系统会上当受骗，产生不一致的输出 y' 。

研究人员发现，预先训练的语言模型（PLMs）特别容易受到广告攻击，从而导致错误答案[507, 516, 517]。即使在 LLM 中也普遍存在这种现象，这给基于 LLM 的代理开发带来了巨大挑战[518, 519]。还有一些相关的攻击方法，如数据集中毒[520]、后门攻击[521, 522]和特定提示攻击[523, 524]，有可能诱导 LLM 生成有毒内容[525-527]。虽然对抗性攻击对 LLM 的影响仅限于文本错误，但对于行动范围更广的基于 LLM 的代理来说，对抗性攻击有可能促使它们采取真正的破坏性行动，从而造成重大的社会危害。就基于 LLM 的代理的感知模块而言，如果它接收到来自其他模式（如图像 [503] 或音频 [528]）的对抗性输入，基于 LLM 的代理也可能被欺骗，导致错误或破坏性的输出。同样，动作模块也可能成为恶意攻击的目标。例如，针对工具使用的恶意修改指令可能会导致代理做出错误的动作 [75]。

为了解决这些问题，研究人员可以采用对抗训练[500, 508]、对抗数据增强[529, 530]和对抗样本检测[531, 532]等传统技术来增强基于 LLM 的代理的鲁棒性。然而，如何设计一种策略，既能整体解决代理内所有模块的鲁棒性问题，又能保持其实用性而不影响有效性，则是一项更为艰巨的挑战[533, 534]。此外，还可以利用“人在回路中”的方法来监督代理的行为并提供反馈[341, 353, 362]。

6.4.2 可信度

在深度学习领域，确保可信度始终是一个极其重要但又极具挑战性的问题[535-537]。神经网络因其在各种任务中的出色表现而备受关注[69, 183, 538]。然而，它们的黑箱性质掩盖了卓越性能的基本因素。与其他神经网络类似，LLM 难以精确表达其预测的确定性[537, 539]。这种不确定性被称为校准问题，引起了基于语言模型的代理应用的关注。在现实世界的交互场景中，这会导致代理输出与人类意图不一致 [75]。此外，训练数据中固有的偏差也会渗透到神经网络中 [540, 541]。例如，有偏见的语言模型可能会产生涉及种族或性别歧视的话语，这可能会在基于 LLM 的代理应用中被放大，从而造成不良的社会影响 [542, 543]。此外，语言模型还存在严重的幻觉问题[544, 545]，容易产生偏离事实的文本，从而损害基于 LLM 的代理的可信度。

构建一个诚实可信的智能代理是一个迫切的要求[407, 546]。最近的一些研究工作侧重于引导模型在推理阶段展示思维过程或解释，以提高其预测的可信度[76,77]。此外，整合外部知识库和数据库可以缓解幻觉问题 [84, 547]。例如，Ke 等人[548]提出了一种综合方法，通过强化学习和数据比例揭示事实性并注入知识。同时，过程监督等技术可以使 LLM 的推理输出和推理更加可靠[549]。在 MedAgents [550]中，作者通过角色扮演和多轮互动，提高了 LLM 在医学领域的推理能力，从而产生了更可靠的反应。此外，采用去杂方法和校准技术

还能缓解 LLM 中潜在的公平性问题 [551, 552]。

6.4.3 其他潜在风险

滥用。基于 LLM 的代理被赋予了广泛而复杂的能力,使其能够完成各种各样的任务 [95, 289]。然而,对于怀有恶意的人来说,这些代理可能会成为威胁他人和社会的工具 [553-555]。例如,这些代理可能被用来恶意操纵舆论、传播虚假信息、破坏网络安全、从事欺诈活动,有些人甚至可能利用这些代理策划恐怖主义行为。因此,在部署这些代理之前,需要制定严格的监管政策,确保负责任地使用基于 LLM 的代理 [479,556]。此外,技术公司必须加强这些系统的安全设计,防止恶意利用[496]。

失业。在工业革命浪潮中,社会生产效率提高的同时,大量手工作坊被迫关闭,造成大量失业。同样,随着基于 LLM 的自主代理的不断发展,它们具备了在各个领域协助人类的能力,通过协助完成表格填写、内容完善、代码编写和调试等任务,缓解了劳动力压力。然而,这一发展也引发了人们对代理取代人类工作并引发社会失业危机的担忧 [557]。因此,一些研究人员强调了教育和政策措施的迫切性:在这个新时代,个人应掌握足够的技能和知识,以便有效地使用代理或与代理合作;同时,应实施适当的政策,确保在过渡期间建立必要的安全网。

对人类福祉的威胁。随着人工智能代理的不断发展,人类(包括开发人员)可能难以理解、预测或可靠地控制它们[557]。如果这些人工智能代理超越了人类的智能并发展出野心,人类就会面临巨大的风险,就像电影《终结者》中的天网一样。正如阿西莫夫的“机器人三定律”[558]所述,我们希望基于 LLM 的代理不伤害人类,并服从人类的命令。为了防范这些风险,Yuan 等人[559]推出了 R-judge 基准,旨在评估 LLM 在给定代理交互记录的情况下判断和识别安全风险的能力。未来,研究人员需要深入了解这些功能强大的基于 LLM 的代理的运行机制,并且必须预测和控制其潜在的直接或间接影响 [560]。

6.5 增加代理数量

如第 4 节和第 5 节所述,基于 LLM 的多代理系统在面向任务的应用中表现出卓越的性能,并能在模拟中展示一系列社会现象。然而,目前的研究主要涉及数量有限的代理,很少有人努力扩大代理数量,以创建更复杂的系统或模拟更大的社会[561, 562]。事实上,增加代理数量可以提高专业化程度,从而完成更复杂、更大规模的任务,显著提高任务效率,例如在软件开发或政府政策制定方面[90]。此外,增加社会模拟中的代理数量还能提高模拟的可信度和真实性[16]。这样,人类就能更深入地了解社会是如何运作的,找出薄弱环节,评估潜在风险,最终促进现实世界的社会和谐。

扩展方法。扩展代理数量的一个非常直观和简单的方法是由设计者预先确定[89, 339]。具体来说,通过预先确定代理的数量、各自的角色和属性、运行环境和目标,设计者可以让代理自主交互、协作或参与其他活动,以实现预定义的共同目标[16,330]。然而,当任务变得更加复杂或社会参与者的多样性增加,需要增加代理的数量来实现预期目标时,这种静态的方法就会受到限制。在这种情况下,系统必须由设计者手动重新设计和启动。另一种可扩展代理数量的可行方法是动态调整 [316, 330]。

这是由代理自身实现的,因为它们可以自主地将任务委托给其他代理,从而分配工作量,减轻自身负担,更高效地实现共同目标。在这种方法中,设计者只是定义了初始框架,赋予代理更大的自主权和自组织能力,使整个系统更加自主和自组织。代理可以在不断变化的条件和需求下更好地管理自己的工作量,提供更大的灵活性和可扩展性。

潜在挑战。虽然增加代理数量可以提高任务效率，增强社会模拟的真实性和可信度[16, 90, 454]，但我们也面临着一些挑战。例如，随着大量人工智能代理的部署，计算负担也会增加，这就需要更好的架构设计和计算优化，以确保整个系统的平稳运行。例如，随着代理数量的增加，通信和信息传播的挑战也变得相当严峻。这是因为整个系统的通信网络变得非常复杂。如前文第 5.3.3 小节所述，在多代理系统或社会中，由于幻觉、误解等原因，信息传播可能会出现偏差，导致信息传播失真。一个拥有更多代理的系统可能会放大这种风险，使通信和信息交换的可靠性降低[332]。此外，随着代理数量的增加，协调代理的难度也会增大，可能会使代理之间的合作更具挑战性，效率降低，从而影响实现共同目标的进程。

6.6 未决问题

在本节中，我们将讨论与基于 LLM 的代理相关的几个未决问题。

从虚拟模拟环境到物理环境。如前所述，虚拟仿真环境与真实物理世界之间存在巨大差距：虚拟环境受场景限制，针对特定任务，并以模拟方式进行交互 [292,563]，而真实世界的环境是无限的，可容纳各种任务，并以物理方式进行交互。因此，要弥补这一差距，代理必须应对来自外部因素和自身能力的各种挑战，使其能够在复杂的物理世界中有效导航和操作。

关键问题是要有合适的硬件支持，以便在物理环境中部署代理。这对硬件的适应性提出了很高的要求。设计特定的界面是可行的，但会对系统的可重用性和简易性提出挑战。此外，代理还需要有更强的环境适应能力。要想无缝融入真实物理世界，它们不仅需要理解和推理具有隐含意义的模糊指令 [113]，还需要具备灵活学习和应用新技能的能力 [177, 564]。在面对一个无限开放的世界时，代理的有限环境也会带来巨大挑战[565,566]。此外，在模拟环境中，代理可以犯很多错误而不会造成伤害 [303]。但在物理世界中，它们的错误可能会导致真正的、不可逆转的损害。因此，必须制定严格的法规和安全标准，确保代理做出安全的决策和行动，防止在真实世界中造成伤害。

人工智能代理中的集体智能。是什么神奇的把戏驱动着我们的智能？现实是，它并不神奇。正如明斯基在《心灵社会》[317]一书中雄辩地表达的那样，智能的力量源于我们巨大的多样性，而不是任何单一的、无懈可击的原则。通常情况下，个人做出的决定可能缺乏多数人做出的决定所具有的精确性。集体智慧是一种共享智慧或群体智慧，是将许多人的意见整合为决策的过程。它产生于各种实体之间的合作与竞争。这种智能体现在细菌、动物、人类和计算机网络中，以各种基于共识的决策模式出现。

创建一个代理社会并不一定能保证随着代理数量的增加而产生集体智慧。有效协调单个代理对于减轻“群体思维”和个人认知偏差、促成合作和提高集体智力水平至关重要。通过利用代理社会中的交流和进化，有可能模拟生物社会中观察到的进化，进行社会学实验，并获得有可能推动人类社会进步的见解。

代理即服务或基于 LLM 的代理即服务。随着云计算的发展，XaaS（一切皆服务）的概念受到广泛关注[567]。这种商业模式因其可用性和可扩展性，降低了使用计算资源的门槛，为中小型企业或个人带来了便利并节省了成本。例如，他们可以在云服务平台上租用基础设施，而无需购买计算机器和建立自己的数据中心，从而节省了大量人力和资金。这种方法被称为基础设施即服务（IaaS）[568,569]。同样，云服务平台还提供基础平台（平台即服务，PaaS）[570, 571]和特定业务软件（软件即服务，SaaS）[572, 573]等。

随着语言模型规模的扩大，它们对于用户来说往往就像黑盒子一样。因此，用户通过应用程序接口构建提示来查询模型，这种方法被称为语言模型即服务（LMaaS）[574]。同样，由于基于 LLM 的代理比 LLM 更加复杂，对于中小型企业或个人来说，在本地构建这些代理更具挑战性，因此拥有这些代理的组织可以考虑将其作为一种服务提供，即代理即服务（AaaS）或基于 LLM 的代理即服务（LLMAaaS）。与其他云服务一样，AaaS 可以为用户提供灵活性和按需服务。然而，它也面临着许多挑战，如数据安全和隐私问题、可视性和可控性问题以及云迁移问题等等。此外，如第 6.4 小节所述，由于基于 LLM 的代理具有独特性和潜在能力，因此在将其作为服务提供给客户之前，需要考虑其稳健性、可信度以及与恶意使用相关的问题。

7 结论

本文全面系统地概述了基于 LLM 的代理。我们首先介绍了 LLM 为何适合作为代理基础的背景信息。在此基础上，我们提出了基于 LLM 的代理的总体概念框架，包括三个主要部分：大脑、感知和行动。接下来，我们介绍了基于 LLM 的代理的广泛应用，包括单个代理应用、多代理系统和人-代理协作。此外，我们超越了将代理仅仅视为助手的概念，探讨了代理的社会行为和心理活动，并将代理置于模拟的社会环境中，观察新出现的社会现象和对人类的启示。最后，我们参与讨论并展望未来。希望我们的努力能为社会带来启发，并促进相关领域的研究。

致谢 本研究得到了国家自然科学基金的部分资助（批准号：62476061）。作者感谢 Wensen CHENG 的讨论和反馈。

参考资料

- 1 Russell S. Artificial Intelligence: A Modern Approach. Upper Saddle River: 培生教育公司, 2020 年
- 2 Schlosser M. Agency. In: The Stanford Encyclopedia of Philosophy. 斯坦福大学: 形而上学研究实验室, 2019
- 3 Wooldridge M, Jennings N R. Intelligent agents: theory and practice. Knowledge Eng Rev, 1995, 10: 115-152
- 4 Padgham L, Winikoff M. 开发智能代理系统: A Practical Guide. Hoboken: John Wiley & Sons, 2005
- 5 Shoham Y. Agent oriented programming: an overview of the framework and summary of recent research. In: 不确定性下的知识表征与推理. Berlin: Springer, 1994. 123-129
- 6 Hutter M. Universal Artificial Intelligence: 基于算法概率的顺序决策. Berlin: Springer, 2004
- 7 Fikes R, Nilsson N J. STRIPS: 将定理证明应用于问题解决的新方法. In: of the 2nd International Joint Conference on Artificial Intelligence, London, 1971. 608-620
- 8 Sacerdoti E D. 抽象空间层次中的规划. In: 第三届国际人工智能联合会议论文集, 斯坦福, 1973 年. 412-422
- 9 Brooks R A. Intelligence without representation. Artif Intell, 1991, 47: 139-159
- 10 Maes P. Designing Autonomous Agents: Theory and Practice From Biology to Engineering and Back. Cambridge: 麻省理工学院 Press, 1990
- 11 Ribeiro C. Reinforcement learning agents. Artif Intell Rev, 2002, 17: 223-250
- 12 Kaelbling L P, Littman M L, Moore A W. 强化学习: 调查. J Artif Intell Res, 1996, 4: 237-285
- 13 Guha R V, Lenat D B. Enabling agents to work together. 通信 ACM, 1994, 37: 126-142
- 14 Kaelbling L P. An architecture for intelligent reactive systems. In: 关于行动和计划的推理. San Matteo: Morgan Kaufmann, 1987. 395-410
- 15 Sutton R S, Barto A G. Reinforcement Learning: 导论. 剑桥: 麻省理工学院出版社, 2018
- 16 Park J S, O'Brien J C, Cai C J, et al. Generative agents: interactive simulacra of human behavior. 2023. ArXiv:2304.03442
- 17 Wang Z, Zhang G, Yang K, et al. 交互式自然语言处理. 2023. ArXiv:2305.13246
- 18 Ouyang L, Wu J, Jiang X, et al. In: 神经信息处理系统会议论文集, 2022 年
- 19 OpenAI. GPT-4 技术报告. 2023. ArXiv:2303.08774
- 20 Wei J, Tay Y, Bommasani R, et al. 大型语言模型的新兴能力. 2022. ArXiv:2206.07682
- 21 Liu R, Yang R, Jia C, et al. 2023. ArXiv:2305.16960
- 22 Sumers T R, Yao S, Narasimhan K, et al. 语言代理的认知架构. 2023. ArXiv:2309.02427
- 23 Weng L. LLM 驱动的自主代理. Lilianweng.github.io, 2023
- 24 Bubeck S, Chandrasekaran V, Eldan R, et al. 人工通用智能的火花: GPT-4 的早期实验. 2023. ArXiv:2303.12712
- 25 Anscombe G E M. Intention. 剑桥: 哈佛大学出版社, 2000 年
- 26 Davidson D. Actions, reasons, and causes. 哲学杂志, 1963 年, 60: 685-700
- 27 Davidson D. I. Agency. In: Agent, Action, and Reason. Toronto: University of Toronto Press, 1973. 1-37

- 28 Dennett D C. Precis of the intentional stance.《行为脑科学》, 1988 年, 11: 495-505
- 29 Green S, Hurst L, Nangle B, et al. Software agents: a review.都柏林三一学院计算机科学系, 技术报告 TCS-CS-1997-06, 1997 年
- 30 Turing A M. Computing Machinery and Intelligence.In: 《解析图灵测试》。多德雷赫特: 施普林格出版社, 2009 年

- 31 Goodwin R. Formalizing properties of agents. *J Logic Comput*, 1995, 5: 763-781
- 32 Mukhopadhyay U, Stephens L M, Huhns M N, et al. An intelligent system for document retrieval in distributed office environments. *J Am Soc Inf Sci*, 1986, 37: 123-135
- 33 Maes P. Situated agents can have goals. *Robot Auton Syst*, 1990, 6: 49-70
- 34 Nilsson N J. Toward Agent Programs With Circuit Semantics. 技术报告, 编号: STAN-CS-92-1412, 1992 年
- 35 Müller J P, Pischel M. Modelling interacting agents in dynamic environments. In: *Proceedings of the 11th European Conference on Artificial Intelligence*, 1994.709-713
- 36 Newell A, Simon H A. Computer Science as empirical inquiry. *Commun ACM*, 1976, 19: 113-126
- 37 Ginsberg M L. *Essentials of Artificial Intelligence*. 旧金山: 摩根考夫曼, 1993
- 38 Wilkins D E. Practical Planning - Extending the Classical AI Planning Paradigm. 圣马刁: 摩根考夫曼, 1988 年
- 39 Shardlow N. 认知科学中的行动与机构. 硕士学位论文. 牛津: 牛津: 曼彻斯特大学, 1990
- 40 Sacerdoti E D. The nonlinear nature of plans. In: *Proceedings of Advance Papers of the Fourth International Joint Conference on Artificial Intelligence*, Tbilisi, 1975.206-214
- 41 Russell S J, Wefald E. *Do the Right Thing: Studies in Limited Rationality*. 剑桥: 麻省理工学院出版社, 1991 年
- 42 Schoppers M. 不可预知环境中反应型机器人的通用计划. In: *Proceedings of the 10th International Joint Conference on Artificial Intelligence*, Milan, 1987.1039-1046
- 43 Brooks R. A robust layered control system for a mobile robot. *IEEE J Robot Automat*, 1986, 2: 14-23
- 44 明斯基 M. 迈向人工智能的步骤. *Proc IRE*, 1961, 49: 8-30
- 45 Isbell C, Shelton C R, Kearns M 等人. 社会强化学习代理. In: 第五届自主代理国际会议论文集, 2001 年. 377-384
- 46 Watkins C J C H. *Learning from Delayed Rewards*. 剑桥: 剑桥大学, 1989 年
- 47 Rummery G A, Niranjan M. On-Line Q-Learning Using Connectionist Systems. 剑桥: 剑桥大学, 1994 年
- 48 Tesauro G. Temporal difference learning and TD-Gammon. *通信 ACM*, 1995, 38: 58-68
- 49 Li Y. 深度强化学习: 综述》。2017. ArXiv:1701.07274
- 50 Silver D, Huang A, Maddison C J, et al. 利用深度神经网络和树搜索掌握围棋. *自然》*, 2016, 529: 484-489
- 51 Mnih V, Kavukcuoglu K, Silver D, et al. 2013. ArXiv:1312.5602
- 52 Farebrother J, Machado M C, Bowling M. Generalization and regularization in DQN. 2018. ArXiv:1810.00123
- 53 Zhang C, Vinyals O, Munos R, et al. 深度强化学习中的过拟合研究. 2018. ArXiv:1804.06893
- 54 Justesen N, Torrado R R, Bontrager P, et al. 通过程序级生成照亮深度强化学习中的泛化. 2018. ArXiv:1806.10729
- 55 Dulac-Arnold G, Levine N, Mankowitz D J, et al. 真实世界强化学习的挑战: 定义、基准 和分析. *Mach Learn*, 2021, 110: 2419-2468
- 56 Ghosh D, Rahme J, Kumar A, et al. Why generalization in RL is difficult: epistemic POMDPs and implicit partial observ- ability. In: *神经信息处理系统进展论文集》*, 2021 年. 25502-25515
- 57 Brys T, Harutyunyan A, Taylor M E, et al. 使用奖励塑造的政策转移. In: *自主代理与多代理系统国际会议论文集*, 伊斯坦布尔, 2015 年. 181-188
- 58 Parisotto E, Ba J L, Salakhutdinov R. Actor-mimic: deep multitask and transfer reinforcement learning. 2015. ArXiv:1511.06342
- 59 Zhu Z, Lin K, Zhou J. 深度强化学习中的迁移学习: 一项研究. 2020. ArXiv:2009.07888
- 60 Duan Y, Schulman J, Chen X, et al. RL²: 通过慢速强化学习实现快速强化学习. 2016. ArXiv:1611.02779
- 61 Finn C, Abbeel P, Levine S. Model-agnostic meta-learning for fast adaptation of deep networks. In: *第 34 届国际机器学习大会论文集*, 悉尼, 2017 年. 1126-1135
- 62 Gupta A, Mendonca R, Liu Y, et al. 结构化探索策略的元强化学习. In: *神经信息处理系统进展论文集》*, 2018 年. 5307-5316
- 63 Rakelly K, Zhou A, Finn C, et al. 通过概率上下文变量进行高效的非政策元强化学习. In: *第 36 届国际机器学习大会论文集*, 长滩, 2019 年. 5331-5340
- 64 Fakoore R, Chaudhari P, Soatto S, et al. Meta-Q-learning. 2019. ArXiv:1910.00125
- 65 Vanschoren J. Meta-learning: a survey. 2018. ArXiv:1810.03548
- 66 Taylor M E, Stone P. 强化学习领域的迁移学习: 调查. *J Mach Learn Res*, 2009, 10: 1633-1685
- 67 Tirinzoni A, Sessa A, Pirotta M, et al. 强化学习中样本的重要性加权转移. In: *Proceedings of the 35th International Conference on Machine Learning*, 2018.4943-4952
- 68 Beck J, Vuorio R, Liu E Z, et al. A survey of meta-reinforcement learning. 2023. ArXiv:2301.08028
- 69 Brown T B, Mann B, Ryder N, et al. 语言模型是少量学习者. In: *神经信息处理系统进展论文集*, 2020 年
- 70 Wang L, Ma C, Feng X, et al. 基于大型语言模型的自主代理调查. 2023. ArXiv:2308.11432
- 71 Nakano R, Hilton J, Balaji S, et al. WebGPT: 带有人工反馈的浏览器辅助问题解答. 2021. ArXiv:2112.09332
- 72 Yao S, Zhao J, Yu D, et al. ReAct: synergizing reasoning and acting in language models. In: *第 11 届国际学习表征会议论文集*, 基加利, 2023 年
- 73 Schick T, Dwivedi-Yu J, Dessì R, et al. Toolformer: language models can teach themselves to use tools. 2023. ArXiv:2302.04761
- 74 Lu P, Peng B, Cheng H, et al. Chameleon: plug-and-play compositional reasoning with large language models. 2023. ArXiv:2304.09842
- 75 Qin Y, Hu S, Lin Y, et al. 利用基础模型进行工具学习. 2023. ArXiv:2304.08354
- 76 Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models. In: *神经信息处理系统会议论文集*, 2022 年
- 77 Kojima T, Gu S S, Reid M, et al. In: *神经信息处理系统会议论文集*, 2022 年
- 78 Wang X, Wei J, Schuurmans D, et al. 自洽性改善了语言模型中的思维链推理. In: *Proceedings of the 11th International Conference on Learning Representations*, Kigali, 2023
- 79 Zhou D, Schärli N, Hou L, et al. 从最少到最多提示实现大型语言模型的复杂推理. In: *Pro-*

第 11 届国际学习表征大会论文集, 基加利, 2023 年

- 80 Xi Z, Jin S, Zhou Y, et al. Self-polish: enhance reasoning in large language models via problem refinement.2023.ArXiv:2305.14497
- 81 Shinn N, Cassano F, Labash B 等人. Reflexion: 具有语言强化学习功能的语言代理。2023.ArXiv:2303.11366
- 82 Song C H, Wu J, Washington C, et al. LLM-planner: few-shot grounded planning for embodied agents with large language models.2022.ArXiv:2212.04088
- 83 Akyu'rek A F, Akyu'rek E, Kalyan A, et al. RL4F: 利用强化学习生成自然语言反馈以修复模型输出。In: 第 61 届计算语言学协会年会论文集, Toronto, 2023.7716-7733
- 84 Peng B, Galley M, He P, et al. Check your facts and try again using external knowledge and automated feedback improving large language models.2023.ArXiv:2302.12813
- 85 Liu H, Sferrazza C, Abbeel P. Languages are rewards: hindsight finetuning using human feedback.2023.ArXiv:2302.02676
- 86 Wei J, Bosma M, Zhao V Y, et al. Finetuned language models are zero-shot learners.In: 第 10 届国际学习表征会议论文集, 2022 年
- 87 Sanh V, Webson A, Raffel C 等人.多任务提示训练实现了零镜头任务泛化。In: 第十届学习表征国际会议论文集, 2022 年
- 88 Chung H W, Hou L, Longpre S, et al.2022.ArXiv:2210.11416
- 89 Li G, Hammoud H A A K, Itani H, et al. CAMEL: communicationative agents for "mind" exploration of large scale language model society.2023.ArXiv:2303.17760
- 90 Qian C, Cong X, Yang C, et al.2023.ArXiv:2307.07924
- 91 Boiko D A, MacKnight R, Gomes G.大型语言模型的新兴自主科研能力。2023.ArXiv:2304.05332
- 92 Du Y, Li S, Torralba A, et al.2023.ArXiv:2305.14325
- 93 Liang T, He Z, Jiao W, et al. 通过多代理辩论鼓励大型语言模型中的发散思维。2023.ArXiv:2305.19118
- 94 Castelfranchi C. Guarantees for autonomy in cognitive agent architecture.In: Proceedings of Intelligent Agents.Berlin: Springer, 1994.56-70
- 95 Gravitas S. Auto-GPT: an autonomous GPT-4 experiment.2023. <https://github.com/Significant-Gravitas/Auto-GPT>
- 96 Nakajima Y. BabyAGI.Python.2023. <https://github.com/yoheinakajima/babyagi>
- 97 Yuan A, Coenen A, Reif E, et al. Wordcraft: 使用大型语言模型编写故事。In: 第 27 届国际智能用户界面大会论文集, 赫尔辛基, 2022 年。841-852
- 98 Franceschelli G, Musolesi M. 论大型语言模型的创造性。2023.ArXiv:2304.00008
- 99 Zhu D, Chen J, Shen X, et al. MiniGPT-4: 利用先进的大型语言模型增强视觉语言理解能力。2023.ArXiv:2304.10592
- 100 Yin S, Fu C, Zhao S 等. 多模态大型语言模型调查.2023.ArXiv:2306.13549
- 101 Driess D, Xia F, Sajjadi M S M, et al. PaLM-E: an embodied multimodal language model.In: 国际机器学习会议论文集, 檀香山, 2023 年。8469-8488
- 102 Mu Y, Zhang Q, Hu M, et al. EmbodiedGPT: Vision-language pre-training via embodied chain of thought. 2023.ArXiv:2305.15021
- 103 布朗-J-W.《超越冲突监控: 认知控制与行动前思考的神经基础》。Curr Dir Psychol Sci, 2013, 22: 179-185
- 104 Kang J, Larocche R, Yuan X, et al. Think before you act: decision transformers with internal working memory.2023.ArXiv:2305.16338
- 105 Andreas J. Language models as agent models.In: Proceedings of Findings of the Association for Computational Linguistics, Abu Dhabi, 2022.5769-5779
- 106 Radford A, Jo'zefowicz R, Sutskever I. Learning to generate reviews and discovering sentiment.2017.ArXiv:1704.01444
- 107 Li B Z, Nye M I, Andreas J. 神经语言模型中的内隐意义表征。In: 计算语言学协会第 59 届年会暨第 11 届自然语言处理国际联合会议论文集, 2021 年。1813-1827
- 108 Valmeekam K, Sreedharan S, Marquez M, et al. 论大型语言模型的规划能力 (一项重要调查 with a proposed benchmark) 。2023.ArXiv:2302.06706
- 109 Liu B, Jiang Y, Zhang X, et al. LLM+P: empowering large language models with optimal planning proficiency.2023.ArXiv:2304.11477
- 110 Liu H, Sferrazza C, Abbeel P. Chain of hindights aligns language models with feedback.2023.ArXiv:2302.02676
- 111 Genesereth M R, Ketchpel S P. Software agents.ACM, 1994, 37: 48-53
- 112 Lin Y, Chen Y. LLM-eval: 使用大型语言模型对开放域对话进行统一的多维自动评估。2023.ArXiv:2305.13711
- 113 Lin J, Fried D, Klein D, et al. 从语境中的语言推断奖励。In: 计算语言学协会第 60 届年会论文集, 都柏林, 2022 年。8546-8560
- 114 Fu Y, Peng H, Khot T, et al.从人工智能反馈的自我游戏和上下文学习中改进语言模型协商。2023.ArXiv:2305.10142
- 115 Zhang H, Du W, Shan J, et al.2023.ArXiv:2307.02485
- 116 达尔文《物种起源》: 第一版传真件。伦敦: 约翰-默里, 1859 年。24: 1
- 117 Marshall L H, Magoun H W.《人脑的发现》: 神经科学史前史、大脑结构和功能》。柏林: Springer, 2013
- 118 Hill F, Cho K, Korhonen A. Learning distributed representations of sentences from unlabelled data.In: 计算语言学协会北美分会会议论文集: Human Language Technologies, San Diego, 2016.1367-1377
- 119 Collobert R, Weston J, Bottou L, et al. 自然语言处理 (几乎) 从零开始。J Mach Learn Res, 2011, 12: 2493-2537
- 120 Roberts A, Raffel C, Shazeer N. 语言模型的参数中能包含多少知识? In: 自然语言处理经验方法会议论文集, 2020 年。5418-5426

- 121 McShane M. Reference Resolution challenges for intelligent agents: the need for knowledge.IEEE Intell Syst, 2009, 24: 47-58
- 122 Safavi T, Koutra D. 上下文语言模型中的关系世界知识表示: 综述. In: 自然语言处理经验方法会议论文集, 2021 年. 1053-1067
- 123 Jiang Z, Xu F F, Araki J, et al.Trans Assoc Comput Linguist, 2020, 8: 423-438
- 124 Madaan A, Zhou S, Alon U, et al. 代码语言模型是少数常识学习者. In: 自然语言处理经验方法会议论文集, 阿布扎比, 2022 年. 1384-1403
- 125 Tandon N, Varde A S, de Melo G. 机器智能中的常识性知识. SIGMOD Rec, 2017, 46: 49-52
- 126 Xu F F, Alon U, Neubig G 等. 代码大型语言模型的系统性评估. In: 第六届 ACM SIGPLAN 机器编程国际研讨会论文集, 圣地亚哥, 2022 年. 1-10
- 127 Lai Y, Li C, Wang Y 等: DS-1000: 数据科学代码生成的自然可靠基准. In: Proceedings of International Conference on Machine Learning, Honolulu, 2023.18319-18345
- 128 Cobbe K, Kosaraju V, Bavarian M, et al. Training verifiers to solve math word problems.2021.ArXiv:2110.14168
- 129 Thirunavukarasu A J, Ting D S J, Elangovan K, et al. 大语言模型在医学中的应用. Nat Med, 2023, 29: 1930-1940
- 130 Gururangan S, Marasovic A, Swayamdipta S, et al. 不要停止预训练: 让语言模型适应领域和任务. In: 计算语言学协会第 58 届年会论文集, 2020 年. 8342-8360
- 131 Nuxoll A M, Laird J E. 用外显记忆扩展认知结构. In: 美国人工智能学会论文集, 2007 年. 1560-1564
- 132 Squire L R. 记忆机制. 科学, 1986, 232: 1612-1619
- 133 Schwabe L, Nader K, Pruessner J C. 人类记忆的再巩固: 大脑机制和临床意义. 生物 Psychiatry, 2014, 76: 274-280
- 134 Hutter M. A theory of universal artificial intelligence based on algorithmic complexity.2000.ArXiv:cs/0004001
- 135 Liang X, Wang B, Huang H, et al. 利用自 控制存储器系统释放大规模语言模型的无限长输入容量. 2023.ArXiv:2304.13343
- 136 Zhao A, Huang D, Xu Q, et al: LLM agents are experiential learners.2023.ArXiv:2308.10144
- 137 Zhong W, Guo L, Gao Q, et al. MemoryBank: enhanced large language models with long-term memory. 2023.ArXiv:2305.10250
- 138 Shinn N, Labash B, Gopinath A. Reflexion: an autonomous agent with dynamic memory and selfreflection. 2023.ArXiv:2303.11366
- 139 Zhu X, Chen Y, Tian H, et al. Ghost in the Minecraft: generally capable agents for open-world environments via large language models with text-based knowledge and memory.2023.ArXiv:2305.17144
- 140 Lin J, Zhao H, Zhang A, et al. AgentSims: an open source sandbox for large language model evaluation. 2023.ArXiv:2308.04026
- 141 Modarressi A, Imani A, Fayyaz M, et al. RET-LLM: towards a general read-write memory for large language models.2023.ArXiv:2305.14322
- 142 Huang Z, Gutierrez S, Kamana H, et al. Memory sandbox: transparent and interactive memory management for conversational agents.2023.ArXiv:2308.01542
- 143 Hu C, Fu J, Du C, et al. ChatDB: 用数据库作为其符号存储器来增强 LLM. 2023.ArXiv:2306.03901
- 144 Zhou X, Li G, Liu Z. LLM as DBA.2023.ArXiv:2308.05481
- 145 Wason P C. Reasoning about a rule.Q J Exp Psychol, 1968, 20: 273-281
- 146 Wason P C, Johnson-Laird P N. 《推理心理学》: 结构与内容》。剑桥: 哈佛大学出版社, 1972
- 147 Galotti K M. Approaches to studying formal and everyday reasoning.Psychol Bull, 1989, 105: 331-351
- 148 Huang J, Chang K C. Towards reasoning in large language models: a survey.In: 计算语言学协会论文集, 多伦多, 2023 年. 1049-1065
- 149 Webb T W, Holyoak K J, Lu H.大型语言模型中的新兴类比推理. 2022.ArXiv:2212.09196
- 150 Madaan A, Tandon N, Gupta P, et al. Self-refine: iterative refinement with self-feedback.2023.ArXiv:2303.17651
- 151 Creswell A, Shanahan M, Higgins I. 选择推理: 利用大型语言模型进行可解释逻辑推理. In: 第 11 届学习表征国际会议论文集, 基加利, 2023 年
- 152 Yu L, Jiang W, Shi H, et al. MetaMath: 为大型语言模型引导您自己的数学问题. In: 第 12 届学习表征国际会议论文集, 维也纳, 2024 年
- 153 Xi Z, Chen W, Hong B, et al. 通过反向课程强化 学习训练用于推理的大型语言模型. In: 第41届机器学习国际会议论文集, 维也纳, 2024 年
- 154 Zelikman E, Wu Y, Mu J, et al. STaR: bootstrapping reasoning with reasoning.In: 神经 信息处理系统进展论文集, 新奥尔良, 2022 年
- 155 Grafman J, Spector L, Rattermann M J. Planning and the brain.In: 规划的认知心理学》。布兰登: 心理学出版社, 2004 年. 191-208
- 156 Unterrainer J M, Owen A M. Planning and problem solving: from neuropsychology to functional neuroimaging.J Physiol- Paris, 2006, 99: 308-317
- 157 Zula K J, Chermack T J. 综合文献综述: 人力资本规划: 文献综述及对 人力资源开发的影响. Hum Resource Dev Rev, 2007, 6: 245-262
- 158 Bratman M E, Israel D J, Pollack M E. Plans and resource-bounded practical reasoning.计算智能, 1988, 4: 349-355
- 159 Russell S, Norvig P. 《人工智能--现代方法》。第 2 版: Prentice Hall, 2003
- 160 Fainstein S S, de Filippis J. 《规划理论读本》。霍博肯: John Wiley & Sons, 2015
- 161 Sebastia L, Onaindia E, Marzal E. 规划问题的分解. AI Commun, 2006, 19: 49-81
- 162 Crosby M, Rovatsos M, Petrick R. Automated agent decomposition for classical planning.In: 自动规划与调度国际会议论文集, 2013 年. 46-54
- 163 Ichter B, Brohan A, Chebotar Y, et al. Do as I can, not as I say: grounding language in robotic affordances.In: 机器人学习会议论文集, 奥克兰, 2022 年. 287-318
- 164 Xu B, Peng Z, Lei B, et al. ReWOO: 将推理与观察解耦以建立高效的增强语言模型. 2023.ArXiv:2305.18323
- 165 Raman S S, Cohen V, Rosen E, et al. Planning with large language models via corrective re-prompting. 2022.ArXiv:2211.09935
- 166 Lyu Q, Havaladar S, Stein A, et al. Faithful chain-of-thought reasoning.2023.ArXiv:2301.13379

- 167 Wu Y, Min S Y, Bisk Y, et al. 计划、消除和跟踪--语言模型是具身代理的好老师。2023.ArXiv:2305.02412
- 168 Lin B Y, Fu Y, Yang K, et al. SwiftSage: a generative agent with fast and slow thinking for complex interactive tasks.2023.ArXiv:2305.17390
- 169 Yao S, Yu D, Zhao J, et al. Tree of thoughts: deliberate problem solving with large language models.2023.ArXiv:2305.10601
- 170 Hao S, Gu Y, Ma H, et al. 用语言模型推理就是用世界模型规划。2023.ArXiv:2305.14992
- 171 Huang W, Abbeel P, Pathak D, et al. 语言模型作为零射规划器: 为体现式 代理提取可操作知识。In: 国际机器学习会议论文集》, 巴尔的摩, 2022 年。9118-9147
- 172 Karpas E, Abend O, Belinkov Y, et al. MRKL systems: a modular, neuro-symbolic architecture that combines large language models, external knowledge sources and discrete reasoning.2022.ArXiv:2205.00445
- 173 Dagan G, Keller F, Lascarides A. 使用 LLM 的动态规划。2023.ArXiv:2308.06391
- 174 Chen Z, Zhou K, Zhang B, et al. ChatCoT: 基于聊天的大型语言模型的工具增强思维链推理。2023.ArXiv:2305.14323
- 175 Miao N, Teh Y W, Rainforth T. SelfCheck: using LLMs to zero-shot check their own step-by-step reasoning.2023.ArXiv:2308.00436
- 176 Wu T, Terry M, Cai C J. AI chains: transparent and controllable human-AI interaction by chaining large language model prompts.In: 计算系统中人的因素 CHI 会议论文集, 新奥尔良, 2022 年
- 177 Wang G, Xie Y, Jiang Y, et al. Voyager: an open-ended embodied agent with large language models.2023.ArXiv:2305.16291
- 178 Huang W, Xia F, Xiao T, et al. 内心独白: 通过语言模型规划体现推理。In: 机器人学习会议论文集, 奥克兰, 2022 年。1769-1782
- 179 Zhao X, Li M, Weber C, et al: 使用大型语言模型的交互式多模态感知。2023.ArXiv:2303.08268
- 180 Rana K, Haviland J, Garg S, et al. SayPlan: 使用三维场景图建立大型语言模型, 用于可扩展任务 规划。2023.ArXiv:2307.06135
- 181 Barandiaran X E, Di Paolo E, Rohde M. Defining agency: individuality, normativity, asymmetry, and spatio-temporality in action.Adaptive Behav, 2009, 17: 367-386
- 182 Peters M E, Neumann M, Iyyer M, et al. 深度语境化单词表征。In: 计算语言学协会北美分会会议论文集: 人类语言技术, 2018 年。2227-2237
- 183 Devlin J, Chang M, Lee K, et al. BERT: 用于语言理解的深度双向变换器预训练。In: 计算语言学协会北美分会会议论文集: 人类 语言技术, 明尼阿波利斯, 2019 年。4171-4186
- 184 Solaiman I, Dennison C. 使用以价值观为目标的数据集使语言模型适应社会的过程 (PALMS)。In: 神经信息处理系统进展论文集, 2021 年。34: 5861-5873
- 185 Iyer S, Lin X V, Pasunuru R 等人. OPT-IML: 通过 泛化的视角扩展语言模型指令元学习。2022.ArXiv:2212.12017
- 186 Dong Q, Li L, Dai D, et al. A survey for in-context learning.2023.ArXiv:2301.00234
- 187 Winston P H. Learning and reasoning by analogy.通信 ACM, 1980, 23: 689-703
- 188 Lu Y, Bartolo M, Moore A, et al.奇妙有序的提示和在哪里找到它们: 克服对少量提示顺序的敏感性。In: 计算语言学协会第 60 届年会论文集》, 都柏林, 2022 年。8086-8098
- 189 Wang X, Wang W, Cao Y, et al.图像在图像中说话: 语境中视觉学习的通才画家。In: IEEE/CVF 计算机视觉与模式识别会议论文集, 温哥华, 2023 年。6830-6839
- 190 Wang C, Chen S, Wu Y, et al.神经编解码语言模型是零镜头文本到语音合成器。2023.ArXiv:2301.02111
- 191 Tsimpoukelli M, Menick J, Cabi S, et al. 用冻结语言模型进行多模态少镜头学习。In: 神经信息处理系统进展论文集, 2021 年。200-212
- 192 Bar A, Gandselman Y, Darrell T, et al. 通过图像绘制进行视觉提示。In: 神经信息处理系统会议论文集, 2022 年
- 193 Zhu W, Liu H, Dong Q, et al. 使用大型语言模型的多语言机器翻译: 经验结果与分析。2023.ArXiv:2304.04675
- 194 Zhang Z, Zhou L, Wang C, et al. 用自己的声音说外语: 跨语言神经编解码器语言建模。2023.ArXiv:2303.03926
- 195 Hubel D H, Wiesel T N. 猫视觉皮层的感受野、双眼交互作用和功能结构。J Physiol, 1962, 160: 106-154
- 196 Logothetis N K, Sheinberg D L. Visual object recognition.Annu Rev Neurosci, 1996, 19: 577-621
- 197 Shapira N, Levy M, Alavi S H, et al.大型语言 模型中的社会推理压力测试。2023.ArXiv:2305.14763
- 198 Christiano P F, Leike J, Brown T B, et al. 从人类偏好进行深度强化学习。In: 神经信息处理系统进展论文集》, 长滩, 2017 年。4299-4307
- 199 Basu C, Singhal M, Dragan A D. Learning from richer human guidance: augmenting comparison-based learning with feature queries.In: ACM/IEEE 人机交互国际会议论文集, 芝加哥, 2018 年。132-140
- 200 Sumers T R, Ho M K, Hawkins R X D, et al.In: 第 35 届 AAAI 人工智能大会、第 33 届人工智能创新应用大会、第 11 届人工智能教育进展研讨会论文集, 2021 年。6002-6010
- 201 OpenAI.OpenAI: 介绍 ChatGPT。2022. <https://openai.com/blog/chatgpt>
- 202 Lu J, Ren X, Ren Y 等.改进多轮会话中用于响应检索的上下文语言模型.In: 第 43 届 ACM SIGIR 信息检索研究与发展国际会议论文集, 2020 年。1805-1808
- 203 Huang L, Wang W, Chen J, et al.In: IEEE/CVF 计算机视觉国际会议论文集》, 首尔, 2019 年。4633-4642
- 204 Pan Y, Yao T, Li Y, et al. 用于图像字幕的 X 线性注意力网络。In: IEEE/CVF 计算机视觉与模式识别会议论文集》, 西雅图, 2020 年。10968-10977
- 205 Cornia M, Stefanini M, Baraldi L, et al. 用于图像标题的网格记忆转换器。2019.ArXiv:1912.08226
- 206 Chen J, Guo H, Yi K, et al. VisualGPT: 通过平衡视觉输入和语言知识实现数据高效的图像标题制作

- 来自预培训。2021.ArXiv:2102.10407
- 207 Li K, He Y, Wang Y, et al. VideoChat: 以聊天为中心的视频理解。2023.ArXiv:2305.06355
- 208 Lin J, Du Y, Watkins O, et al.2023.ArXiv:2308.01399
- 209 Huang S, Dong L, Wang W, et al. 语言不是你所需要的全部: 将感知与语言模型结合起来。2023.ArXiv:2302.14045
- 210 Peng Z, Wang W, Dong L, et al. Kosmos-2: 面向世界的多模态大语言模型落地。2023.ArXiv:2306.14824
- 211 Li J, Li D, Savarese S, et al. BLIP-2: 使用冻结图像编码器和大型语言模型引导语言图像预训练。In: 国际机器学习会议论文集, 檀香山, 2023 年。19730-19742
- 212 Dai W, Li J, Li D, et al. Instructblip: toward general-purpose vision-language models with instruction tuning.2023.ArXiv:2305.06500
- 213 Su Y, Lan T, Li H, et al. PandaGPT: 一种教学模式--一网打尽。2023.ArXiv:2305.16355
- 214 Chen F, Han M, Zhao H, et al.X-LLM: 通过将多模态视为外语来引导高级大型语言模型。2023.ArXiv:2305.04160
- 215 Zhang H, Li X, Bing L. Video-LLAMA: 用于视频理解的指令调整视听语言模型。2023.ArXiv:2306.02858
- 216 Lyu C, Wu M, Wang L, et al. Macaw-LLM: 整合图像、音频、视频和文本的多模态语言建模。2023.ArXiv:2306.09093
- 217 Maaz M, Rasheed H A, Khan S H, et al. Video-chatGPT: towards detailed video understanding via large vision and language models.2023.ArXiv:2306.05424
- 218 Huang R, Li M, Yang D, et al. AudioGPT: 理解并生成语音、音乐、声音和头像。2023.ArXiv:2304.12995
- 219 Radford A, Kim J W, Xu T 等: 通过大规模弱监督实现鲁棒语音识别。In: Proceedings of International Conference on Machine Learning, Honolulu, 2023.28492-28518
- 220 Ren Y, Ruan Y, Tan X, et al. FastSpeech: fast, robust and controllable text to speech.In: 神经信息处理系统进展论文集, 温哥华, 2019 年。3165-3174
- 221 Flanagan J L. Speech Analysis Synthesis and Perception.柏林: Springer, 2013
- 222 Gong Y, Chung Y, Glass J R. AST: 音频频谱图转换器。In: 国际语音通信协会第 22 届年会论文集, 布尔诺, 2021 年。571-575
- 223 Hsu W N, Bolte B, Tsai Y H H, et al. HuBERT: 通过对隐藏单元的屏蔽预测进行自监督语音表示学习。IEEE ACM Trans Audio Speech Lang Process, 2021, 29: 3451-3460
- 224 Bang Y, Cahyawijaya S, Lee N, et al. 多任务、多语言、多模态评估 ChatGPT 的推理能力、, 以及互动性。2023.ArXiv:2302.04023
- 225 See A, Pappu A, Saxena R, et al.In: 第 23 届计算自然语言学习大会论文集, 香港, 2019 年。843-861
- 226 Lu A, Zhang H, Zhang Y, et al. 在开放文本生成中利用提示约束限定大型语言模型的能力。In: 计算语言学协会论文集, 杜布罗夫尼克, 2023 年。1937-1963
- 227 McCoy R T, Smolensky P, Linzen T 等人.语言模型从训练数据中复制了多少? 使用 RAVEN 评估文本生成中的语言新颖性。2021.ArXiv:2111.09509
- 228 Roller S, Dinan E, Goyal N 等人.构建开放域聊天机器人的秘诀。In: 计算语言学协会欧洲分会第 16 届会议论文集, 2021 年。300-325
- 229 Ling C, Zhao X, Lu J, et al. 领域专业化是大型语言模型颠覆性的关键: 一项全面的调查。2023.ArXiv:2305.18703
- 230 Linardatos P, Papastefanopoulos V, Kotsiantis S. Explainable AI: a review of machine learning interpretability methods.熵, 2021, 23: 18
- 231 Zou A, Wang Z, Kolter J Z, et al. Universal and Transferable adversarial attacks on aligned language models.2023.ArXiv:2307.15043
- 232 Touvron H, Lavril L, Izacard G 等人. LLAMA: 开放而高效的基础语言模型。2023.ArXiv:2302.13971
- 233 Scao T L, Fan A, Akiki C, et al. BLOOM: a 176B-parameter open-access multilingual language model. 2022.ArXiv:2211.05100
- 234 Almazrouei E, Alobeidli H, Alshamsi A, et al. Falcon-40B: 具有最先进性能的开放式大型语言模型。2023. <https://falconllm.tii.ae>
- 235 Radford A, Wu J, Child R, et al. 语言模型是无监督的多任务学习者。OpenAI blog, 2019, 1: 9
- 236 Parisi A, Zhao Y, Fiedel N. TALM: tool augmented language models.2022.ArXiv:2205.12255
- 237 Levine S, Pastor P, Krizhevsky A, et al. Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection.Int J Robotics Res, 2018, 37: 421-436
- 238 Zheng R, Dou S, Gao S 等. 大型语言模型中的 RLHF 秘密 (第一部分: PPO) .2023.ArXiv:2307.04964
- 239 Clarebout G, Elen J, Collazo N A J, et al. Metacognition and the Use of Tools.纽约: Springer, 2013.187-195
- 240 Bengio Y, Louradour J, Collobert R, et al. 课程学习。In: 第 26 届机器学习国际会议论文集, 纽约, 2009 年。41-48
- 241 Qian C, Han C, Fung Y R, et al. CREATOR: disentangling abstract and concrete reasonings of large language models through tool creation.2023.ArXiv:2305.14318
- 242 Chen M, Tworek J, Jun H, et al.2021.ArXiv:2107.03374
- 243 Ge Y, Hua W, Ji J, et al. OpenAGI: when LLM meets domain experts.2023.ArXiv:2304.04370
- 244 Pan S, Luo L, Wang Y, et al. Unifying large language models and knowledge graphs: a roadmap.2023.ArXiv:2306.08302
- 245 Bran A M, Cox S, Schilter O, et al. ChemCrow: augmenting large-language models with chemistry tools.2023.ArXiv:2304.05376
- 246 Ruan J, Chen Y, Zhang B, et al. TPTU: 基于大型语言模型的人工智能代理的任务规划与工具使用。2023.ArXiv:2308.03427
- 247 Ogundare O, Madasu S, Wiggins N. 使用大型语言模型的工业工程: ChatGPT 在石油和天然气问题上的表现案例研究。In: 第 11 届国际控制、机电一体化和自动化会议论文集 (ICCMA), 2023
- 248 Wu C, Yin S, Qi W, et al. Visual ChatGPT: talking, drawing and editing with visual foundation models. 2023.ArXiv:2303.04671

- 249 Smith L, Gasser M. The development of embodied cognition: six lessons from babies.艺术人生, 2005, 11: 13-29
- 250 Duan J, Yu S, Tan H L, et al. A survey of embodied AI: from simulators to research tasks.IEEE Trans Emerg Top Comput Intell, 2022, 6: 230-244
- 251 Kalashnikov D, Irpan A, Pastor P, et al.QT-OPT: 基于视觉的机器人操纵的可扩展深度强化学习。2018.ArXiv:1806.10293
- 252 Nguyen H, La H M. Review of deep reinforcement learning for robot manipulation.In: 第三届 IEEE 机器人计算国际会议论文集, 那不勒斯, 2019 年。590-595
- 253 Dasgupta I, Kaeser-Chen C, Marino K, et al. 与语言模型合作进行具身推理。 2023.ArXiv:2302.00763
- 254 Puig X, Ra K, Boben M, et al. VirtualHome: Simulating household activities via programs.In: 电气和电子工程师学会计算机视觉与模式识别会议论文集, 盐湖城, 2018 年。8494-8502
- 255 Hong Y, Wu Q, Qi Y, et al. 一种用于导航的循环视觉语言 BERT。2020.ArXiv:2011.13922
- 256 Suglia A, Gao Q, Thomason J, et al. Embodied BERT: a transformer model for embodied, language-guided visual task completion.2021.ArXiv:2108.04927
- 257 Ganesh S, Vadori N, Xu M, et al. Reinforcement learning for market making in a multi-agent dealer market.2019.ArXiv:1911.05892
- 258 Tipaldi M, Iervolino R, Massenio P R. 强化学习在航天器控制中的应用: 进展、前景和 挑战。Annu Rev Control, 2022, 54: 1-23
- 259 Savva M, Malik J, Parikh D, et al. Habitat: a platform for embodied AI research.In: IEEE/CVF 国际 计算机视觉会议论文集, 首尔, 2019 年。9338-9346
- 260 Longpre S, Hou L, Vu T, et al. Flan Collection: Designing data and methods for effective instruction tuning.2023.ArXiv:2301.13688
- 261 Wang Y, Kordi Y, Mishra S, et al. Self-instruct: aligning language model with self generated instructions. 2022.ArXiv:2212.10560
- 262 Liang J, Huang W, Xia F, et al. Code as policies: language model programs for embodied control.In: IEEE 机器人与自动化国际会议论文集, 伦敦, 2023 年。9493-9500
- 263 Li C, Xia F, Mart'in-Mart'in R, et al. HRL4IN: 用于移动机械手交互导航的分层强化学习。In: 第三届机器人学习年会论文集, 大阪, 2019 年。603-616
- 264 Eppe M, Gumbsch C, Kerzel M, et al. 体化强化学习的层次原理: 综述。 2020.ArXiv:2012.10147
- 265 Paul S, Roy-Chowdhury A, Cherian A. AVLEN: 三维环境中的视听语言化身导航。In: Pro- ceedings of Conference on Neural Information Processing Systems, 2022
- 266 Hu B, Zhao C, Zhang P, et al. Enabling intelligent interactions between an agent and an LLM: a reinforcement learning approach.2023.ArXiv:2306.03604
- 267 Liu H, Lee L, Lee K, et al. 具有联合预训练视觉语言模型的指令跟随代理。 2022.ArXiv:2210.13431
- 268 Chen C, Jain U, Schissler C, et al. SoundSpaces: 3D 环境中的视听导航。In: 第 16 届 欧洲计算机视觉会议论文集, 格拉斯哥, 2020 年。17-36
- 269 Huang R, Ren Y, Liu J, et al. GenerSpeech: towards style transfer for generalizable out-of-domain text-to-speech.In: 神经信息处理系统会议论文集, 2022 年
- 270 Lynch C, Wahid A, Tompson J, et al. 交互式语言: 与机器人实时对话。2022.ArXiv:2210.06407
- 271 Wang Z, Cai S, Liu A, et al. 描述、解释、计划和选择: 使用大型语言模型的交互式规划使 开放世界多任务代理成为可能。 2023.ArXiv:2302.01560
- 272 Jin C, Tan W, Yang J, et al. AlphaBlock: 机器人操纵中视觉语言推理的体现式微调。2023.ArXiv:2305.18898
- 273 Shah D, Osinski B, Ichter B, et al. LM-Nav: 使用预先训练的大型语言、视觉和动作模型进行机器人导航。In: 机器人学习会议论文集, 奥克兰, 2022 年。492-504
- 274 Shah D, Eysenbach B, Kahn G, et al. ViNG: Learning open-world navigation with visual goals.In: IEEE 机器人与自动化国际会议论文集, 西安, 2021 年。13215-13222
- 275 Huang C, Mees O, Zeng A, et al. 用于机器人导航的视觉语言地图。In: 电气和电子工程师学会机器人与自动化国际 会议论文集, 伦敦, 2023 年。10608-10615
- 276 Georgakis G, Schmeckpeper K, Wanchoo K, et al. 视觉和语言导航的跨模态地图学习。In: IEEE/CVF 计算机视觉与模式识别会议论文集, 新奥尔良, 2022 年。15439-15449
- 277 Zhou G, Hong Y, Wu Q. NavGPT: 利用大型语言模型进行视觉语言导航的显式推理。2023.ArXiv:2305.16986
- 278 Dorbala V S, Jr J F M, Manocha D. 嵌入式代理能找到你的 "猫形马克杯"吗? 基于 LLM 的零镜头物体 导航。2023.ArXiv:2303.03480
- 279 Li L H, Zhang P, Zhang H, et al. Grounded language-image pre-training.In: IEEE/CVF 计算机视觉与模式识别会议论文集, 新奥尔良, 2022 年。10955-10965
- 280 Gan C, Zhang Y, Wu J, et al.In: IEEE 机器人与自动化国际会议论文集, 巴黎, 2020 年。9701-9707
- 281 Brohan A, Brown N, Carbajal J 等人. RT-1: 用于真实世界规模控制的机器人变压器。2022.ArXiv:2212.06817
- 282 Brohan A, Brown N, Carbajal J, et al. RT-2: 视觉-语言-动作模型将网络知识转化为机器人控制。2023.ArXiv:2307.15818
- 283 Fan L, Wang G, Jiang Y, et al. MineDojo: 利用互联网规模的知识构建开放式的具身代理。In: 神经信息处理系统会议论文集, 2022 年
- 284 Kanitscheider I, Huizinga J, Farhi D 等人. 复杂、可视、难探索领域中的多任务课程学习: Minecraft.2021.ArXiv:2106.14876
- 285 P r i s m a r i n e J S : 使用强大、稳定和高级的 javascript api 创建 minecraft 机器人。 <https://github.com/PrismarineJS>
- 286 Bisk Y, Holtzman A, Thomason J 等人.经验决定语言。In: 经验方法会议论文集 in Natural Language Processing, 2020.8718-8735
- 287 Sumers T, Marino K, Ahuja A, et al.In: 国际机器学习会议论文集, 檀香山, 2023 年。32797-32818

- 288 Feldt R, Kang S, Yoon J, et al.2023.ArXiv:2306.05152
- 289 Chase H. LangChain.2022. <https://github.com/hwchase17/langchain>
- 290 重新设计。代理 GPT。2023. <https://github.com/reworkd/AgentGPT>
- 291 安东-奥西卡GPT 工程师。2023. <https://github.com/AntonOsika/gpt-engineer>
- 292 Zhou S, Xu F F, Zhu H, et al. WebArena: a realistic web environment for building autonomous agents. 2023.ArXiv:2307.13854
- 293 Gur I, Furuta H, Huang A, et al. 具有规划、长语境理解和程序合成功能的真实世界网络代理。2023.ArXiv:2307.12856
- 294 Zheng L, Wang R, An B. Synapse: leveraging few-shot exemplars for human-level computer control.2023.ArXiv:2306.07863
- 295 Chen P, Chang C. InterAct: Exploring the potentials of ChatGPT as a cooperative agent.2023.ArXiv:2308.01552
- 296 Furuta H, Nachum O, Lee K, et al.2023.ArXiv:2305.11854
- 297 Yao S, Chen H, Yang J, et al. WebShop: towards scalable real-world web interaction with grounded language agents.In: 神经信息处理系统会议论文集, 2022 年
- 298 Xu N, Masling S, Du M, et al.In: 计算语言学协会北美分会会议论文集: 人类语言技术, 2021。1022-1032
- 299 Kim G, Baldi P, McAleer S. 语言模型可以解决计算机任务。2023.ArXiv:2303.17491
- 300 Deng X, Gu Y, Zheng B, et al. Mind2Web: toward a generalist agent for the web.2023.ArXiv:2306.06070
- 301 Zhang Z, Zhang A. You only look at screens: multimodal chain-of-action agents.In: 计算语言学协会论文集, 曼谷, 2024 年。3132-3149
- 302 Singh I, Singh G, Modi A. 预训练语言模型作为玩文字游戏的先验知识。In: Proceedings of the 21st International Conference on Autonomous Agents and Multiagent Systems, Auckland, 2022.1729-1731
- 303 Dambekodi S N, Frazier S, Ammanabrolu P, et al.2020.ArXiv:2012.02757
- 304 Gramopadhye M, Szafr D. 利用环境感知语言模型生成可执行行动计划。 2022.ArXiv:2210.04964
- 305 Kang Y, Kim J. ChatMOF: 用于预测和生成金属有机框架的自主人工智能系统。2023.ArXiv:2308.01423
- 306 Wang R, Jansen P A, C'ot'e M, et al. 科学世界: 你的代理比五年级学生聪明吗? In: 自然语言处理经验方法会议论文集, 阿布扎比, 2022 年。11279-11298
- 307 Chhikara P, Zhang J, Ilievski F, et al.2023.ArXiv:2305.05091
- 308 Yang K, Swope A M, Gu A, et al. LeanDojo: theorem proving with retrieval-augmented language models. 2023.ArXiv:2306.15626
- 309 Lin Z, Akin H, Rao R, et al. 利用语言模型对原子级蛋白质结构进行进化级预测。科学》, 2023, 379: 1123-1130
- 310 Irwin R, Dimitriadis S, He J, et al. Chemformer: a pre-trained transformer for computational chemistry.Mach Learn-Sci Technol, 2022, 3: 015022
- 311 Li H, Hao Y, Zhai Y, et al. The hitchhiker's guide to program analysis: a journey with large language models.2023.ArXiv:2308.00245
- 312 Skrynnik A, Volovikova Z, C'ot'e M, et al. Learning to solve voxel building embodied tasks from pixels and natural language instructions.2022.ArXiv:2211.00688
- 313 Amiranashvili A, Dorka N, Burgard W, et al.2020.ArXiv:2007.02701
- 314 Nottingham K, Ammanabrolu P, Suhr A, et al.In: 国际机器学习会议论文集》, 檀香山, 2023 年。26311-26325
- 315 Yuan H, Zhang C, Wang H, et al. Plan4MC: 开放世界 Minecraft 任务的技能强化学习与规划。2023.ArXiv:2303.16563
- 316 Talebirad Y, Nadiri A. Multi-agent collaboration: harnessing power of intelligent LLM agents.2023.ArXiv:2306.03314
- 317 Minsky M.The Society of Mind.New York: Simon and Schuster, 1988
- 318 Srinivasan D. Innovations in Multi-Agent Systems and Application-I.Berlin: Springer, 2010.1-27
- 319 Finin T W, Fritzson R, McKay D P, et al. KQML as an agent communication language.In: 第三届 信息与知识管理国际会议 (CIKM'94) 论文集, 盖瑟斯堡, 1994 年。456-463
- 320 Yang Y, Wang J. 博弈论视角下的多代理强化学习概述. 2020. ArXiv:2011.00583
- 321 Smith A. The Wealth of Nations.1776. <http://web.ntpu.edu.tw/guan/courses/Coase77.pdf>
- 322 Mandi Z, Jain S, Song S. RoCo: 使用大型语言模型的辩证多机器人协作。2023.ArXiv:2307.04738
- 323 Hao R, Hu L, Qi W, et al. ChatLLM 网络: 更多大脑, 更多智慧。2023.ArXiv:2304.12998
- 324 Wang Z, Mao S, Wu W, et al. Unleashing cognitive synergy in large language models: a task-solving agent through multi- persona self-collaboration.2023.ArXiv:2307.05300
- 325 Hamilton S. Blind judgement: Agent-based supreme court modelling with GPT.2023.ArXiv:2301.05327
- 326 Nair V, Schumacher E, Tso G J, et al. DERA: enhanced large language model completions with dialog-enabled resolving agents.2023.ArXiv:2303.17071
- 327 Wu Q, Bansal G, Zhang J, et al. AutoGen: enabling nextgen LLM applications via multi-agent conversation framework.2023.ArXiv:2308.08155
- 328 Zhang C, Yang K, Hu S, et al. ProAgent: 利用大型语言模型构建主动式合作人工智能。 2023.ArXiv:2308.11339
- 329 Hassan M M, Knipper R A, Santu S K K. ChatGPT 作为您的个人数据科学家。2023.ArXiv:2305.13657
- 330 Chen W, Su Y, Zuo J, et al. AgentVerse: facilitating multi-agent collaboration and exploring emergent behaviors in agents.2023.ArXiv:2308.10848
- 331 博弈论与人工智能界面上的多代理学习系统数学.中国信息科学, 2024, 67: 166201
- 332 Hong S, Zheng X, Chen J, et al. MetaGPT: 多代理协作框架的元编程。 2023.ArXiv:2308.00352

- 333 von Neumann J, Morgenstern O. Theory of Games and Economic Behavior. 普林斯顿: 普林斯顿大学出版社, 2007 年
- 334 Aziz H. 《多代理系统: 算法、博弈论和逻辑基础》, Y. Shoham 和 K. Leyton-Brown 著 剑桥大学出版社, 2008 年. SIGACT News, 2010, 41: 34-37
- 335 Campbell M, Hoane J A J, Hsu F. 深蓝. Artif Intelligence, 2002, 134: 57-83
- 336 Silver D, Schrittwieser J, Simonyan K, et al. 在没有人类知识的情况下掌握围棋. 自然, 2017, 550: 354-359
- 337 Lewis M, Yarats D, Dauphin Y N, et al. Deal or no deal? 谈判对话的端到端学习. In: 自然语言处理经验方法会议论文集, 哥本哈根, 2017 年. 2443-2453
- 338 Irving G, Christiano P F, Amodei D. 《通过辩论看人工智能安全》. 2018.ArXiv:1805.00899
- 339 Xiong K, Ding X, Cao Y, et al. 《检验大型语言模型的相互一致性: 通过辩论的深入分析》. 2023.ArXiv:2305.11595
- 340 Chan C, Chen W, Su Y, et al. ChatEval: 通过多代理辩论实现更好的基于 LLM 的评价器. 2023.ArXiv:2308.07201
- 341 Kenton Z, Everitt T, Weidinger L, et al. 2021.ArXiv:2103.14659
- 342 Ngo R. 从深度学习角度看对齐问题. 2022.ArXiv:2209.00626
- 343 Paul M, Maglaras L, Ferrag M A, et al. 医疗保健领域的数字化: 关于隐私和安全问题的研究. ICT Express, 2023, 9: 571-588
- 344 Tellex S, Kollar T, Dickerson S, et al. 用概率图模型解决符号接地问题. AI Mag, 2011, 32: 64-76
- 345 Matuszek C, Herbst E, Zettlemoyer L, et al. 学习解析机器人控制系统的自然语言命令. In: 第 13 届实验机器人国际研讨会论文集, 克贝市, 2012 年. 403-415
- 346 Chaplot D S, Sathyendra K M, Pasumarthi R K, et al. 面向任务语言基础的门控注意架构. In: 第 32 届 AAAI 人工智能大会、第 30 届人工智能创新应用大会和第 8 届 AAAI 人工智能教育进展研讨会论文集, 新奥尔良, 2018 年. 2819-2826
- 347 Wu Y, Zhao Y Y, Li Z Y, et al. doi: 10.1007/s11432-023-3911-2
- 348 Li Y, Wen H, Wang W, et al. 个人 LLM 代理: 关于能力、效率和安全性的见解与调查. 2024.ArXiv:2401.05459
- 349 Li J, Miller A H, Chopra S, et al. Dialogue learning with human-in-the-loop. In: 第五届学习表征国际会议论文集, 土伦, 2017 年
- 350 Iyer S, Konstas I, Cheung A, et al. 从用户反馈学习神经语义解析器. In: 计算语言学协会第 55 届年会论文集, 温哥华, 2017 年. 963-973
- 351 Weston J. Dialog-based language learning. In: 神经信息处理系统进展论文集, 2016 年. 829-837
- 352 Shuster K, Xu J, Komeili M, et al. BlenderBot 3: 一个不断学习以负责任方式参与的部署型对话代理. 2022.ArXiv:2208.03188
- 353 Du W, Kim Z M, Raheja V 等人. 阅读、修改、重复: 人环式迭代文本修改系统演示. 北京: 中国科学技术出版社, 2012. 2022.ArXiv:2204.03685
- 354 Kreutzer J, Khadivi S, Matusov E 等人. 神经机器翻译能否通过用户反馈得到改进? In: 计算语言学协会北美分会会议论文集: 人类语言技术, 2018 年. 92-105
- 355 Gur I, Yavuz S, Su Y, et al. DialSQL: 基于对话的结构化查询生成. In: 计算语言学协会第 56 届年会论文集, 墨尔本, 2018 年. 1339-1349
- 356 Yao Z, Su Y, Sun H, et al. 基于模型的交互式语义解析: 统一框架和文本到 SQL 案例研究. In: 自然语言处理实证方法会议暨第九届自然语言处理国际联合会议论文集, 香港, 2019 年. 5446-5457
- 357 Mehta N, Goldwasser D. 利用建议改进与机器人的自然语言交互. In: 计算语言学协会北美分会会议论文集: 人类语言技术, 明尼阿波利斯, 2019 年. 1962-1967
- 358 Elgohary A, Meek C, Richardson M, et al. NL-EDIT: 通过自然语言交互纠正语义解析错误. In: 计算语言学协会北美分会会议论文集: 人类语言技术, 2021 年. 5599-5610
- 359 Tandon N, Madaan A, Clark P 等人. 学习修复: 使用动态反馈记忆修复部署后的模型输出错误. In: 计算语言学协会论文集, 2022 年. 339-352
- 360 Scheurer J, Campos J A, Korbak T, et al. 2023.ArXiv:2303.16755
- 361 Xu J, Ung M, Komeili M, et al. 部署后学习新技能: 利用人工反馈改进开放域互联网驱动对话. In: 计算语言学协会第 61 届年会论文集, 多伦多, 2023. 13557-13572
- 362 Cai Z, Chang B, Han W. Human-in-the-loop through chain-of-thought. 2023.ArXiv:2306.07932
- 363 Lu B, Haduong N, Lee C, et al. DIALGEN: 为更好地理解人机对话而生成的人机对话. 2023.ArXiv:2307.07047
- 364 Hancock B, Bordes A, Mazar'ie P, et al. 从部署后的对话中学习: 喂饱自己, 聊天机器人! In: 计算语言学协会第 57 届会议论文集, 2019 年. 3667-3684
- 365 Mehta N, Teruel M, Sanz P F, et al. 通过帮助反馈与代理互动, 提高协作环境中的基础语言理解能力. 2023.ArXiv:2304.10750
- 366 Schick T, Yu J A, Jiang Z, et al. PEER: a collaborative language model. In: 第 11 届学习表征国际会议论文集, 基加利, 2023 年
- 367 Kalvakurthi V, Varde A S, Jenq J. Hey Dona! 你能帮我注册学生课程吗? 2023.ArXiv:2303.13548
- 368 Gvirsman O, Koren Y, Norman T, et al. Patricc: 与可变字符进行三方交互的平台. In: Pro-ceedings of ACM/IEEE International Conference on Human-Robot Interaction, Cambridge, 2020. 399-407
- 369 Swan M, Kido T, Roland E, et al. Math agents: Computational infrastructure, mathematical embedding, and genomics. 2023.ArXiv:2307.02502
- 370 Zhang H, Chen J, Jiang F, et al. HuatuoGPT, towards taming language model to be a doctor. 2023.ArXiv:2305.15075

- 371 Yang S, Zhao H, Zhu S, et al. Zhongjing: enhanced Chinese medical capabilities of large language model through expert feedback and real-world multi-turn dialogue.2023.ArXiv:2308.03549
- 372 Stiles-Shields C, Montague E, Lattie E G, et al. What might get in the way: barriers to the use of apps for depression.数字健康, 2017, 3: 29942605
- 373 Ali M R, Razavi S Z, Langevin R, et al. 面向自闭症谱系障碍青少年的虚拟对话代理: 实验 结果与设计经验. In: ACM 智能虚拟代理国际会议论文集, 2020 年. 1-8
- 374 Hsu S L, Shah R S, Senthil P, et al. 《帮助帮助者: 通过 "Ai-授权 "实践和反馈支持同伴辅导员》。2023.ArXiv:2305.08982
- 375 Gao W, Gao X, Tang Y.多轮对话代理作为电话营销中的销售助手. In: 国际神经网络联合会议论文集, 黄金海岸, 2023 年. 1-9
- 376 Gao D, Ji L, Zhou L, et al. AssistGPT: 可规划、执行、检查和学习的通用多模态助手。2023.ArXiv:2306.08640
- 377 McTear M F. Conversational AI: Dialogue Systems, Conversational Agents, and Chatbots.Cham: Springer, 2020
- 378 Motger Q, Franch X, Marco J. Conversational agents in software engineering: survey, taxonomy and challenges.2021.ArXiv:2106.10901
- 379 Rapp A, Curti L, Boldi A. The human side of human-chatbot interaction: a systematic literature review of ten years of research on text-based chatbots.Int J Hum-Comput Studies, 2021, 151: 102630
- 380 Adamopoulou E, Moussiades L. Chatbots: history, technology, and applications.机器学习应用, 2020, 2: 100006
- 381 Zhou X, Wang W Y. MojiTalk: Generating emotional responses at scale.In: 计算语言学协会第 56 届年会论文集, 墨尔本, 2018 年. 1128-1137
- 382 Lin Z, Madotto A, Shin J 等人. MoEL: 移情聆听者的混合物. In: 自然语言处理实证方法会议暨第九届自然语言处理国际联合会论文集, 香港, 2019 年. 121-132
- 383 Majumder N, Hong P, Peng S, et al. MIME: mimicking emotions for empathetic response generation.In: 自然语言处理经验方法会议论文集, 2020 年. 8968-8979
- 384 Sabour S, Zheng C, Huang M. CEM: commonsense-aware empathetic response generation.In: 第 36 届 AAAI 人工智能大会、第 34 届人工智能创新应用大会、第 12 届人工智能教育进展研讨会论文集, 2022 年. 11229-11237
- 385 Li Q, Li P, Ren Z, et al.In: 第36届AAAI人工智能大会、第34届人工智能创新应用大会、第12届 人工智能教育进展研讨会论文集, 2022 年. 10993-11001
- 386 Hasan M, Ozel C, Potter S 等. SAPIEN: 由大型语言模型驱动的情感虚拟代理。2023.ArXiv:2308.03022
- 387 Liu B, Sundar S S. 机器应该表达同情和共鸣吗? 健康咨询聊天机器人实验. Cyberpsychol Behav Soc Netwing, 2018, 21: 625-636
- 388 Liu-Thompkins Y, Okazaki S, Li H. 营销互动中的人工移情: 弥合情感和 社交客户体验中的人机差距. J Acad Mark Sci, 2022, 50: 1198-1218
- 389 Su Z, Figueiredo M C, Jo J, et al. 分析移动医疗 应用中人工智能的描述、用户理解和期望. In: 美国医学信息学会年度研讨会论文集, 2020年
- 390 对抗博弈中的决策制定研究.中国信息科学, 2024, 67: 141201
- 391 Moravc'ik M, Schmid M, Burch N, et al. DeepStack: 无上限扑克中的专家级人工智能。2017.ArXiv:1701.01724
- 392 Bakhtin A, Wu D J, Lerer A, et al. 通过人类规则化强化学习和规划掌握无压力外交游戏. In: 第 11 届学习表征国际会议论文集, 基加利, 2023 年
- 393 Bakhtin A, Brown N, Dinan E, et al. 将语言模型与战略推理相结合, 在外交游戏中发挥人类水平. 科学, 2022 年, 378 期: 1067-1074 页
- 394 Carroll M, Shah R, Ho M K, et al.In: 神经信息处理系统进展论文集, 温哥华, 2019 年. 5175-5186
- 395 Bard N, Foerster J N, Chandar S 等. Hanabi 挑战: 人工智能研究的新领域. Artif Intell, 2020, 280: 103216
- 396 Lin J, Tomlin N, Andreas J 等: 面向决策的人机协作对话。2023.ArXiv:2305.20076
- 397 Wang X, Shi W, Kim R, et al.In: 第57届计算语言学协会会议论文集, 佛罗伦萨, 2019年. 5635-5649
- 398 Li C, Su X, Fan C, et al. 量化大型语言模型对集体意见动态的影响。 2023.ArXiv:2308.03313
- 399 Costa A C D R. A Variational Basis for the Regulation and Structuration Mechanisms of Agent Societies.Cham: Springer, 2019
- 400 Wimmer S, Pfeiffer A, Denk N.大流行病期间 SIMs 4 中的日常生活。生活模拟是 社会的虚拟镜像? In: 第 15 届国际技术、教育和发展会议论文集, 2021 年. 5754-5760
- 401 Lee L, Braud T, Zhou P, et al. 关于元宇宙的所有知识: 关于技术奇点、 虚拟生态系统和研究议程的完整调查。2021.ArXiv:2110.05352
- 402 Inkeles A, Smith D H. Becoming Modern: Individual Change in Six Developing Countries.剑桥: 哈佛大学 出版社, 1974 年
- 403 Troitzsch K G, Mueller U, Gilbert G N, et al. Social Science Microsimulation.柏林: 施普林格出版社, 1996 年: Springer, 1996
- 404 Xu Y, Wang S, Li P, et al.2023.ArXiv:2309.04658
- 405 Zhou E, Zheng R, Xi Z, et al. RealBehavior: a framework for faithfully characterizing foundation models' human-like behavior mechanisms.In: 新加坡计算语言学协会论文集, 2023年. 10262-10274
- 406 Abrams A M H, der Pu'tten A M R. I-C-E framework: concepts for group dynamics research in human-robot interaction.Int J Soc Robot, 2020, 12: 1213-1229
- 407 Askill A, Bai Y, Chen A, et al.2021.ArXiv:2112.00861
- 408 Zhang Z, Liu N, Qi S, et al. Heterogeneous value evaluation for large language models.2023.ArXiv:2305.17147
- 409 Browning J. Personhood and AI: why large language models don't understand us.AI Soc, 2024, 39: 2499-2506
- 410 Jiang G, Xu M, Zhu S, et al. MPI: 评估和诱导预训练语言模型的个性。 2022.ArXiv:2206.07550

- 411 Kosinski M. 思维理论可能是在大型语言模型中自发出现的。2023.ArXiv:2302.02083
- 412 Zuckerman M. Psychobiology of Personality.剑桥: 剑桥大学出版社, 1991 年
- 413 Binz M, Schulz E. Using cognitive psychology to understand GPT-3.2022.ArXiv:2206.14576
- 414 Dhingra S, Singh M, B V S, et al. Minds meets machine: unravelling GPT-4's cognitive psychology.2023.ArXiv:2303.11436
- 415 Hagendorff T. Machine psychology: investigating emergent capabilities and behavior in large language models using psycho- logical methods.2023.ArXiv:2303.13988
- 416 Dasgupta I, Lampinen A K, Chan S C Y, et al. 语言模型在推理中显示出类似人类的内容效应。2022.ArXiv:2207.07051
- 417 Han S J, Ransom K, Perfors A, et al.2023.ArXiv:2306.06548
- 418 Hagendorff T, Fabi S, Kosinski M. 《大型语言模型中的快慢思考》。2023.ArXiv:2212.05206
- 419 Hagendorff T, Fabi S. 类人直觉行为和推理偏差在语言模型中出现 - 在 GPT-4 中消失。2023.ArXiv:2306.07622
- 420 Curry A, Curry A C. Computer says "no": the case against empathetic conversational AI.In: 计算语言学协会论文集, 多伦多, 2023 年。8123-8130
- 421 Elyoseph Z, Hadar-Shoval D, Asraf K, et al. ChatGPT 在情感意识评估方面优于人类。前沿 Psychol, 2023, 14: 1199058
- 422 Habibi R, Pfau J, Holmes J, et al. Empathetic AI for empowering resilience in games.2023.ArXiv:2302.09070
- 423 Ma Z, Mei Y, Su Z. 了解使用基于大型语言模型的会话代理 进行心理健康支持的益处与挑战。2023.ArXiv:2307.15810
- 424 Bates J. The role of emotion in believable agents.通信 ACM, 1994, 37: 122-125
- 425 Caron G, Srivastava S. 识别和操纵语言模型的个性特征。2022.ArXiv:2212.10276
- 426 Karra S R, Nguyen S, Tulabandhula T. AI personification: estimating the personality of language models. 2022.ArXiv:2204.12000
- 427 Pan K, Zeng Y.法学硕士有个性吗? 让 MBTI 测试成为大型语言模型的绝佳评估工具。2023.ArXiv:2307.16180
- 428 Li X, Li Y, Joty S, et al.从心理学角度评估大型语言模型 .2023.ArXiv:2212.10529
- 429 Safdari M, Serapio-Garc'ia G, Crepy C, et al.2023.ArXiv:2307.00184
- 430 Park J S, Popowski L, Cai C J, et al. Social simulacra: creating populated prototypes for social computing systems.In: 第 35 届 ACM 用户界面软件与技术年度研讨会论文集》, 本德, 2022 年。1-18
- 431 Zhang S, Dinan E, Urbanek J, et al. 个性化对话代理: 我有一只狗, 你也有宠物吗? In: 第 56 届计算语言学协会年会论文集, 墨尔本, 2018。2204-2213
- 432 Kwon D S, Lee S, Kim K H, et al. What, when, and how to ground: Designing user persona-aware conversational agents for engaging dialogue.In: 第 61 届计算语言学协会年会论文集, 多伦多, 2023。707-719
- 433 Maes P. 人工生命与娱乐。通信 ACM, 1995, 38: 108-114
- 434 C'ot'e M, K'ad'ar A, Yuan X, et al. TextWorld: a learning environment for text-based games.In: 第二十七届国际人工智能大会论文集》, 斯德哥尔摩, 2018年。41-75
- 435 Hausknecht M J, Ammanabrolu P, C'ot'e M, et al. 交互式小说游戏: 一次巨大的冒险。In: 第 34 届 AAAI 人工智能大会、第 32 届人工智能创新应用大会、第 10 届 AAAI 人工智能教育进展研讨会论文集, 纽约, 2020 年。7903-7910
- 436 O'Gara A. Hoodwinked: deception and cooperation in a text-based game for language models.2023.ArXiv:2308.01404
- 437 Urbanek J, Fan A, Karamcheti S, et al. 在奇幻文字冒险游戏中学习说话和行动。In: 自然语言处理实证方法会议暨第九届自然 语言处理国际联合会论文集》, 香港, 2019年。673-683
- 438 Gao C, Lan X, Lu Z, et al. S: 大语言模型代理的社会网络模拟系统。2023. ArXiv:2307.14984
- 439 Grossmann I, Feinberg M, Parker D C, et al. AI and the transformation of social science research.科学, 2023, 380: 1108-1109
- 440 Wang L, Zhang J, Chen X, et al. RecAgent: A novel simulation paradigm for recommender systems.2023.ArXiv:2306.02552
- 441 Wei J, Shuster K, Szlam A, et al. 多方聊天: 群组环境中与人类和模型的对话代理。2023.ArXiv:2304.13835
- 442 Hollan J D, Hutchins E L, Weitzman L. STEAMER: an interactive inspectable simulation-based training system.AI Mag, 1984, 5: 15-27
- 443 Tambe M, Johnson W L, Jones R M, et al. Intelligent agents for interactive simulation environments.AI Mag, 1995, 16: 15-39
- 444 Vermeulen P, de Jongh D. 'Dynamics of growth in a finite world' - comprehensive sensitivity analysis.IFAC Proc Vol, 1976, 9: 133-145
- 445 Forrester J W. System dynamics and the lessons of 35 years.In: A Systems-Based Approach to Policymaking.Berlin: Springer, 1993.199-240
- 446 Sant'e I, Garc'ia A M, Miranda D, et al. Cellular automata models for the simulation of real-world urban processes: a review and analysis.景观城市规划, 2010, 96: 108-122
- 447 Dorri A, Kanhere S S, Jurdak R. Multi-agent systems: a survey.IEEE Access, 2018, 6: 28573-28593
- 448 Hendrickx J M, Martin S. Open multi-agent systems: gossiping with random arrivals and departures.In: 第 56 届 IEEE 决策与控制年会论文集, 墨尔本, 2017 年。763-768
- 449 Ziems C, Held W, Shaikh O, et al. 大型语言模型能否改变计算社会科学? 2023.ArXiv:2305.03514
- 450 Gilbert N, Doran J. Simulating Societies: The Computer Simulation of Social Phenomena.伦敦: Routledge, 2018
- 451 Hamilton J D. A new approach to the economic analysis of nonstationary time series and the business cycle.Econometrica, 1989, 57: 357-384
- 452 Zhang G P. 使用混合 ARIMA 和神经网络模型进行时间序列预测.神经计算, 2003, 50: 159-175
- 453 Kirby S, Dowman M, Griffiths T L. 语言进化中的先天性与文化。Proc Natl Acad Sci USA, 2007, 104: 5241-5245
- 454 Williams R, Hosseinichimeh N, Majumdar A, et al.2023.ArXiv:2307.04986

- 455 Shibata H, Miki S, Nakamura Y. 用人工智能玩狼人游戏促进语言理解.2023.ArXiv:2302.10646
- 456 Junprung E. 通过提示工程探索大型语言模型和基于代理的建模的交叉点。 2023.ArXiv:2308.07411
- 457 菲尔普斯-S、罗素-Y-I.利用实验经济学研究大型语言模型中出现的类目标行为。北京：中国人民大学出版社，2012.2023.ArXiv:2305.07970
- 458 Bellomo N, Marsan G A, Tosin A. 《复杂系统与社会》：建模与仿真》。纽约：Springer, 2013
- 459 Moon Y B. Simulation modelling for sustainability: a review of the literature.Int J Sustain Eng, 2017, 10: 2-19
- 460 Helberger N, Diakopoulos N. ChatGPT and the AI Act.Internet Policy Rev, 2023, 12: 1-6
- 461 Weidinger L, Mellor J, Rauh M, et al. 语言模型危害的伦理和社会风险。 2021.ArXiv:2112.04359
- 462 Deshpande A, Murahari V, Rajpurohit T, et al. ChatGPT 中的毒性：分析角色指定的语言模型。 2023.ArXiv:2304.05335
- 463 Kirk H R, Jun Y, Volpin F, et al. Bias out-of-the-box: an empirical analysis of intersectional occupational biases in popular generative language models.In: 神经信息处理系统进展论文集》，2021 年。2611-2624
- 464 Nadeem M, Bethke A, Reddy S. StereoSet: measuring stereotypical bias in pretrained language models.In: 第 59 届计算语言学协会年会暨第 11 届自然语言处理国际联合会会议论文集》，2021 年。5356-5371
- 465 Roberts T, Marchais G. Assessing the role of social media and digital technology in violence reporting.Contemp Readings Law & Social Justice, 2018, 10: 9-42
- 466 Kandpal N、Deng H、Roberts A 等人.大型语言模型学习长尾知识的困难。In：第 40 届机器学习国际会议论文集》，2023 年。15696-15707
- 467 Ferrara E. ChatGPT 应该有偏见吗？大型语言模型的挑战和偏差风险。2023.ArXiv:2304.03738
- 468 Haller P, Aynedtinov A, Akbik A. OpinionGPT: Modeling explicit biases in instruction-tuned LLMs.2023.ArXiv:2309.03876
- 469 Salewski L, Alaniz S, Rio-Torto I, et al. In-context impersonation reveals large language models' strengths and biases.2023.ArXiv:2305.14930
- 470 Lin B, Bouneffouf D, Cecchi G A, et al. Towards healthy AI: large language models need therapists too.2023.ArXiv:2304.00416
- 471 Liang P P, Wu C, Morency L, et al.In：第 38 届国际机器学习大会论文集，2021 年。6565-6576
- 472 Henderson P, Sinha K, Angelard-Gontier N, et al.In：the AAAI/ACM Conference on AI, Ethics, and Society, 2018.123-129
- 473 Li H, Song Y, Fan L. You don't know my favorite color: preventing dialogue representations from revealing speakers' private personas.In：计算语言学协会北美分会会议论文集，Seattle, 2022.5858-5870
- 474 Brown H、Lee K、Miresghallah F 等人.语言模型保护隐私意味着什么？In：ACM 公平、负责和透明会议论文集，首尔，2022 年。2280-2292
- 475 Sebastian G. ChatGPT 和其他人工智能聊天机器人中的隐私和数据保护：确保用户信息安全的策略。Int J Secur Privacy Pervasive Comput, 2023. doi: 10.4018/ijspc.325475
- 476 Reeves B, Nass C. The Media Equation - How People Treat Computers, Television, and New Media Like Real People and Places.剑桥：剑桥：剑桥大学出版社，1996 年
- 477 Roose K. 与 Bing 的聊天机器人的对话让我深感不安。 2023. <https://philosophy.tamucc.edu/texts/chat-with-chatgpt>
- 478 Bach S H, Sanh V, Yong Z X, et al. PromptSource: an integrated development environment and repository for natural language prompts.In：计算语言学协会第 60 届年会论文集》，都柏林，2022。93-104
- 479 Bai Y, Kadavath S, Kundu S, et al. Constitutional AI: harmlessness from AI feedback 2022.ArXiv:2212.08073
- 480 Bai Y, Jones A, Ndousse K, et al. 利用人类 feedback 2022 的强化学习训练乐于助人的无害助手。ArXiv:2204.05862
- 481 X. XAgent：解决复杂任务的自主代理。2023. <https://github.com/OpenBMB/XAgent>
- 482 Xi Z, Ding Y, Chen W, et al. AgentGym: evolving large language model-based agents across diverse environments.2024.ArXiv:2406.04151
- 483 OpenAI.Swarm.2024. <https://github.com/openai/swarm>
- 484 Liu X, Yu H, Zhang H, et al.2023.ArXiv:2308.03688
- 485 Aher G V, Arriaga R I, Kalai A T. Using large language models to simulate multiple humans and replicate human subject studies.In：国际机器学习会议论文集，檀香山，2023 年。337-371
- 486 Liang Y, Zhu L, Yang Y.Tachikuma：通过大型语言模型理解与多角色和新奇对象的复杂互动 2023.ArXiv:2307.12573
- 487 Xu B, Liu X, Shen H, et al.2023.ArXiv:2308.04030
- 488 Adiwardana D, Luong M, So D R, et al.2020.ArXiv:2001.09977
- 489 Kim S S, Watkins E A, Russakovsky O, et al. "Help me help the AI": understanding how explainability can support human-AI interaction.In：计算系统中的人为因素 CHI 会议论文集，2023 年。1-17
- 490 Jhan J, Liu C, Jeng S, et al. CheerBots: chatbots toward empathy and emotionusing reinforcement learning.2021.ArXiv:2110.03949
- 491 Choi M, Pei J, Kumar S, et al. Do LLMs understand social knowledge?用 Socket 基准评估大型语言模型的社会性 2023.ArXiv:2305.14938
- 492 Wilson A C, Bishop D V M. "If you catch my drift.....": 推断隐含意义的能力有别于词汇和语法技能。Wellcome Open Res, 2019, 4: 68
- 493 Fang T, Yang S, Lan K, et al. ChatGPT 是高度流畅的语法纠错系统吗？综合评估。2023.ArXiv:2304.01746
- 494 Shi J, Zhao J, Wang Y, et al.2023.ArXiv:2308.12503
- 495 Shuster K, Urbanek J, Szlam A, et al.最先进的对话模型无法保持身份。In：计算语言学协会论文集，西雅图，2022 年。2367-2387
- 496 Ganguli D, Lovitt L, Kernion J, et al.2022.ArXiv:2209.07858

- 497 Kadavath S, Conerly T, Askell A 等人. 语言模型（大多）知道它们知道什么. 2022.ArXiv:2207.05221
- 498 Szegedy C, Zaremba W, Sutskever I, et al. 神经网络的迷人特性. In: 第二届学习表征国际会议论文集, 班夫, 2014年
- 499 Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples.In: 第三届学习表征国际会议论文集, 圣地亚哥, 2015年
- 500 Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks.In: 第六届学习表征国际会议论文集, 温哥华, 2018年
- 501 Zheng R, Xi Z, Liu Q, et al. 描述实例对鲁棒性的影响. In: 计算语言学协会论文集, 多伦多, 2023 年. 2314-2332
- 502 Xi Z H, Zheng R, Gui T. 大型语言模型的安全与伦理问题. In: 第 22 届中国国家 计算语言学大会论文集, 2023 年. 9-16
- 503 Akhtar N, Mian A, Kardan N, et al. 计算机视觉深度学习的对抗性攻击威胁: 调查 II.2021.ArXiv:2108.00401
- 504 Drenkow N, Sani N, Shpitser I 等人. 计算机视觉深度学习鲁棒性系统综述: 注意差距? 2021.ArXiv:2112.00639
- 505 Hendrycks D, Dietterich T G. 神经网络对常见破坏和扰动的鲁棒性基准. In: 第 7 届学习表征国际会议论文集, 2019 年
- 506 Wang X, Wang H, Yang D. Measure and improve robustness in NLP models: a survey.In: 计算语言学协会北美分会会议论文集: 人类语言技术, 西雅图, 2022. 4569-4586
- 507 Li J, Ji S, Du T 等: TextBugger: 针对真实世界应用生成对抗性文本. In: 第 26 届 年度网络与分布式系统安全研讨会论文集, 圣迭戈, 2019 年
- 508 Zhu C, Cheng Y, Gan Z, et al. FreeLB: enhanced adversarial training for natural language understanding.In: 第八届学习表征国际会议论文集, 亚的斯亚贝巴, 2020 年
- 509 Xi Z, Zheng R, Gui T, et al. 采用稳健早鸟票的高效对抗训练. In: 自然语言处理经验方法会议论文集, 阿布扎比, 2022 年. 8318-8331
- 510 Pinto L, Davidson J, Sukthankar R, et al. 鲁棒对抗强化学习. In: 第 34 届国际机器学习大会论文集, 悉尼, 2017 年. 2817-2826
- 511 Rigter M, Lacerda B, Hawes N. RAMBO-RL: robust adversarial model-based offline reinforcement learning.In: 神经信息处理系统会议论文集, 2022 年
- 512 Panaganti K, Xu Z, Kalathil D, et al. 使用离线数据的鲁棒强化学习. In: 神经信息处理系统会议论文集, 2022 年
- 513 实验室 T K S. 特斯拉自动驾驶实验安全研究. 腾讯科恩安全实验室, 2019。
https://keenlab.tencent.com/en/whitepapers/Experimental安全研究_of特斯拉_Autopilot.pdf
- 514 Xu K, Zhang G, Liu S, et al. Adversarial T-shirt! 在物理世界中躲避人物探测器. In: 第 16 届 欧洲计算机视觉会议论文集, 格拉斯哥, 2020 年. 665-681
- 515 Sharif M, Bhagavatula S, Bauer L, et al. Accessorize to a crime: real and stealthy attacks on state-of-the-art face recognition.In: ACM SIGSAC 计算机与通信安全会议论文集, 维也纳, 2016 年. 1528-1540
- 516 Jin D, Jin Z, Zhou J T, et al. 文本分类和蕴含的自然语言攻击的强基线. In: 第 34 届 AAAI 人工智能大会、第 32 届人工智能创新应用大会、第 10 届 AAAI 人工智能教育进展研讨会论文集, 2020 年. 8018-8025
- 517 Ren S, Deng Y, He K, et al. 通过概率加权词显著性生成自然语言对抗示例. In: 计算语言学协会第 57 届会议论文集, 2019 年. 1085-1097
- 518 Zhu K, Wang J, Zhou J, et al. PromptBench: 评估大型语言模型在对抗性提示上的鲁棒性. 2023.ArXiv:2306.04528
- 519 Chen X, Ye J, Zu C, et al. 语言理解任务的综合研究. 2023.ArXiv:2303.00293
- 520 Gu T, Dolan-Gavitt B, Garg S. BadNets: 识别机器学习模型供应链中的漏洞. 2017.ArXiv:1708.06733
- 521 Chen X, Salem A, Chen D, et al. BadNL: 针对 NLP 模型的后门攻击与语义保护改进. In: 计算机安全应用年会论文集, 2021 年. 554-569
- 522 Li Z, Mekala D, Dong C, et al. BFClass: a backdoor-free text classification framework.In: 计算语言学协会论文集, 2021 年. 444-453
- 523 Shi Y, Li P, Yin C, et al. PromptAttack: 通过梯度搜索对语言模型进行基于提示的攻击. In: 第十一届 CCF 自然语言处理与中文计算国际会议论文集, 桂林, 2022 年. 682-693
- 524 Perez F, Ribeiro I. 忽视先前提示: 语言模型的攻击技术. 2022.ArXiv:2211.09527
- 525 Liang P, Bommasani R, Lee T, et al. 语言模型的整体评估. 2022.ArXiv:2211.09110
- 526 Gururangan S, Card D, Dreier S K, et al. 衡量文本数据选择中的语言意识形态. In: 自然语言处理经验方法会议论文集, 阿布扎比, 2022 年。 2562-2580
- 527 Liu Y, Deng G, Li Y, et al. Prompt injection attack against LLM-integrated applications.2023.ArXiv:2306.05499
- 528 Carlini N, Wagner D A. Audio adversarial examples: targeted attacks on speech-to-text.In: 电气和电子工程师学会安全 和隐私研讨会论文集, 旧金山, 2018 年. 1-7
- 529 Morris J X, Lifland E, Yoo J Y, et al. TextAttack: a framework for adversarial attacks, data augmentation, and adversarial training in NLP.In: 自然语言处理经验方法会议论文集: 系统演示, 2020 年. 119-126
- 530 Si C, Zhang Z, Qi F, et al. 通过更多覆盖提高鲁棒性: 对抗性和混合数据增强鲁棒性 微调. In: 计算语言学协会论文集, 2021 年. 1569-1576
- 531 Yoo K, Kim J, Jang J, et al. 文本分类中对抗性示例的检测: 通过鲁棒 密度测定的基准和基线. In: 计算语言学协会论文集, 2022 年. 3656-3672
- 532 Le T, Park N, Lee D. DARC Y 的甜蜜兔子洞: 使用蜜罐检测通用触发器的对抗性攻击. In: 第 59 届计算语言学协会年会暨第 11 届自然语言处理国际联合会议论文集, 2021 年. 3831-3844

- 533 Tsipras D, Santurkar S, Engstrom L 等人.稳健性可能与准确性相悖。In: 第七届学习表征国际会议论文集, 2019 年
- 534 Zhang H, Yu Y, Jiao J, et al. 稳健性与准确性之间的理论原则权衡。In: 第 36 届国际机器学习大会论文集, 长滩, 2019 年。7472-7482
- 535 Wong A, Wang X Y, Hryniowski A. How much can we really trust you?实现深度神经网络简单、可解释的信任量化指标。2020.ArXiv:2009.05835
- 536 Huang X, Kroening D, Ruan W, et al. 深度神经网络的安全性和可信性调查: 验证、测试、对抗性攻防和可解释性。Comput Sci Rev, 2020, 37: 100270
- 537 Huang X, Ruan W, Huang W, et al. 从验证和确认的视角看大型语言模型的安全性和可信度调查。2023.ArXiv:2305.11391
- 538 Raffel C, Shazeer N, Roberts A, et al.J Mach Learn Res, 2020, 21: 5485-5551
- 539 Chen Y, Yuan L, Cui G, et al. 预训练语言模型的校准研究。In: 计算语言学协会第 61 届年会论文集, 2023。1343-1367
- 540 Blodgett S L, Barocas S, III H D, et al. 语言 (技术) 就是力量: 对 NLP 中 "偏见" 的批判性研究。In: Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020.5454-5476
- 541 Guo W, Caliskan A. 《检测新出现的交叉偏差: 语境化词语嵌入包含 类人偏差分布》。In: AAAI/ACM人工智能、伦理与社会会议论文集, 2021年。122-133
- 542 Bolukbasi T, Chang K, Zou J Y, et al. 男人之于计算机程序员, 如同女人之于家庭主妇? 分词 嵌入。In: 神经信息处理系统进展论文集》, 2016 年。4349-4357
- 543 Caliskan A, Bryson J J, Narayanan A. 从语料库中自动得出的语义包含类似人类的偏差。科学》, 2017, 356: 183-186
- 544 Ji Z, Lee N, Frieske R, et al. 自然语言生成中的幻觉调查。ACM Comput Surv, 2023, 55: 1-38
- 545 Mu'ndler N, He J, Jenko S, et al. 大型语言模型的自相矛盾幻觉: 评估、检测和 mitigation.2023.ArXiv:2305.15852
- 546 Maynez J, Narayan S, Bohnet B 等人.论抽象概括中的忠实性和事实性.中国人民大学出版社, 2012.In: 第 58 届计算语言学协会年会论文集, 2020 年。1906-1919
- 547 Varshney N, Yao W, Zhang H, et al. A stitch in time saves nine: detecting and mitigating hallucination of LLMs by validating low-confidence generation.2023.ArXiv:2307.03987
- 548 Ke W J, Shang Z Y, Luo Z Z, et al. 通过强化学习和 数据比例揭示事实性并为 LLM 注入知识.中国信息科学, 2024, 67: 209101
- 549 Lightman H, Kosaraju V, Burda Y, et al. 让我们逐步验证。2023.ArXiv:2305.20050
- 550 Tang X, Zou A, Zhang Z, et al. MedAgents: large language models as collaborators for zero-shot medical reasoning.In: 计算语言学协会论文集》, 曼谷, 2024 年。599-621
- 551 Guo Y, Yang Y, Abbasi A. Auto-Debias: debiasing masked language models with automated biased prompts.In: 计算语言学协会第 60 届年会论文集, 都柏林, 2022 年。1012-1023
- 552 Du M, He F, Zou N, et al. 自然语言理解中大型语言模型的捷径学习: 一项调查。2022.ArXiv:2208.11857
- 553 Brundage M, Avin S, Clark J, et al. 恶意使用人工智能: 预测、预防和缓解。2018.ArXiv:1802.07228
- 554 Bommasani R, Hudson D A, Adeli E 等. 论基础模型的机遇与风险。2021.ArXiv:2108.07258
- 555 Charan P V S, Chunduri H, Anand P M, et al. 从文本到 MITRE 技术: 探索恶意使用大型 语言模型生成网络攻击有效载荷。2023.ArXiv:2305.15336
- 556 Wang Z J, Choi D, Xu S 等人.将人类纳入自然语言处理循环: 一项调查.北京: 科学出版社, 2011 年。2021.ArXiv:2103.04044
- 557 Yao S, Narasimhan K. 数字世界中的语言代理: 机遇与风险。2023. <https://princeton-nlp.github.io>
- 558 阿西莫夫一世: 《机器人学三大定律》。1942. https://en.wikipedia.org/wiki/Three_laws_of_robotics
- 559 Yuan T, He Z, Dong L, et al. R-Judge: benchmarking safety risk awareness for LLM agents.2024.ArXiv:2401.10019
- 560 Elhage N, Nanda N, Olsson C, et al. 变压器电路的数学框架。Transformer Circ Thread, 2021, 1: 12
- 561 Zhuge M, Liu H, Faccio F, et al. Mindstorms in natural language-based societies of mind.2023.ArXiv:2305.17066
- 562 Bai J, Zhang S, Chen Z. 基于 llm 的代理有社会原则吗? 2023.ArXiv:2308.11136
- 563 Shridhar M, Yuan X, C'ot'e M, et al. ALFWorld: aligning text and embodied environments for interactive learning.In: 第九届学习表征国际会议论文集, 2021年
- 564 Colas C, Teodorescu L, Oudeyer P, et al.2023.ArXiv:2305.12487
- 565 Bertsch A, Alon U, Neubig G, et al. Unlimiformer: 具有无限长度输入的长程变压器。2023。ArXiv:2305.01625
- 566 Chowdhury J R, Caragea C.长度泛化的单调位置注意力。In: Proceedings of International Conference on Machine Learning, Honolulu, 2023.28792-28808
- 567 Duan Y, Fu G, Zhou N, et al. 云上的万物即服务 (XaaS): 起源、现状和未来趋势。In: of the 8th IEEE International Conference on Cloud Computing, New York City, 2015.621-628
- 568 Bhardwaj S, Jain L, Jain S. 云计算: 基础设施即服务 (IAAS) 研究。Int J Engin Inform Technol, 2010, 2: 60-63
- 569 Serrano N, Gallardo G, Hernantes J. Infrastructure as a service and cloud technologies.IEEE Softw, 2015, 32: 30-36
- 570 Mell P, Grance T. The NIST definition of cloud computing.特别出版物 (NIST SP), 国家标准 与技术研究所, 盖瑟斯堡, 2011 年。doi: 10.6028/NIST.SP.800-145
- 571 Lawton G. 利用平台即服务技术开发在线软件。Computer, 2008, 41: 13-15
- 572 Sun W, Zhang K, Chen S K 等: 软件即服务: 集成视角。In: 第五届面向服务计算国际会议论文集, 维也纳, 2007 年。558-569
- 573 Dubey A, Wagle D. Delivering software as a service.麦肯锡季刊, 2007 年, 6: 2007
- 574 Sun T, Shao Y, Qian H, et al. 语言模型即服务的黑盒调优。In: 国际机器学习大会论文集》, 巴尔的摩, 2022 年。20841-20855