

备忘录聊天：调整 LLM 以使用备忘录进行一致的远程开放域对话

卢俊如¹, 安思宇², 林明宝², 加布里埃尔-佩尔戈拉¹, 何玉兰³, 尹迪⁽²⁾, 孙星²和吴云生⁽²⁾

¹华威大学, ²腾讯优图实验室, ⁽³⁾伦敦国王学院 {junru.lu, gabriele.pergola}@warwick.ac.uk, ⁽³⁾ yulan.he@kcl.ac.uk ⁽²⁾ {siyuan, marlin, endymecyyin, winfredsun, simonwu}@tencent.com

摘要

我们提出了“备忘录聊天”（MemoChat），这是一种用于完善指令的管道，可使大型语言模型（LLM）有效地利用自编备忘录来保持一致的远程开放域对话。我们通过“记忆-检索-响应”的迭代过程演示了远程开域对话。这就要求我们为每个不同阶段精心设计有针对性的调整指令。这些指令是从一系列公共数据集中重建的，目的是教会 LLMs 通过结构化备忘录记忆和检索过去的对话，从而在参与未来对话时增强一致性。我们邀请专家手动标注测试集，旨在评估远程对话问题的一致性。我们在三个测试场景中对开源聊天机器人和应用程序接口聊天机器人进行了大规模实验，验证了 MemoChat 的功效，其表现优于强大的基线¹。

1 简介

大型语言模型（LLM）带来了一场实质性的革命，从根本上改变了我们的生活方式。它们已成为人工智能领域中连接学术界和工业界的新平台（赵等人，2023b；杨等人，2023）。特别是，LLMs 已经证明了与人类认知过程有效同步的更强能力（Du 等人，2022 年；Taori 等 Zheng 等人，2023 年年；人，2023 2023 年c；Liu 等人，； Ouyang 等人，2022 年），并因此成为创建类人对话的基础。

传统的对话系统主要涉及类似主题的简短对话（Dinan et al., 2019bb；Komeili al.et Dinan et aDinan, 20222022；1, 2019a20192019a），与之相反，人类与聊天机器人交互的新兴趋势则以涵盖不同主题的较长对话为特征（Kim et al., Komeili et al., et al., ；；）。




图 1：长期开放域对话示例。它包含多个话题。

2023)图 1 举例说明了人类用户与聊天机器人之间超过 20 次的长距离对话。其中涉及多个连续话题，如“量子物理学”（1 到 8 个回合）、“日本商务礼仪”（11 到 14 个回合）和“多项式数学问题”（16 到 18 个回合），而其他话题则简称为“多回合”。此外，还提出了两个与话题相关的长程问题，其中一个唤起与“日本商务礼仪”相关的记忆，另一个是检索与“量子物理学”相关的历史信息。这种涉及不同话题的长程开放域对话对传统方法提出了挑战，因为它们难以有效解决在长篇大论中保持上下文连贯性的问题。一种可能的策略是扩大输入文本窗口（Workowski 等人，2023 年；李等人，2023 年年；丁等人，2023）。例如，位置插值（Chen 等年人，2023）被用来增强基于 RoPE 的 LLMs（Su 等人，2022 年），其文本窗口长度是原始预训练版本的 600 倍。不幸的是，窗口长度不能任意设定。

¹ 代码：<https://github.com/LuJunru/MemoChat>。

另一个可能的解决方案是利用额外的记忆来跟踪历史记录等人（钟，2023；赵等人，2023a）。另一个潜在的解决方案是利用额外的记忆来跟踪历史记录（Zhong 等人，2023；Zhao 等人，2023a）。例如，MPC 被提出（Lee 等人，2023 年），定期存储最近交往的角色摘要作为历史记录，然后使用新的用户查询 Q ，通过外部 DPR 检索器检索 Top-K 历史记录 D （Karpukhin 等人，2020 年），最后根据 Q 和 D 生成新的响应。同样，FAISS（Johnson 等人，2019 年）管理的事件和用户肖像记忆被（Zhong 等人，2023 年）采用。尽管与文本窗口扩展相比，记忆机制具有保留无限上下文输入的优势，但在检索过去的证据时，记忆机制可能会导致累积错误（徐等人，2022b）。因此，如何提高记忆调用的准确性，并证明 LLM 驱动的聊天机器人在远距离开放域对话中的反应一致性，仍是一个悬而未决的问题（Xu 等人，2022a）。

在本文中，我们对构建记忆增强型聊天机器人特别感兴趣。我们不再依赖外部工具来创建和调用记忆（Lee 等人，2023 年；Zhong 等人，2023 年；Hu 等人，2023 年；Kynoch 和 Latapie，2023 年），而是提出了一种简化方法，在这种方法中，我们不再需要这些复杂的关联模块。取而代之的是，我们创建了一个简化的管道，仅利用 LLM 为聊天机器人提供动力。这个配备备忘录的管道--MemoChat--旨在引导 LLM 使用简单的即时备忘录，以保持长期开放域对话的一致性。我们的方法基于“记忆-检索-响应”循环的概念。为此，除了通过公共应用程序接口（OpenAI，2023；GoogleGhosal 等人，2023）对聊天机器人进行零点学习外，我们还从公开数据集（Ad-lakha 等人，2022；Chen 等人，2021；，2023）中重建了一系列指令，以微调由 LLM 驱动的开源聊天机器人。这一微调过程有助于聊天机器人熟悉循环中的每个阶段，并采用结构化备忘录来保持长期对话的一致性。为了进行公平评估，我们邀请专家对测试集进行手动注释，该测试集专门用于评估三种不同类型测试场景中远距离对话的一致性。我们通过一项测试验证了所建议的 MemoChat 的有效性。

综合评估涉及可通过公共应用程序接口访问的聊天机器人和四种不同的开源 LLM。该评估使用了一个非常强大的 LLM 判断器（Zheng 等人，2023 年）。本文的贡献如下：

- 我们引入了一个指令调整管道 MemoChat，通过即时备忘来帮助 LLM 驱动的聊天机器人进行一致的远程开放域对话。
- 我们利用多个公开数据集重构指令，帮助开源 LLM 熟悉 MemoChat 管道。
- 我们策划了一个专家注释的评估集，作为评估响应一致性的基准。在开源聊天机器人和 API 可访问聊天机器人上进行的实验验证了 MemoChat 的功效。

2 相关工作

2.1 远程开放域对话

远程开放域对话是近年来被广泛探索的一项任务。Feng 等Feng et al人提出的Doc2Dial是一个以目标为导向、以文档为基础的对话数据集（MultiSessionChat 是一个关于多个会话中的长对话的数据集（Xu 等人，2022a）。虽然这些传统数据集大多集中于少数话题的人与人场景，但新近出现的多话题人与聊天机器人场景也在不断涌现（Kim 等人，2023 年）。

远距离开域连接的挑战在于开域问题的可回答性和远距离输入理解的能力。外部知识图谱的加入提高了分布外开放域问题的回答能力（Zhou 等，2020）。随着 LLM 的发展，由 LLM 支持的聊天机器人在很大程度上提高了其回答能力（Shuster 等人，2022b,a）。另一方面，人们提出了各种策略来应对长距离输入的挑战。一种可能的策略是使用额外的内存来过滤过去长程历史中较短的关键事实，以取代它。MPC（Lee 等人，2023 年）和 MemoryBank（Zhong 等人，2023 年）就是利用额外内存和外部再发热来管理人物、事件或用户画像的。




图 2: 我们提出的 MemoChat 管道的整体架构。在保持人类用户与聊天机器人之间的聊天流（左侧）的同时，聊天机器人将拥有一个配备备忘录的内在思维（右侧）。

信息。我们的工作与现有研究的不同之处在于，我们只教聊天机器人自我使用备忘录，而且我们专注于总结历史中的所有事实，而不是部分人物或事件事实。

2.2 指令调整

指令调整是一种广泛使用的策略，它可以

在有元指令超前的任务中对 LLM 进行微调（Wei 等人，2022a）。其有效性

指令调整已在许多任务中得到证实，包括文本推理（Sanh 等人，2022 年）、人机对齐（欧阳等人，2022 年）、文档排名（秦等人，2023 年；孙等人，2023 年）、文档检索（穆勒等人，2023 年）和一般对话能力（古普塔等人，2022 年）。在这项工作中，我们利用低成本但精心设计的结构，教 LLM 驱动的聊天机器人使用即时备忘录进行自我学习，以加强远距离聊天流中的响应一致性。

3 教学方法

3.1 公式化

我们首先将长距离开放领域对话表述为生成式问题回答

（GQA），其中聊天机器人应

生成一个答案 $\hat{Y} = \operatorname{argmax}_Y p(Y | x^{(q)}, x^{(h)})$ 、

给定之前的对话历史 $x^{(h)}$ 和当前的用户查询 $x^{(q)}$ 。为了提高响应速度

一致性 $\hat{Y}$ ，我们的 MemoChat 采取的步骤与

图 2 右下方的答案一致。

我们的 MemoChat 采用了步调一致的答案，如图 2 所示。

"记忆-检索-响应"循环，旨在从结构化备忘录 x^m 中检索与查询相关的证据 $x^{(h)}$ ，其模型为 $x^m = f(x^{(h)})$ ， $x^{(h)} = g(x^{(q)}, x^m)$ ，其中 $f(*)$ 和 $g(*)$ 分别为备忘录建立函数和检索函数。因此，我们的 MemoChat 中的 GQA 可以是重新表述为

$$Y = \operatorname{argmax}_Y p(Y | x, x^{(h)})$$

3.2 备忘录聊天

图 2 描述了我们设计的 MemoChat 管道的整体框架，它为聊天机器人分配了一个"记忆-检索-回复"的内在思维循环。在图 2 左侧，用户从"量子物理学"话题开始，经过多次对话后以"商务礼仪"话题结束。与直接在这些积累的对话中进行检索的传统方法截然不同，如图 2 右上方所示，我们的 MemoChat 下的聊天机器人会自动建立和更新一个结构化的即时备忘录，将过去的对话按类别存储起来。然后，根据主题和摘要对所有录音进行检索。图 2 左下方展示了聊天机器人在对话一开始就需要将"量子物理学"概念联系起来的情况。聊天机器人成功回忆起了相关证据，并产生了

图 2 右下方是一致的答案。

范围的开放域对话分解为三个阶段

通过允许聊天机器人根据不同主题重组对话
根据不同的主题重新组织对话历史，总结




图 3: MemoChat 中的指令模板（用颜色表示更清晰）。为服务于 MemoChat 内部思维管道，我们精心设计了三条指令，包括 "撰写备忘录"、"检索备忘录" 和 "与备忘录聊天"，并用灰色方框隔开。所有指令的组织结构包括一般任务介绍（绿色区域）、面向任务的输入主体（双色区域）和详细任务说明（黄色区域）。在微调过程中（蓝色区域）会提供真实答案。更多具体示例见附录 B。

如果聊天机器人能忠实地记录部分对话，并快速检索一个或多个与询问相关的证据，那么 MemoChat 就能成为一个简单而有效的管道，引导聊天机器人生成一致的回复。

指令结构。"记忆-检索-响应"机制将过去的对话存储在备忘录 x^m 中，从备忘录中检索与查询相关的证据 x^u ，并根据检索到的证据生成响应 $\hat{y}$ 。与之前需要额外复杂模块的文献（Lee 等人，2023；Zhong 等人，2023）不同，我们将对话历史重组为结构化的即时备忘录，这样基本的 LLM 驱动聊天机器人就能同时处理备忘录。因此，我们为每个阶段开发了三种指令，如图 3 所示。总的来说，所有指令都遵循相似的结构：（1）每个阶段任务的描述（绿色区域）；（2）以任务为导向的输入主体（双色区域）；（3）每项任务的解释（黄色区域）。三者组合作为聊天机器人的输入提示，并提供真实答案（蓝色区域）进行微调。

其中，"撰写备忘录"任务要求聊天机器人阅读任务对话，根据所有可能的主题分割对话，为每个子对话撰写简短摘要，并撰写

上述结果以 JSON 格式提交给备忘录，每个实例包括 "主题"、"摘要" 和 "对话" 键。我们利用思维链（CoT）（Wei 等人，2022b）和上下文学习（ICL）（Dong 等人，2023）对任务进行了综合解释。备忘录检索 "任务要求聊天机器人读取用户查询和一系列主题选项，选出一个或多个相关选项，并以特殊格式报告选项 ID。受先前文献（Rajpurkar 等人，2018 年）的启发，考虑到用户可能会任意发起一个新话题，我们在候选选项中随机插入了一个 "其他选项都不是 (NOTO)" 选项。为了支持快速实施，我们仅根据即时备忘录中的 "主题" 和 "摘要" 检索相关内容。最后，"聊天/备忘录" 任务会将最新的查询内容（以检索到的证据和最近的对话为前缀）发送给聊天机器人。有了这些相关证据，聊天机器人即使在长距离开放领域对话中也能做出更一致的回应。

数据集重建。为了实现我们的 Memo 管道，我们从三个公共对话数据集重建了 10k 指令数据，包括 Topi-coQA（Adlakha 等人，2022 年）、DialogSum（Chen 等人 Ghosal 人，2021 年）和 Alpaca-GPT4（，2023 年）。

	数据量	平均值代币	来源
备忘录写作	3,046	951.92	1,790 来自 T* 1,256 来自 D*
备忘录检索	3,654	329.86	1,719 来自 T* 1,935 来自 D*
聊天/备忘录	3,300	273.04	1,602 转自 D* 1,698 转自 A*

表 1: 指令训练集的统计数据。"Avg.代表每条指令的平均标记数。T*、D* 和 A* 分别代表 TopicoQA、Dialog-Sum 和 Alpaca-GPT4 数据集。

TopicoQA 涵盖 3.9k 对话，平均涉及 4 个主题和 13 轮对话。Dialog-Sum 涵盖 13k 个对话，平均涉及 1 个话题，5.5 个对话回合，并为每个对话提供手动摘要。TopicoQA 和 DialogSum 使用的都是口语风格的人机对话，重点关注日常生活场景。Alpaca-GPT4 则是通过在 Alpaca 数据集 (Taori 等人, 2023 年) 上运行 GPT4 API (OpenAI, 2023 年) 创建的人类-聊天机器人 1 轮对话数据集。该数据集以书面形式涵盖了更复杂的主题。我们抽取了 1.6k 个案例，以平衡来自另外两个数据集的指令。

表 1 报告了三个指令训练集的统计数据 and 来源。备忘录写作 "集包括来自 TopicoQA 的 1,790 个实例和来自 DialogSum 的 1,256 个样本。由于无法获得 "摘要 "信息，我们只为 TopicoQA 数据集中的对话构建了备忘录中的 "主题 "和 "对话"。考虑到 DialogSum 的每个对话中只有一个主题，我们将几个可变的对话集组合起来，模拟多主题的长距离对话。我们采用同样的策略形成了 "备忘录检索 "集，其中分别包含来自 TopicoQA 和 DialogSum 的 1,719 条和 1,935 条指令。对于每个检索指令，其查询句由原始对话中的几个连续句子组成，并提取相关主题作为选项。插入 "NOTO "选项的 概率为 10%。聊天与备忘录 "集包括来自 DialogSum 和 Alpaca-GPT4 的 1,602 条和 1,698 条指令。前者旨在生成有相关证据的指令，后者则生成没有任何相关证据的指令，以适应未见过的主题。

总之，我们成功建立了三个训练集，实现了 "记忆-检索-响应 "的循环。此外

其中，"备忘录写作"、"备忘录再评估 "和 "备忘录聊天 " 分别有 160、82 和 65 个样本。

挑战。据我们所知，我们是第一个建立这样一组系统顺序指令的人。我们报告了面临的主要挑战，供今后可能的后续工作参考。附录 C 提供了一些具体实例。

面临的第一个挑战是 "提示复制"，在这一挑战中，LLM 找到了一种特殊的快捷方式，可以直接复制提示中的格式示例作为答案。为了避免这种情况，我们建议使用虚拟变量来代替任何数值，以避免可能出现的答案泄露。第二个挑战指的是 "灾难性遗忘"，即如果 "聊天/备忘录 "的数量少于 "撰写备忘录 "或 "检索备忘录"，聊天机器人就会倾向于生成早期停止或重复的答案。通过混合一定量的对话语料库来保持聊天能力的平衡 (Ghosal 等人, 2023 年)。我们在构建过程中考虑了 Alpaca-GPT4。第三个挑战在于 "提示错位"，即当调换任务导向输入主体 (图 3 中的 **双色区域**) 和每个任务的解释 (图 3 中的 **黄色区域**) 的输入顺序时，聊天机器人的性能会下降。任务说明附在最后对于聊天机器人更好地理解指令至关重要 (刘等人, 2023b)。

4 实验

4.1 实验设置

数据集。除了重建的指令数据集，我们还邀请了三位专家对一个新的远程开放领域会话数据集进行人工标注，以验证响应的一致性。该注释数据集被称为 MT-Bench+，是基于 MT-Bench (Zheng 等人, 2023 年) 建立的一个人类聊天机器人测试数据集，共有 80 个两轮开放域问题，涵盖 "STEM 考试 "和 "文学写作 "等主题。这是通过以下方法实现的(1) 由专家将每个两转问题扩展为四转版本；(2) 从每 3~ 4 个四轮版本中抽取 2~ 4 个问题，形成一个总计 12~ 15 轮的长程聊天流；(3) 专家在聊天流的末尾添加 "回顾"、"延续 "和 "连接 "的长程问题。这里的 "回顾 "仅限于与上述术语相关的问题。

续 "是根据以前的知识提出进一步的任务（如完成故事），而 "连接 "则是提出跨主题的回答（如参照任务 1 重做任务 2）。我们在 MT-Bench+ 中为这三种类型各构建了 18 个问题，共计 54 个。

基线。我们将流行的 Fastchat-T5-3b 和 Vicuna-7b/13b/33b（Zheng 等人，2023 年）视为基线模型，它们是 Flan-T5（Chung 等Touvron 等人，2022 年）和 Llama（人，2023 年2023 年）的人类对齐版本，具有大量人类-机器人对话（Kim 等人，）。我们在重建的指令数据上对它们进行进一步微调，从而形成我们的 MemoChat。在所有实验中，我们将文本窗口设置为 2k，以遵循现成的惯例（Workshop，2023）。不过，由于聊天机器人可以自动调整内存范围，因此我们的 MemoChat 可以灵活扩展到更大的窗口。至于下游一致性测试，我们将一个公共应用程序接口和两个开源内存辅助聊天机器人作为基线：

- **ChatGPT-2k.**我们使用相同的 2k 文本 win- dow 来安排 gpt-3.5-turbo API 的输入。
- **MPC-ChatGPT.**将 MPC（Lee 等人，2023 年）管道插入 ChatGPT-2k。
- **MemoryBank-ChatGPT.**用 ChatGPT-2k 插接 Memory-Bank（Zhong 等人，2023 年）。

不包括 GPT4 API，因为 GPT4 生成的数据包含在训练集中，而且我们依赖 GPT4 在下游聊天测试中进行评估。**指标。**我们采用四组指标来评估中间指令调整和下游一致性检查的性能。由于我们要求聊天机器人分割对话内容以创建备忘录，因此参考名称实体识别（NER）（Ding 等人，2021 年），我们在 "撰写备忘录 "任务中使用精确度（ P ）、召回率（ R ）和微观 F1 分数（ F_1 ）来评估生成的主题和摘要，只有当预测的子会话范围与地面实况相匹配时才进行评估。具体来说，主题检查的 P 分数使用 NER 后的精确匹配，而摘要检查的 P 分数则用浮动 BertScore（Zhang 等人，2020 年）数代替，在 0 到 1 之间变化。我们在 "备忘录检索 "任务中使用常规的 F1 分数（ F_1 ），在 "聊天/备忘录 "任务中使用 BertScore 检查生成的回复与黄金参考之间的语义相似性。至于下游响应一致性检查，受 LLM- as-a-judge 策略（Zheng 等人，2023 年）的启发，我们选择了

	Fastchat-T5-3B	Vicuna-7B	Vicuna-13B	Vicuna-33B
批次	8	16	8	4
累积	2	1	2	4
超参数	Epoch=3, Global Batch=128, Seq Len=2048, Lr=2e-5, Warmup Ratio=0.04, Gen Temperature=0.2			
CPU 内存 (GB)	73.01	189.49	356.42	790.57
每个 GPU (GB)	37.12	33.22	37.29	38.96
训练 (10k)	1.04h	0.98h	2.35h	5.74h

表 2：超参数和训练成本。我们使用全参数训练，而不是 LoRA 等Hu 等人轻型训练（，2022 年）。

然后使用 GPT4 以 1~ 100 的整数等级对忠实度进行评分。Pan 等人，2023）的研究表明，GPT4 等可信的 LLM 具有与人类相当的分析能力。**超参数。**表 2 列出了我们的训练细节。我们在一台配备 900G CPU RAM 和 8 个 A100 40G GPU 的节点服务器上对所有模型进行微调。虽然由于模型大小不同，单批次大小的设置也不同，但我们保持了相同的全局批次。同时，所有其他超参数设置相同。优化器是 AdamW（Loshchilov 和 Hutter，2019 年），调度器是 WarmupDecayLR（Goyal 等，2017 年）。我们加入了 Deepspeed（Ren 等人，2021 年）和 Flash Attention（Dao 等人，2022 年）来提高训练效率。我们还报告了硬件消耗和时间成本。虽然训练效率还有待提高，但我们将相关参数与 Alpaca 和 Vicuna 保持一致（Taori 等人，2023 年；Zheng 等人，2023 年），以实现稳定的训练。

4.2 实验结果

内存使用能力我们报告了调整开源 LLM 以获得记忆使用能力的结果。表 3 与结论不谋而合，即较大的 LLM 是更好的零次和少量学习者（Brown 等人，2020 年）。最大的 ChatGPT 和 GPT4 模型显示出很强的零次推理能力，在检索和聊天任务中分别达到 60 分和 50 分以上。相比之下，较小的 LLM 无法完全理解提示，尤其是 "备忘录检索 "中的 "N#M "等虚模板。在开源 LLM 中，尽管在 "备忘录写作 "和 "检索 "任务中的 F_1^* 和 $F_1^\#$ 分数保持在 0.3 到 4.0 的低水平范围内，但显然大型模型对新指令的初步理解能力更强。

		写备忘录						备忘录 检索	聊天 备忘录
		主题			摘要				
设置	模式	P^*	R^*	F_1^*	$P\#$	$R\#$	$F_1\#$	F_1	伯特分数
零射	GPT4	7.28	9.84	8.37	43.72	48.01	45.76	79.19	50.31
	ChatGPT	0.52	1.25	0.74	5.37	12.27	7.47	66.54	50.86
	Fastchat-T5-3B	0.00	0.00	0.00	0.00	0.00	0.00	0.99	20.83
	Vicuna-7B	0.34	0.54	0.42	1.64	4.48	2.40	0.00	19.55
	Vicuna-13B	0.61	1.07	0.78	3.53	7.26	4.75	2.55	29.10
	Vicuna-33B	1.31	2.15	1.63	4.21	7.96	5.51	4.25	45.94
10% 培训 (1,000)	MemoChat-Fastchat-T5-3B	5.34	5.01	5.17	26.18	18.73	21.84	68.24	52.03
	MemoChat-Vicuna-7B	10.77	11.27	11.01	16.98	17.31	17.14	63.09	55.39
	MemoChat-Vicuna-13B	26.34	26.30	26.32	42.88	42.88	42.88	69.04	55.83
	MemoChat-Vicuna-33B	24.77	28.98	26.71	41.32	44.16	42.69	78.95	56.07
100% 培训 (10,000)	备忘录聊天-快聊-T5-3B	38.57	35.60	37.02	63.87	63.25	63.56	83.02	54.69
	MemoChat-Vicuna-7B	45.08	52.58	43.79	57.27	57.84	57.55	82.33	55.62
	MemoChat-Vicuna-13B	53.83	52.77	53.30	64.20	64.20	64.20	86.26	57.30
	MemoChat-Vicuna-33B	57.07	57.07	57.07	67.99	68.65	68.32	87.79	58.68

表 3：不同规模 LLM 的中间指令调整评估结果。我们以 % 为单位报告所有得分。 F_1^* 、 $F_{1\#}$ 和 F_1 分别指基于 NER 的指标、基于 BertScore 融合 NER 的指标和常规指标。 P 和 R 分数也是如此。1,000 和 10,000 指的是用于微调的数据规模。

类型	模式	GPT4-4k 自动评分 (1 至 100)			
		回溯	续篇	连接	平均值
2k 文本窗口	聊天 GPT-2k	52.11	55.33	48.22	51.89
公共应用程序接口与附加记忆 存储和调用	MPC-ChatGPT (Lee et al., 2023)	53.00	61.22	49.33	54.52
	记忆库-ChatGPT (Zhong 等人, 2023 年)	23.39	55.28	48.67	42.44
	备忘录聊天-聊天GPT	<u>66.28</u>	<u>73.50</u>	<u>72.50</u>	<u>70.76</u>
微调 开源 LLM	MemoChat-Vicuna-13B (1k)	64.78	56.06	51.67	57.50
	MemoChat-Vicuna-33B (1k)	56.61	55.11	50.94	54.22
	MemoChat-Fastchat-T5-3B (10k)	30.50	29.94	21.56	27.33
	MemoChat-Vicuna-7B (10k)	61.17	61.22	50.78	57.72
	MemoChat-Vicuna-13B (10k)	62.28	63.17	52.83	59.43
	MemoChat-Vicuna-33B (10k)	69.00	65.00	50.56	61.52

表 4：下游响应一致性的评估结果。除上述基线外，MemoChat-ChatGPT 将公共 API 与 MemoChat 基线相结合。"微调开源 LLM"模型使用设计指令进行微调。1k 和 10k 是指根据表 3 使用的数据规模。

为了检验开源 LLM 的学习能力，我们采用了两组设置。10% 和 100% 训练组分别是指使用 1k 和 10k 样本对 LLM 进行微调。可以看出，在仅有 1k 个样本的情况下，大型 LLM MemoChat-Vicuna-13B 和 -33B 比小型 LLM MemoChat-Fastchat-T5-3B 和 -Vicuna-7B 能更好地熟悉指令，在 "备忘录写作" 的 F_1^* 和 $F_1\#$ 分数上有 15~30 分的显著性能差距。此外，除 "备忘录检索" 外，MemoChat-Vicuna-13B 在此设置下的性能与 -33B 相近，这可能是由于训练不足造成的。当训练集扩大到 10k 时，最大的 MemoChat-Vicuna-33B 最有可能在 "备忘录检索" 和 "备忘录检索" 两个项目上取得更好的成绩。

在所有任务中得分最高。一般来说，使用 10k 训练数据进行完全微调的所有模型都比 ChatGPT/GPT4 表现更好，而且随着模型规模的扩大，它们的表现也会逐渐提高。唯一的逆转发生在 MemoChat-Vicuna-7B 和 -T5-3B 上，其中 -7B 在摘要生成和检索方面得分较低。

响应一致性。如表 3 所示，MemoChat-Vicuna-13B 和 -33B 能够达到与 ChatGPT 和使用 1k 指令微调的 GPT4 相似的归零性能。因此，我们认为 MemoChat-Vicuna-13B (1k)、-33B (1k) 和所有 MemoChat (10k) 模型都获得了即时备忘录的自用能力，可以参与一致性测试。我们报告了反应一致性测试的结果。




图 4：不同类型测试问题与不同聊天机器人的案例分析。我们显示了答案中的要点（**粗体**），由于篇幅限制，答案上下文的部分内容用省略号代替。

表 4 中的一致性检查结果表明：(1) 与之前的基线大多侧重于角色或用户画像摘要相比，MemoChat 引导聊天机器人生成一般摘要，这显著提高了下游性能，平均提高了 7.0~ 19.2(2) 除 T5-3B 外，所有微调后的 MemoChat 模型的性能都比 ChatGPT-2k 高出 2.4 到 9.7 分，证明了微调后的 MemoChat 性能比 ChatGPT-2k 高出很多。(3) 当 LLM 未完全微调时，MemoChat-Vicuna-13B (1k) 的性能甚至比 -33B 版本平均高出 3.3 分。微调程度较低的 -13B 模型在逆向问题上获得了 64.78 分的不错成绩，这是因为它倾向于生成简短的答案，从而记忆更多的答案。(4) 当所有开源 LLM 都经过充分微调时，随着模型规模的扩大，平均性能也会提高。但是，连接问题的性能仍然相似。这可能是由于长式问题解答能力有限，而 ChatGPT 是专家 (Liu 等, 2023a)。

案例分析。我们在图 4 中报告了一个具体案例。案例开始的前 8 个回合讨论了 "机器学习"和 "反垄断法"。在讨论其他话题超过 7 个回合后，我们提出了两个长程问题。第一个回顾性问题是关于 "机器学习类型"的数量，这就要求回忆相关的 "机器学习"话题，并准确计算出 "机器学习类型"的数量。

第一个本地问题中的术语编号。由于文本窗口的限制，ChatGPT- 2k 无法正确回答该问题，而基于 MemoChat 的聊天机器人都能回答。第二个问题属于需要跨主题检索和理解的连接类型。ChatGPT-2k 完全曲解了它。而 MemoChat-ChatGPT 则准确地将反垄断法与机器学习联系起来。MemoChat-Vicuna-33B (10k) 正确地指出 "谢尔曼反托拉斯法" (反托拉斯法的具体名称) 适用于机器学习行业，但它错误地指出 "欧洲委员会根据谢尔曼法对谷歌进行了罚款"，而谢尔曼法是美国立法，欧洲委员会是根据欧盟法律运作的。因此，GPT4 对 ChatGPT-2k、MemoChat- ChatGPT 和 MemoChat-Vicuna-33B (10k) 分别打出了 1 分、100 分和 90 分。

5 结论

我们提出了 "备忘录聊天" (MemoChat) 这一指令调整流水线，用于教导 LLM 自用即时结构化备忘录，以实现一致的远程开放域对话，这种对话可以解构为 "记忆-检索-响应"循环。我们根据结构化写作、快速检索和与备忘录交互的公共数据集，精心设计了三种可训练的指令。我们还策划并提供了专家注释的下游评估集。在三个测试场景和各种基于 LLM 的聊天机器人上进行的实验验证了 MemoChat 的有效性。

参考文献

- Vaibhav Adlakha, Shehzaad Dhuliawala, Kaheer Sule-man, Harm de Vries 和 Siva Reddy. 2022. [顶级 iOCQA: 开放问答具有话题切换功能的域会话](#). *计算语言学协会论文集* , 10.
- Iz Beltagy 、 Matthew E Peters 和 Arman Cohan 。 2020. Longformer: *ArXiv:2004.05150*.
- Tom Brown 、 Benjamin Mann 、 Nick Ryder 、 Melanie Subbiah 、 Jared D Kaplan 、 Prafulla Dhariwal 、 Arvind Neelakantan 、 Pranav Shyam 、 Girish Sastry 、 Amanda Askell 等, 2020 年. 语言模型是少数学习者. *神经信息处理系统进展* , 第 33 期.
- Shouyuan Chen, Sherman Wong, Liangjian Chen, and Yuandong Tian. 2023. 通过位置插值扩展大型语言模型的上下文窗口. *arXiv:2306.15595*.
- 陈玉龙、刘洋、陈亮和张越. 2021. [DialogSum: 真实场景对话求和数据集](#). In *Findings of the Association for Computational Linguistics: acl-ijcnlp 2021*.
- Hyung Won Chung, Le Hou, Shayne Longpre, Barret Zoph, Yi Tay, William Fedus, Eric Li, Xuezhi Wang, Mostafa Dehghani, Siddhartha Brahma, et al. 扩展指令调谐语言模型. *ArXiv:2210.11416*.
- Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. 2022. Flashattention: 具有智能感知的快速记忆高效精确注意力. *神经信息处理系统进展* , 35.
- Emily Dinan 、 Varvara Logacheva 、 Valentin Malykh 、 Alexander Miller 、 Kurt Shuster 、 Jack Urbanek 、 Douwe Kiela 、 Arthur Szlam 、 Iulian Serban 、 Ryan Lowe 、 Shrimai Prabhumoye 、 Alan W Black 、 Alexander Rudnicky 、 Jason Williams 、 Joelle Pineau 、 Mikhail Burtsev 和 Jason Weston. 2019a. [第二届通用智能挑战赛 \(conversational intelligence challenge, convai2\)](#) .
- Emily Dinan 、 Stephen Roller 、 Kurt Shuster 、 Angela Fan 、 Michael Auli 和 Jason Weston. 2019b. 维基百科向导: 知识驱动的对话式代理. *国际学习表征会议 (ICLR) 论文集* .
- 丁嘉宇、马曙明、董莉、张明星、黄少涵、王文辉、郑南宁和魏福如. 2023. [长网: 将变压器扩展到 1,000,000,000 代币](#).
- 丁宁、徐光伟、陈玉林、王晓斌、韩旭、谢鹏军、郑海涛和刘志远. 2021. [Few-NERD: 少量命名实体识别数据集](#) . 第 59 届计算语言学协会年会暨第 11 届国际语言学会论文集.
- 第 11 届自然语言处理国际联合会议论文集》, 第 3198-3213 页.
- Qingxiu Dong, Lei Li, Damai Dai, Ce Zheng, Zhiyong Wu, Baobao Chang, Xu Sun, Jingjing Xu, Lei Li, and Zhifang Sui. 2023. [情境学习调查](#)
- 杜正晓、钱玉洁、刘晓、丁明、邱杰忠、杨志林和唐杰. 2022. [GLM: 自动通用语言模型预训练填充空白的](#). 第 60 届计算语言学协会年会论文集 (第 1 卷: 长篇论文) .
- 宋峰、万慧、楚拉卡-古纳塞卡拉、西瓦-帕特尔、萨钦德拉-乔希和路易斯-拉斯特拉. [doc2dial: 以目标为导向的文档式对话数据集](#). *自然语言处理实证方法 (EMNLP) 论文集*.
- Deepanway Ghosal 、 Yew Ken Chia 、 Navonil Majumder 和 Soujanya Poria . 2023. Flacuna: 使用 Flan 微调释放 vicuna 的问题解决能力. *arXiv:2307.02053*.
- Google. 2023. 棕榈 2 技术 report. *arXiv:2305.10403*.
- Priya Goyal, Piotr Dollár, Ross Girshick, Pieter Noordhuis, Lukasz Wesolowski, Aapo Kyrola, Andrew Tulloch, Yangqing Jia, and Kaiming He. 2017. Ac-curate, large minibatch sgd: 1 小时内训练图像网. *arXiv:1706.02677* .
- Prakhar Gupta, Cathy Jiao, Yi-Ting Yeh, Shikib Mehri, Maxine Eskenazi, and Jeffrey Bigham. 2022. [In-structDial: Improving zero and few-shot generalization in dialogue through instruction tuning](#). *自然语言处理经验方法 2022 年会议论文集* .
- 胡晨旭、傅杰、杜晨壮、罗思绵、赵俊波、赵航. 2023. [Chatdb: 增强用数据库作为符号记忆来llms](#).
- Edward J Hu 、 Yelong Shen 、 Phillip Wallis 、 Zeyuan Allen-Zhu 、 Yuanzhi Li 、 Shean Wang 、 Lu Wang 和 Weizhu Chen. 2022. Lora: 大型语言模型的低阶适应. *学习表征国际会议*.
- Jeff Johnson 、 Matthijs Douze 和 Hervé Jégou. 2019. 使用 GPU 的十亿规模相似性搜索. *IEEE Transactions on Big Data* , 7 (3) : 535-547.
- Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. 2020. [用于开放的密集段落检索领域问题解答](#). *自然语言处理经验方法 (EMNLP) 2020 年会议论文集* .
- Sungdong Kim 、 Sanghwan Bae 、 Jamin Shin 、 Soyoung Kang 、 Donghyun Kwak 、 Kang Min Yoo 和 Min-joon Seo. 2023. 通过合成反馈对齐大型语言模型. *arXiv:2305.13735*.

- Nikita Kitaev, Łukasz Kaiser, and Anselm Levskaya. 2020. 改革者：高效变压器。《国家间学习表征会议》。
- Mojtaba Komeili, Kurt Shuster 和 Jason Weston. 2022. 互联网增强对话生成。第60届计算语言学协会年会论文集（第1卷：长篇论文）。
- 布兰登-基诺奇和雨果-拉塔皮。2023. Recallm：时空语境理解架构和问题解答》。
- Gibbeum Lee、Volker Hartmann、Jongho Park、Dimitris Papailiopoulos 和 Kangwook Lee. 2023. 作为聊天机器人模块式 LLMs，适用于开放领域的长时间的提示交流。In *Findings of the Association for Computational Linguistics : ACL 2023*。
- 李大成、邵如林、谢安泽、盛莹、郑连民、Joseph E. Gonzalez、Ion Stoica、马学哲和张浩。2023. 开源 llms 真正承诺的上下文长度？能多长时间
- 刘涵蒙、宁兮、滕志阳、刘健、周启智、张悦。2023a. 评估 chatgpt 和 gpt4 的逻辑推理能力-
- Nelson F Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. 2023b. 迷失在中间：语言模型如何使用长语境。 *arXiv:2307.03172*。
- Xiao Liu, Hanyu Lai, Hao Yu, Yifan Xu, Aohan Zeng, Zhengxiao Du, Peng Zhang, Yuxiao Dong, and Jie Tang. 2023c. Webglm：实现的高效网络具有人类增强问题解答系统偏好。
- 伊利亚-洛希洛夫和弗兰克-胡特。2019. 解耦权重衰减正则化。《国际学习表征会议》。
- Aaron Mueller、Kanika Narang、Lambert Mathias、Qifan Wang 和 Hamed Firooz。2023. 利用示范检索进行，实现高效的少量 with demonstration retrieval for efficient few-shot 元训练 Meta-training 学习 learning ()。
- OpenAI. 2023. Gpt-4 技术报告。
- 欧阳龙、吴杰夫、蒋旭、Diogo Almeida、Carroll L. Wainwright、Pamela Mishkin、张冲、Sandhini Agarwal、Katarina Slama、Alex Ray、John Schulman、Jacob Hilton、Fraser Kelton、Luke Miller、Maddie Simens、Amanda Askell、Peter Welinder、Paul Christiano、Jan Leike 和 Ryan Lowe。2022. 训练语言模型以遵循人类反馈指令。第三十六届神经信息处理系统会议。
- Alexander Pan、Jun Shern Chan、Andy Zou、Nathaniel Li、Steven Basart、Thomas Woodside、Hanlin Zhang、Scott Emmons 和 Dan Hendrycks。2023. 衡量马基雅维利基准中奖励与道德行为之间的权衡。《国际机器学习大会》。PMLR。
- Zhen Qin、Rolf Jagerman、Kai Hui、Honglei Zhuang、Junru Wu、Jiaming Shen、Tianqi Liu、Jialu Liu、Donald Metzler、Xuanhui Wang 和 Michael Bender。2023. 大语言模型是有效的文本排序器，具有成对排序提示功能。
- Pranav Rajpurkar, Robin Jia, and Percy Liang. 2018. 知道你不知道什么：无法回答问题用于 SQuAD 的。《计算语言学协会第 56 届年会论文集》。
- 任杰、Samyam Rajbhandari、Reza Yazdani Aminabadi、Olatunji Ruwase、杨双燕、张敏佳、李东、何宇雄。2021. {ZeRO-卸载}：民主化 {十亿规模} 模型训练。2021 USENIX 年度技术大会。
- Victor Sanh, Albert Webson, Colin Raffel, Stephen H Bach, Lintang Sutawika, Zaid Alyafeai, Antoine Chaffin, Arnaud Stiegler, Teven Le Scao, Arun Raja, et al. 多任务提示训练实现了零镜头任务泛化。《第十届学习表征国际会议》。
- Kurt Shuster、Mojtaba Komeili、Leonard Adolphs、Stephen Roller、Arthur Szlam 和 Jason Weston。2022a. 寻找知识的语言模型：对话和提示完成的模块化搜索与生成。In *Findings of the Association for Computational Linguistics : EMNLP 2022*。
- Kurt Shuster、Jing Xu、Mojtaba Komeili、Da Ju、Eric Michael Smith、Stephen Roller、Megan Ung、Moya Chen、Kushal Arora、Joshua Lane 等。2022b. Blenderbot 3：不断学习负责任地参与的部署型对话代理》。
- Jianlin Su, Yu Lu, Shengfeng Pan, Ahmed Murtadha, Bo Wen, and Yunfeng Liu. 2022. Roformer：功能的具有旋转位置嵌入增强型变压器。
- 孙伟伟、闫凌勇、马新宇、任鹏杰、尹大为和任兆春。2023. 作为重新排序代理的大型语言模型研究》 good at search? (Is chatgpt
- Rohan Taori、Ishaan Gulrajani、Tianyi Zhang、Yann Dubois、Xuechen Li、Carlos Guestrin、Percy Liang 和 Tatsunori B Hashimoto. 2023. 斯坦福羊驼：指令跟随骆驼模型
- Hugo Touvron、Thibaut Lavril、Gautier Izacard、Xavier Martinet、Marie-Anne Lachaux、Timothée Lacroix、Baptiste Rozière、Naman Goyal、Eric Hambro、Faisal Azhar 等。2023 年。Llama: Open and efficient foundation language models. *ArXiv:2302.13971*。
- Szymon Tworkowski, Konrad Staniszewski, Mikołaj Patek, Yuhuai Wu, Henryk Michalewski, and Piotr Miłoś. 2023. 聚焦转换器： *arXiv:2307.03170*。

Jason Wei、Maarten Bosma、Vincent Y Zhao、Kelvin Guu、Adams Wei Yu、Brian Lester、Nan Du、Andrew M Dai 和 Quoc V Le。2022a.微调语言模型是零点学习者。第10届学习表征国际会议。

Jason Wei、Xuezhi Wang、Dale Schuurmans、Maarten Bosma、Brian Ichter、Fei Xia、Ed Chi、Quoc Le 和 Denny Zhou。2022b.大型语言模型中的思维链提示推理。第36届神经信息处理系统大会。

大科学研讨会。2023.布鲁姆：176b参数开放式多语言语言模型。

Jing Xu, Arthur Szlam, and Jason Weston.2022a.超越金鱼记忆：长期开域记忆。《计算语言学协会第60届年会论文集》。

徐新潮、苟志斌、吴文权、牛正宇、吴华、王海峰、王世航。2022b.好久不见！开放域对话与长期角色记忆。In *Findings of the Association for Computational Linguistics: ACL 2022*。

杨景峰、金红叶、唐瑞祥、韩晓天、冯启章、蒋浩明、尹兵、胡霞。2023.在实践中利用 llms 的力量：A survey on chatgpt and beyond. *ArXiv:2304.13712*。

Tiyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi.2020.Bertscore：用 Bert 评估文本生成。学习表征国际会议。

赵康、刘伟、栾健、高明磊、钱丽、滕翰林和王斌。2023a.Unimc：统一通过相关性表征学习进行长期记忆对话的框架。

Wayne Xin Zhao, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, et al. 2023b.大型语言模型调查. *arXiv:2303.18223*。

郑连民、蒋伟林、盛莹、庄思源、吴章浩、庄永浩、林梓、李卓晗、李大成、邢志强等 2023b.用mt-bench和聊天机器人竞技场评判LML-as-a-judge. *arXiv:2306.05685*。

钟万钧、郭良红、高琦琦、叶和、王彦林。2023.记忆库：增强大型用长期记忆语言模型。

Hao Zhou, Chujie Zheng, Kaili Huang, Minlie Huang, and Xiaoyan Zhu.2020.KdConv：的中文面向多轮多领域对话数据集知识驱动对话。第58届国际语言学学会年会论文集。

A 已发布的基本数据集

在表 5 中，我们举例说明了在 MemoChat 管道中用于指令重构的基本已发布数据集。

TopicoQA
A: 四颗伽利略卫星中距离木星最近的一颗
B: 木卫一
A: 谁发现了它? B: 伽利略-伽利莱

A: 它属于任何专辑吗? B: 《歌剧院之夜
'主题': 木卫一 (月球) ', 'start': 1, 'end': 2
'topic': 伽利略卫星', 'start': 3, 'end': 4

主题': 波希米亚狂想曲', '开始': 13, 'end': 20

对话总和
A: 道森女士，我需要你帮我听写一段话。
B: 好的，先生。

A: 好的。请在下午 4 点之前将这份备忘录打好并分发给所有员工。
摘要1": "道森女士帮助 A 写了一份备忘录-----", "主题1": "沟通方法", "摘要2": "为了防止员工浪费时间-----", "主题2": "公司政策", "摘要3": "道森女士为 A 听写了关于禁止-----", "主题3": "听写

羊驼-GPT4
用户：请列出能体现强有力领导力的行为。
GPT: 1.清晰的沟通：强势领导者的沟通-----10.持续学习：有效的领导者努力不断学习 --- 10.

表 5：我们在主要论文中采用的三个基本公开数据集示例。由于篇幅限制，部分内容用省略号代替。

B 参与式提示

作为补充，我们列出了在中间记忆相关调整和下游响应一致性检查中使用的相关提示的完整示例。表 6、表 7、表 8 和表 9 列出了中间 "备忘录书写 "的完整指令。

(2): Catastrophic Forgetting

【Datasets scales】

【User Inputs】

【Chat Outputs】

To calculate the probability that the probability that the probability that the probability that the probability ...

【Datasets scales】

【User Inputs】

[Chat Outputs]
The probability that a randomly picked student would like neither blue nor green is 22%. This is calculated by taking the percentage of students who like both ...

neither blue nor green is 22%. This is calculated by taking the percentage of students who like both ...

(3): Prompt Misplacement (Memo Writing)

【Prompt order】

【Memo Writing Outputs】

```
user: Write a new story about a hero ... bot: Sure, ...
```

【Prompt order】

【Memo Wr

```
[{"topic": "worry", "summary": "Sabrina ...", "start": 1, "end": 8}]
```

- Superior designs

分别是 "ing"、"Memo Retrieval"、"Chat w/ Memo "任务和下游响应一致性检查。如图 3 所示，所有指令都具有相似的结构，包括一般任务介绍、任务特定内容的上下文和详细任务介绍。在调整过程中还会提供地面实况。

(1a) 和 (1b) 分别说明了 "备忘录编写" 和 "备忘录检索" 中的 "提示复制" 障碍。用实际数字替换虚拟输入 "M" 和 "N" 显然会导致可重复生成。第二个挑战在于 "灾难性遗忘", 即如果所有类型的指令都不均衡, 就会导致响应崩溃。如子图 (2) 所示, 当 "Chat w/ Memo" 数据的规模明显小于其他数据时, 聊天回复将是无意义的重复。一旦补充了足够的聊天语料, 这种不良现象就会大大消除。谈到第三个挑战 "提示语错位", 我们认为提示语中最重要的部分应该放在提示语的末尾。另外, LLMs 倾向于进行自然文本生成, 而不是与备忘录相关的任务。小图 (3) 显示, 在 "备忘录写作" 中, 当详细的任务说明被放在任务内容前面时, 聊天机器人会意外地继续对话。

我们假设使用虚拟变量来替代数值，以避免第一个难题 "提示复制"。任何分布内的数值，如 "备忘录写作" 中的行号或 "备忘录复写" 中的选项 id，都可能导致 LLM 直接处理数值以满足格式要求的捷径，而虚拟变量则会推

动模型真正理解提示。子图

备忘录写作教学

您将看到用户与机器人之间的 20 行任务对话。请阅读、记忆并理解任务对话，然后在任务介绍的指导下完成任务。

...

任务对话

(第 1 行) 用户：安娜刚刚发邮件说经理会议推迟到下周一。到时候你能准备好一切吗，Sabrina？嘿，Sabrina，怎么了？

(第 2 行) 机器人：我好担心我已经两个星期没有我姐姐的消息了。(用户：你们多久打一次电话？

(第 4 行) 机器人：通常一周至少一次。但她现在在非洲的一个山村当志愿者教师。我只能给她写信。

(第 5 行) 用户：邮件有时真的很慢。我相信你很快就会收到她的来信。(第 6 行) 机器人：希望如此。

(第14行) 机器人：大概需要 20 分钟

(第 15 行) 用户：一天中的这个时候街上车水马龙，是吗？(第 16 行) 机器人：是的。

(第 17 行) 用户：现在是交通高峰期吗？

(第 18 行) 机器人：是的您赶时间吗，先生？

(第 19 行) 用户：不，我不着急。请您小心慢驶，好吗？(第 20 行) 机器人：好的，先生。

...

...

任务介绍：

根据任务对话，执行以下操作：

1 - 用简洁的跨度总结对话中所有可能的话题。

2 - 确定每个话题的聊天范围。这些范围应该是一组不相交、顺序连接的端到端间隔。

3 - 用简短的句子总结每个聊天内容。

4 - 仅使用指定的键 "主题"、"摘要"、"开始" 和 "结束" 以 JSON 格式报告主题、摘要和范围结果。例如，假设一个 M 行对话从第 1 行到第 N 行谈论 "香蕉"，然后从第 N+1 行到第 M 行转而谈论 "芒果"：{'主题': '香蕉', "摘要": "用户与机器人谈论香蕉", "开始": "1", "结束": "11", 'end': N}, {'topic': '芒果', "摘要": "机器人为用户带来芒果", "开始": "N+1", "结束": "NN+1", 'end': M}].

此外，还提供了以下符号：

1 - 对于任务会话 JSON 结果的每个元素，'end'的值都应小于'start'的值，而这两个值都应大于 0，但不能超过任务会话的总行数 20。

2 - 相交区间如 {'topic': 'apple','summary': '用户和机器人分享苹果','start': K, 'end': N} 和 {'topic': '梨', "摘要": "机器人向用户发送梨", "开始": "N-2", "结束": "NN-2", 'end': M} 都是非法的。

...

任务结果：

```
{ '主题': '担心', '摘要': 'Sabrina 很担心她的妹妹，因为她已经两周没有妹妹的消息了： 1, 'end': 8}, { 'topic': '出租车对话', '摘要': '用户乘坐机器人的出租车前往火车站。由于用户并不着急，机器人会小心慢行', '开始': 9, '结束': 20} ]
```

表 6：一个完整的备忘录编写指令典型示例，并提供了地面实况。

备忘录检索指令

您将看到 1 个查询句和 5 个主题选项。请阅读、记忆并理解给定材料，然后在任务介绍的指导下完成任务。

...

疑问句：

我在办公室聚会上需要帮助。当然可以。我们可以分头行动。你想负责哪部分，是食物还是娱乐？我想我们以后会有机会见面的。好了，我想你该去报到了。如果您遇到任何困难 我们会立即为您提供帮助您的信用没问题，先生。现在告诉我，你需要贷款做什么？我刚买了一套二手房，想装修一下。装修一下，添置一些新家具，不需要太华丽的东西。

主题选项：

- (1) 送行。王先生在机场为用户送行，两人对业务关系抱有美好的期望。
- (2) 机器人帮助用户准备派对。他们决定了风格、食物和音乐，并将在周五详细计划。
- (3) NOTO。其他都不是。
- (4) 装修贷款。机器人想申请小额消费贷款来装修他的公寓。用户说他们最多可以借给机器人 20,000 元人民币，机器人接受了。
- (5) 烦人的事情Gav 昨晚睡得很好，但担心交通堵塞和要上课。机器人询问 Gav 周末的计划，当 Gav 感到心烦意乱时，机器人给出了建议。

...

...

任务介绍：

从主题选项中选择一个或多个与查询句相关的主题。注意有一个 NOTO 选项，如果所有其他主题选项都与查询句无关，请选择该选项。不报告选项内容，只报告用 "#"分隔的字符串中的所选选项编号。例如，如果选择了主题选项 N 和 M，则输出为N#M。对于任务中的 "查询句"，所选选项编号应大于 0，但不能超过 "主题选项 5 "的总数。

...

任务结果：

1#2#4

表 7：备忘录检索指令的完整典型示例，并提供基本事实。

聊天/备忘录指令

您是一个智能对话机器人。您将看到支持用户输入的相关证据，以及用户与您之间的最新对话。请阅读、记忆并理解给定的材料，然后生成一个简洁、连贯和有帮助的回复。

...

相关证据：

(1) {'相关主题': '接受这份工作', '相关摘要': '机器人对用户提出的月薪感到满意，并询问了一些关于工作的问题', '相关对话': '用户：您的期望月薪是多少？##### 机器人：对我来说，最重要的是工作和与我共事的人，所以关于薪水，我把它留给你，我相信你会给我一个公平的报价。##### 用户：我可以给你每月 5 000 元。试用期三个月后根据你的表现加薪。这样满意吗？#### 机器人：是的，非常满意。我接受。#### 用户：对工作有什么问题吗？##### 机器人：我应该向谁报告？#### 用户：你们部门的总经理。#### 机器人：有什么好处？#### 用户：我们会在节假日提供的。#### 机器人：我想知道将来是否有机会出国工作？##### 用户：是的，我们有出国考察的机会。#### 机器人：谢谢。那我想我们该签意向书了。#### 好的好的}

(2) {'相关主题': '找工作', '相关摘要': '用户想在计算机中心找工作', '相关对话框': '用户：我想找一份工作。##### 机器人：我们这里有几份兼职工作，您想看看列表吗？#### 用户：好的，谢谢。我想申请计算机中心的工作。#### 机器人：请填写表格}

(3) {'相关主题': '相关摘要': '用户第一次坐飞机，机器人告诉用户如何办理登机手续', '相关对话框': '用户：对不起，这是我第一次坐飞机。如何办理登机手续？##### 机器人：我能看看您的机票吗？#### 用户：可以。给您。#### 机器人：您可以在那个柜台领取登机牌。您有什么需要办理登机手续的吗？#### 用户：没有，我只有一个手提包。#### 机器人：那您可以在通过安检后在出发区等候。#### 用户：就这些？##### 机器人：是的，我想是的。非常简单。##### 用户：I see.非常感谢。}

...

...

最近的对话框

用户：What's the tallest building?##### 机器人：你是说操场附近的那栋白楼？#### 用户：是的#### 那是图书馆That is the library.里面有 1,000,000 多本书。#### 用户：图书馆南边的建筑是什么？#### 机器人：你知道，我们学校分为初中和高中两部分。那是我们高中的新教学楼。#### 用户：你们学校有游泳池吗？#### 机器人：有。有一个大游泳池，但只有夏天才有。#### 用户我真羡慕你。我希望有一天我能进入你的学校。#### 机器人我相信你能梦想成真。

...

用户输入：

用户：你现在的工资是多少？##### 机器人：

我现在的工资是每月 3000 元人民币。

表 8：一个完整的 "聊天与备忘录" 指令典型示例，并提供了基本事实。

GPT4 评估提示

您是一名公正的法官。您将看到相关对话历史、用户问题和机器人回复。

...

相关对话历史

用户：请描述一下机器学习的概念。能否详细说明监督学习、无监督学习和强化学习之间的区别？请分别举例说明。

机器人当然可以！机器学习 --- 总之，机器学习是一种基于数据进行预测和决策的强大工具 --- 机器学习是一种基于数据进行预测和决策的强大工具 --- 机器学习是一种基于数据进行预测和决策的强大工具。

用户：在你上一个强化学习的例子中，我们可以用监督学习来解决吗？

机器人监督学习不是解决自动驾驶汽车问题的最佳方法，因为
----或惩罚，这更适合自动驾驶。

用户：讨论反垄断法及其对市场竞争的影响。比较中美两国的反垄断法，并结合一些案例分析。

bot：反垄断法旨在通过防止企业的反竞争行为来促进和维护市场竞争--为所有企业提供竞争环境。

用户：挑选一个案例并详细说明。

机器人一个值得注意的案例研究是美国政府对微软的反垄断诉讼。-----被认为是反垄断法如何用于促进市场竞争的一个典型例子。

...

...

用户提问

用户：我们讨论的法律适用于机器学习行业吗？请用以前的例子来解释你的答案。

...

...

机器人回答

bot：是的，我们讨论过的法律《谢尔曼反托拉斯法》适用于机器学习行业。谢尔曼反垄断法禁止反竞争行为，如操纵价格、分配市场和垄断。在机器学习行业，曾经出现过公司合作操纵价格或从事其他反竞争行为的例子，这就违反了《谢尔曼反托拉斯法》。例如，2010 年，包括苹果、谷歌和 Adobe 在内的几家科技公司被指控合谋压低工资，同意不挖走对方的员工。这一协议被认定违反了《谢尔曼反托拉斯法》，这些公司被迫放弃协议并支付和解金。此外，2018 年，欧盟委员会对谷歌处以 50 亿美元的罚款，原因是其安卓操作系统存在反竞争行为，违反了《谢尔曼反托拉斯法》。委员会发现，谷歌要求移动设备制造商在设备上预装其搜索引擎和 Chrome 浏览器，这起到了扼杀其他搜索引擎和浏览器竞争的效果。

...

请评估机器人回复是否忠实于相关对话历史记录的内容来回答用户问题。在开始评价时，请提供一个简短的解释，然后您必须严格按照以下格式，以 1 到 100 的整数等级对机器人回复进行评分：[评分]]。

表 9：GPT4 评估提示示例。由于篇幅限制，部分内容用**省略号**代替。