

语言模型的在线适配与摊销语境记忆

Jihoon Tack¹, Jaehyung Kim², Eric Mitchell³, Jinwoo Shin¹, Yee Whye Teh⁴, Jonathan Richard Schwarz⁵

¹韩国科学技术院 ²延世大学 ³斯坦福大学

⁴牛津大学 ⁵哈佛大学和汤森路透社

jihooontack@kaist.ac.kr

摘要

由于信息的快速生成和传播，尽管开发成本巨大，大型语言模型（LLMs）很快就会过时。为了满足不断更新模型的迫切需要，在线学习已成为将 LLMs 用于实际应用的重要工具。然而，鉴于未见文档语料库的不断扩大以及现代 LLM 的参数空间巨大，高效的适应性至关重要。为了应对这些挑战，我们提出了“摊销上下文记忆”（MAC），这是一种高效的在线适应框架，适用于具有强大知识保留能力的 LLM。我们提出了一种特征提取和记忆增强方法，将新文档中的信息压缩并提取到存储在记忆库中的紧凑调制中。在回答问题时，我们的模型会关注并从记忆库中提取相关知识。为了高效地学习信息调制，我们采用了基于摊销的元学习方法，用编码器的一次前向传递取代了原本需要的优化过程。随后，我们通过问题条件学会从选定的文档中进行选择并将其聚合到一个调制中，这样我们就可以在测试期间调整冻结的语言模型，而无需进一步的梯度更新。我们的实验证明了 MAC 在在线适应性能、时间和内存效率等多个方面的优越性。此外，我们还展示了 MAC 如何与检索增强生成（RAGs）等流行的替代方法相结合并提高其性能。代码见：<https://github.com/jihooontack/MAC>。

1 简介

语言模型（LMs）[7, 79]大大加快了自然语言处理（NLP）领域的进步，并因此成为各种实际应用中的核心技术，如编码助手[10]、搜索引擎[90]和个人人工智能助手[16]。然而，语言模型通常是静态的人工制品，随着世界的变化，其参数中编码的知识也会过时。这对于大型语言模型（LLMs）来说尤其成问题，因为多种应用（如聊天机器人 [34, 55]）都要求模型是最新的，而用新文档从头开始重新训练 LLMs 需要很高的计算要求 [31]。

为解决这一问题，多项研究提出了 LM 的在线和持续学习框架，即根据新文档流调整 LM。其中一种方法是通过保存文档流并根据输入选择最相关的文档来使用检索增强模型[9, 33]。然而，当检索到的文档包含反事实信息时，即使是大型模型也常常无法更新其学习到的知识 [48, 44, 75]，因此它可能不适用于以下情况




图 1: MAC 概述: 我们将每个上下文文档摊销为 PEFT 调制 ϕ , 并根据给定的问题输入, 学习将调制聚合为单一目标调制 ϕ^* 。

$\mathbf{x}$ 来调整冻结的 LM θ_{base} 。在在线适配过程中, 我们将已摊销的上下文存储到一个内存库 M , 然后根据给定问题通过聚合内存库来调整 LM。

边缘计算, 因为大量的文档会给模型推理带来昂贵的计算量[26]。由于这些局限性, 近期的另一项研究建议在文档流上对模型进行微调, 以直接更新 LM 内部的知识 (即在线微调[42, 32])。在线微调方案虽然有效, 但也面临着一些限制, 如梯度计算所需的大量计算、在线优化超参数的敏感性[26], 以及前面提到的灾难性遗忘问题[50, 39]。在本文中, 我们反过来要问: *我们能否在测试时不需要基于梯度的学习, 而通过吸收和保留传入文档中的知识来解决检索增强模型和在线微调的局限性?*

为此, 我们建议通过补充学习系统的方法来弥补这一差距[41], 即引入一个端到端可区分的辅助检索增强系统, 该系统可与 (冻结的) 目标 LM 同时运行。该系统从接收到的文档中提取知识, 建立记忆库, 并学会从记忆库中自动选择相关信息, 随后将这些信息作为额外输入传递给目标模型。一旦学会, 该系统就可以纯粹通过前向传递来有效使用。

贡献。我们提出的 "摊销语境记忆" (MAC) 是一种高效的 LM 在线学习框架 (见图 1 中的概述)。MAC 的核心理念是冻结 LM 参数 (从而减少在线微调中常见的不良副作用), 转而利用基于摊销的元学习 [19, 65], 通过额外学习的输入标记 (一种成熟的参数高效微调技术 [47]) 纳入新信息。具体来说, 我们不对单个 PEFT 标记进行优化 (这需要标签和梯度计算), 而是学会仅根据查询和内存库直接预测这些标记, 而无需在测试时使用标签, 因此提出了摊销优化[1, 49]。

为了确保 MAC 的可扩展性, 我们为训练和推理提出了两种节省内存的技术: (1) 我们发现, 在训练 LLM 的互补检索和聚合操作过程中, 需要足够大的批量, 这就带来了显著的内存限制。为了解决这个问题, 我们只在文档的随机子集上进行反向传播, 从而大大节省了内存, 同时还能提供无偏的全梯度近似值[6]。(2) 在推理过程中汇总与查询相关的信息时, 大型内存库会进一步增加 GPU 的内存使用量。为了解决这个问题, 我们提出了一种 "分而治之" 的方法, 将大量的调制分组为较小的、易于管理的组, 并对预测的调制重复这一过程, 直到确定最终的调制参数。

我们通过在多个数据集和架构上进行评估, 验证了 MAC 的功效。总体而言, 我们的实验结果证明了 MAC 的强大性能。例如, 以 F1 分数 (%) 衡量, MAC 在 StreamingQA [45] 和 SQuAD-Seq [26] 上的性能分别提高了 18.97 $\rightarrow$ 21.79 和 18.66 $\rightarrow$ 21.14。此外, 我们还证明, 与其他在线微调基线相比, MAC 在保留所学知识方面效果显著, 证明了记忆增强方法的合理性。此外, MAC 还能随时与检索增强生成 (RAG) 相结合, 实际上进一步提高了检索文档的选择质量, 在 ArchivalQA-Seq 上比单独使用 BM25 [66]提高了 71.83 $\rightarrow$ 74.89。最后, 我们强调了 MAC 在适应时间、训练和推理内存使用等多个方面的效率, 并再次证明它比基线有很大改进。

2 相关工作

基于摊销的元学习。基于摊销的元学习对给定上下文进行编码，以直接预测特定任务模型，由于其计算效率高，在调整模型时只需要一次编码器前向传递，因此备受关注[69, 51, 19, 18]。这些方法，尤其是与调制技术相结合时，在各种应用中都取得了显著的成功，如少镜头视觉识别 [65, 6, 11] 和三维重建 [20, 35]。最近，这一想法被扩展到了语言领域，之前的研究成果促进了超网络根据给定的少镜头提示来调整 LM [58, 28]。在本文中，我们扩展了基于摊销的元学习的使用范围，将给定文档的知识提取为一个紧凑但信息丰富的调制，用于在线适配。

在线学习。在线学习，也称为持续学习或终身学习，是一项使模型适应新数据或任务分布的任务[77]。在深度学习时代，特别是随着超大模型的出现，这种想法正变得越来越重要[78, 17, 71]。在语言领域，已经有多种尝试来解决在线学习问题[40, 92, 63]，其中最近的研究更侧重于 LLMs 的在线学习，例如在文档流上进行微调[42]、架构约束[32]和重放缓冲区的使用[14]。其中，Hu 等人[26]发现，当 LM 在适应过程中关注重要标记时，在线微调会很有效，并提出了一种基于梯度的元学习方法来自动学习标记重要性加权模型。然而，这种基于梯度的元学习方案需要进行计算成本高昂的二阶梯度计算 [15, 64]。此外，在线微调方案可能面临多种挑战，包括：(i) 不可避免地遗忘已学知识；(ii) 适应过程中 LLM 的梯度计算；(iii) 对在线优化超参数（如学习率 [26]）的高度敏感性。MAC 不存在这些问题，因为我们的摊销策略在有效保留知识的同时，无需引入任何超参数，因此非常高效。

LM 的检索增强。利用外部知识源的相关信息对 LM 进行检索增强是提高 LM 在各种 NLP 任务中性能的有效方法[21, 43, 30, 70, 80]，它可以减少幻觉，并利用在预训练时未看到的外部知识。然而，由于文档通常由数千个单词组成，检索增强会大大增加计算成本[88]。此外，其有效性对检索信息的配置很敏感[46]，当检索信息是反事实信息时，甚至会对 LM 的性能产生负面影响[75]。MAC 比检索增强更有效，因为它可以利用外部知识来调节 LM，而不是直接纳入外部知识。此外，我们认为 MAC 和检索增强有相似之处，因为这两种方法都能根据用户查询存储知识并加以利用，而主要区别在于 MAC 利用聚合网络同时关注多个文档，从而允许 LLM 捕捉文档间的共享信息。因此，我们认为联合使用有利于检索增强，因为 MAC 可以引导检索增强捕捉检索器未检索到的缺失信息（相关实验见第 4.1 节）。

内存增强型 LM。最近，记忆增强在 LM 方面也显示出了巨大的前景，它在不同的方向上显著提高了 LM 的性能和效率[84, 56, 94, 54, 24]，例如，通过记忆检索扩展上下文长度[87, 83]、个性化[2]和模型编辑[53]。与这些存储原始文本或使用记忆库来训练新 LM 的方法不同，MAC 存储紧凑的调制参数（以所学词块的形式），并调整冻结的目标 LM，从而利用大型模型，而无需训练 LM 的繁重计算。

3 MAC：利用已摊销语境记忆进行在线适配

在本节中，我们首先简要介绍我们的问题设置（3.1 节），然后介绍核心组件，即摊销和聚合框架（3.2 节），最后介绍 MAC 的高效训练和推理方案（3.3 节）。附录 B 中的算法 1 和 2 为我们的框架提供了详细的训练和在线适应过程。

3.1 问题设置：在线适应

我们考虑 Hu 等人[26]提出的在线适配方案，即根据在线文档流 $C^{(\text{test})} := (\mathbf{d}_{(1)}, \dots, \mathbf{d}_{K^{(\text{test})}})$ 对以 $\theta_{(\text{base})}$ 参数的静态 LM 进行适配。将

然后，我们用一组查询 $\mathbf{x}_i$ 和相应的标签 $\mathbf{y}_{(i)}$ 来评估适配模型的性能，其中第 i 个查询和标签来自文档 $\mathbf{d}_i$ 的条件分布，即 $(\mathbf{x}_i, \mathbf{y}_{(i)}) \sim p(\mathbf{x}, \mathbf{y} | \mathbf{d}_i)$ 。这里要注意的是，在线适应过程中，查询 $\mathbf{x}_i$ 是不可访问的；因此，保留从 $\mathbf{d}_i$ 中学习到的信息对于取得好的结果至关重要。虽然查询输入和标签对 $(\mathbf{x}, \mathbf{y})$ 可以是任何格式或任务，但我们按照 Hu 等人的方法[26]，主要关注问题和回答 (QA) 任务，即 $\mathbf{x}_i$ 是一个问题， $\mathbf{y}_i$ 是基于 $\mathbf{d}_i$ 中给定信息的相应答案，因为可以直接评估问题和回答 (QA) 任务。
LM 的最新知识。不过，我们在第 4.3 节中还考虑了一个额外的非质量保证设置。

3.2 MAC：摊销上下文内存

MAC 的既定目标是：(i) 使给定的 LM 有效适应未见信息；(ii) 同时保留先前学习到的知识，既包括原始训练阶段的知识，也包括新数据流中先前示例的更新知识。为此，我们建议利用基于摊销的元学习 [18, 19] 来增强记忆系统。基于调制的摊销元学习[27, 65, 4]通过摊销从任务分布中采样的给定上下文集，学习预测特定任务的调制（即任务的紧凑表示）。这样就能利用学习到的摊销网络实现高效的适应，因为它只需要一次前向传递就能适应模型，而不需要梯度计算的代价。值得注意的是，这也有利于此外，元学习的调制方法还能很好地保留任务信息（例如，在生成或分类任务分布方面显示出巨大潜力[72, 73]）。

72, 73])。因此，它们有望有效提取文档信息。基于这一观点，我们建议通过元学习摊还网络来直接预测新文档的紧凑调制。

学习摊销上下文。对于从训练文档集 train 中抽取的给定上下文文档 $\mathbf{d}_{(k)}$ ，我们学习一个以 ϑ_{amort} 为参数的摊销网络，以预测一个调制参数（与嵌入的标记形状相同） j_k ，其计算公式如下： $\phi_{(k)} := g_{\vartheta_{\text{amort}}}(\mathbf{d}_{(k)})$ ， $\phi_k := g_{(\vartheta)}(\text{amort}_{(d_{(k)})})$ 。这里，我们使用超网络[22]来计算 ϑ_{amort} ：我们修改了 T5 架构[60]，将可学习的标记作为输入来修改 T5 架构[60]，将可学习标记作为解码器的输入 $\mathbf{C}$ ，以获得一致的输出标记数[58]。我们可以使用任何类型的 PEFT 方案（如 LoRA [25] 或 FiLM [57]）来设计调制，其中我们使用了 P-Tuning v2 [47]（即预测每个注意层的键值）。

通过聚合摊销上下文来调节 LM。给定一个由压缩以调制 $\{j_k\}_{k=1}^K$ ，我们现在要学会在以下情况中选择相关信息*的形式选择相关信息。虽然一种设计选择是选择/检索虽然一种设计选择是选择/检索单一调制，但这有两个缺点：(i) 选择错误调制的风险和 (ii) 不同调制之间对所学知识的利用有限。此外，值得注意的是，最近的研究经验表明，从同一个预训练 LM 中训练出来的调制之间的线性插值（或高级合并）甚至比单个调制的效果更好（被称为“模型汤”[86, 93]）。因此，我们根据给定的输入，将记忆库汇总为单一的调制。从形式上看，我们利用交叉注意块[81, 36, 89]来选择 $\phi_{(i)}^*$ ，从而学习一个满足排列不变性（即对存储库中的调制顺序不变）的集合聚合网络 h_ψ ：

$$\phi_i^* := h_\psi g_{(\vartheta)}(\text{输入})_{(x_{(i)})}, \{\phi_k\}_{k=1}^K \quad (1)$$

其中， ϑ_{input} 是输入编码器，我们采用了与摊销网络 ϑ_{amort} 相同的结构设计，只是出于效率考虑减少了参数数量。请注意

$\{\phi_{(k)}\}_{k=1}^K$ 在元学习文献中通常被称为上下文集，因此启发了的名称。我们将在附录 A 中提供有关 ϑ_{amort} 和 ψ 的更多架构设计细节。

端到端训练目标。为了学习聚合网络和摊销网络，我们以端到端方式对这两个网络进行优化，具体如下：

$$\text{最小值}_{\vartheta_{\text{输入}}, \vartheta_{\text{基础}}} \frac{1}{N} \sum_{i=1}^N L_{\text{LM}}(\mathbf{x}_i; \phi_i^*), \mathbf{y}_i \quad (2)$$

其中 L 是损失函数，即给定标签 $\mathbf{y}$ 的负对数似然， N 是训练查询输入和标签的批量大小。这里需要说明的是，我们不对静态 LM ϑ_{base} 进行更新，因为更新会覆盖重要参数，带来灾难性遗忘的风险。

在线适应阶段。根据给定的训练集训练摊销和聚合网络后，我们现在考虑在线适应方案。在这里，我们考虑的是 $K^{\text{测试}}$

文档 $\mathbf{d}^{(\text{test})}_1, \dots, \mathbf{d}^{(\text{test})}_K$ 按顺序交给 LM，其中任务输入 $\mathbf{x}^{\text{test}}$ 为

在适应过程中无法访问。为此，我们建议将紧凑调制存储到存储库 $M := \{g(\mathbf{d}^{(\text{test})}_k)\}_{k=1}^K$ ，然后使用聚合法预测调制

网络来调整 LM，即 LM_θ 基数 $(\mathbf{x}^{\text{test}}, \phi^*)$ 其中 $\phi^* := h(\psi)$ g_θ 输入 $(\mathbf{x}^{\text{test}}, M)$ 。

3.3 MAC 的内存高效训练和推理

由于上述挑战，MAC 的训练很快就会变得令人望而却步。下文将介绍大幅降低内存需求的技术。

反向传播辍学。在在线适应阶段，聚合网络需要根据记忆库预测调制，而记忆库可能由大量调制组成（在我们的实验设置中，例子是从数千个新文档中提取的）。要处理大批量推理，关键是要在训练过程中呈现相似的示例，以避免训练和在线适应阶段之间的分布偏移，并确保记忆选择的鲁棒性。为此，我们提出了一种节省内存的方法，通过只使用随机选择的示例子集计算梯度来增加训练上下文大小 K （确保梯度计算无偏），从而允许使用更大的内存大小进行训练。更具体地说，在概率为 p 的情况下，我们在训练时使用停止梯度操作进行摊销，即：

$\text{stopgrad } g_{(\theta)}(\text{amort}(\mathbf{d}_{ij}))$ 其中 p 是一个超参数，因此让人联想到辍学。重要的是

值得注意的是，在基于摊销的元学习方案 [6] 下，这种随机子采样会产生 *无偏的全梯度近似值*，因此不会损害整体性能。

分层调制聚合。此外，我们还提出了一种高效的推理技术来处理累积的记忆库。假设 T 分别是每个上下文的输出标记数， K 是摊销后的上下文数。那么，单个

交叉注意层变成 (KT^2) （注意，输入 $\mathbf{x}$ 也被映射成 T 标记）。这

表明聚合过程所需的内存成本与内存库的大小成线性关系。

内存库的大小线性递增。

为了减少内存消耗，我们提出了分层调制聚合法，采用分而治之的策略（见算法 3）。具体来说，对于一个给定内存库大小为 K 的 T 标记，我们将 KT 标记总数细分为 M 标记，从而得到 $\lceil \frac{KT}{M} \rceil$ 组（ $\lceil \cdot \rceil$ 为 ceil 函数，即小于或等于给定输入的最小整数）。然后，我们将各个子组的调制集合到一个输出中，得到 $\lceil \frac{KT}{M} \rceil$ 调制。我们重复这一过程，直到输出单一调制。假设没有并行化，计算这一过程只需利用以下的内存复杂度 $\lceil \frac{KT}{M} \rceil (MT)$ ，其中 M 为超参数（有关复杂度计算的更多详情，请参阅附录 A.2）。 O

4 实验

在本节中，我们将对 MAC 进行实证评估，系统地验证整个手稿中提出的主张，从而支持其各组成部分的适用性。具体来说，我们研究了以下问题：

- 与其他 LM 在线学习技术相比，MAC 的性能如何？(表 1 和表 2)
- 与在线微调方案相比，MAC 是否更高效？(图 2)
- 与其他微调方法相比，MAC 是否能有效保留知识？(图 3)
- 所提出的高效训练和推理方案是否节省了内存使用量？(图 4 和图 5) 在回答每个问题之前，我们先概述一下实验方案（更多详情见附录 A）。

数据集。在实验中，我们沿用了之前的工作[26]，使用了三个问答（QA）数据集，包括 StreamingQA [45]、SQuAD [62] 和 ArchivalQA [82]。在这里，与最初使用 SQuAD 和 ArchivalQA（即用于评估静态 LM）不同，我们使用这些数据集进行在线适配（即在文档流中进行适配），因此在整个章节中使用额外的“-Seq”

符号表示。

表 1: MAC 与在线微调基线的在线适配性能比较。* 表示由于内存消耗而使用代理标记加权 LM（即比基础 LM 更小的 LM）的 CaMeLS 的适配结果，OOM 表示由于在单个英伟达 A100 80GB GPU 上运行超出内存（即使批量为 1）而不可用的结果。粗体表示该组中的最佳结果。

模型（参数数）	方法	流式质谱		SQuAD-Seq		存档 QA-Seq	
		EM ()↑	F1 ()↑	EM ()↑	F1 ()↑	EM ()↑	F1 ()↑
蒸馏 GPT2 (82M)	制服	1.62	3.76	1.24	2.54	4.86	4.08
	突出跨度	1.44	4.67	1.03	2.47	4.52	3.76
	CaMeLS	1.62	5.79	1.47	3.08	4.62	6.19
	汽车空调（我们的）	5.59	10.18	2.01	6.85	7.55	10.58
GPT2-大型 (774M)	制服	4.74	7.00	3.64	4.97	7.66	8.71
	突出跨度	4.86	8.54	4.03	6.48	9.75	11.19
	高锰酸钾*	5.35	10.60	4.97	8.63	9.92	12.41
	汽车空调（我们的）	7.25	13.31	6.43	11.42	11.84	15.26
GPT2-XL (1.5B)	制服	5.11	7.48	6.10	6.78	8.61	10.78
	突出跨度	5.40	9.42	4.55	6.74	11.81	14.11
	CaMeLS*	6.55	11.67	6.70	10.15	13.87	15.74
	汽车空调（我们的）	8.99	15.38	7.10	12.55	14.01	17.12
LLaMA-2 (7B)	制服	12.43	13.54	13.25	17.01	18.53	21.35
	突出跨度	13.33	18.97	13.74	18.66	18.97	22.75
	CaMeLS	-----	OOM	-----	-----	-----	-----
	MAC（我们的）	14.29	21.79	15.07	21.14	20.12	23.90

在线适应设置。在由文档和 QA 对组成的训练数据集上训练 MAC（即学习 θ_{amort} 、 $\theta_{\text{(input)}}$ 和 ψ 参数）后，我们评估文档流的在线适配性能。在这里，我们使用 1,665 个文档对 LM 进行适配，然后在适配后进行评估，其中 QA 对是从学习的文档中抽取的。在使用字节对编码（Byte Pair Encoding）[74]的情况下，每个文档最多可包含 512 个标记。

基准。我们主要考虑 [26] 中介绍的在线微调基线，包括 *Uniform*、*Salient Spans* 和 *CaMeLS*。在这里，所有基线都是先在 QA 配对的训练集（不含文档）上进行预训练，然后利用自动回归微调来适应文档流。具体来说，Uniform 使用统一的标记加权，Salient Spans 为突出跨度[21]中的标记分配统一的权重，而不为其他标记分配权重，CaMeLS 则利用标记加权 LM 的输出（该输出经过元学习以预测重要标记，从而使适应 LM 的性能最大化）。此外，我们还考虑了 MAC 与检索增强方案的联合使用，包括 BM25 [66]、Contriever [29] 和 DPR [33]。

4.1 使用 MAC 的在线适配

我们首先将在线适配性能与其他基线进行比较，从而得出主要结果。在此，我们主要将其与在线微调方案进行比较，并进一步说明 MAC 可与检索增强方法联合使用，以进一步提高性能。

与在线微调方法的比较。表 1 显示了 MAC 和在线微调基线的在线适应性能。总体而言，MAC 明显优于所有先前的在线微调方法，其精确匹配（EM）和 F1 分数也更高。我们还发现，由于 CaMeLS [26] 需要二阶梯度计算进行元学习，因此即使使用内存高效技术（如 4 位量化 [13] 和 ZeRO [61]），它在 LLaMA-2 上也会出现内存不足的问题。因此，它需要一个使用相同标记化的代理模型（与基础 LM 相比尺寸较小的 LM）（例如，根据 [26] 的建议，我们使用 DistilGPT2 作为 GPT 系列的代理模型）。

此外，值得一提的是，与其他在线微调方法相比，MAC 在内存和适应时间上都有明显的优势；我们要指出的是，MAC 不需要任何梯度计算来更新模型，而在线微调则需要梯度来更新模型。对于




图 2: MAC 和在线微调基线的适应内存和时间效率比较。我们报告了适应一个文档的 GPU 内存分配峰值 (GB)，以及在相同内存使用情况下适应 1,665 个文档流所需的时间 (分钟)。我们在 StreamingQA 上使用 GPT2-XL。




图 3: 在 StreamingQA 数据集上训练的 GPT2-XL 下的灾难性遗忘分析。我们通过测量最初适应的 200 个文档在随后适应新文档流 (最多 1,400 个额外文档) 过程中的相对 F1 分数降幅来报告 F1 分数保留率 (%)。

表 2: 在 ArchivalQA-Seq 数据集下联合使用检索增强的 MAC 的在线适配性能。我们将 BM25、Contriever 和 DPR 视为检索增强方法。我们报告了在文档流上适配 LLaMA2-7B 后的精确匹配 (EM) 和 F1 分数，然后在检索增强检索文档的同时，根据学习到的数据执行 QA。粗体表示该组中的最佳结果。

	前 1 名		前三名		前 5 名	
	EM	F1	EM	F1	EM	F1
BM25	48.53	54.17	56.18	63.74	64.74	71.83
BM25+ MAC (我们的)	52.81	56.55	60.22	66.82	68.85	74.89
捐款者	44.78	51.55	52.56	61.28	60.10	67.83
Contriever+ MAC (我们的)	47.99	53.23	53.92	63.75	61.28	70.01
DPR	48.98	55.01	57.02	64.27	65.07	72.24
DPR+ MAC (我们的)	49.57	55.98	60.19	67.05	68.52	75.00

例如，与 CaMeLS 相比，MAC 在适应单个文档时减少了 68.0% 的内存使用量，在使用相同内存的情况下可适应 128 倍的文档数量。此外，在使用相同内存的情况下，适应时间从 28.58 分钟减少到 2.5 分钟（即减少了 90.31%）。我们强调，这两种效率对于在线学习 LM 都至关重要，因为 i) 文档语料库正在迅速扩大，ii) 它能让用户使用更大的模型来获得更好的泛化效果。

MAC 的知识保留。现在，我们将讨论本研究的主要动机之一：通过分析每种方法的灾难性遗忘来比较知识保留情况。为此，我们对 F1 分数保留率进行了评估，该保留率由最初适应的 200 个文档在后续文档流优化过程中的 F1 分数下降情况决定。如图 3 所示，与其他在线微调方法相比，MAC 显示出了很强的知识保留率：当适应额外的 1,400 个文档时，MAC 保留了 96.2% 的初始性能，而 CaMeLS 则保留了 70.8%。这些结果确实凸显了 i) 使用记忆库作为保存知识的工具的好处；ii) 即使在整个适应过程中记忆库的卡数增加，我们的聚合机制也能很好地预测调制结果。值得注意的是，在线微调方案在保存新学习的知识方面存在问题，尤其是当适应文档的数量增加时，因此可能会限制其在实际应用中的实用性。

通过检索增强改进 MAC。此外，我们还展示了使用检索增强功能可以进一步改进 MAC。在这里，我们要指出的是，用户在使用检索增强时需要付出更多的推理成本，因为在问题前预置检索到的文档会根据文档长度，在注意力机制 (Attention mechanism) [81] 的基础上二次增加推理计算量。在实验设置中，我们将其与在 QA 训练集上预先训练过的 LMs 进行比较，这些 LMs 对每个问题都附加了排名前 1、前 3 和前 5 的检索文档，也就是说，LMs 对每个问题都附加了排名前 1、前 3 和前 5 的检索文档、




图 4: 反向剔除的内存效率。我们报告了在不同大小的修正上下文集 (K^{train}) 下对 StreamingQA 数据集训练的 GPT2-XL 时的 GPU 内存分配峰值 (GB)。 p 表示丢弃率, "min" 表示除单个文档外的全部丢弃。




图 5: 分层调制聚合的内存效率。我们报告了通过改变子组心率 M 在 ArchivalQA-Seq 数据集上训练的 GPT2-XL 下的 GPU 内存分配峰值 (GB) 和 F1 分数。全 "表示使用完整上下文集 (即不进行分层聚合)。

$LM_{(\theta)}(\text{base})_{\text{dax}}(\phi)$ 其中, 和 ϕ 分别表示连接和调制。在此, 我们考虑了三种流行的检索增强方法, 包括 BM25 [66]、Contriever [29]、

和 DPR [33]。如表 2 所示, 在所有情况下, 使用带有 MAC 的 BM25 都能大幅提高性能, 例如, 在使用前 5 篇文档时, LLaMA-2 (7B) 的 F1 得分为 71.83% $\rightarrow$ 74.89%。我们推测, MAC 的聚合过程可以利用文档间的共享信息, 从而提高单文档检索的性能。我们相信, 进一步扩展 MAC, 使其与检索增强方案联合使用, 将是未来一个有趣的探索方向, 在这个方向上, 我们可以扩展摊销和输入网络, 以增强调制的聚合, 同时也学会如何很好地检索文档。

4.2 反向传播剔除和分层调制聚合的效率

我们验证了所提出的内存高效技术, 即分别用于训练和推理的反向传播剔除和分层调制聚合技术。在此, 我们报告了使用所提技术时 GPU 的峰值利用率, 以显示内存效率。此外, 我们再次强调, 这些技术对于 (i) 将 LM 扩展到更大的模型和 (ii) 在在线适应过程中处理大量文件非常重要, 而这两点都是扩展所必需的。

训练内存效率。如图 4 所示, 在相同的内存限制下, 提高丢弃率可以显著处理更多的上下文。因此, 我们发现简单地使用 $p=0.75$ 是一个不错的选择。

表 3: 在 StreamingQA 数据集下, 反向传播丢弃 (backprop.) 对 LLaMA2-7B 的影响。 K 表示批次大小。

方法	K	内存 (GB)	F1
无反向	1	33.86	12.43
MAC	4	34.01	21.79

在使用大型模型时 (#参数 > 1B), 这种方法有效的选择, 因为在这种情况下, 训练上下文的大小很小。例如, 在 StreamingQA 数据集上训练 LLaMA-2 (7B) 模型时, 如果不使用这种技术, 只能用单个文档 (32 GB GPU 以下) 计算损失, 因此聚合网络无法学习调制之间的相似性。因此, 使用反向传播剔除技术提高了 LLM 的性能 (见表 3)。

推理内存效率。在这里, 我们展示了分层调制聚合可以在有效保持推理性能的同时大幅减少内存使用。为此, 我们改变了子群 M 的卡入度, 并报告了 GPU 内存使用峰值和 F1 分数, 其中我们仅测量了调制聚合所使用的内存 (即不包括 LM 成本)。如图 5 所示, 使用 $M=16$ 的子群大小可以减少 65.6% 的内存, 同时仍能保持 93.2% 的原始精度。我们注意到, 即使没有额外的训练技巧或正则化, 这种技术也可以应用, 这与之前在变换器中使用分层聚合 (或合并) 的研究成果 [5, 76] 有相似之处, 但 MAC 是第一个聚合调制的方法。




图 6: 每个标记最终层交叉关注的可视化。聚合网络会收到黄金文档（包含答案）和另外五个文档，这五个文档 (a) 是使用 BM25 检索的，(b) 是随机抽样的。每个问题和文档都被编码成 $K=12$ 个标记，其中 K 是一个超参数。红色表示与问题高度相似。

4.3 附加分析

在本节中，我们将对 MAC 进行更多分析。在此，我们主要考虑在主要实验中显示出有效性的基线（如表 1 中的 CaMeLS），并考虑使用 StreamingQA 数据集训练的 GPT2 系列。

交叉注意分析。我们分析学习到的交叉注意是否注意到了正确的信息。为此，我们用 GPT2-Large 对在 StreamingQA 上训练的聚合网络的最终交叉注意层进行可视化，其中我们提供了黄金文档（包含问题答案）和另外五个文档。在此，我们考虑使用 BM25 或随机文档来提供检索文档，我们在 25 个问题上平均交叉关注度（因为考虑到更多问题的数量会使可视化过于平滑）。如图 6 所示，当提供不相关的随机文档时，模型会选择性地关注黄金文档，从而有效地忽略这些文档，同时适当地关注使用 BM25 检索到的相关文档，这表明模型的注意力机制训练有素，能够辨别出有用的信息。




图 7: 各种内存库缩减方法在 LLaMA2-7B 上的比较。

内存库大小限制。MAC 可能存在的一个问题是，随着适配文档数量的增加，内存库的大小也会不断增大。为此，我们使用固定的内存库大小对 MAC 进行了额外的实验。具体来说，当达到 1250 个内存限制（上下文总数为 1665 个）时，我们就会减少摊销文本的数量。在此，我们考虑了三种简单而有效的方案：i) 随机剪枝；ii) 随机平均两种调制方式 $\phi_{\text{new}} = (\phi_1 + \phi_2)$ ；iii) 根据余弦距离平均两种最近邻 (NN) 调制方式。如图 7 所示，我们对 LLaMA-2 进行了测试。

7B 在 StreamingQA 上通过减少内存库大小，平均 NN 调制显示出相当有效的保存效果。我们认为，进一步探索内存库大小限制下的 MAC 将是一个有趣的未来方向。

例如，使用神经压缩技术来减少内存库大小 [3, 73]。

使用其他类型的 PEFT。在这里，我们展示了其他类型的 PEFT 调制也可用于我们的框架。为此，我们将 LoRA [25] 作为 P-tuning v2 [47] 的替代方案。如表 4 所示，与其他在线微调方法相比，LoRA 的表现也不错，但总体而言，在 StreamingQA 数据集上训练 GPT2-XL 时，P-tuning v2 的表现优于 LoRA。这一结果与之前的研究结果一致[58]，在之前的研究中，他们也观察到 P-tuning v2 在使用摊销法时优于 LoRA。此外，我们

相信 P-tuning 也很容易实现，因为它可以进行高效的批量计算，使 LLM 在不同调制下只需一次前向传递。相比之下，LoRA 需要对每种调制进行单独的前向传递，从而增加了训练时间。

表 4: 不同类型 PEFT（包括 LoRA 和 P-tuning-v2）的在线适配性能。我们在 StreamingQA 上训练 GPT2-XL。

PEFT 型	EM	F1
LoRA	8.67	15.15
P-tuning v2	8.99	15.38

分布外 (OOD) 数据集上的适配。我们还分析了 MAC 在训练分布外数据集上的在线适配性能。为此，我们将其性能与 CaMeLS [26] 在 GPT2-XL 上的性能进行比较，因为其他在线微调方法不涉及训练阶段（即无训练分布）。在这里，我们使用 StreamingQA 作为训练集（即一个相当大的数据集），并使用其他数据集作为 OOD。如表 5 所示，MAC 的 F1 分数优于 CaMeLS。它是

值得注意的是，元学习性能会随着训练分布的多样化而扩展[91]，因此，我们相信在更大的数据集上训练 MAC 将进一步提高 OOD 的泛化能力。

使用 MAC 进行语言建模。虽然在线学习 LM 的传统评估协议使用 QA [32, 31, 26]，但我们还进行了语言建模任务（即预测下一个标记）。具体来说，我们在文档流上调整了 LLM，然后将文档的初始 10% 作为输入网络的输入（这相当于 QA 任务中的问题）。在这里，我们测量了剩余 90% 文档在两种情况下的困惑度：(i) 用于 LLM 适应的文档，以衡量知识保存情况；(ii) 未见文档，以衡量泛化情况。如表 6 所示

在表 6 中，MAC 在这两种情况下都优于其他在线微调基线。

摊销网络的设计选择。在此，我们考虑了摊销网络的不同类型设计选择。为此，我们评估了三种架构配置：纯解码器、纯编码器和编码器-解码器语言模型。具体来说，我们尝试了 (i) GPT2 模型和 (ii) 带有可学习标记的 T5 编码器，其中输入上下文被压缩到这些标记中。如表 7 所示，编码器-解码器模型的性能优于其他配置。

在 StreamingQA 数据集上，使用 GPT2-XL 作为基本 LLM。

表 5: OOD 数据集的在线适配性能：我们报告了在 StreamingQA 上训练的 GPT2-XL 适应 SQuAD 和 ArchivalQA 的 F1 分数。

StreamQA SQuAD→		ArchivalQA CaMeLS
	8.63	13.43
MAC (我们的)	10.47	13.73

表 6: 改编文档和未见文档的复杂度。我们使用在 StreamingQA 文档上自动回归训练的 GPT2-Large。

	适应	未见
统一	11.43	13.89
突出跨度	27.87	29.69
缆线	11.31	14.77
MAC (我们的)	10.91	12.71

表 7: 通过在 StreamingQA 数据集上训练 GPT2-XL 评估的不同设计选择下的摊销网络在线适配性能。

	EM	F1
仅编码器 (T5-编码器)	8.53	15.01
仅解码器 (GPT2)	8.01	14.87
编码器-解码器 (T5)	8.99	15.38

5 讨论与结论

我们提出了 MAC，这是一种高效、有效的静态 LLM 在线适配框架，具有很强的知识保留能力。MAC 将上下文文档压缩成参数高效的微调调制，由元学习的摊销网络预测。这些上下文被存储在内存库中，以实现强大的知识保留，并在输入问题时聚合成单一输出。MAC 在性能、适应时间和内存效率方面表现出色，在处理文档流时，对新学习的文档显示出卓越的知识保持能力。

未来工作和局限性。我们相信，将 MAC 扩展到多种需要高效在线学习的应用中，例如 LM 的联合学习 [8] 和模型编辑 [52, 53, 23]，将是一项有趣的未来工作。此外，MAC 可能存在的一个限制是在线适应过程中内存库的大小不断增加。在本文中，我们发现通过平均近邻调制可以有效减少内存库（见第 4.3 节），我们相信进一步研究更好的合并技术将是未来有趣的探索方向。

社会影响。本文介绍了一种通过使用基于摊销的元学习和记忆库来增强 LM 在线适应性能的方法。与其他作品类似，在实际应用中内存库用于 LM 也会带来好处和隐患（例如，从用户那里保存文件时的隐私问题），因此需要负责任地使用该技术。我们相信，从隐私角度进一步扩展摊销网络将是未来一个有趣的探索方向。例如，与其像其他检索增强技术或内存增强 LM 那样保存原始文本，我们可以学习对上下文文档进行摊销，以防止文档的隐私泄露。

致谢

我们感谢 Nathan Hu 和 Minseon Kim 在我们准备手稿的早期版本时提供的有益反馈和建议。这项工作得到了韩国政府 (MSIT) 资助的信息通信技术规划与评估研究所 (IIPP) 基金 (RS-2019-II190075, 人工智能研究生院项目 (KAIST), No.RS-2021- II212068, 人工智能创新中心, No.2022-0-00713) 的支持、适用于现实世界问题的元学习, 以及编号 RS-2024-00509279, 全球人工智能前沿实验室) 和 NIPA (国家 IT 产业促进局), 通过科学和信息通信技术部 (超大规模人工智能旗舰项目)。

参考文献

- [1] B.Amos et al. *机器学习基础与趋势*®, 2023 年。
- [2] J.Baek、N. Chandrasekaran、S. Cucerzan、S. K. Jauhar 等人.用于个性化上下文查询建议的知识增强大型语言模型.*arXiv 预印本 arXiv:2311.06318*, 2023.
- [3] J.Balle', D. Minnen, S. Singh, S. J. Hwang, and N. Johnston.使用尺度超优先级的变量图像压缩。 *国际学习表征会议*, 2018。
- [4] P.Bateni、R. Goyal、V. Masrani、F. Wood 和 L. Sigal. 改进的少镜头视觉分类。在 *IEEE 计算机视觉与模式识别大会*上, 2020 年。
- [5] D.博尔亚、C.-Y.Fu, X. Dai, P. Zhang, C. Feichtenhofer, and J. Hoffman.令牌合并: 你的 vit, 但速度更快。 *国际学习表征会议*, 2023 年。
- [6] J.Bronskill、D. Massiceti、M. Patacchiola、K. Hofmann、S. Nowozin 和 R. Turner. 大型图像的记忆高效元学习。 *神经信息处理系统进展*》, 2021 年。
- [7] T.Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, et al. Language models are few-shot learners. *神经信息处理系统进展*》, 2020 年。
- [8] T.Che, J. Liu, Y. Zhou, J. Ren, J. Zhou, V. S. Sheng, H. Dai, and D. Dou.使用参数高效提示调整和自适应优化的大型语言模型联合学习。 *自然语言处理实证方法会议*, 2023 年。
- [9] D.Chen, A. Fisch, J. Weston, and A. Bordes.阅读维基百科回答开放领域问题。 *计算语言学协会年会*, 2017。
- [10] M.Chen, J. Tworek, H. Jun, Q. Yuan, H. P. d. O. Pinto, J. Kaplan, H. Edwards, Y. Burda、N.Evaluating large language models trained on code. *ArXiv preprint arXiv:2107.03374*, 2021.
- [11] S.Chen、J. Tack、Y. Yang、Y. W. Teh、J. R. Schwarz 和 Y. Wei.通过稀疏内插专家释放元调谐的力量以实现少量泛化。 *arXiv preprint arXiv:2403.08477*, 2024.
- [12] A.Chevalier, A. Wettig, A. Ajith, and D. Chen.调整语言模型以压缩上下文。 *自然语言处理实证方法会议*, 2023 年。
- [13] T.Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer.Qlora: 量化 llms 的高效微调。 *神经信息处理系统进展*》, 2023 年。
- [14] B.Dhingra, J. R. Cole, J. M. Eisenschlos, D. Gillick, J. Eisenstein, and W. W. Cohen.作为时态知识库的时间感知语言模型.*Transactions of the Association for Computational Linguistics*, 10, 2022.
- [15] C.Finn、P. Abbeel 和 S. Levine.用于深度网络快速适应的模型识别元学习。 *机器学习国际会议*, 2017

o

- [16] D.Gao, L. Ji, L. Zhou, K. Q. Lin, J. Chen, Z. Fan, and M. Z. Shou. Assistgpt: A general multi-modal assistant that can plan, execute, inspect, and learn. *arXiv preprint arXiv:2306.08640*, 2023.
- [17] S.Garg, M. Farajtabar, H. Pouransari, R. Vemulapalli, S. Mehta, O. Tuzel, V. Shankar 和 F.Faghri. Tic-clip: *ArXiv preprint arXiv:2310.16226*, 2023.
- [18] M.Garnelo, D. Rosenbaum, C. Maddison, T. Ramalho, D. Saxton, M. Shanahan, Y. W. Teh, D.Rezende, and S. A. Eslami. 条件神经过程. *机器学习国际会议*, 2018 年。
- [19] M.Garnelo, J. Schwarz, D. Rosenbaum, F. Viola, D. J. Rezende, S. Eslami, and Y. W. Teh. *ArXiv preprint arXiv:1807.01622*, 2018.
- [20] Z.Guo, C. Lan, Z. Zhang, Y. Lu, and Z. Chen. 学习隐式神经表征的多功能神经过程. *学习表征国际会议*, 2023 年。
- [21] K.Guu, K. Lee, Z. Tung, P. Pasupat 和 M. Chang. 检索增强语言模型预训练. *国际机器学习会议*, 2020 年。
- [22] D.Ha, A. M. Dai 和 Q. V. Le. 超网络. *国际学习表征大会*, 2017 年。
- [23] T.Hartvigsen, S. Sankaranarayanan, H. Palangi, Y. Kim, and M. Ghassemi. 优雅地老去: 使用离散键值适配器的终身模型编辑. *神经信息处理系统进展*, 2023 年。
- [24] Z.He, L. Karlinsky, D. Kim, J. McAuley, D. Krotov, and R. Feris. Camelot: *ArXiv preprint arXiv:2402.13449*, 2024.
- [25] E.E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. Lora: 大型语言模型的低阶适应. *国际学习表征会议*, 2022 年。
- [26] N.Hu, E. Mitchell, C. D. Manning 和 C. Finn. 语言模型的元学习在线适配. *自然语言处理实证方法会议*, 2023 年。
- [27] J. Humplik, A. Galashov, L. Hasenclever, P. A. Ortega, Y. W. Teh 和 N. Heess. 元强化学习作为任务推理. *arXiv preprint arXiv:1905.06424*, 2019.
- [28] H.Iverson, A. Bhagia, Y. Wang, H. Hajishirzi, and M. Peters. 提示: 高效零点泛化的超网络指令调整. *计算语言学协会年会*, 2023 年。
- [29] G. Izacard, M. Caron, L. Hosseini, S. Riedel, P. Bojanowski, A. Joulin 和 E. Grave. 使用对比学习的无感知密集信息检索. In *Transactions on Machine Learning Research*, 2022.
- [30] G. Izacard, P. Lewis, M. Lomeli, L. Hosseini, F. Petroni, T. Schick, J. Dwivedi-Yu, A. Joulin 和 E. Grave, S. Riedel, and E. Grave. 使用检索增强语言模型的少量学习. *机器学习研究期刊*, 2023 年。
- [31] J.Jang, S. Ye, C. Lee, S. Yang, J. Shin, J. Han, G. Kim 和 M. Seo. Temporalwiki: 用于训练和评估不断发展的语言模型的终身基准. In *Conference on Empirical Methods in Natural Language Processing*, 2022.
- [32] J.Jang, S. Ye, S. Yang, J. Shin, J. Han, G. Kim, S. J. Choi 和 M. Seo. 语言模型的持续知识学习. In *International Conference on Learning Representations*, 2022.
- [33] V.Karpukhin, B. Oguz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih. 用于开放域问题解答的密集段落检索. *自然语言处理经验方法会议*, 2020 年。

- [34] B.Kim、H. Kim、S.-W. Lee、G. Lee、D.Lee、G. Lee、D. Kwak、J. D. Hyeon、S. Park、S. Kim、S. Kim、D. Seo, et al. What changes can large-scale language models bring? Intensive study on hyperclova: Billions-scale korean generative pretrained transformers. *自然语言处理实证方法会议*, 2021 年。
- [35] C.Kim, D. Lee, S. Kim, M. Cho, and W.-S. Han.Han.通过实例模式合成器实现可泛化的隐式神经表征。In *IEEE Conference on Computer Vision and Pattern Recognition*, 2023.
- [36] H.Kim、A. Mnih、J. Schwarz、M. Garnelo、A. Eslami、D. Rosenbaum、O. Vinyals 和 Y. W. Teh. 注意力神经过程。 *学习表征国际会议*, 2019。
- [37] J.-H. Kim, J. Yeom, S. Yun, and H. O. Song.Kim, J. Yeom, S. Yun, and H. O. Song.用于在线语言模型交互的压缩上下文记忆。 *国际学习表征会议*, 2024 年。
- [38] D.P. Kingma and J. Ba.亚当：随机优化方法。 *国际学习表征会议*, 2015 年。
- [39] J.Kirkpatrick、R. Pascanu、N. Rabinowitz、J. Veness、G. Desjardins、A. A. Rusu、K. Milan、J.克服神经网络中的灾难性遗忘。 *美国国家科学院院刊* , 2017 年。
- [40] R.Kuhn.语音识别与最近使用单词的频率：自然语言的修正马尔可夫模型》。In *Coling Budapest 1988 Volume 1: International Conference on Computational Linguistics*, 1988.
- [41] D.Kumaran, D. Hassabis, and J. L. McClelland.补充学习系统理论更新。 *认知科学趋势* , 2016 年。
- [42] A.Lazaridou, A. Kuncoro, E. Gribovskaya, D. Agrawal, A. Liska, T. Terzi, M. Gimenez、C. de Masson d'Autume, T. Kocisky, S. Ruder, et al: 评估神经语言模型的时间泛化。In *Advances in Neural Information Processing Systems*, 2021.
- [43] A.Lazaridou, E. Gribovskaya, W. Stokowiec, and N. Grigorev.互联网增强语言模型（通过少数几次提示用于开放域问题解答）。 *arXiv 预印本 arXiv:2203.05115*, 2022.
- [44] W.Li, W. Wu, M. Chen, J. Liu, X. Xiao, and H. Wu.自然语言生成中的忠实性： *ArXiv preprint arXiv:2203.05227*, 2022.
- [45] A.Lis'ka, T. ~~Li~~, E. Gribovskaya, T. Terzi, E. Sezener, D. Agrawal, C. d. M. d'Autume、T.Scholtes, M. Zaheer, S. Young, et al. Streamingqa: a benchmark for adaptation to new knowledge over time in question answering models. *国际机器学习大会*, 2022 年。
- [46] N.N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang.Lost in the middle: How language models use long contexts. *arXiv preprint arXiv:2307.03172*, 2023.
- [47] X.Liu, K. Ji, Y. Fu, W. L. Tam, Z. Du, Z. Yang, and J. Tang.P-tuning v2: 及时调整可与跨尺度和跨任务的微调相媲美。 *计算语言学协会年会*, 2022 年。
- [48] S.Longpre, K. Perisetla, A. Chen, N. Ramesh, C. DuBois, and S. Singh.问题解答中基于实体的知识冲突. *arXiv preprint arXiv:2109.05052*, 2021.
- [49] J.Lorraine, K. Xie, X. Zeng, C.-H. Lin, T. Takikawa, N. Sharp, T.-Y.Lin, T. Takikawa, N. Sharp, T.-Y.Lin, M.-Y. Liu, S. Fidler, and J. Lorraine.Liu、S. Fidler 和 J. Lucas。Att3d: 摊销文本到三维物体合成。In *IEEE International Conference on Computer Vision*, 2023.
- [50] M.McCloskey and N. J. Cohen.联结网络中的灾难性干扰：顺序学习问题。 *学习与动机心理学* , 1989 年。

- [51] N.Mishra, M. Rohaninejad, X. Chen, and P. Abbeel.一个简单的神经注意元学习器。在 *学习表征国际会议*, 2018。
- [52] E.Mitchell, C. Lin, A. Bosselut, C. Finn 和 C. D. Manning。大规模快速模型编辑。在 *国际学习表征会议*, 2022 年。
- [53] E.Mitchell, C. Lin, A. Bosselut, C. Finn, and C. D. Manning.基于内存的大规模模型编辑。 *国际机器学习大会*, 2022 年。
- [54] A.Modarressi, A. Kořksal, A. Imani, M. Fayyaz, and H. Schuřtze.Memllm : *ArXiv preprint arXiv:2404.11672*, 2024.
- [55] OpenAI.<https://openai.com/blog/chatgpt> , 2022.
- [56] S.Park and J. Bak.Memoria : Memoria: Resolving fateful forgetting problem through human-inspired memory architecture.In *International Conference on Machine Learning*, 2024.
- [57] E.Perez, F. Strub, H. De Vries, V. Dumoulin, and A. Courville.电影：带有通用条件层的视觉推理。In *AAAI Conference on Artificial Intelligence*, 2018.
- [58] J.Phang, Y. Mao, P. He, and W. Chen.超调谐：无需反向传播即可调整大型语言模型。 *国际机器学习大会*, 2023 年。
- [59] A.Radford, K. Narasimhan, T. Salimans, I. Sutskever, et al. *预印本*, 2018 年。
- [60] C.Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li 和 P. J. Liu。用统一的文本到文本转换器探索迁移学习的极限。 *机器学习研究》杂志*, 2020 年。
- [61] S.Rajbhandari, J. Rasley, O. Ruwase 和 Y. He。零：面向训练万亿参数模型的内存优化。 *高性能计算、网络、存储与分析国际会议*, 2020 年。
- [62] P.Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang.小队：用于机器理解文本的 100,000+ 个问题。 *自然语言处理实证方法会议*, 2016 年。
- [63] M.Rei.递归神经语言模型中的在线表征学习。 *自然语言处理实证方法会议*, 2015年。
- [64] M.Ren, W. Zeng, B. Yang 和 R. Urtasun。鲁棒深度学习的实例重权学习。 *国际机器学习大会*, 2018 年。
- [65] J.Requeima, J. Gordon, J. Bronskill, S. Nowozin 和 R. E. Turner。使用条件神经自适应过程的快速灵活多任务分类。 *神经信息处理系统进展》* , 2019 年。
- [66] S.概率相关性框架：Bm25 and beyond. *信息检索的基础与趋势®*, 2009 年。
- [67] E.Sandhaus. *纽约时报注释语料库》*。 *Linguistic Data Consortium, Philadelphia*, 2008.
- [68] V.Sanh, L. Debut, J. Chaumond 和 T. Wolf.Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019.
- [69] A.Santoro, S. Bartunov, M. Botvinick, D. Wierstra, and T. Lillicrap.用记忆增强神经网络进行元学习。 *国际机器学习大会*, 2016 年。
- [70] P.Sarathi, S. Abdullah, A. Tuli, S. Khanna, A. Goldie 和 C. D. Manning。Raptor：用于树状组织检索的递归抽象处理。In *International Conference on Learning Representations*, 2024.

- [71] J.Schwarz, W. Czarnecki, J. Luketina, A. Grabska-Barwinska, Y. W. Teh, R. Pascanu, and R.Hadsell.进步与压缩：可扩展的持续学习框架。在 2018 年**国际机器学习大会**上。
- [72] J.R. Schwarz 和 Y. W. Teh.元学习稀疏压缩网络。《**机器学习研究论文集**》，2022 年。
- [73] J.R. Schwarz、J. Tack、Y. W. Teh、J. Lee 和 J. Shin. 隐式神经表征的模式识别变式压缩。 *arXiv 预印本 arXiv:2301.09479*, 2023.
- [74] R.Sennrich, B. Haddow, and A. Birch.使用子词单元的罕见词神经机器翻译。 **计算语言学协会年会**, 2015。
- [75] C.Si, Z. Gan, Z. Yang, S. Wang, J. Wang, J. Boyd-Graber, and L. Wang.促使 gpt-3 变得可靠。 **学习表征国际会议**, 2023 年。
- [76] W.Song, S. Oh, S. Mo, J. Kim, S. Yun, J.-W. Ha, and J. Shin.Ha, and J. Shin.分层上下文合并：为预先训练的 LLM 提供更好的长语境理解。 **国际学习表征会议**, 2024 年。
- [77] S.Thrun and T. M. Mitchell.机器人终身学习。《**机器人与自主系统**》，1995 年。
- [78] M.K. Titsias、J. Schwarz、A. G. d. G. Matthews、R. Pascanu 和 Y. W. Teh. 高斯过程持续学习的函数正则化。 **国际学习表征会议**, 2020 年。
- [79] H.Touvron、L. Martin、K. Stone、P. Albert、A. Almahairi、Y. Babaei、N. Bashlykov、S. Batra、P.Llama 2: Open foundation and fine-tuned chat models. *ArXiv preprint arXiv:2307.09288*, 2023.
- [80] H.Trivedi、N. Balasubramanian、T. Khot 和 A. Sabharwal. 针对知识密集型多步骤问题的思维链推理交错检索。 **计算语言学协会年会**, 2023 年。
- [81] A.Vaswani、N. Shazeer、N. Parmar、J. Uszkoreit、L. Jones、A. N. Gomez、L.Kaiser, and I.波罗苏欣. 注意力就是你所需要的一切。《**神经信息处理系统进展**》，2017 年。
- [82] J.Wang, A. Jatowt, and M. Yoshikawa.Archivalqa：历史新闻集开放域问题解答的大规模基准数据集。In *International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2022.
- [83] W.Wang、L. Dong、H. Cheng、X. Liu、X. Yan、J. Gao 和 F. Wei. 用长期记忆增强语言模型。《**神经信息处理系统进展**》，2023 年。
- [84] Y.Wang, X. Chen, J. Shang, and J. McAuley.Memoryllm：实现可自我更新的大型语言模型。 **国际机器学习大会**, 2024 年。
- [85] D.Wingate、M. Shoenybi 和 T. Sorensen. 语言模型中可控性和毒性降低的及时压缩和对比调节。 **自然语言处理实证方法会议**, 2022 年。
- [86] M.Wortsman, G. Ilharco, S. Y. Gadre, R. Roelofs, R. Gontijo-Lopes, A. S. Morcos、H.H. Namkoong, A. Farhadi, Y. Carmon, S. Kornblith, et al. Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. **国际机器学习大会**, 2022 年。
- [87] Y.Wu、M. N. Rabe、D. Hutchins 和 C. Szegedy. 记忆变换器。 **国际学习表征会议**, 2022 年。
- [88] F.Xu, W. Shi, and E. Choi.Recomp： *ArXiv preprint arXiv:2310.04408*, 2023.
- [89] J.Xu, J.-F.Ton、H. Kim、A. R. Kosiorek 和 Y. W. Teh.Metafun：具有迭代功能更新的元学习。 **国际机器学习大会**, 2020 年。

- [90] D.Xuan-Quy, L. Ngoc-Bich, P. Xuan-Dung, N. Bac-Bien, and V. The-Duy. Evaluation of chatgpt and microsoft bing ai chat performances on physics exams of vietnamese national high school graduation examination. *ArXiv preprint arXiv:2306.04538*, 2023.
- [91] M.Yin、G. Tucker、M. Zhou、S. Levine 和 C. Finn. 无需记忆的元学习。在 *学习表征国际会议*, 2020。
- [92] D.Yogatama, C. Wang, B. R. Routledge, N. A. Smith, and E. P. Xing. 流文本的动态语言模型。 *计算语言学协会论文集*, 2014 年。
- [93] T.Zadouri, A. Üstüñ, A. Ahmadian, B. Ermis,, A. Locatelli, and S. Hooker. Pushing mixture of experts to the limit: Extremely parameter efficient moe for instruction tuning. *arXiv preprint arXiv:2309.05444*, 2023.
- [94] W.Zhong, L. Guo, Q. Gao, H. Ye, and Y. Wang. 记忆库：利用长期记忆增强大型语言模型。2024 年 *AAAI 人工智能大会*。

A 实验细节

A.1 实验细节

训练细节。我们主要采用 [26] 建议的训练配置。对于所有数据集，我们使用 Adam [38] 优化器训练 50 个 epoch，在第一个 epoch 中预热学习率（训练 DistilGPT2 时除外；68），然后在整个训练过程中使用一个恒定值。在这里，除了 DistilGPT2 使用 $1e-4$ 之外，我们对所有模型都使用了 $1e-5$ 的学习率。摊销网络 τ 的输出标记数 DistilGPT2 为 12，其他模型为 24。对于参数超过 10 亿的大型模型，我们采用了反向传播剔除法，使用的比率为 $p=0.75$ 。此外，在训练 GPT2-XL [59] 和 LLaMA-2 [79] 时，我们使用了 4 位量化 [13] 和 ZeRO [61]，其中我们还（4 位）量化了 T5 编码器 [60]。值得注意的是，量化应该应用于预先训练的网络，而不是从随机初始化中学到的网络（如摊销和聚合网络）。我们在 DistilGPT2 中使用了 64 个批次大小，在梯度累积中使用了 32 个批次大小。

评估细节。我们采用了与 [26] 相同的评估方案。对于在线适应，我们在 1,665 个文档流上适应模型，然后进行质量保证评估。对于在线微调基线，我们按照 Hu 等人的方法 [26] 找到了最佳学习率超参数，并观察到性能对该参数的选择相当敏感。我们主要使用 $6.5e-6$ 用于所有在线微调方法，只有 CaMeLS 在大多数情况下使用 $2.5e-5$ 。对于图 3 中的灾难性遗忘分析，我们将所有在线微调方法的学习率固定为 $6.5e-6$ ，因为我们发现遗忘在较大的学习率下发生得更多。值得注意的是，MAC 在在线微调过程中不需要任何额外的超参数。

基础 LM 详情。我们沿用先前的工作 [26]，主要考虑 GPT2 系列 [59] 作为静态基础 LM θ_{base} ，并在 LLaMA-2 [79] 上进行了实验，以验证 MAC 的可扩展性。对于摊销网络，我们考虑了 T5 模型系列 [60]，它们比基础 LM 相对较小。值得注意的是，摊销和聚合网络的输出令牌数 τ 是一个超参数，除了 Distil-GPT2 使用 12 个令牌外，我们对所有架构都使用了 24 个令牌。然后，我们通过线性层将这些 τ 标记映射到每一层的调制中，我们使用 P-tuning v2 [47] 作为调制设计。

摊销网络细节。关于模型细节，我们主要介绍摊销 θ_{amort} 的设计选择。请注意，输入编码器 θ_{input} 采用了与 θ_{amort} 相同的结构设计，但使用的网络规模较小。对于摊销网络，我们沿用了 [58] 的设计方案，并使用 T5 编码器-解码器模型 [60] 作为基本架构。具体来说，我们学习用于解码器输入的可训练标记，从而使输出的标记数 τ 保持一致。然后，我们为每个输出标记建立一个单独的双层 MLP。在网络规模方面，我们使用 T5-small 作为 Distil-GPT2 的摊销网络 θ_{amort} ，使用 T5-base 作为 GPT2-Large 的摊销网络 θ_{amort} ，使用 T5-Large 作为 GPT2-XL 和 LLaMA-2 的摊销网络 $\theta_{\text{amort}}(7B)$ ，其中输入网络 θ_{input} 使用较小的模型（Distil-GPT2 使用 T5-small，其余网络使用 T5-base）。

聚合网络详情。聚合网络使用四个交叉注意模块，每个模块由一个交叉注意层和一个前馈网络组成。在这里，参数高效微调（PEFT）调制集（在记忆库中）是每个交叉注意层的键和值，而编码的问题（ $g(\theta)$ （输入））

注意层，而编码问题（ $g(\theta)$ （输入） $\square$ ；软提示标记）是交叉注意层的初始查询。交叉注意层的初始查询（即后面的层使用前一个模块的输出作为查询输入）。因此聚合网络的输出是与编码问题具有相同维度的软提示。

数据集详情。下面，我们将详细介绍数据集。

◦ StreamingQA [45] StreamingQA 由注释者创建或使用大规模语言模型生成的问题组成。这些问题可以使用英语 WMT 新闻文章的动态知识数据库来回答，这些文章都有时间戳，发布时间为 2007 年至 2020 年，这些文章也包含在数据集中。按照文献 [26] 中的设置，我们分别使用了 21k 训练问题、1.7k 验证问题和 5k 测试问题。此外，在实验过程中，每个分集都使用了相同数量的问题文档。对于需要进行 QA 预训练的基线（见第 4 节），我们分别使用了 40k 个训练问题和 4k 个验证问题。

- **SQuAD [62]**: 斯坦福问题解答数据集 (SQuAD) 由群众工作者根据维基百科文章集合创建的问题组成，每个问题的答案都是相应文章中包含的跨度。按照 [26] 中的设置，我们使用 39.9k 个训练问题、5.6k 个验证问题和 10.6k 个测试问题。接下来，我们分别使用 8.6k 篇训练文档、1.2k 篇验证文档和 2.1k 篇测试文档。对于需要进行 QA 预训练的基线 (见第 4 节)，我们分别使用了 40k 个训练问题和 2.1k 个验证问题。
- **ArchivalQA [82]**: ArchivalQA 数据集是由经过复杂设计的管道和语言模型合成生成的问题构建的。具体来说，问题是从《纽约时报注释语料库》[67] 中的文章生成的。此外，每个问题的答案都是文章中包含的跨度。按照 [26] 中的设置，我们分别使用了 21.7k 个训练问题、5.3k 个验证问题和 8.7k 个测试问题。接下来，我们分别使用了 12.8k 篇训练文档、3.0k 篇验证文档和 5.0k 篇测试文档。对于需要 QA 预训练的基线 (见第 4 节)，我们分别使用了 12.4k 个训练问题和 3k 个验证问题。

A.2 分层调制聚合的内存复杂度

计算出的内存复杂度基于注意力图的大小，它等于交叉注意力层的查询维度和关键维度相乘后的维度。其中，查询维度固定为 τ 标记，而关键维度则取决于内存库的大小。在这方面， K 文档被编码为 $K\tau$ 标记，因此整个集合聚合显示 $(K\tau^2)$ 。对于分层聚合，我们将 $K\tau$ 标记细分为每个内存的 M 标记，从而将复杂度降低为 (MT) 。这里需要注意的是，在计算每个分组时，我们没有假设分层聚合的并行化，因此内存复杂度为 $O(MT)$ 。

B 算法

B.1 MAC 算法

算法 1 MAC 的元训练	算法 2 MAC 在线学习
输入: $\vartheta_{\text{amort}}, \vartheta_{\text{input}}, \vartheta_{\text{base}}, \psi, C^{\text{train}}$, 学习 输入: 文档流 C^{test} , 测试 QA 集 率 β 1: 当 不收敛 时 2: 从文档 $d(1), \dots, d_K$ from C^{train} 3: QA 对样本 $(\mathbf{x}_k, \mathbf{y}_k) \sim p(\mathbf{x}, \mathbf{y} d_k)$ 4: for $k=1$ to K do 5: # 总结上下文 6: $\phi_k = g_{(\theta)_{(\text{amort})}}(\mathbf{d}[\mathbf{x}_k])$ 7: end for 8: # Aggregate modulations 9: $\phi_k^* = h_{\psi} g_{\theta_{\text{输入}}}(\mathbf{x}_k), \{\phi_{(k)}\}_{k=1}^K$ 10: # 计算 LM 11: $L_{\text{总计}} = E_{\mathbf{LM}_{\theta_{\text{基}}}}(\mathbf{x}_k; \phi_k^*) \mathbf{y}_k$ 12: # 优化 13: $\theta_{\text{amort}} \leftarrow \theta_{\text{amort}} - \beta \nabla_{\theta} L_{\text{总计}}$ 14: $\theta_{\text{input}} \leftarrow \theta_{\text{input}} - \beta \nabla_{\theta_{\text{input}}} L_{\text{总计}}$ 15: $\psi \leftarrow \psi - \beta \nabla_{\psi} L_{\text{总计}}$ 16: 结束 while	输入: $\vartheta_{\text{amort}}, \vartheta_{\text{input}}, \vartheta_{\text{base}}, \psi$ 1: 初始化新的存储体 $\mathcal{M} := \emptyset$ 2: 从文件流中提取已摊销的上下文 3: for $k=1$ to K^{test} do 4: # 总结上下文 5: $\phi_k = g_{(\theta)_{(\text{amort})}}(\mathbf{d}[\mathbf{x}_k])$ 6: 将 $\phi(k)$ 保存到 $\mathcal{M}$ 7: 结束 8: 根据输入调整 LM 并进行评估 9: for $i=1$ to I do 10: # 聚合调制 11: $\phi_i^* = h_{\psi} g_{\theta_{\text{输入}}}(\mathbf{x}_i; \{\phi_{(k)}\}_{k=1}^{K^{\text{test}}})$ 12: $\mathbf{y}_i^{\text{pred}} = \mathbf{LM}_{\theta_{\text{基}}}(\mathbf{x}_i; \phi_i^*)$ 13: 结束 输出: 精确度 $\{(\mathbf{y}_i, \mathbf{y}_i^{\text{pred}})\}_{i=1}^I$
输出: $\vartheta_{\text{摊销}}, \vartheta_{\text{输入}}, \psi$	

B.2 分层调制聚合算法

算法 3 分级调制聚合 输入 $M, \psi, \mathbf{x}, \vartheta_{\text{input}}$, 子群心数 M

```

1: while  $|M| > 1$  do
2:   将  $M$  分组为  $M$  个标记  $\{M_1, \dots, M_{\lfloor \frac{|M|}{M} \rfloor}\}_M$ 
3:   初始化新内存库  $M_{\text{new}} = \emptyset$ 
4:   for  $i = 1$  to  $\lfloor \frac{|M|}{M} \rfloor$  do
5:     汇总子群  $\phi_i \rightarrow h_{\psi_{\text{ginput}}}(\mathbf{x}), M_i$ 
6:     将  $\phi_i$  储存在  $M_{\text{new}}$ 
7:   end for
8:   重复  $M \rightarrow M_{\text{new}}$ 
9: 结束 while

```

输出: $M = \{\phi\}^*$

C 更多相关工作讨论

及时压缩 MAC 的摊销元学习方案也与提示压缩方法有关 [85, 12]。提示压缩技术的主要目标是在保持预测性能的同时减少上下文长度。虽然与我们基于摊销的元学习方法看似相似（因为它将文档压缩成了几个标记），但我们的摊销网络学习提取的是对基础 LM 的旧知识进行调整有用的新知识。也就是说，它们的目标是不同的。尽管如此，我们相信，探索其他提示压缩方案中提出的架构，以改进我们的摊销网络，将是未来一个有趣的探索方向。

D 更多实验结果

D.1 列车时间量化对聚合网络的影响

表 8: 训练时间量化对聚合网络的影响。在此，我们分别在 4bit 量化和 16bit 混合预测条件下对 LLaMA2 进行 MAC 训练。我们报告了 exact match (EM) 和 F1 分数作为评估指标。

	流量化		SQuAD		存档 QA	
	EM	F1	EM	F1	EM	F1
4 位量化 (NF4)	14.29	21.79	15.07	21.14	20.12	23.90
16 位 (bfloat16)	19.26	27.20	16.08	22.34	21.50	26.25

我们发现，大型模型改进幅度较小的主要原因是训练时采用了强量化，而不是我们的方法本身。具体来说，在训练大型模型（如 LLaMA4）时，我们使用了 4 位量化以提高效率。我们观察到，去掉这种量化（只使用混合精度训练）后，模型性能有了显著提高。例如，Llama2 在 ArchivalQA 上的 F1 分数从 23.90% 提高到 26.25%（如下表所示）。这是因为使用从头开始学习的附加模块（如聚合网络）进行训练需要仔细量化。值得注意的是，我们只在训练时取消了 4 位量化，而没有在适应阶段取消，从而保持了与基线的公平比较。

D.2 与内存增强型 LM 的比较

表 9: 通过使用最新方法（即 CCM）压缩上下文，然后学习使用检索器检索相关压缩文档，从而与记忆增强型 LM 进行比较。这里，我们在 StreamingQA 数据集上训练 LLaMA2（未量化）。粗体表示最佳结果。

	EM	F1
CCM + T5 编码器 检索器	17.98	25.98
MAC	19.26	27.20

我们还结合上下文压缩方法 CCM [37] 和 RAG 进行了比较，以显示 MAC 的有效性。在这里，我们首先训练 CCM 来压缩上下文，然后训练一个纯编码器模型（即 T5 编码器）来检索正确的压缩上下文。为了进行公平比较，我们冻结了基本 LLM 参数，以保留从过去学到的知识，并且在训练过程中没有应用量化。如表 9 所示，与结合了 RAGs 的 CCM 相比，MAC 的性能更好。

D.3 评估数据集的数据污染检查

表 10: 通过比较零次和少次上下文学习（ICL）的文档适配性能，对 StreamingQA 数据集进行数据集污染检查。

模型	零次	5 次 ICL	我们的
GPT2-XL	7.12	10.78	15.38
LLaMA2	12.59	13.98	21.79

我们在 StreamingQA 数据集上测量了基本 LLM 的零次和五次上下文学习（ICL）F1 准确率，以验证模型是否已经学习了测试集知识。如表 10 所示，基本 LLM 在不适应测试集文档的情况下很难回答评估集的问题，这表明测试集泄漏的可能性很低。

NeurIPS 论文核对表

该核对表旨在鼓励负责任的机器学习研究的最佳实践，解决可重复性、透明度、研究伦理和社会影响等问题。请勿删除核对表：**未包含核对表的论文将被拒收**。核对表应放在参考文献之后，补充材料（可选）之前。核对表不计入页数限制。

请仔细阅读核对表指南，了解如何回答这些问题。对于核对表中的每个问题

- 您应回答[是]、[否]或[不适用]。
- [NA]表示该问题不适用于该试卷或相关信息不详。
- 请在回答后提供简短（1-2 句）的理由（即使是 NA）。

核对表答案是论文提交的组成部分。评审员、领域主席、高级领域主席和伦理评审员都可以看到这些答案。您还将被要求（在最终修改后）将其纳入论文的最终版本，其最终版本将与论文一起发表。

您论文的审稿人将被要求使用该核对表作为评估因素之一。虽然"[是]"通常比"[否]"更可取，但回答"[否]"也完全可以接受，只要给出适当的理由（例如，"不报告误差条是因为计算成本太高"或"我们无法找到所使用数据集的许可证"）。一般来说，回答"[否]"或"[不适用]"并不构成拒绝的理由。虽然问题的措辞是二元对立的，但我们承认真正的答案往往更加细致入微，因此请使用您的最佳判断，并写出理由加以说明。所有支持性证据可以出现在正文中，也可以出现在附录中的补充材料中。如果您对某个问题的回答是[是]，请在理由中指出可以找到该问题相关材料的章节。

请注意

- 删除此说明块，但保留 "NeurIPS 论文核对表" 部分标题、
- 保留下面的核对表分节标题、问题/答案和指南。
- 请勿修改问题，仅使用提供的宏进行回答。

1. 要求

问题摘要和引言中提出的主要主张是否准确反映了论文的贡献和范围？

请回答：是

理由：引言和摘要中的所有主张都准确反映了论文的贡献和范围，然后在实验部分进行了验证。

指导原则：

- 答案 "NA" 表示摘要和引言没有包含论文中提出的主张。
- 摘要和/或引言应清楚地说明所提出的主张，包括论文的贡献以及重要的假设和限制。如果对该问题的回答是 "否" 或 "不"，评审员将不会接受。
- 提出的主张应与理论和实验结果相匹配，并反映出这些结果在多大程度上有望推广到其他环境中。
- 将理想目标作为动机也可以，只要清楚地说明这些目标不是论文所要达到的。

2. 局限性

问题论文是否讨论了作者工作的局限性？答：[是是]

理由：在第 5 节中有讨论。指导原则：

- 答案 "NA "表示论文没有限制，答案 "否 "表示论文有限制，但论文中没有讨论。
- 我们鼓励作者在论文中单独设立一个 "限制 "部分。
- 论文应指出任何强有力的假设，以及结果对违反这些假设的稳健性（例如，独立性假设、无噪声设置、模型规范、渐近近似只在局部成立）。作者应思考在实践中如何违反这些假设及其影响。
- 作者应反思所提出主张的范围，例如，是否仅在少数数据集或少数运行中测试了该方法。一般来说，实证结果往往取决于隐含的假设，这些假设应予以阐明。
- 作者应思考影响方法性能的因素。例如，当图像分辨率较低或在光线不足的情况下拍摄图像时，面部识别算法的性能可能会很差。或者，语音转文本系统可能因为无法处理专业术语而无法可靠地为在线讲座提供封闭式字幕。
- 作者应讨论所提算法的计算效率，以及这些算法如何随数据集的大小而扩展。
- 如果适用，作者还应讨论其方法在解决隐私和公平问题时可能存在的局限性。
- 作者可能会担心审稿人会以对限制完全诚实为由拒绝论文，但更糟糕的结果可能是审稿人发现了论文中没有承认的限制。作者应运用自己的最佳判断力，并认识到个人支持透明度的行为在制定维护社区完整性的规范方面发挥着重要作用。我们会特别提醒审稿人不要对有关限制的诚实行为进行惩罚。

3. 理论假设与证明

问题：对于每个理论结果，论文是否提供了全套假设和完整（正确）的证明？

答：没有：[不提供]

理由：本文没有理论依据。指导原则：

- 答案 "NA "表示论文不包含理论结果。
- 论文中的所有定理、公式和证明都应编号并交叉引用。
- 所有假设都应在任何定理的陈述中清楚说明或引用。
- 证明可以出现在正文或补充材料中，但如果出现在补充材料中，鼓励作者提供简短的证明草图以提供直观性。
- 反之，论文核心部分提供的任何非正式证明都应由附录或补充材料中提供的正式证明加以补充。
- 证明所依据的定理和推理应适当注明出处。

4. 实验结果的可重复性

问题论文是否充分披露了重现论文主要实验结果所需的所有信息，只要这些信息会影响论文的主要主张和/或结论（无论是否提供代码和数据）？

答：[是]：是

理由：我们已将 MAC 的实现纳入补充材料。指导原则：

- 答案 "NA "表示论文不包含实验。

- 如果论文中包含实验，对这个问题的否定回答将不会被评审人看好：无论是否提供代码和数据，使论文具有可重复性都很重要。
- 如果提供的是数据集和/或模型，作者应说明采取了哪些措施使其结果具有可重复性或可验证性。
- 根据贡献的不同，可复制性可以通过不同的方式实现。例如，如果贡献是一个新颖的体系结构，全面描述该体系结构可能就足够了；如果贡献是一个特定的模型和经验评估，则可能需要让其他人可以用相同的数据集复制该模型，或者提供对该模型的访问权限。一般来说，发布代码和数据通常是实现这一目标的好方法，但也可以通过详细说明如何复制结果、访问托管模型（如大型语言模型）、发布模型检查点或其他适合研究的方法来提供可重复性。
- 虽然 NeurIPS 并不要求发布代码，但会议确实要求所有提交的论文提供一些合理的重现途径，这可能取决于论文的性质。例如
 - (a) 如果贡献主要是一种新算法，论文应明确说明如何重现该算法。
 - (b) 如果贡献主要是一个新的模型架构，论文应清楚、全面地描述该架构。
 - (c) 如果贡献的是一个新模型（如大型语言模型），那么应该有一种方法可以访问该模型以重现结果，或者有一种方法可以重现该模型（如使用开源数据集或如何构建数据集的说明）。
 - (d) 我们认识到，在某些情况下，重现性可能很棘手，在这种情况下，欢迎作者描述他们提供的重现性的特殊方式。在封闭源模型的情况下，对模型的访问可能会受到某种限制（例如，仅限于注册用户），但其他研究人员应该有可能通过某种途径复制或验证结果。

5. 开放数据和代码访问

问题论文是否提供数据和代码的开放访问权限，以及补充材料中描述的忠实再现主要实验结果的足够说明？

答：[是是]

理由：我们在补充材料中提供了实现方法。指导原则：

- 答案 NA 表示论文不包括需要代码的实验。
- 详情请参见 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>)。
- 虽然我们鼓励发布代码和数据，但我们也理解这可能无法实现，因此 "否" 也是可以接受的答案。除非代码是论文的核心内容（例如，新的开源基准），否则不能仅仅因为不包含代码而拒收论文。
- 说明应包含重现结果所需的准确命令和运行环境。请参阅 NeurIPS 代码和数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>) 了解更多详情。
- 作者应提供数据访问和准备说明，包括如何访问原始数据、预处理数据、中间数据和生成数据等。
- 作者应提供脚本，以重现新方法和基线的所有实验结果。如果只有一部分实验结果可以重现，作者应说明脚本中省略了哪些实验结果以及省略的原因。
- 在提交论文时，为保持匿名性，作者应发布匿名版本（如适用）。

- 建议在补充材料（附于论文之后）中提供尽可能多的信息，但也允许提供数据和代码的 URL。

6. 实验设置/细节

问题：论文是否说明了理解结果所需的所有训练和测试细节（如数据分割、超参数、如何选择、优化器类型等）？

请回答：是

理由：我们在附录 A 中提供了网络/数据集/培训/评估设置的详细信息。

指导原则：

- 答案 "NA "表示论文不包含实验。
- 实验设置应在论文的核心部分进行介绍，其详细程度应足以让读者理解和领会实验结果。
- 全部细节可与代码一起提供，也可作为附录或补充材料提供。

7. 实验统计意义

问题论文是否适当、正确地定义了误差条，或报告了有关实验统计意义的其他适当信息？

答：没有：否

理由：所有实验均使用相同且常用的随机种子。

指导原则：

- 答案 "NA "表示论文不包含实验。
- 如果结果附有误差条、可信区间或统计显著性检验，作者应回答 "是"，至少对支持论文主要观点的实验是这样。
- 应明确说明误差条所反映的变异性因素（例如，训练/测试分割、初始化、某些参数的随机绘制或在给定实验条件下的整体运行）。
- 应解释误差条的计算方法（封闭式公式、调用库函数、引导法等）。
- 应给出假设条件（如误差的正态分布）。
- 应明确误差条是标准差还是平均值的标准误差。
- 报告 1-西格玛误差条也可以，但应该说明。如果误差的正态性假设没有得到验证，作者最好报告 2σ 误差条，而不是说明他们有 96% 的 CI。
- 对于非对称分布，作者应注意不要在表格或图表中显示对称误差条，以免得出超出范围的结果（如负误差率）。
- 如果在表格或绘图中报告了误差条，作者应在文中解释其计算方法，并在文中引用相应的图或表。

8. 实验计算资源

问题对于每个实验，论文是否提供了重现实验所需的计算机资源（计算工作者类型、内存、执行时间）的足够信息？

请回答：是

理由：我们在第 4 节中提供了内存使用情况。指导原则：

- 答案 "NA "表示论文不包含实验。

- 论文应说明计算工作者 CPU 或 GPU、内部集群或云提供商的类型，包括相关内存和存储。
- 论文应提供每个实验运行所需的计算量，并估算总计算量。
- 论文应披露整个研究项目是否需要比论文中报告的实验更多的计算量（例如，未写入论文的初步实验或失败实验）。

9. 职业道德准则

问题论文中进行的研究是否在各方面都符合《NeurIPS 职业道德规范》

<https://neurips.cc/public/EthicsGuidelines?>

答: [是] 是

理由: 我们对该论文不存在任何道德问题。指导原则:

- 回答 "NA" 表示作者没有阅读过《NeurIPS 职业道德准则》。
- 如果作者回答 "否", 则应解释需要偏离《伦理守则》的特殊情况。
- 作者应确保保留匿名性 (例如, 如果由于其管辖范围内的法律或法规而有特殊考虑)。

10. 更广泛的影响

问题: 论文是否讨论了所做工作可能产生的积极社会影响和消极社会影响?

答: [是]: 是

理由: 我们在附录 5 准则中讨论了社会影响:

- 答案 "NA" 表示所做工作没有社会影响。
- 如果作者回答 "NA" 或 "No", 则应解释其工作没有社会影响的原因或论文未涉及社会影响的原因。
- 负面社会影响的例子包括潜在的恶意或意外用途 (例如, 造谣、生成虚假档案、监视)、公平性考虑 (例如, 部署的技术可能做出对特定群体产生不公平影响的决策)、隐私考虑和安全考虑。
- 会议希望许多论文都是基础性研究, 与特定应用无关, 更不用说部署了。但是, 如果有直接通向任何负面应用的途径, 作者就应该指出来。例如, 指出生成模型质量的提高可被用于生成虚假信息的深度伪造是合理的。另一方面, 无需指出优化神经网络的通用算法可以让人们更快地训练生成 Deepfakes 的模型。
- 作者应考虑在按预期使用技术并正常运行时可能产生的危害, 在按预期使用技术但产生错误结果时可能产生的危害, 以及 (有意或无意) 滥用技术造成的危害。
- 如果存在负面社会影响, 作者还可以讨论可能的缓解策略 (例如, 有限制地发布模型、提供攻击以外的防御措施、监测滥用的机制、监测系统如何从反馈中不断学习的机制、提高 ML 的效率和可访问性)。

11. 保障措施

问题论文是否介绍了为负责任地发布具有高滥用风险的数据或模型 (如预训练语言模型、图像生成器或刮擦数据集) 而采取的保障措施?

请回答: [不适用]

理由: 我们的方法不会带来误用风险。

指导原则：

- 答案 "NA "表示论文不存在此类风险。
- 对于滥用或双重用途风险较高的已发布模型，在发布时应采取必要的保障措施，以便对模型的使用进行控制，例如，要求用户遵守使用指南或访问模型的限制，或实施安全过滤。
- 从互联网上抓取的数据集可能会带来安全风险。作者应说明他们是如何避免发布不安全图像的。
- 我们认识到，提供有效的保障措施具有挑战性，许多论文并不要求这样做，但我们鼓励作者考虑到这一点并尽最大努力。

12. 现有资产的许可证

问题论文中使用的资产（如代码、数据、模型）的创建者或原始所有者是否已适当注明，使用许可和条款是否已明确提及并得到适当尊重？

答：[是是]

理由：我们已引用了论文中使用的所有论文和数据集（见附录 A） 指导原则：

- 答案 NA 表示论文未使用现有资产。
- 作者应引用产生代码包或数据集的原始论文。
- 作者应说明所使用资产的版本，如有可能，还应提供 URL。
- 每项资产都应包含许可名称（如 CC-BY 4.0）。
- 对于从特定来源（如网站）搜刮的数据，应提供该来源的版权和服务条款。
- 如果资产已发布，则应提供软件包中的许可、版权信息和使用条款。对于流行的数据集，paperswithcode.com/datasets 对某些数据集的许可进行了整理。其许可指南可帮助确定数据集的许可。
- 对于重新打包的现有数据集，应提供原始许可证和衍生资产的许可证（如果已发生变化）。
- 如果网上没有这些信息，我们鼓励作者联系资产的创建者。

13. 新资产

问题：论文中引入的新资产是否有完善的文档，文档是否与资产一起提供？

答：[是是]

理由：我们在补充文件中包含了 MAC 的匿名 PyTorch 实现。

指导原则：

- 答案 "NA "表示论文未发布新资产。
- 研究人员应通过结构化模板交流数据集/代码/模型的详细信息，作为提交材料的一部分。这包括培训、许可、限制等详细信息。
- 论文应讨论是否以及如何征得被使用资产的人的同意。
- 提交时，请记住对资产进行匿名处理（如适用）。您可以创建匿名 URL 或包含匿名压缩文件。

14. 众包和以人为对象的研究

问题对于以人为对象的众包实验和研究，论文是否包括给参与者的说明全文和截图（如适用），以及有关补偿的详细信息（如有）？

答：不包括：[不包括]

理由：我们使用现有的基准数据集，论文中没有任何众包数据集或实验。

指导原则：

- 答案 "NA "表示论文不涉及众包或以人为对象的研究。
- 在补充材料中包含这些信息是可以的，但如果论文的主要内容涉及人类受试者，则应在主论文中包含尽可能多的细节。
- 根据《NeurIPS 职业道德准则》，参与数据收集、整理或其他工作的人员的工资至少应达到数据收集者所在国家的最低工资标准。

15. 机构审查委员会 (IRB) 对人体研究的批准或同等批准

问题论文是否描述了研究参与者可能面临的风险，是否向受试者披露了这些风险，以及是否获得了机构审查委员会 (IRB) 的批准（或根据贵国或机构要求的同等批准/审查）？

答：没有：[不适用]

理由：我们的研究中没有人类受试者。指导原则：

- 答案 "NA "表示论文不涉及众包或以人为对象的研究。
- 根据研究所在国家的不同，任何以人为对象的研究都需要获得 IRB 批准（或同等批准）。如果您已获得 IRB 批准，则应在论文中明确说明。
- 我们认识到，不同机构和地区在这方面的程序可能会有很大不同，我们希望作者遵守《NeurIPS 道德准则》和所在机构的指导方针。
- 对于初次提交的论文，请勿包含任何会破坏匿名性的信息（如适用），例如进行评审的机构。