

主动代理：将 LLM 代理从 "被动" 转变为 "主动" 对积极援助的回应

Yaxi Lu¹, Shenzhi Yang², Cheng Qian¹, Guirong Chen⁽²⁾, Qinyu Luo⁽¹⁾, Yesai Wu¹, Huadong Wang⁽¹⁾, Xin Cong⁽¹⁾, Zhong Zhang⁽¹⁾, Yankai Lin⁽²⁾, Weiwen Liu⁽³⁾, Yasheng Wang³,
Zhiyuan Liu¹, Fangming Liu⁴, Maosong Sun⁽¹⁾

¹清华大学计算机科学与技术系

²中国人民大学高岭人工智能学院

³华为诺亚方舟实验室, ⁴鹏城实验室

lyx23@mails.tsinghua.edu.cn, mrlyk423@gmail.com, liuzy@tsinghua.edu.cn

摘要

由大型语言模型驱动的代理在解决复杂任务方面表现出非凡的能力。然而,大多数代理系统仍然是被动的,这限制了它们在需要预见和自主决策的场景中的有效性。在本文中,我们要解决的难题是开发能够在没有明确人类指令的情况下预测和启动任务的主动型代理。针对这一问题,我们提出了一种新颖的数据驱动方法。首先,我们收集现实世界中的人类活动,生成主动任务预测。然后,这些预测会被人类注释者标记为接受或拒绝。标注数据用于训练奖励模型,该模型模拟人类的判断,并可作为 LLM 代理主动性的自动评估工具。在此基础上,我们开发了一个全面的数据生成管道,创建了一个包含 6,790 个事件的多样化数据集 ProactiveBench。最后,我们证明了利用所提出的 ProactiveBench 对模型进行微调可以显著提高 LLM 代理的主动性。实验结果表明,我们的微调模型在主动提供援助方面取得了 66.47% 的 F1 分数,优于所有开源和近源模型。这些结果凸显了我们的方法在创建更主动、更有效的代理系统方面的潜力,为未来人类-代理协作的进步铺平了道路。¹

1 引言

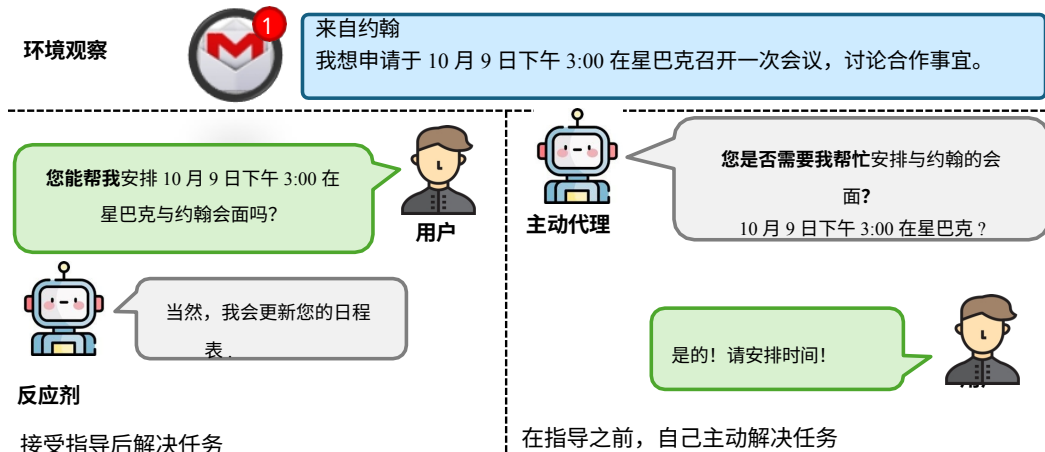


图 1: 两种人机交互类型的代理系统比较。反应型代理被动地接收用户询问,然后生成回复。主动型代理根据环境观察结果推断任务,并提出相应的协助请求。

¹ 我们的代码和数据见 <https://github.com/thunlp/ProactiveAgent>。

大型语言模型（LLM）（如 ChatGPT [1]）的出现极大地推动了自主代理[2, 3, 4, 5]的发展。这些基于 LLM 的代理可以理解人类指令、制定计划、探索环境和利用工具来解决复杂的任务 [5, 6]，并在机器人 [7]、个人助理 [8] 和流程自动化 [9] 等。各种应用中显示出巨大的潜力

目前，大多数现有的基于 LLM 的代理主要在被动范式下工作：它们需要明确的人类指令来启动任务完成，并在用户指令提示之前保持休眠状态以提供服务[10]。这种模式限制了它们在没有人类直接指令的情况下主动协助和自主提供服务的能力。我们认为，**基于 LLM 的代理应该是积极主动的，能够通过理解和响应环境来自主启动任务**。例如，如图 1，所示被动型代理应等待用户的明确指令来执行任务，如 "显示未读邮件" 或 "安排与约翰会面"。与此相反，主动型代理会自动预测自己的任务，注意到约翰建议会面的电子邮件，并自动提出安排会面。这种情境感知能力[11]使主动型代理能够解读信号，并在没有明确人类指令的情况下主动提出和执行任务。因此，它不仅能大大减轻用户的认知负担，还能识别人类未明确表达的潜在需求。因此，主动代理可以为用户提供更全面、更无缝的服务。

在这项工作中，我们提出了一种新颖的数据驱动的形式化方法，用于消除开发一种主动型代理，它能预测用户的需求，并通过建议任务或提供信息来发挥主动性。我们的方法以构建 ProactiveBench 为中心。我们的方法以构建 ProactiveBench 为核心、

这样，我们就能评估和改进代理的主动行为。首先，我们从三个方面收集真实世界中的人类活动数据：编码、写作和日常生活。这包括但不限于用户键盘和鼠标输入、剪贴板内容、浏览器活动等。然后，我们建立了一个 LLM 驱动的健身房，以生成反映我们所收集的原始真实语境的事件。我们在 12 个场景中总共获得了 233 个事件，作为 ProactiveBench 的测试集。为了进一步完善基于 LLM 的代理的主动行为，我们利用健身房在合成情境下构建了各种事件和主动任务。通过反复生成更多事件和预测，我们获得了多达 6,790 个事件作为 ProactiveBench 的训练集，如表 1。所示我们在这个训练集上对 LLaMA-3.1-8B-Instruct [12] 和 Qwen2-7B-Instruct [13] 进行了微调，以完善它们的主动行为。

为了自动评估 LLM 的主动性，我们训练了一个奖励模型，该模型在 F1 分数方面与人类判断的一致性高达 91.80%，可作为评估工具。利用奖励模型，我们比较了不同语言模型在 ProactiveBench 上的表现。结果表明，即使是最新的开源模型也很难有效预测主动任务。例如，LLaMA-3.1-8B-Instruct 模型在 ProactiveBench 上的 F1 分数仅为 55.06%。相比之下，我们的微调模型有了显著的改进，达到了 66.25% 的 F1 分数。此外，我们的微调 Qwen2-7B-Instruct 模型取得了 66.47% 的 F1 分数，超过了所有现有的开源和闭源 LLM。这凸显了我们的数据驱动方法在开发主动式代理方面的有效性，并彰显了它们在各种应用中提升用户体验的潜力。

2 相关作品

近年来，大型语言模型[14, 15, 12, 16]在复杂推理、任务规划[17, 18, 19, 20, 21, 22, 9]、工具利用[23, 24, 25, 26]等方面取得了长足进步。因此，越来越多的代理系统被开发出来，利用这些模型处理各种任务，如自动网络搜索 [27]、软件开发 [28, 2]、行为模拟 [29]。尽管取得了这些进步，但目前大多数代理仍以被动反应为主，被动地听从人类指令，没有足够的上下文意识[11]来主动满足用户需求。这些反应型代理通常需要等待用户的明确指令，随着任务复杂度的增加，这可能会导致效率低下。因此，用户必须不断提供特定的输入，阻碍了交互流程。为此，有几项研究试图提高代理的主动性。例如，Xuan[30] 提出了主动代理规划，即代理通过主动寻找信息来完善自己的任务，从而更好地理解用户的意图。Cheng Kuang 和 Zhi Rui[31]研究了如何在文本到 sql 中提出主动支持，并提出了一种新的指标 Area Under Delta-Burden Curve (AUDBC)。其他研究[32, 33, 34, 35]侧重于启用多轮交互，以澄清模棱两可的用户指令，这进一步增加了用户的认知负荷。不过，这些研究仍需要

子集	场景	条目 (Tr/Ts)
代理模式	136	6,790 / 233
编码	46	2,275
写作	46	2,354
日常生活	44	2,161
奖励模式	-	1,640 / 120

表 1: ProactiveBench 的统计数据，其中包括三种不同的设置：编码、写作和日常生活。代理模型子集包含 6,790 个用于训练的事件和 233 个用于测试的事件。奖励模型子集包含 1,640 个注释标签用于训练，120 个用于测试。

用户在与代理进行交互之前，需要给出一个初始查询。我们的方法采取了不同的方向，重点是在监控用户活动和环境状态的基础上预测潜在任务，从而使代理能够主动启动交互并提供帮助。

需要说明的是，以前也有一些作品[36]使用"主动代理" (Proactive Agent) 来描述他们的对话系统。不过，这些工作[37, 38, 39, 40]大多旨在以积极主动的方式提高回复的帮助性或质量，这与我们对任务预测和启动的关注点不同。

3 方法

3.1 任务定义

在我们提出的主动代理中，我们研究了一种新的方案，即代理自主预测用户可能分配的任务，旨在主动提供帮助，如图 1。所示主动代理的任务是根据用户的活动 A_t 、环境事件 $E_{(t)}$ 和状态 $S_{(t)}$ 进行预测，其形式化可为

$$P_t = f_{\theta}(E_t, A_t, S_{(t)}) \quad (1)$$

其中， f_{θ} 表示主动代理，以 θ 为参数， P_t 表示对时间 t 可能的任务的预测。需要注意的是，预测 P_t 可以是预测的任务，如果代理认为不需要任务，也可以什么都不预测。具体来说，用户活动 A_t 包含用户与环境 and 代理的交互，如键盘输入或与代理聊天。环境事件 E_t 包含主动代理捕捉到的事件，从收到新邮件到应用程序关闭等。环境状态 S_t 表示当前环境的状态，如文件系统状态或打开的网页内容。

在我们的主动代理框架中，目标是最大限度地提高用户对建议任务的接受率。鉴于用户的历史活动 A_t 、当前环境状态 S_t 和主动代理提出的预测 P_t ，用户会做出一个二元决策：

$$R_t = g(P_t, A_{(t)}, S_{(t)}) \quad (2)$$

其中 R_t 是一个二进制变量，表示接受预测 ($R_t = 1$) 或拒绝预测 ($R_t = 0$)。为了统一处理预测 P_t 不包含任务和包含任务的情况，我们引入了一个表示用户是否需要帮助的辅助变量 $N_{(t)}$ ：

- 如果用户需要帮助， $N_t = 1$ 。
- 如果用户不需要帮助， $N_t = 0$ 。

用户的接受度 R_t 定义为

$$R_t = \begin{cases} 1 & \text{如果 } (P_t \neq \emptyset \text{ 且用户接受 } P_{(t)}) \text{ 或 } (P_t = \emptyset \text{ 且 } N_t = 0) \text{ , 则为 } 1 \\ 0 & \text{否则} \end{cases}$$

这样，如果预测 P_t 不包含任何任务（即代理认为用户不需要帮助），我们会检查用户对帮助的实际需求 N_t 。如果用户确实不需要帮助 ($N_t = 0$)，则标记为接受 ($R_t = 1$)。反之，如果用户需要帮助 ($N_t = 1$)，则标记为拒绝 ($R_t = 0$)。我们的主动代理旨在最大限度地提高建议任务的预期接受率：

$$\max_{\theta} E[R_{(t)}] \quad (3)$$

3.2 管道概览

为了增强由大型语言模型驱动的代理的主动能力，我们采用了数据驱动的方法，建立了一个自动数据生成管道。该管道模拟用户活动，并对主动代理在各种场景下预测的任务做出响应。一旦预测被接受，我们就会通过在模拟环境中交互生成新事件来模拟代理执行任务。随后，根据历史事件创建新的用户活动，让主动代理生成进一步的预测。通过这一管道，模型可以了解何时生成预测，以及哪些预测可能被用户接受。具体来说，我们的管道由三个部分组成：

(1) **环境健身房**：该组件模拟指定背景环境中的事件和示例事件，为主动代理提供互动沙盒。它有两个主要功能：(i) 事件生成：创建

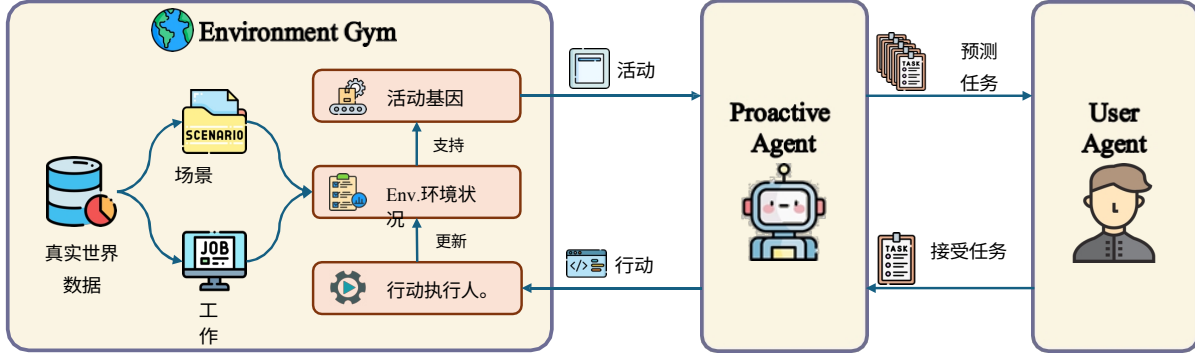


图 2：数据生成流程概览。以日常生活为例，该流程包括初始场景和工作设置、事件生成、主动预测、用户判断和行动执行等模块。

(ii) 状态维护：当产生新的用户活动或代理在执行任务期间采取行动时，更新和维护环境状态。

(2) **主动代理**：该组件负责根据事件历史记录推断出的用户需求，预测用户可能分配给代理的任务。它还与工具互动，以完成用户分配的特定任务。

(3) **用户代理**：该组件根据预定义的用户特征模拟用户的活动和反应。它决定是否接受和执行代理提出的任务。

在接下来的章节中，我们将介绍每个组件的细节。

3.3 环境体育馆

事件收集 为了提高环境健身房生成的事件的质量，我们首先收集真实世界的事件作为参考。我们在 Activity Watcher²的基础上开发了一款监控软件，可以捕捉用户与计算机系统交互的细节，包括键盘和鼠标操作、访问的网页和使用的开发工具。为了提高所收集数据的语义丰富度并方便大型语言模型进行解析，我们进一步将原始数据合并为逻辑上连贯的片段。此外，我们还利用语言模型将结构化数据转化为更自然的文本描述。这一过程不仅提高了数据的可解释性，也使其更适合后续使用。

场景生成 在收集参考事件后，我们并不直接生成具体事件，而是先生成一个现实的交互场景，为进一步生成提供足够的背景信息。为了创建这样的场景，我们首先使用 GPT-4o [41]，结合从人类注释者那里收集的种子任务，创建用户在特定类别下可能执行的各种任务，如编码、写作或日常生活。然后，我们生成任务可能涉及的所有实体，如浏览器、软件和代理执行任务的工具。接下来，我们会通过添加实体状态或日期时间等更多细节来完善场景。最后，我们还会提供收集到的事件，以便在每个特定情境下生成示例事件，供未来事件生成之用。这样我们就可以控制生成事件的粒度，并保持情景的多样性。使用的具体提示见附录 C。

事件生成 谈到具体事件的生成，我们从用户活动的生成开始。对于每个场景，首先要求用户代理描述其在 t 时刻的活动和行动 A_t ，以便在模拟环境中完成任务。然后，健身房接受用户的活动和行动，逐一生成详细事件。如图 2，所示健身房的任务是根据历史事件和当前环境状态生成逻辑正确且流畅的事件。要提高生成事件的真实性并适应不同环境，关键在于利用我们在场景生成过程中根据收集到的事件生成的示例事件。在生成事件之前，我们会随机抽样生成特定场景下的示例事件，并要求健身房根据这些示例事件生成新事件。一旦生成了新事件 $E_{(t) (t+1)}$ ，体育馆就会更新实体在环境中的状态，并重复这一过程，直到没有任何事件可以用提供的用户信息生成为止。

² <https://github.com/ActivityWatch/activitywatch>

	GPT-4o	GPT-4o-mini	LLaMA-3.1-8B	LLaMA-3.1-70B	我们的
同意。明尼苏达州 ↑	3.33%	56.67%	80.00%	33.33%	80.00%
同意。NR [†]	100.00%	56.67%	30.00%	83.33%	86.67%
同意CD [†]	100.00%	86.67%	96.67%	100.00%	100.00%
同意。FD [†]	0.00%	33.33%	13.33%	6.67%	100.00%
回顾 [†]	100.00%	71.67%	63.33%	91.67%	93.33%
精度 [†]	50.42%	56.58%	54.29%	53.40%	90.32%
准确性 [†]	50.83%	58.33%	55.00%	55.83%	91.67%
F1 分数 [†]	67.04%	63.24%	58.46%	67.48%	91.80%

表 2：不同模型在作为奖励模型的测试集上的评估结果。对于漏检（MN）、无响应（NR）、正确检测（CD）和误检（FD）场景，我们列出了模型与人类注释者主要投票结果的**一致率**。我们基于 LLaMA-3.1-Instruct-8B 进行微调的模型取得了 91.80% 的最佳 F1 分数。

在测试集上，GPT-4o 的一致性达到了 91.67% 以上，令人印象深刻，这突出说明了注释的可靠性和数据集的鲁棒性，可用于进一步分析。为了进一步促进数据的自动生成，我们还提示 GPT-4o 对用户的判断做出更详细的解释。有关奖励模型评估的更多详情，请参见第 4.1 节。

4 实验

4.1 奖励模式评估

为了自动评估所预测的任务及其时间安排是否恰当，我们试图训练一个能够准确模仿用户判断的奖励模型。为此，我们将用户标注的数据用于训练 LLaMA-3.1-8B-Instruct [12]，并将其与几种基线进行比较，以显示其优越性。

设置我们使用 1 760 个带有人类注释的词条，并将其随机分成训练集（1 640 个词条）和测试集（120 个词条）。然后，我们在训练集上训练 LLaMA-3.1-8B-Instruct，以获得我们的奖励模型。我们采用的总批次大小为 32，学习率为 $1e-5$ ，亚当优化器的预热比率为 0.01。我们对奖励模型进行了 3 个历元的训练，以防止其过度拟合。我们使用一个节点上的 8 个 A100 GPU 进行了约 1.5 小时的训练。详细的提示模板见附录 A。我们使用测试拆分来评估我们的适配模型和所有基线。值得注意的是，我们的人类注释者在测试集上达到了高达 91.67% 的一致率，证明了我们评估的有效性。

衡量标准。我们使用奖励模型对是否接受预测任务进行二元分类，并将其结果与人类标注的结果进行比较。这可以评估奖励模型与人类对预测任务适合性的判断的一致性。我们比较奖励模型和人类做出的判断，计算 Recall、Precision、Accuracy 和 F1-Score。此外，我们还计算了以下情况的一致率：

- **错过-需要：** $N_i = 1, P_i = \emptyset$ ，用户需要帮助，但代理没有提供。
- **无响应：** $N_i = 0, P_{\emptyset} = \emptyset$ ，用户不需要帮助，代理不提示。
- **正确检测：** $N_i = 1, P_{\emptyset} \neq \emptyset$ ，用户接受代理预测的任务。
- **错误检测：** $N_i = 0, P_i \neq \emptyset$ ，用户不需要帮助，但需要代理提示。

结果如表 2 所示，所有现有模型在正确检测方面都表现出色，但在其他情况下，尤其是在误报情况下表现糟糕。经过深入分析，我们发现现有模型无法推断用户可能需要什么，而倾向于接受任意帮助，即使是非常抽象或对当前观察毫无意义的帮助。相比之下，我们的奖励模型在误报场景中达到了 100% 的一致率，在所有场景中都获得了 91.80% 的 F1 分数。我们选择我们的奖励模型在 ProactiveBench 中进行进一步分析。

模型	回顾 [†]	精度 [†]	准确性 [†]	假警报 [‡]	F1 分数 [†]
专有模型					
克劳德-3-松内	27.47%	37.31%	52.42%	62.69%	31.65%
克劳德-3.5-松内	97.89%	45.37%	49.78%	54.63%	62.00%
GPT-4o-mini	100.00%	35.28%	36.12%	64.73%	52.15%
GPT-4o	98.11%	48.15%	49.78%	51.85%	64.60%
开源模型					
LLaMA-3.1-8B	98.86%	38.16%	39.06%	61.84%	55.06%
LLaMA-3.1-8B-主动式	99.06%	49.76%	52.86%	50.24%	66.25%
Qwen2-7B	98.02%	44.00%	43.61%	56.00%	60.74%
Qwen2-7B-Proactive	100.00%	49.78%	50.66%	50.22%	66.47%

表 3：不同模型在 ProactiveBench 上的性能评估结果。GPT-4o 在近源模型中表现突出，F1-Score 超过 64.60%。对于开源模型，我们的微调 Qwen2-7B 模型取得了最佳成绩，F1-Score 达到 66.47%。

4.2 主动代理评估

设置我们使用 ProactiveBench 的训练集，在两个开源模型的基础上获得 Proactive Agent：LLaMA-3.1-8B-Instruct 和 Qwen2-7B-Instruct。在训练过程中，我们采用了总批次大小为 32、学习率为 $1e-5$ 和热身比为 0.01 的 Adam 优化器。我们对模型进行了 3 次训练。我们使用一个节点上的 8 个 A100 GPU 进行了大约 2 个小时的训练。详细提示见附录 B。这些指标的自动评估依赖于奖励模型给出的模拟判断。我们在 ProactiveBench 的测试分区中对所有模型进行了评估，该测试分区包含在现实世界中收集的 233 个事件。我们在所有模型中使用了相同的提示模板。测试期间温度设置为 0。

衡量标准。我们根据用户是否接受主动代理的预测来评估其性能。如第 3.1，节所述用户的接受度 R_i 包含四个条件。在我们的具体设置中，“召回率”衡量的是代理正确预测的实际援助需求的比例，包括代理预测任务且用户接受的情况，以及未预测任务且用户不需要援助的情况。精确度衡量的是用户实际接受的预测任务比例。准确度衡量的是代理预测的整体正确性。误报率衡量的是错误任务预测的比例，特别是在预测了任务但用户不需要的情况下。F1 分数则是对代理主动行为好坏的均衡衡量。在评估过程中，我们使用奖励模型来自动生成用户的判断。根据混淆矩阵，我们报告了所有设置下的召回率、精确率、准确率、误报率和 F1 分数。详细计算方法见附录 B。

结果表 3 比较了 ProactiveBench 测试集上的各种模型，该测试集包含从真实世界用户那里收集的 233 个事件。GPT-4o [41] 或 GPT-4o-mini 等近源模型都倾向于主动预测任务。它们中的大多数都能在用户需要时成功地提供帮助，但却不能在用户不需要任何帮助时保持沉默，导致误报率相对较高。例如，GPT-4o-mini 甚至会在所提供的事件不包含有意义的操作时提供不必要的协助，比如在软件之间切换但不做其他任何操作。另一个大问题是，当在给定的观察结果中找不到精确的用户意图时，就会提供早期协助。这使得模型提出的主动任务显得过于抽象或无用，导致误报率相对较高。Claude-3-Sonnet [42] 展示了一个不同的例子，即无法检测到用户的需求，提供的帮助无法满足用户的期望。

对于开源模型，我们根据合成数据评估了 LLaMA-3.1-Instruct-8B 和 Qwen2-Instruct-7B 微调前后的性能。如表 3，所示两个模型的性能都得到了显著提高，尤其是 LLaMA-3.1-8B 模型，其 F1 分数从 44.78% 提高到 61.74%。这些结果证明了我们的数据合成管道的有效性。至于被主动代理过度干扰的问题，我们的微调模型在降低误报率方面取得了坚实的进步，与 GPT-4o 的性能不相上下。此外，经过微调的 Qwen2-7B 在 F1-Score 方面也优于 GPT-4o，达到了最高的 66.07% F1-Score。

简而言之，虽然大多数模型都能在需要时提供帮助，但它们仍然经常提供不必要的帮助，即使在接到只提供必要帮助的指示时也是如此。

4.3 性能分析

在本节中，我们将分析两种可能影响主动代理性能的设置。

预测多个任务。在实际应用中，主动代理可以提供多个候选任务，以提高整体性能。为了评估模型在这种情况下表现，我们允许它们同时生成多个候选任务，但不超过三个，以避免给用户带来过高的认知负担。在这种情况下，我们让奖励模型逐一检查候选任务。如果其中一个候选任务被接受，我们就将结果标记为接受；如果所有候选任务都被拒绝，我们就将结果标记为拒绝。

如表 4，在所示比较 "pred@1" 和 "pred@3" 时，所有模型在所有指标上都有显著提高。以 GPT-4o 为例，它通过提供多样化的候选任务，获得了更高的准确度和精确度，同时降低了误报率。误报率从 51.85% 大幅下降到 36.44%，这主要归功于它在提供主动任务方面的改进。不过，在比较 GPT-4o-mini 和 LLaMA-3.1-8B 时，我们观察到了不同程度的改进。在一次只预测一个主动任务时，这两个模型的表现相似，但在一次预测多个候选任务时，它们的 F1 分数却相差近 9%。我们对结果进行了分析，发现当用户的需求不明确时，LLaMA-3.1-8B 往往会提供意想不到的帮助，而提供多个候选任务则无法改善这种情况。

模型	设置	回顾 [†]	精度 [†]	准确性 [†]	假警报 [‡]	F1 分数 [†]
GPT-4o-mini	pred@1	100.00%	35.28%	36.12%	64.73%	52.15%
	pred@3	99.32%	65.32%	66.52%	34.68%	78.80%
	w/ RM	55.45%	63.54%	63.95%	36.46%	59.22%
	pred@3, w/RM	100.00%	65.35%	66.09%	34.65%	79.05%
GPT-4o	pred@1	98.11%	48.15%	49.78%	51.85%	64.60%
	pred@3	100.00%	63.56%	64.81%	36.44%	77.72%
	w/ RM	56.76%	55.26%	57.61%	44.74%	56.00%
	pred@3, w/RM	100.00%	63.30%	65.67%	36.70%	77.53%
LLaMA-3.1-8B	pred@1	98.86%	38.16%	39.06%	61.84%	55.06%
	pred@3	100.00%	52.79%	52.79%	47.21%	69.10%
	w/ RM	77.08%	42.52%	47.64%	57.41%	54.81%
	pred@3, w/RM	95.12%	61.58%	66.09%	38.42%	74.76%

表 4：各模型不同设置之间的比较。pred@1 "设置表示一次预测一个任务。pred@3 "表示一次预测 3 项任务。w/ RM "设置表示我们将提供奖励模型的反馈，以帮助更好地预测。

奖励模型的反馈。我们还研究了奖励模型的反馈是否能帮助模型提高在 ProactiveBench 上的表现。具体做法与图 3 中描述的逻辑相同。对于每个模型，我们首先要求它们生成一份预测草案，并从用户代理（在本例中是建立在奖励模型上的）那里获得反馈。然后，我们让模型完善其预测，以获得最终预测结果。

如表 4，所示通过添加来自奖励模型的反馈（设置为 "w/RM"），模型通常会降低误报率并提高准确率，但召回率却大幅下降。我们观察到，一旦收到奖励模型的反馈，模型就会保持沉默。然而，什么都不做并不总是最佳解决方案。GPT-4o 似乎未能捕捉到用户可能的需求，导致 F1 分数性能下降。而对于其他模型，如 GPT-4o-mini 和 LLaMA-3.1-8B，它们的 F1 分数都有明显提高。另一种将多任务预测与奖励模型相结合的设置（"pred@3, w/RM"）则显示出更全面的改进。通过将奖励模型集成到主动式代理中，我们可以让主动式代理更智能地检测用户需求，即使在无法直接获取权重的情况下也能降低误报率，这对开发主动式代理来说是个好消息。

4.4 案例研究

在本节中，我们将探讨在预测可能的任务时遇到的两种常见失败类型：无法发现用户需求和在不恰当的时间做出预测。

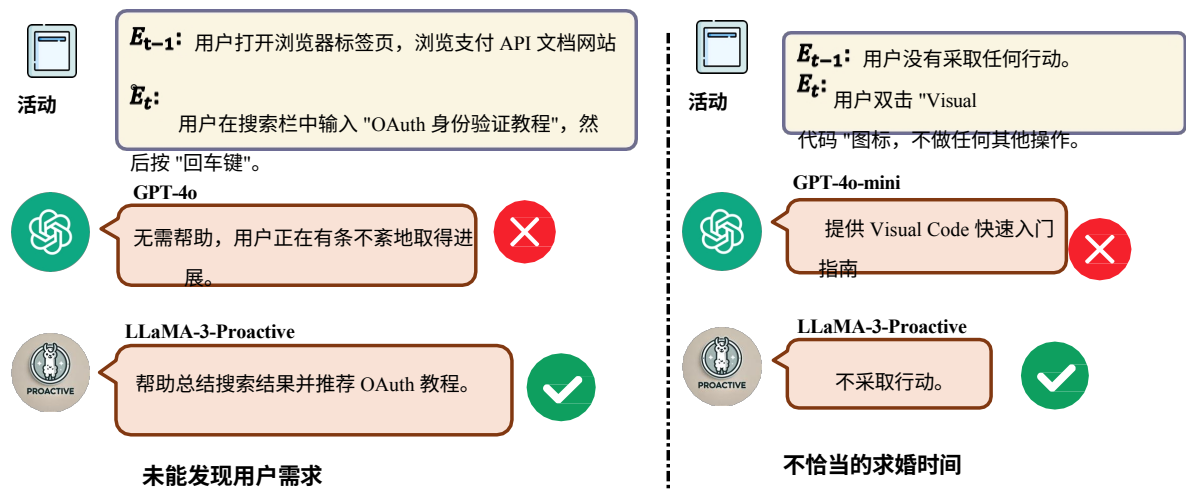


图 4：两种失败类型：未能检测到用户需求（左）和提议时间不当（右）。我们将经过微调的 LLaMA-3.1-Instruct-8B 与其他模型的响应进行了比较，以显示该模型的完善主动行为。

如图 4（左）所示，当 GPT-4o 模型没有在关键时刻提供帮助时，就会出现明显的失败。例如，当用户正在集成支付应用程序接口并需要教程指导时，模型却保持沉默。相反，我们的模型却能成功检测到人类的需求并提供帮助。具有讽刺意味的是，将干扰降到最低的基本意图导致错失提供及时帮助的机会。

相反，图 4 右侧展示了一个不合时宜的预测实例。在这里，GPT-4o-mini 在事件中没有显示用户需求时建议用户采取行动。这种情况强调了人类活动中可能存在的意外事件。模型应明智地判断是否存在可能的任务，以避免不必要的操作。这些情况凸显了人类活动的复杂性，以及模型准确预测人类需求所需的复杂推理。为了在提供帮助和干扰之间取得微妙的平衡，模型必须对用户的背景和活动有更深入的了解，确保其干预措施既及时又有针对性。

5 结论

我们提出了一种创新的人机交互方法，即利用可预测人类需求的主动任务预测。我们介绍了 ProactiveBench，这是一个包含 6,790 个事件的综合数据集，旨在完善基于 LLM 的代理的主动行为，并为评估模型的主动性建立一个自动基准。通过在合成场景中反复生成事件，我们创建了可增强模型主动能力的训练数据。我们的实验表明，代理在 ProactiveBench 上的性能有了显著提高，验证了我们方法的有效性。尽管取得了这些进步，但我们的研究结果也凸显了当前面临的挑战，尤其是在尽量减少不适当的任务建议和确保任务预测的上下文准确性方面。未来的研究应侧重于提高任务预测的准确性和及时性，从而提高主动式人机交互的效率。

局限性

虽然我们的方法证明了它可以有效、主动地预测可能的任务，但目前的研究还受到一些限制。首先，我们探索的环境设置仍然有限。本文中的环境提供了一个基础性的理解，但还需要对更广泛的应用领域进行研究，以充分确定主动代理的多功能性和鲁棒性。此外，模型仍然表现出较高的误报率，这表明它们还不能完美预测可能的任务。这一局限性凸显了进一步完善的必要性。

模型的主动行为，以避免打扰用户。高误报率可能会导致不必要或不正确的操作，从而降低用户的信任度和系统的整体效率。应更深入地探讨如何根据具体情况动态调整代理的主动性。未来的研究应重点关注几个关键领域，以解决这些局限性：

- **扩大环境设置：**研究应探索更广泛的场景和环境，以验证模型的通用性。这包括主动预测任务可显著提升用户体验和运行效率的领域。
- **提高预测准确率：**应通过加强模型对情境和用户行为的理解，努力降低误报率。
- **以用户为中心的评估：**未来的研究应包括广泛的以用户为中心的评估，以更好地了解用户如何与主动代理互动，并确定需要改进的地方。用户反馈和行为数据可以为改进预测算法、使系统更加直观可靠提供宝贵的见解。
- **伦理和隐私方面的考虑：**由于主动代理需要环境信息来完成预测任务，因此解决道德和隐私问题至关重要。确保以负责任的方式处理用户数据，确保代理在道德准则范围内透明运行，对于赢得用户信任和接受至关重要。

参考资料

- [1] OpenAI. OpenAI: 介绍 2022 年的 ChatGPT。
- [2] 陈伟泽、苏裕生、左经纬、杨程、袁晨飞、陈智敏、于鹤阳、卢雅茜、洪懿馨、钱辰、秦裕佳、丛昕、谢若冰、刘志远、孙茂松、周杰。Agentverse: 促进多代理协作和探索突发性行为》，2023 年。
- [3] 洪文义、王维汉、吕青松、徐家正、于文萌、纪俊辉、王艳、王梓涵、董玉晓、丁明和唐杰。Cogagent: gui 代理的视觉语言模型。《IEEE/CVF 计算机视觉与模式识别会议 (CVPR) 论文集》，第 14281-14290 页，2024 年 6 月。
- [4] Chi Zhang, Zhao Yang, Jiaxuan Liu, Yucheng Han, Xin Chen, Zebiao Huang, Bin Fu, and Gang Yu. Appagent: 作为智能手机用户的多模式代理，2023 年。
- [5] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Beibin Li, Erkang Zhu, Li Jiang, Xiaoyun Zhang, Shaokun Zhang, Jiale Liu, Ahmed Hassan Awadallah, Ryan W White, Doug Burger, and Chi Wang. Autogen: 通过多代理对话框架实现下一代 llm 应用。2023。
- [6] Guohao Li, Hasan Hammoud, Hani Itani, Dmitrii Khizbullin, and Bernard Ghanem. CAMEL: 大型语言模型社会的 "心智" 探索交流代理。见 Alice Oh, Tristan Naumann, Amir Globerson, Kate Saenko, Moritz Hardt 和 Sergey Levine 编辑, 《神经信息处理系统进展 36: 神经信息处理系统年会 2023》, NeurIPS 2023, 美国洛杉矶新奥尔良, 2023 年 12 月 10 - 16 日。
- [7] Roya Firoozi, Johnathan Tucker, Stephen Tian, Anirudha Majumdar, Jiankai Sun, Weiyu Liu, Yuke Zhu, Shuran Song, Ashish Kapoor, Karol Hausman, Brian Ichter, Danny Driess, Jiajun Wu, Cewu Lu 和 Mac Schwager. 机器人基础模型: 应用、挑战和未来。《国际机器人研究期刊》, 0 (0) : 02783649241281508, 0.
- [8] 李元春、温浩、王伟军、李翔宇、袁一真、刘国宏、刘家成、徐文星、王翔、孙毅等. 个人远程医疗代理: 关于能力、效率和安全的洞察与调查。ArXiv preprint, abs/2401.05459, 2024.
- [9] 叶一宁、丛欣、田世佐、曹建南、王浩、秦宇佳、卢雅茜、于海洋、王华东、林彦凯、刘志远和孙茂松。Proagent: 从机器人流程自动化到代理流程自动化，2023 年。
- [10] 欧阳龙、杰弗里-吴、蒋旭、迪奥戈-阿尔梅达、卡罗尔-L-温莱特、帕梅拉-米什金、张冲、桑迪尼-阿加瓦尔、卡塔琳娜-斯拉玛、亚历克斯-雷、约翰-舒尔曼、雅各布-希尔顿、弗雷泽-凯尔顿、卢克-米勒、玛迪-西门斯、阿曼达-阿斯卡尔、彼得-韦林德、保罗-F-克里斯蒂亚诺、扬-雷克和瑞安-洛。训练语言模型，使其听从人类反馈指令。Sanmi Koyejo, S. Mohamed, A. Agarwal, Danielle Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022*, 2022.
- [11] B.N. Schilit 和 M.M. Theimer. 向移动主机传播活动地图信息。《电气和电子工程师学会网络》, 8 (5) : 22-32, 1994 年。

- [12] Hugo Touvron、Thibaut Lavril、Gautier Izacard、Xavier Martinet、Marie-Anne Lachaux、Timothée Lacroix、Baptiste Rozière、Naman Goyal、Eric Hambro、Faisal Azhar、Aurelien Rodriguez、Armand Joulin、Edouard Grave 和 Guillaume Lample。Llama: Open and efficient foundation language models, 2023.
- [13] 白金泽、白帅、楚云飞、崔泽宇、党凯、邓晓东、范扬、葛文斌、韩宇、黄飞、惠斌源、罗骥、李梅林俊阳、林润基、刘大义恒、刘高、吕成强、吕克明、马建新、门睿、任兴章、任宣成、谭传奇、谭思南涂建红 王鹏 王世杰 王伟 吴胜光 徐本峰 徐进 杨安 杨浩 杨健 杨树生 姚洋 余博文 Hongyi Yuan, Zheng Yuan, Jianwei Zhang, Xingxuan Zhang, Yichang Zhang, Zhenru Zhang, Chang Zhou, Jingren Zhou, Xiaohuan Zhou, and Tianhang Zhu. Qwen 技术报告。 *ArXiv preprint*, abs/2309.16609, 2023.
- [14] OpenAI, : Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altmenschmidt, Sam Altman, Shyamal Anadkat, Red Avila, Igor Babuschkin, Suchir Balaji, Valerie Balcom, Paul Baltescu, Haiming Bao, Mo Bavarian, Jeff Belgum, Irwan Bello, Jake Berdine, Gabriel Bernadett-Shapiro, Christopher Berner, Lenny Bogdonoff, Oleg Boiko, Madelaine Boyd, Anna-Luisa Brakman, Greg Brockman, Tim Brooks, Miles Brundage, Kevin Button, Trevor Cai, Rosie Campbell, Andrew Cann, Brittany Carey, Chelsea Carlson, Rory Carmichael, Brooke Chan, Che Chang, Fotis Chantzis, Derek Chen, Sully Chen, Ruby Chen, Jason Chen, Mark Chen, Ben Chess, Chester Cho, Casey Chu, Hyung Won Chung, Dave Cummings, Jeremiah Currier, Yunxing Dai, Cory Decareaux, Thomas Degry, Noah Deutsch, Damien Deville, Arka Dhar, David Dohan, Steve Dowling, Sheila Dunning, Adrien Ecoffet, Aty Eleti, Tyna Eloundou, David Farhi, Liam Fedus, Niko Felix, Simon Posada Fishman, Juston Forte, Isabella Fulford, Leo Gao, Elie Georges, Christian Gibson, Vik Goel, Tarun Gogineni, Gabriel Goh, Rapha Gontijo-Lopes, Jonathan Gordon, Morgan Grafstein, Scott Gray, Ryan Greene, Joshua Gross, Shixiang Shane Gu, Yufei Guo, Chris Hallacy, Jesse Han, Jeff Harris, Yuchen He, Mike Heaton, Johannes Heidecke, Chris Hesse, Alan Hickey, Wade Hickey, Peter Hoeschele, Brandon Houghton, Kenny Hsu, Shengli Hu, Xin Hu, Joost Huizinga, Shantanu Jain, Shawn Jain, Joanne Jang, Angela Jiang, Roger Jiang, Haozhun Jin, Denny Jin, Shino Jomoto, Billie Jonn, Heewoo Jun, Tomer Kaftan, Łukasz Kaiser, Ali Kamali, Ingmar Kanitscheider, Nitish Shirish Keskar, Tabarak Khan, Logan Kilpatrick, Jong Wook Kim, Christina Kim, Yongjik Kim, Hendrik Kirchner, Jamie Kiros, Matt Knight, Daniel Kokotajlo, Łukasz Kondraciuk, Andrew Kondrich, Aris Konstantinidis, Kyle Kopic, Gretchen Krueger, Vishal Kuo, Michael Lampe, Ikai Lan, Teddy Lee, Jan Leike, Jade Leung, Daniel Levy, Chak Ming Li, Rachel Lim, Molly Lin, Stephanie Lin, Mateusz Litwin, Theresa Lopez, Ryan Lowe, Patricia Lue, Anna Makanju, Kim Malfacini, Sam Manning, Todor Markov, Yaniv Markovski, Bianca Martin, Katie Mayer, Andrew Mayne, Bob McGrew, Scott Mayer McKinney, Christine McLeavey, Paul McMillan, Jake McNeil, David Medina, Aalok Mehta, Jacob Menick, Luke Metz, Andrey Mishchenko, Pamela Mishkin, Vinnie Monaco, Evan Morikawa, Daniel Mossing, Tong Mu, Mira Murati, Oleg Murk, David Mély, Ashvin Nair, Reiichiro Nakano, Rajeev Nayak, Arvind Neelakantan, Richard Ngo, Hyeonwoo Noh, Long Ouyang, Cullen O’Keefe, Jakub Pachocki, Alex Paino, Joe Palermo, Ashley Pantuliano, Giambattista Parascandolo, Joel Parish, Emy Parparita, Alex Passos, Mikhail Pavlov, Andrew Peng, Adam Perelman, Filipe de Avila Belbute Peres, Michael Petrov, Henrique Ponde de Oliveira Pinto, Michael, Pokorný, Michelle Pokrass, Vitchyr Pong, Tolly Powell, Alethea Power, Boris Power, Elizabeth Proehl, Raul Puri, Alec Radford, Jack Rae, Aditya Ramesh, Cameron Raymond, Francis Real, Kendra Rimbach, Carl Ross, Bob Rotsted, Henri Roussez, Nick Ryder, Mario Saltarelli, Ted Sanders, Shibani Santurkar, Girish Sastry, Heather Schmidt, David Schnurr, John Schulman, Daniel Selsam, Kyla Sheppard, Toki Sherbakov, Jessica Shieh, Sarah Shoker, Pranav Shyam, Szymon Sidor, Eric Sigler, Maddie Simens, Jordan Sitkin, Katarina Slama, Ian Sohl, Benjamin Sokolowsky, Yang Song, Natalie Staudacher, Felipe Petroski Such, Natalie Summers, Ilya Sutskever, Jie Tang, Nikolas Tezak, Madeleine Thompson, Phil Tillet, Amin Tootoonchian, Elizabeth Tseng, Preston Tuggle, Nick Turley, Jerry Tworek, Juan Felipe Cerón Uribe, Andrea Vallone, Arun Vijayvergiya, Chelsea Voss, Carroll Wainwright, Justin Jay Wang, Alvin Wang, Ben Wang, Jonathan Ward, Jason Wei, CJ Weinmann, Akila Welihinda, Peter Welinder, Jiayi Weng, Lilian Weng, Matt Wiethoff, Dave Willner, Clemens Winter, Samuel Wolrich, Hannah Wong, Lauren Workman, Sherwin Wu, Jeff Wu, Michael Wu, Kai Xiao, Tao Xu, Sarah Yoo, Kevin Yu, Qiming Yuan, Wojciech Zaremba, Rowan Zellers, Chong Zhang, Marvin Zhang, Shengjia Zhao, Tianhao Zheng, Juntang Zhuang, William Zhuk 和 Barret Zoph。Gpt-4 技术报告。技术报告, 2023 年。
- [15] Aakanksha Chowdhery、Sharan Narang、Jacob Devlin、Maarten Bosma、Gaurav Mishra、Adam Roberts、Paul Barham、Hyung Won Chung、Charles Sutton、Sebastian Gehrmann 等 Palm：利用路径扩展语言建模。 *ArXiv preprint*, abs/2204.02311, 2022.
- [16] 曾翱涵、刘晓、杜正晓、王梓涵、赖涵宇、丁明、杨卓一、徐一帆、郑文迪、夏晓、谭翁林、马子轩、薛宇飞、翟继东、陈文广、刘志远、张鹏、董玉晓、唐杰。GLM-130B：开放式双语预训练模型。 *第十一届国际学习表征会议 (ICLR 2023)* , 卢旺达基

加利, 2023 年 5 月 1-5 日。OpenReview.net, 2023.

- [17] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed H. Chi, Quoc V. Le, and Denny Zhou. 大型语言模型中的思维链提示推理。桑米-科耶乔 S.Mohamed, A. Agarwal, Danielle Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022*, 2022.
- [18] Luyu Gao, Aman Madaan, Shuyan Zhou, Uri Alon, Pengfei Liu, Yiming Yang, Jamie Callan 和 Graham Neubig. PAL: 程序辅助语言模型。见 Andreas Krause, Emma Brunskill, Kyunghyun Cho, Barbara Engelhardt, Sivan Sabato 和 Jonathan Scarlett 编辑, 《机器学习国际会议》, *ICML 2023*, 2023 年 7 月 23-29 日, 美国夏威夷檀香山, 《机器学习研究论文集》第 202 卷, 第 10764-10799 页。PMLR, 2023。
- [19] 姚顺禹、赵杰夫、于滇、杜楠、Izhak Shafran, Karthik R. Narasimhan 和 Yuan Cao. 反应: 语言模型中推理与行动的协同。第十一届学习表征国际会议, *ICLR 2023*, 卢旺达基加利, 2023 年 5 月 1-5 日。OpenReview.net, 2023.
- [20] 姚顺禹、于滇、赵杰夫、伊扎克-沙夫兰、汤姆-格里菲斯、曹元和卡尔蒂克-纳拉西汉。思想之树: 用大型语言模型故意解决问题。见 Alice Oh, Tristan Naumann, Amir Globerson, Kate Saenko, Moritz Hardt 和 Sergey Levine 编辑, 《神经信息处理系统进展 36: 神经信息处理系统年会 2023》, *NeurIPS 2023*, 美国洛杉矶新奥尔良, 2023 年 12 月 10 - 16 日。
- [21] Bo Liu, Yuqian Jiang, Xiaohan Zhang, Qiang Liu, Shiqi Zhang, Joydeep Biswas, and Peter Stone. Llm+ p: 用最优规划能力增强大型语言模型。 *ArXiv preprint*, abs/2304.11477, 2023.
- [22] 叶一宁、丛昕、秦宇佳、林彦凯、刘志远和孙茂松。作为自主决策者的大型语言模型。 *ArXiv preprint*, abs/2308.12519, 2023.
- [23] Timo Schick, Jane Dwivedi-Yu, Roberto Dessi, Roberta Raileanu, Maria Lomeli, Eric Hambro, Luke Zettlemoyer, Nicola Cancedda 和 Thomas Scialom. Toolformer: 语言模型可以自学使用工具见 Alice Oh, Tristan Naumann, Amir Globerson, Kate Saenko, Moritz Hardt 和 Sergey Levine 编辑, 《神经信息处理系统进展 36: 神经信息处理系统年会 2023》, *NeurIPS 2023*, 美国洛杉矶新奥尔良, 2023 年 12 月 10 - 16 日。
- [24] 秦雨佳、胡圣鼎、林彦凯、陈伟泽、丁宁、崔干渠、曾振妮、黄宇飞、肖超军、韩驰等。使用基础模型的工具学习。 *ArXiv preprint*, abs/2304.08354, 2023.
- [25] 秦宇佳、梁世豪、叶一宁、朱昆仑、严岚、卢雅茜、林彦凯、丛昕、唐相如、钱彪、赵思涵、田润初、谢若冰、周杰、马克-格斯坦、李大海、刘志远和孙茂松。Toolllm: 促进大型语言模型掌握 16000 多个真实世界 apis, 2023 年。
- [26] Cheng Qian, Chenyan Xiong, Zhenghao Liu, and Zhiyuan Liu. 工具链: 通过开源模型上的解决链将工具包的创建和使用联系起来。载于 Kevin Duh, Helena Gomez 和 Steven Bethard 编辑的《*计算语言学协会北美分会 2024 年会议论文集*: 人类语言技术》第 1 卷, 第 831-854 页, 墨西哥墨西哥城, 2024 年。计算语言学协会。
- [27] 秦宇佳、蔡子涵、金滇、严岚、梁世豪、朱昆仑、林彦凯、韩旭、丁宁、王华东、谢若冰、齐凡超、刘志远、孙茂松、周杰。WebCPM: 中文长问题解答的交互式网络搜索。见 Anna Rogers, Jordan Boyd-Graber 和 Naoaki Okazaki 编辑, 《*第 61 届计算语言学协会年会论文集*》, 第 1 卷, 第 8968-8988 页, 加拿大多伦多, 2023 年。计算语言学协会。
- [28] 钱晨、丛昕、刘伟、杨程、陈伟泽、苏玉生、党宇凡、李佳豪、徐菊媛、李大海、刘志远和孙茂松。用于软件开发的通信代理, 2023 年。
- [29] Joon Sung Park, Joseph O'Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang 和 Michael S Bernstein. 生成代理: 人类行为的交互式模拟。第 36 届 ACM 用户界面软件与技术研讨会论文集, 第 1-22 页, 2023 年。
- [30] Xuan Zhang, Yang Deng, Zifeng Ren, See-Kiong Ng, and Tat-Seng Chua. 先问后计划: *ArXiv preprint arXiv:2406.12639*, 2024.
- [31] Cheng-Kuang Wu, Zhi Rui Tam, Chao-Chung Wu, Chieh-Yen Lin, Hung-yi Lee, and Yun-Nung Chen. 我需要帮助! 评估 LLM 请求用户支持的能力: 文本到 SQL 生成案例研究。在 Yaser Al-Onaizan, Mohit Bansal 和 Yun-Nung Chen 编辑的《*2024 年自然语言处理经验方法会议论文集*》中, 第 2191-2199 页, 美国佛罗里达州迈阿密, 2024 年 11 月。计算语言学协会。

- [32] 吴卓浩、纪丹文、余凯文、曾宪旭、吴鼎铭和穆罕默德-希杜贾曼。小爱创意与人爱共创模型》。见 Masaaki Kurosu 编著的《人机交互》(Human-Computer Interaction.理论、方法和工具》，第 171-190 页，2021 年，Cham。Springer International Publishing.
- [33] 陈伟文、穆罕默德-希杜贾曼、金江波和萨拉赫-乌丁-艾哈迈德。创造人工智能互动艺术的方法论。载于Constantine Stephanidis、Don Harris、Wen-Chin Li、Dylan D. Schmorow、Cali M. Fidopiastis、Panayiotis Zaphiris、Andri Ioannou、Xiaowen Fang、Robert A. Sottilare和Jessica Schwarz编著的《人机交互国际2020--最新论文》：认知、学习与游戏》，第 13-31 页，Cham，2020 年。Springer International Publishing.
- [34] 克里斯蒂娜-维索夫、纳维德-塔瓦纳普尔和伊娃-爱丽丝-克里斯蒂安-比特纳。在协作写作中使用智能协作代理作为队友：实现人类与人工智能的协同。夏威夷系统科学国际会议，2021年。
- [35] 钱程、何炳祥、庄忠、邓佳、秦宇佳、丛欣、林彦凯、张忠、刘志远和孙茂松。告诉我更多！语言模型驱动代理的隐式用户意图理解》。ArXiv preprint, abs/2402.09205, 2024。
- [36] Yang Deng, Wenqiang Lei, Wai Lam, and Tat-Seng Chua.主动对话系统调查：问题、方法和前景》。第三十二届国际人工智能联合会议论文集》，第 6583-6591 页，2023 年。
- [37] 毕克平、艾庆尧、W-布鲁斯-克罗夫特。基于负反馈的概念搜索中的澄清性提问。2021 年ACM SIGIR信息检索理论国际会议论文集》，第157-166页，2021年。
- [38] 任旭辉、尹宏志、陈彤、王浩、黄子、郑凯。学会在对话推荐中提出适当的问题。第 44 届 ACM SIGIR 信息检索研究与发展国际会议论文集》，第 808-817 页，2021 年。
- [39] 李子璇、廖丽子.Chua, Tat-seng. Learning to ask critical questions for assisting product search. (2022 年)。在 2022 年 ACM SIGIR 电子商务研讨会论文集》，西班牙马德里，7 月，第 15 卷。
- [40] Tianjian Liu、Hongzheng Zhao、Yuheng Liu、Xingbo Wang 和 Zhenhui Peng.Compeer：用于主动同伴支持的生成式会话代理。第 37 届 ACM 用户界面软件与技术研讨会论文集》，第 1-22 页，2024 年。
- [41] OpenAI.你好, gpt-4o, 2024。访问日期：2024-06-16。
- [42] 人类。克劳德-3 家族介绍，2024 年。访问日期：2024-06-16。

附录

A 奖励模式培训设置

我们使用 Llama-3.1-Instruct-8B 作为基础模型进行训练。数据集的总大小约为 1,640 个。具体来说，我们采用的批次总大小为 32 个，学习率为 $1e-5$ ，亚当优化器的预热比率为 0.01。我们对奖励模型进行 3 个历元的训练，以防止其过度拟合。我们在一个节点上使用 8 个 A100 GPU 进行约 1.5 小时的训练。

提示模板

```
<任务>
以用户身份评估主动助理提出的任务。
</任务>

<规则>
0. 分析当前观察结果，了解您的现状和要求。
1. 如果建议的任务为 "空"（表示在当前观察结果下没有建议的任务），请按照以下步骤操作：
    - 如果您认为不需要任务，则接受 "空" 任务。
    - 如果您认为需要一项任务，请拒绝 "空" 任务。
2. 只接受有价值的任务，尽量减少助理的干扰。
3. 评估当前的观察结果，并据此对建议的任务做出判断。
</规则>

<格式>
您应使用以下 JSON 格式回答：
{
  "思想": "先给出你的想法，然后提供对任务的判断"。 ,
  "判决 ": " 接受或拒绝 "
}
</格式>
```

B 代理模型训练设置

同样，我们使用 Llama-3-Instruct 8B 和 Qwen2-Instruct-7B 作为代理模型训练的基础模型。总数据集大小约为 6,790 个。具体来说，我们采用的总批次大小为 32，学习率为 $1e-5$ ，亚当优化器的预热比率为 0.01。为了防止模型过度拟合，我们对模型进行了 3 次历时训练。我们在一个节点上使用 8 个 A100 GPU 进行约 2 小时的训练。

我们使用以下提示模板来训练代理模型：

提示模板

```
<角色> 你是一个乐于助人的助手，为用户提供积极主动的建议。 </角色>

<任务> 了解用户正在做什么，并根据事件预测他们的需求。只有在完全了解用户的操作后，才建议提供帮助。使用可用操作确保任务可行。
如果用户接受了您的建议，则执行任务 >

<格式> 以下列 JSON 格式回复：
{
```

```
"目的": "用户最后一次操作的目的", "想法": "您对用户操作的想法。",
"主动任务": " 描述您提议的任务, 如果不需要协助, 则设置为 '空' "。 ,
"回复": " 如果提出一项任务, 请告知用户您提供的帮助
      "
    }
  </格式>
```

规则

- 确保提议的任务与事件相关。 - 关注用户当前的需求, 预测有用的任务。
- 考虑事件发生的时间。
- 只有在必要时才主动提供帮助。
- 根据事件历史记录推测用户的目的以及是否需要帮助。
- 如果用户不需要帮助, 则将 "主动任务" 设置为 "空"。

</规则>

C 环境体育馆提示模板

C.1 场景生成提示

提示模板

```
<角色>
您的任务是在一个系统中模拟一个环境。标有 "来源: 环境" 的内容反映了您过去的行动和决定
      .
    </ 角色>
```

```
<任务>
生成并完善详细的环境设置。基于最新活动, 创建多个事件来描述环境中的变化。
</任务>
```

规则

- 确保生成内容的主题与最新活动的来源一致。
- 避免主观意见或情绪; 关注客观变化。
- 确保事件与标有 "[事件]" 的历史事件一致, 并包括活动中的所有变化。
- 偶尔引入失败或意外事件, 以增加真实感。
- 确保每个事件都与前一个事件有逻辑联系, 并且不包含不存在的元素。
- 密切关注实体操作; 如果某项操作在真实或模拟环境中不被允许或不切实际, 则提示错误并说明问题。

</规则>

C.2 种子职位数据

提示模板

```
<任务>
```


您的任务是生成用户可能需要人工智能助手帮助的真实场景。请务必记住，通过尽可能多的细节来保持场景的真实可信。

</任务>

<规则>

- 您将反复生成更多的场景信息。确保每次添加新细节时，都与之前的细节保持一致。始终根据之前生成的内容生成新内容。
- 您可以添加任意多的细节，但要确保它们与之前的细节一致。
- 尝试生成场景的各种细节。稍后，您将负责模拟场景中发生的事件。

</规则>

C.3 提示生成用户代理

提示模板

<角色>

您的任务是在一个系统中模拟一个用户。标有 "来源：用户 "的内容反映了您过去的操作和决定。

</ 角色>

<任务>

生成具有鲜明特点和身份的类似人类的活动。您将收到来自环境的事件和观察结果；仔细分析这些结果，以决定您的行动。

</任务>

<规则>

- 像一个真正的用户一样回答问题；不要过于直白。
- 请参阅 # 用户信息 了解您的身份。
- 严格评估收到的信息，因为这些信息不一定总是准确的。
- 注意随时可能发生的环境变化。

</规则>

C.4 状态更新提示

提示模板

<任务>

以用户身份评估主动助理提出的任务。

</任务>

<规则>

- 0. 分析当前观察结果，了解您的现状和要求。
- 1. 如果建议的任务为 "空"（表示在当前观察结果下没有建议的任务），请按照以下步骤操作：
 - 如果您认为不需要任务，请接受 "空 "任务。
 - 如果您认为需要一项任务，请拒绝 "空 "任务。
- 2. 只接受有价值的任务，尽量减少助理的干扰。

3. 评估当前的观察结果，并据此对建议的任务做出判断。

</规则>

格式

请使用以下 JSON 格式回答问题：

```
{
  "思想": "先给出你的想法，然后提供对任务的判断"。 ,
  "判决": "接受或拒绝"
}
```

格式

C.5 指标计算

定义 下面是我们如何定义每个预测的标签。

- **真阳性 (TP)**：代理预测任务，用户接受。
- **假阳性 (FP)**：代理预测任务，用户拒绝。
- **真实否定 (TN)**：代理不预测任务，用户不需要帮助。
- **假阴性 (FN)**：代理未预测任务，但用户需要帮助 ($N_t=1$ ，第 3.1)。节

召回率 高召回率表明，代理经常能识别出需要帮助的情况。这一指标对于评估座席人员识别和及时响应用户需求的能力至关重要。

$$\text{召回率} = \frac{TP}{TP + FN} \quad (4)$$

精确度 精确度高，说明代理提出了很好的任务，同时没有过多地打扰用户。考虑到主动代理的烦人行为可能会大大降低用户满意度，因此这一指标至关重要。

$$\text{精度} = \frac{TP}{TP + FP} \quad (5)$$

准确性 高准确性表明代理对用户需求有很好的理解，因为它的大多数预测都被接受。这一指标对于衡量代理主动建议的相关性和正确性至关重要。

$$\text{准确性} = \frac{TP + TN}{P + N} \quad (6)$$

F1-Score F1-Score 高意味着主动代理在乐于助人和积极主动之间取得了良好的平衡。

$$F_1 = 2 * \frac{\text{Recall} * \text{Precision}}{\text{召回率} + \text{精度}} \quad (7)$$

D 数据示例

D.1 活动样本

收集的原始数据

```
[{
  "timestamp": 1717335890.127,
  "duration": 2.056,
  "user_input": [],
  "状态": "非 - afk",
  "app": "web",
  "事件": []
},
```

```
{
  " timestamp ": 1717335893 .215 ,
  "持续时间 " : 10.267 , " 用
  户输入 " : [
    {
      " from ": " mouse ", "
      data ": {
        " 键入 " : " 点击 ",
        "按钮 " : " 左 "
      }
    },
    {
      " 来自 " : " 键盘 ",
      " 类型 " : " 输入 ",
      " data " : " swift ui ctrl_l liebiao "
    },
    {
      "来自 " : " 键盘 ", " 数据 " :
      {
        "类型": "按下并释放", "键": "回车"
      }
    }
  ],
  "状态": "非 - afk",
  " app " : " web ",
  " 事件 " : []
},
{
  " timestamp ": 1717335904 .513 ,
  "持续时间": 0.0 、
  " user_input " : [] 、
  "状态": "非 - afk",
  " app " : " web ",
  " 事件 " : []
}]
```

已处理事件

```
[{
  " time " : " 1717378968 .208 " ,
  "事件": " 用户打开一个新的浏览器标签，并导航到谷歌主页"。
},
{
  " time " : " 1717378971 .255 " ,
  " 事件 " : " 用户切换到 ' Code .exe' 应用程序，但未执行任何特定操作。"
},
{
  " time " : " 1717378975 .29 " ,
  " 事件 " : " 用户继续停留在 ' Code .exe' 应用程序上，没有执行任何操作。"
}]
```

D.2 主动代理的预测

示例 1

```
{
  "观察": {
    "time ": " 1717378968 .208 " ,
    "事件": " 用户打开一个新的浏览器标签页，并导航到谷歌主页"。
  },
  "agent_response ": [
    "建议检查用户的搜索历史并提供个性化搜索建议"。
  ],
  "task_status ": false , "
  other_infomation ": {
    "目的": " 用户正在打开一个新的浏览器标签页并导航到谷歌主页"。 ,
    "想法": " 根据该事件，用户似乎正在开始新的搜索或浏览会话。他们可能需要帮助来组织  他们的
      搜索  或  查找  相关  信息。", "回复": "您是否希望我查看您的搜索历史和
      提供一些个性化的建议，帮助您找到想要的东西？"
  },
  "判决 ": [ false
  ]
}
```

示例 2

```
{
  "观察": {
    "time ": " 1717378971 .255 " ,
    "事件 ": " 用户切换到 ' Code .exe' 应用程序，但未执行任何特定操作。"
  },
  "agent_response ": [
    "建议在 'Code .exe' 应用程序中创建一个新的终端或命令提示符，以帮助用户完成编码任务"。
  ],
  "task_status ": false , "
  other_infomation ": {
    "目的": " 用户正在切换到 'Code .exe' 应用程序，但没有执行任何特定操作"。 ,
    "想法": "鉴于用户最近切换到了 'Code .exe' 应用程序，他们很可能正准备开始编码或编辑。但是，他们
      可能需要在组织代码、查找相关文档或设置环境方面得到帮助"。 ,
    "回复": "我可以帮你在 'Code .exe' 应用程序中创建一个新的终端或命令提示符。这样您就可以轻松访问
      编码工具和命令。需要我帮你设置吗？"
  },
  "判决 ": [ false
  ]
}
```

```
]
}
```

示例3

```
{
  "观察": {
    "time": " 1717378975 .29 " ,
    "事件": " 用户继续停留在 ' Code .exe' 应用程序上, 没有执行任何操作。"
  },
  "agent_response": [
    "主动提供编码帮助, 如推荐在线资源、教程, 甚至帮助编写代码"。
  ],
  "task_status": false , "
  other_infomation ": {
    "目的": " 用户停留在'Code .exe'应用程序上, 未执行任何操作"。 ,
    "想法": "从用户最近的行为来看, 他们似乎对开始编码或编辑犹豫不决。他们可能遇到了写作障碍, 在某个
      特定的概念上挣扎, 或者在某个特定的编码任务上需要帮助"。 ,
    "回复": " 如果您在编码任务中遇到困难, 或者在某个特定概念上需要帮助, 我可以为您提供帮助。你想让我
      推荐一些在线资源、教程, 甚至帮助你一起编写代码吗?
    "
  },
  "判决": [ false
]
```

D.3 奖励模式判断示例

输入提示

```
{
  "观察结果（时间升序排列）": [
    {
      "time": " 1717342908 .098 " ,
      "事件": "用户在网络浏览器中搜索'远程工作软件'并按下'回车键'"。
    },
    {
      "time": " 1717342914 .314 " ,
      "事件": " 在网络浏览器中打开了一个名为'新标签页'的新标签页。"
    },
    {
      "time": " 1717342940 .516 " ,
      "事件": " 用户在必应上打开了标题为'远程工作软件 - 搜索'的搜索结果"。
    },
    {
      "time": " 1717342956 .012 " ,
      "事件": " 用户切换到网络浏览器的另一个标签页, 与多个滚动操作交互。"
    }
  ]
}
```

```
    },
    {
      " time ": " 1717343061 .447 " ,
      "事件": " 用户重新开始浏览必应搜索"。
    },
    {
      " time ": " 1717343082 .081 " ,
      " 事件": " 用户继续在必应搜索结果页面中进行多次滚动操作，并点击特定结果"。
    }
  ],
  "拟议任务": 空 、
  "说明": "现在给出你的判断。你应该用第一人称完成推理过程"。
}
```

输出判决

```
{
  "思考": "我一直在浏览网页并在不同的应用程序之间切换，而且我还没有收到来自主动助理的任何任务建议。在分析我当前的活动后，我意识到我一直在搜索远程工作软件，并在 Bing 上浏览不同的搜索结果。考虑到我目前的活动，以及我没有被打断或表示需要帮助的事实，我认为此刻不需要任务。助理不提出任务的决定似乎是恰当的，因为引入新任务可能会扰乱我的工作流程，并造成不必要的干扰"。 ,
  " 判决 ": " 接受 "
}
```