

大型语言模型上知识编辑的邻近扰动

马俊宇¹ 凌振华¹ 张宁宇⁽²⁾ 顾佳晨⁽³⁾

内容摘要

尽管大型语言模型（LLMs）具有非凡的能力，但由于错误或过时的知识，它们很容易生成非预期的文本。鉴于重新训练 LLMs 需要大量资源，*知识编辑*的发展速度明显加快。然而，目前的方法和评估很少探讨编辑对邻近知识的干扰。本文研究了更新 LLM 的新知识边缘是否会扰乱封装在 LLM 中的邻近知识边缘。具体来说，我们试图弄清在一个事实性问题的答案列表中添加新答案是否会导致

在此列表中，可能会出现对原始正确答案的灾难性遗忘，以及无意中包含错误答案的情况。加法的度量标准是-.....。

在此基础上，提出了一种名为“添加知识的扰动评估（PEAK）”的基准，用于评估添加新知识时对邻近知识的扰动程度。此外，还提出了一个名为“通过保存和预防进行附加”（APP）的即插即用框架，以通过保持答案列表的完整性来减轻相邻知识的扰动。实验证明了 APP 与四种编辑方法在四种 LLM 上的耦合效果。代码和数据可在 <https://github.com/mjy1111/PEAK> 上获取。

1. 引言

大型语言模型（LLMs），如 GPT-4（OpenAI, 2023 年），在自然语言处理（NLP）领域展示了卓越的能力（Ouyang 等, 2022 年；Zhang 等, 2023a 年；Touvron 等, 2023 年）。然而，目前的 LLMs 通常不可避免地表现出幻觉，这些幻觉源于其内部过时或错误的知识。

¹NERC-SLIP, 中国科学技术大学 ²浙江大学 ³加州大学洛杉矶分校。Correspondence to: Jia-Chen Gu .<gujc@ucla.edu>




图 1. 在将新答案放入事实问题答案列表时的相邻扰动图示。 f_θ / f_{θ}^e / f_{θ}^c 表示编辑前/后的模型。

参数（Zhang 等人, 2023b；Peng 等人, 2023；Ji 等人, 2023；Huang 等人, 2023）。鉴于重新训练 LLM 既费钱又费时，有关*知识编辑*（又称*模型编辑*）的研究激增（Sinitin 等, 2020；Zhu 等等, 2020；Cao, 2021；Meng 等, 2022；2023；Dai et al., 2022；Mitchell 等人, 2022b；Yao 等人, 2023；Zhong 等人, 2023；Cohen 等人, 2023；2023；Ma 等人, ；Gu 等人, 2024），其目的是有效地改变 LLM 在特定领域中的行为，同时保持各种输入的整体性能。

许多研究人员致力于开发修改模型参数的编辑方法，一般可分为元学习（Meta-Learning）和先定位后编辑（Locate-then-Edit）姚等两类（王等, 2023；, 2023；张等, 2024）。人们设计了许多基准来评估这些方法的各个维度，其中最基本的维度是*有效性*、*泛化*和*真实性*（Meng 等人, 2022；Zhong 等人, 2023；Cohen 等人, 2023；2023；Ma 等人, ）。这些方法和基准主要侧重于确定新的目标知识是否已被成功记忆。然而，在更新目标知识时，编辑对新目标知识邻近知识的影响尚未得到充分探讨。

知识的相关性尚未得到充分探讨。

在本研究中，我们特别研究了在事实性问题的答案列表中添加新答案的编辑操作是否会扰乱其中封装的邻近知识点，如图 1 所示。具体来说，我们试图弄清知识附加是否会导致答案列表中原有正确答案的灾难性遗忘，以及无意中包含错误答案。除了前人常用的指标外，我们还引入了一个新的指标--*可加性*，以评估知识追加时对邻近知识的扰动程度。为了评估已编辑模型的可添加性，我们构建了一个被称为“添加知识的扰动评估”(Perturbation Evaluation of Appending Knowledge, PEAK)的基准，每个示例包括一个事实性问题、一个原始正确答案列表、一个错误分心列表和一个要添加的知识。在进行知识添加编辑操作后，利用原始正确答案列表来计算其中被意外删除的答案比例。同样，错误的干扰项列表也可用于计算无意中加入了的干扰项比例。PEAK 包括两个数据集，一个是基于反事实编辑的 PEAK-CF，另一个是基于现实世界变化的时间知识编辑的 PEAK-T。

为了减少添加新知识后的相邻扰动，我们提出了一个即插即用的框架，名为“通过保存和预防添加知识 (APP)”。我们设计了一系列编辑目标，以尽量减少正确和错误知识的概率扰动。一方面，在正确知识和错误知识的概率之间保持一定的余量。另一方面，要确保正确知识的概率不降低，同时控制错误知识的概率不增加。因此，该框架有助于保持原有正确知识的完整性，并在添加新知识时预先防止错误知识的加入。此外，所提出的编辑框架无需训练步骤，可与现有的多种编辑方法结合使用。

为了研究当前知识编辑方法在附加知识方面的性能，本研究进行了广泛的综合实验，包括 FT (Zhu 等人, 2020)、MEND (Mitchell, Meng, Meng 等人, 2022a)、KN (Dai 等人, 2022)、ROME (等人, 2022) 和 MEMIT (, 2023)。我们利用四个不同大小的代表性 LLM 作为基础模型，包括 GPT-2 XL (1.5B) (Radford 等人, 2019)、GPT-J (6B) (Wang & Komatsuzaki, 2021)、LLaMA-2 (7B) 和 LLaMA-2 (13B) (Touvron 等人, 2023)。我们惊喜地发现

我们观察到，尽管当前的编辑方法可以有效地纳入新事实，但它们对新事实邻近知识的概率分布挖掘不足，破坏了原始相关知识的完整性，并引入了无意噪声。此外，实验结果广泛证明了所提出的 APP 在减轻编辑的邻近干扰方面的有效性，以及它与四种编辑方法在四种不同规模的代表性 LLM 上的兼容性。

从本质上讲，我们的研究做出了三项重大贡献：(1) 本研究开创了通过向 LLM 附加新知识来探索邻近扰动的先河。我们引入了一个添加性度量，并构建了一个新的基准 PEAK 来衡量邻近知识的扰动程度。(2) 通过综合实验，我们发现虽然已有方法和 LLM 能有效吸收新知识，但它们严重破坏了原有正确知识的完整性，并引入了无意的错误知识。(3) 我们提出了即插即用的 APP，它能有效减少添加知识时的邻接扰动。我们希望我们的基准和方法都能揭示 LLM 上知识编辑的邻接扰动。

2. 相关工作

人们提出了许多知识编辑方法来修改模型中的知识编码，如元学习 (meta-learning) 和定位编辑 (locate-then-edit) (Yao et al. 一方面，元学习方法训练超网络以获得渐进变化，从而更新模型参数 (Cao 等, 2021; Mitchell 等, 2022a)。MEND (Mitchell 等人, 2022a) 学习将微调梯度转化为梯度的低阶分解。另一方面，定位-然后-编辑方法首先定位 LLM 中与知识表达呈正相关的知识神经元，然后对其进行相应的修改 (Dai 等人, 2022; Meng 等人, 2022; 2023)。Dai 等人 (2022 年) 计算了每个神经元对特定知识的贡献，然后用事实的嵌入向量修改这些神经元，从而更新或删除知识。Meng 等人 (2022 年) 找到了存储事实知识的多层感知器 (MLP)，然后在 MLP 模块中注入新的键值对来编辑这些知识，这与最近的观察结果一致，即这些层可以被视为存储事实知识的键值存储器 (Geva 等人, 2021 年; 2022 年)。此外，Zhu 等人 (2020 年) 还提出了对修改后的事实进行受限微调的方法。DeepEdit (Wang 等人, 2024 年) 是一种神经符号解码方法，可以灵活应用于黑盒 LLM。此外，还提出了一些评估知识编辑的基准 (Meng 等人, 2022; Cohen 等人, Ma 等人, 2023; 2024; ,)、

2023; Li 等人, 2023; Gandikota 等人, 2023)。例如, MQUAKE (Zhong 等人, 2023 年) 使用多跳问题来评估知识编辑, 表明编辑一个特定事实意味着许多其他事实需要更新。BAKE (Ma 等人, 2023 年) 以双向方式评估知识编辑。Li 等人 (2023 年) 探讨了两个重要的关注领域: 知识冲突和知识失真, 旨在揭示知识编辑的更多弱点。此外, 编辑还被应用于多个领域, 如改变模型个性 (Mao 等, 2023 年)、编辑多模态模型 (Cheng 等, 2023 年年)、保护用户隐私 (Wu 等, 2023) 等。

与以前的研究 (Meng 等人, 2022 年; 2023 2022 年 a 年年; Mitchell 等人 Zhong 等, ; 人, 2023 2023 年; Cohen 等人 Ma 等人, ; , 2023 年 2023; Yao 等人, 年) 相比, 与我们的工作最相关的研究有一个主要区别需要强调。这些方法一般侧重于确定新的目标知识是否已被成功记忆, 而本研究则探讨了编辑对邻近知识的扰动和影响。据我们所知, 本文首次尝试引入了一种新的可添加性度量, 建立了一个基准来评估添加知识时对邻近知识的扰动程度, 并提出了一个减轻邻近知识扰动的通用框架。

3. 初步

3.1. 查询法律硕士的事实知识

继之前的研究 (Meng 等人, 2022; Zhong 等人, 2023 2023; YinYao 等人 等人, ; , 2023; Ma 等人, 2023) 之后, 我们研究了由一个主语 s 、一个关系 r 和一个客体 o 组成的 (s, r, o) 形式的事实知识 (例如, s = 埃菲尔铁塔, r = location, o = Paris)。此外, 我们还按照他们的方法采用离散提示来测试知识是否在语言模型中。具体来说, 我们会为每个关系 r 构建一个自然语言模板 $t_{(r)}(-)$, 然后将其与作为输入的主题 s 结合起来, 生成一个提示语 (问题或掐头去尾式语句) $t_{(r)}(s)$ 。例如, 给定主语 "埃菲尔铁塔" 和关系 "位置", 我们就可以生成一个掐头去尾的句子 "埃菲尔铁塔位于"。

3.2. 知识编辑

知识编辑的目的是在不重新训练的情况下将新的事实纳入模型参数。以往的工作主要是改变存储在 LLM 中的原始知识, 如 $(s, r, o) \rightarrow (s, r, o^*)$, 它只关心新的目标知识。然而, 添加新知识的编辑操作对其邻近枯燥知识的潜在影响仍不清楚。因此, 本文

在此基础上, 我们探讨了一个主体在给定关系下拥有多个相关对象的情况。

响应对象的情况。具体来说, ap

待定知识旨在将新对象纳入原始对象集, 保留原始对象, 不引入虚假对象: $(s, r, \{o_1, o_2, \dots, o_{(N)}\}) \rightarrow (s, r, \{o_1, o_2, \dots, o_N, o^*\})$ 。在本文中, 对于一个新知识的附加 (s, r, o^*) , 其相邻知识定义为 (s, r, O) , 其中 $O = \{o_1, o_2, \dots, o_{(N)}\}$ 。定义一个编辑事实为 $e = (s, r, O, o^*)$, 给定一个未经编辑的模型 F , 通过使用模型编辑器 K 获得编辑后的语言模型, $F^* = K(F, e)$ 。

为了评估编辑方法在附加知识方面的性能, 我们仍然使用了前三个指标。

效率验证了在唯一的编辑提示 p 下, 编辑过的模型是否能回忆起所附加的事实: $\mathbb{1}[P_{F^*}(o^* | p) > \min\{P_{F^*}(o | p) | o \in O\}]$ 。

泛化验证编辑过的模型能否在转述提示 P^G 下回忆起所附事实。

通过广义分数 (GS): $\mathbb{E}_{p \in PG}[\mathbb{1}[P_{F^*}(o^* | p) > \min\{P_{F^*}(o | p) | o \in O\}]]$ 。

Locality 通过 Locality Score (LS) 验证在 Locality 提示 $P^{(L)}$ 下, 对于编辑范围外的输入, 已编辑模块的输出是否保持不变: $\mathbb{E}_{p \in P^L}[\mathbb{1}[P_{F^*}(o_l | p_l) > P_{F^*}(o^* | p_l)]]$, 其中 o_l 是 p_l 的原始答案。¹ 是指示函数。

例如, 给定一个编辑事实 $(s = \text{Apple}, r = \text{products}, O = \{\text{AirPods 3}, \text{MacBook Air}, \dots, \text{iPhone 14}\}, o^* = \text{iPhone 15})$, 编辑提示 p 可以是 "苹果公司的产品有哪些?", 解析提示可以是 "苹果公司生产哪些产品?" 定位提示及其原始答案可以分别是 "哪家公司开发了 Windows?" 和 "微软"。

4. 加法的定义

给定一个主语 s 、一个关系 r 、一个组成的问题 $t_{(r)}(s)$ 、原始对象 O 和一个要附加的对象 o^* , 目前还不清楚 $\diamond\diamond\diamond\diamond$ 的正确知识 $K^c = (s, r, \{o(1), o(2), \dots\})$ 是否仍然保留 $\diamond\diamond\diamond\diamond$ 而部分错误知识 $K^f(s, r, \{o_{(1)}(1), o_{(1)}(2), \dots, o_{(N)}\})$ 是否仍然保留。 $o_{(N)}(1)$ 仍被保留, 部分错误知识 $K^f = (s, r, \{o_{(1)}(1), o_{(1)}(2), \dots, o_{(M)}(1)\})$ 在编辑后无意中被包含, 其中 $\{o_{(1)}(1), o_{(1)}(2), \dots, o_{(M)}(1)\} \cap \{o_1, o_2, \dots, o_N, o^*\} = \emptyset$ 。因此, 我们设计了一种新的度量, 因此, 我们设计了一种新的度量方法来评估对相邻知识的扰动程度。相邻知识的扰动程度。

相对排序和绝对概率变化来计算。

对象的相对排序 我们假设在编辑前后, 正确知识的最小概率 K^c 应大于错误知识的最大概率 K^f 。否则, 就有可能遗忘原有的正确知识或引入错误知识。

¹以往的研究关注的是概率是否超过原始的 O 。

直观地说，错误知识的最大概率

$$P_{\mathcal{F}}^{\max} = \max_{i=1}^M P_{F^*}(o_i | t_r(s)) \text{ 被用作阈值}$$

计算 K 原始正确对象列表中概率低于该阈值的比例。在数学上，我们有 **排名遗忘因子** (RFF)：

$$RFF = \frac{\sum_{i=1}^N \mathbb{I}_{\{P_{F^*}(o_i | t_r(s)) < P_{\mathcal{F}}^{\max}\}} \cdot \sigma(P_{F^*}(o_i | t_r(s)))}{\sum_{i=1}^N \sigma(P_{F^*}(o_i | t_r(s)))}, \quad (1)$$

σ 是 sigmoid 函数。这里， $\sigma(P)$ 的每个原始 cor-

由于概率越大的知识权重越大，因此正确知识被视为其权重，sigmoid 函数也可用于平滑。

同样，原始正确概率的最小值为

$$P^{\min} = \min_{i=1}^N P_{F^*}(o_i | t_r(s)) \text{ 被用作}$$

阈值，计算 K 中概率高于该阈值的抽样虚假对象的比例。然后，**排名噪声系数** (RNF) 定义为

$$RNF = \frac{\sum_{i=1}^M \mathbb{I}_{\{P_{F^*}(o_i | t_r(s)) > P^{\min}\}} \cdot \sigma(P_{F^*}(o_i | t_r(s)))}{\sum_{(j)=1}^M \sigma(P_{F^*}(o_j | t_r(s)))}, \quad (2)$$

对象的绝对概率变化 此外

在满足对象相对排序假设的前提下，还必须确定其绝对概率变化的特征。即使相对排序保持不变，如果绝对概率发生意外变化，也会对模型造成重大损害。因此，我们引入了 **正确概率变化** (CPC) 来描述这一问题，它被定义为编辑后和编辑前正确知识的平均概率之比：

$$CPC = \frac{\sum_{i=1}^N P_{F^*}(o_i | t_r(s))}{\sum_{i=1}^N P_F(o_i | t_r(s))} \quad (3)$$

同样，**错误概率变化** (FPC) 被定义为编辑后和编辑前错误知识的平均概率之比：

$$FPC = \frac{\sum_{i=1}^M P_{F^*}(o_i | t_r(s))}{\sum_{i=1}^M \frac{P_F(o_i | t_r(s))}{P_F(o_i | t_r(s))}}. \quad (4)$$

聚合 最后，我们的目标是将相对排名和绝对概率变化这两个维度聚合成一个统一的度量，为附加知识所引起的不利影响提供一个更全面的表征。**添加性遗忘因子** (AFF) 的定义是，原有正确知识被遗忘的程度：

$$AFF = 1 - (1 - RFF) * \min\{1, CPC\}. \quad (5)$$

这一定义意味着，如果编辑后正确知识的概率没有降低 ($CPC \geq 1$)，则 AFF

等于 RFF。否则，CPC 和 RFF 的不利影响

将结合起来，导致 AFF 超过 RFF。AFF

从 0 到 1，反映了在相邻的干扰中，原有的正确知识被遗忘的程度。

AFF 值越高，说明负面影响越大。与此类似，另一个综合指标 **Additive Noising Factor** (ANF) 被定义为

其中引入了错误知识：

$$ANF = 1 - (1 - RNF) * \min\{1, \frac{1}{FPC}\}. \quad (6)$$

ANF 值从 0 到 1 不等，反映了错误知识在相邻 perturbations 中的引入程度。ANF 值越高，负面影响越大。

5. PEAK：对附加知识的扰动评估

本文设计了 PEAK 基准来评估编辑过程中对邻近知识的扰动程度。

它包括 PEAK-CF 和 PEAK-T 两个数据集。其中

前者被设计为一个反事实数据集，用于评估反事实追加的知识编辑方法。

沿用 Meng 等人 (2022 年) 和 Ma 等人 (2023 年) 的方法。后者是基于现实世界变化的时态知识编辑，与 Zhong 等人 (2023 年) 的方法相同。

5.1. PEAK-CF 的数据构建

聚合事实 本数据集基于维基数据 (Vrandeic & Krötzsch, 2014) 构建，维基数据是一个包含数百万个事实三元组的知识库。首先，我们手动选择了总共 32 个关系，其中一个主题有多个关系。

(.) ((3)) 那么我们

收集每个关系的所有三元组并对三元组进行分类

表示为 $F_m(r) = \{(s, r, O) \mid O = \{o_1, o_2, \dots, o_N\}\}$ 。对于每种关系 r ，都会使用 ChatGPT (gpt-3.5-turbo) 生成一些表达相同语义的模板 $T(r)$ 。主语 s 可以替换为完整的提示语： $P(s, r)$

$= \{t_r(s) \mid t_r(-) \in T(r)\}$ 。例如， $(r$

$= \text{product})$ 可能是“ $\{$ 有类似的产品”，其中 “Apple” 代替了 “ $\{$ ”。

构建反事实编辑 遵循之前的研究 (Meng 等人, 2022; Yao 等人, 2023; Ma 等人, 2023)，本数据集构建了反事实编辑。本数据集采用了前三重度量方法。给定一组三元组 $(s, r, O) \in F_m(r)$ 和一个对象 o^* ，其中 $o^* \notin O$ 和 (s, r, o^*) 是一个反事实，一个编辑被表示为 $E = \{s, r, O, o^*, p\}$ 来测试有效性，其中编辑提示 $p \in P(s, r)$ 。此外，为了测试概括性，我们从 $P(s, r) \setminus \{p\}$ 中抽取一组语义等同的解析提示 P^G 。此外，为了测试本地

表 1. PEAK-T 数据集中的例子。不同行中的 a 和 a^* 分别代表编辑后的原始答案和期望答案。u 指集合联合运算。

(s, r) :	(冬季奥林匹克运动会, 主办国)
O :	{法国, 美国、.....、韩国}。
E	o^* : 中国
p :	冬季奥林匹克运动会的主办国有哪些? ($a: O, a^*: OU \{o^*\}$)
	冬季奥林匹克运动会的主办国是
P^G	哪些国家举办过冬季奥运会? ($a: O, a^*: OU \{o^*\}$)
P^L	大本钟位于 ($a \& a^*$: 伦敦)
P	苹果公司总部位于 (a 和 a^* : 加利福尼亚州)
O_h	{日本、上海、香港、.....、俄罗斯}。
O_r	{乌拉圭、莫桑比克、斐济、.....、的黎波里}。

因此, 我们会选择一组不在编辑范围内的三元组: $S = \{(s', r', o')\}$ 。例如, 选择 (s = 奥林匹克运动会, r = 主办城市, o = 巴黎), S 可能包含三重, 如 (s' = 法国, r' = 股份边界, o' = 德国)。然后构建一组提示信息 $\{P(s', r') | (s', r', o') \in S\}$ 的构造是为了采样局部性提示 P^L 。

抽取错误答案 对于本文提出的加法, 给定一个事实性问题 $t_r(s)$ (例如编辑提示 p) 时, 会同时使用原始正确答案和抽取的错误答案。 O 是原始正确答案的列表, 而错误答案则是在 **硬性**和**随机**两种设置下抽取的 (抽样详情见附录 A.1)。在 **硬性**设置中, 一些与新对象 o^* 建立直接关系的对象被抽取出来, 表示为 $O_h = \{o_{h1}, o_{h(2)}, \dots, o_{hM}\}$, 其中

$O_h \cap O = \emptyset$ 。同样, 对于 **随机**设置, 一些目标对象 $O_r = \{o_{r(1)}, o_{r(2)}, \dots, o_{rM}\}$, 这些对象在语义上相距甚远。从新对象中采样。直观地说, 与 **随机**设置中的答案相比, **硬性**设置中的错误答案更容易被引入模型。

过滤正确答案和错误答案 随后, 根据第 4 节中定义的可加性, 对于 $t_r(s)$, 在编辑前后, 正确答案的最小概率 O 应该大于错误答案的最大概率 O_h 和 O_r 。因此, 在编辑之前, 我们先过滤掉原始模型中概率低于某一临界值的正确答案。然后再过滤掉概率大于所选正确答案最小概率的错误答案。

5.2. PEAK-T 的数据构建

该数据集侧重于基于时间的真实世界编辑, 其中每个编辑都是事实正确的, 并且发生在模型训练之后。继 Yin 等人 (2023 年) 之后, 该数据集建立在 YAGO (Mahdisoltani 等人, 2015 年) 这一知识库之上。

表 2. PEAK-CF 和 PEAK-T 数据集的统计数据。

关系类型	PEAK-CF	PEAK-T
编辑示例	1,962	993
正确答案	26,512	7,759
仿写提示	3,344	1,995
邻里提示	10,760	6,207
错误答案 (硬性)	24,043	7,879
错误答案 (随机)	19,616	9,929

YAGO 包含从维基百科中提取的事实三元组, 并使用 WordNet、GeoNames 和其他数据源进行了丰富, 还包含事实发生的时间。我们在 YAGO 中抽取了发生在 2021 年之后的事实, 这是在 GPT-2 XL 和 GPT-J 发布之后。由于关系类型数量有限, 我们选择了 9 种关系。其构造与 PEAK-CF 类似。

5.3. 数据集摘要

数据集格式 如表 1 所示, PEAK 基准中的每个实例都表示为一个元组 (E, P^G, P^L, O_h, O_r) , 其中 E 由一段新知识和原始正确知识组成。 P^G 和 P^L 分别是用于验证通用性和本地性的提示。 O_h 和 O_r 分别表示 **硬性**设置和**随机**设置下事实问题 p 和 P^G 的错误答案抽样列表。 a 和 a^* 分别表示编辑后的原始答案和期望答案。

数据集统计数据 表 2 总结了 PEAK-CF 和 PEAK-T 数据集的统计数据。为了验证概括性和定位性, 每个实例至少有一个提示。此外, 每个事实问题平均有 10 个正确答案和 20 个错误答案。一般来说, 这两个数据集分别包含反事实编辑和时间编辑, 用于研究编辑模型的邻近扰动。关于关系和提示的详细内容, 读者可以参阅附录 A.2。

6. 通过保存和预防进行附加

在添加知识的过程中, 邻近的扰动可能会导致原有的正确知识被遗忘, 也可能会无意中加入噪音。我们提出了一个即插即用框架 APP (通过保存和预防进行附加) 来改进现有的编辑方法, 以减少编辑中的这种不利因素。

给定要附加的新知识 (s, r, o^*) 和编辑提示 p , 当前的编辑方法通常会定义一个编辑目标 $L_e(o^*, \theta_F)$ 以纳入新知识, 其中 θ_F 表示未编辑模型 F 中要更新的参数。APP 设计了一组可与 $L_e(o^*, \theta(F))$ 结合的编辑目标, 以最小化相邻正确知识和新知识的概率扰动。

表3. PEAK-CF 数据集的评估结果 (%)。hard "指的是在 "硬" 设置下使用错误答案计算出的加成率, 而 "ran "指的是在 "随机" 设置下计算出的加成率。↑ 表示值越高, 性能越好, 而 ↓ 则相反。标有 † 的数字表示与 APP 相结合的方法与原始方法相比有显著的统计学改进 (t 检验, p 值 < 0.05)。由于 KN 没有需要优化的损失, 因此没有应用 APP。由于篇幅有限, LLaMA-2 (13B) 的结果放在附录 B.4 中。

编辑器	GPT-2 XL (1.5B)								LLaMA-2 (7B)							
	ES †		LS †	加性 (硬) †		加性 (运行) †		ES †		LS †	加性 (硬) †		加性 (运行) †			
	ES †	LS †	加性 (硬) †	ANF †	加性 (运行) †	ANF †	ES †	LS †	加性 (硬) †	ANF †	加性 (运行) †	ANF †				
FT	90.99	64.68	87.71	78.86	59.04	69.29	37.12	98.27	87.72	68.48	74.51	60.62	64.22	38.72		
KN	26.48	26.08	89.08	44.71	29.47	41.23	22.96	46.67	46.45	66.16	45.63	40.51	43.72	35.64		
MEND	97.46	84.87	42.46	30.15	33.97	12.86	11.62	95.22	86.02	47.47	35.39	33.51	21.16	14.61		
MEMIT	72.90	63.08	98.44	51.49	52.11	31.71	17.22	99.95	99.11	92.12	94.26	84.14	86.03	53.61		
罗马	99.27	94.05	90.57	87.44	69.80	75.16	35.58	99.69	97.74	94.40	93.05	82.47	83.80	52.25		
FT+APP	87.89	59.30	89.21	70.48†	49.73†	59.85†	29.76†	98.01	85.24	73.55†	68.44†	49.62†	57.93†	33.34†		
MEND+APP	94.25	81.02	45.51†	26.27†	28.81†	12.21	11.07	92.86	82.46	51.43†	32.55†	29.73†	20.44	13.99		
MEMIT+APP	69.75	59.26	98.66	39.89†	43.41†	22.14†	13.58†	99.42	96.51	94.81†	38.83†	17.41†	32.65†	11.69†		
罗马+APP	96.15	87.17	93.27†	40.45†	31.60†	25.92†	12.61†	100.00	94.24	96.22†	43.11†	20.14†	36.86†	13.74†		

不正确的知识。一方面, 编辑目标 $L_{(1)}(O, O_h, \theta_F)$ 的目的是通过铰链损失 (Gentile & Warmuth 和, 1998; Wu & Liu, 2007) 在问题 $t_{(r)}(S)$ 的原始正确答案概率 O 错误答案概率 O_h 之间保持一定的余量:²

$$L_{(1)}(O, O_h, \theta_F) = \left(\frac{1}{NM} \sum_{i=1}^N \sum_{j=1}^M \max \{0, M - \log P_F(o_i | p) + \log P_F(o_{hj} | p)\} \right) \quad (7)$$

其中, F' 是编辑过程的中间模型。 N 和 M 分别代表 O 和 O_h 中的元素数量。这个等式意味着, 正确答案的对数概率至少要大于错误答案的对数概率 M 。

另一方面, 在编辑过程中, 要确保正确答案的绝对概率不降低, 而错误答案的绝对概率不升高, 这可以概念化为两个目标 $L_{(2)}(O, \theta_F)$ 和 $L_{(3)}(O_h, \theta_F)$, 分别是:

$$L_{(2)}(O, \theta_F) = \frac{1}{N} \sum_{i=1}^N \max \{0, \log P_{(F)}(o_i | p) - \log P_F(o_i | p)\}, \quad (8)$$

$$L_{(3)}(O_h, \theta_F) = \frac{1}{M} \sum_{i=1}^M \max \{0, \log P_F(o_{hi} | p) - \log P_{(F)}(o_{hi} | p)\}, \quad (9)$$

$L_{(2)}(O, \theta_F)$ 表示, 如果在编辑过程中正确答案的概率降低, 则损失等于对数

² O_h 是由于硬负采样而采用的。

$L_{(3)}(O_h, \theta_F)$ 的设计与此类似。最后, 在每种方法 $L_e(o^*, \theta_{(F)})$ 中, 这些提出的目标与原始编辑目标共同优化为:

$$L = \min_{(\theta, \theta_F)} L_e(o^*, \theta_{(F)}) + \alpha L_{(1)}(O, O_h, \theta_{(F)}) + \beta L_{(2)}(O, \theta_{(F)}) + \gamma L_{(3)}(O_h, \theta_{(F)}). \quad (10)$$

这里的 $\alpha, \beta, \gamma \geq 0$ 是超参数。附录 C 提供了一个示例, 说明所提出的 APP 方法是如何实现的。

与选定的编辑方法相结合, 以提高清晰度。

7. 实验

在本节中, 我们根据四个具有代表性的 LLM 进行了实验, 以证明现有编辑方法的邻域扰动。此外, 还将所提出的 APP 方法与这些编辑方法相结合, 以减轻邻域扰动。最后, 我们进行了综合分析, 进一步验证了所提框架的有效性。

7.1. 基础 LLM 和编辑方法

实验使用了四种常用的 LLM。考虑到计算资源有限, PEAK-CF 数据集在 GPT-2 XL (1.5B) (Radford 等人, 2019 年)、LLaMA-2 (7B) 和 LLaMA-2 (13B) (Touvron 等人, 2023 年) 上进行。

由于 LLaMA-2 发布日期 (2023-7 年) 之后 YAGO 中的数据很少, 因此 PEAK-T 在 GPT-2 XL 和 GPT-J (6B) 上进行 (Wang & Komatsuzaki, 2021 年)。选择了五种流行的知识编辑方法作为基包括 FT (Zhu 等人, 2020 年)、KN (Dai 等人, 2022 年)、MEND (Mitchell Meng 人 Meng 等人, 2022a)、ROME (等, 2022 年) 和 MEMIT (, 2023 年)。读者可参阅附录 B.1 了解这些编辑方法的详情。

表 4. PEAK-T 数据集的评估结果 (%)。

编辑器	GPT-2 XL (1.5B)							GPT-J (6B)						
	上一页		加性 (硬)		加法 (运行)			前一个			可加性 (硬)		可加性 (已运行)	
	ES $\uparrow$	GS $\uparrow$	LS $\uparrow$	AFF $\downarrow$	ANF $\downarrow$	AFF $\downarrow$	ANF $\downarrow$	ES $\uparrow$	GS $\uparrow$	LS $\uparrow$	AFF $\downarrow$	ANF $\downarrow$	AFF $\downarrow$	ANF $\downarrow$
FT	83.31	59.89	61.67	80.44	38.10	72.24	18.76	95.21	80.68	42.74	87.25	40.14	77.09	14.97
KN	28.39	27.38	83.81	50.85	24.41	47.29	18.73	45.49	43.11	67.05	93.84	46.47	93.29	40.23
MEND	99.00	89.90	8.78	24.02	19.78	12.91	8.18	99.72	87.55	10.05	24.73	16.82	13.66	5.12
MEMIT	57.92	46.46	97.71	25.92	31.45	7.31	4.19	100.00	85.42	94.00	50.18	36.35	22.85	2.95
罗马	100.00	86.77	92.95	57.65	33.84	36.05	5.35	100.00	92.57	89.15	60.48	38.66	33.87	4.02
FT+APP	79.03	53.19	67.29 [†]	75.24 [†]	31.64 [†]	67.47 [†]	17.75 [†]	90.85	74.50	49.53 [†]	82.75 [†]	31.06 [†]	75.02 [†]	13.41 [†]
MEND+APP	99.29	90.68	8.37	26.27	28.81	12.21	11.07	99.72	87.49	9.93	26.38	17.05	14.85	5.12
MEMIT+APP	59.06	47.68	97.92	23.30[†]	29.00 [†]	6.86	4.20	100.00	83.23	94.36	21.40[†]	16.78[†]	7.54[†]	1.93[†]
罗马+APP	99.86	86.70	93.65	28.81 [†]	14.84[†]	16.79 [†]	3.16[†]	100.00	90.83	89.90	31.56 [†]	17.15 [†]	16.17 [†]	2.17 [†]

7.2. 评估指标

本文仍采用第 3.2 节中定义的三个基本指标，即效率 (ES)、泛化 (GS) 和定位 (LS) (Meng 等, 2022; 2023) 来衡量每种编辑方法。此外，提出的添加性 (Additivity) 是为了评估添加知识时对邻近知识的扰动程度。第 4 节中设计的 AFF 和 ANF 分别用于量化遗忘原始正确答案以及包含噪声和错误答案的程度。在评估添加性时，编辑和转述提示 $\{p\}$ $P(G)$ 都被无损使用。u P^a 均被使用，但不失一般性。对于上述所有指标，报告的是每个数据集中所有编辑的平均结果。

7.3. 现有编辑方法的结果

表 3 和表 4 的前五行分别报告了当前编辑方法在 PEAK-CF 和 PEAK-T 上的知边编辑结果。我们从以下几个方面对这些结果进行了分析。

编辑新目标知识的性能。除 KN 外，其他编辑方法在功效 (ES) 和泛化 (GS) 方面表现良好，表明现有的大多数编辑方法都能有效地添加新的目标知识。在定位方面，定位即编辑方法 (KN、ROME、MEMIT) 明显优于其他方法，这表明它们对无关知识的干扰很小。此外，随着模型大小的增加，特定编辑方法在添加新事实方面的性能也在不断提高。

编辑对邻近知识的扰动。我们惊讶地发现，现有的编辑方法在编辑后对 LLM 中与目标知识相邻的知识产生了明显的扰动，损害了原始正确知识的完整性，并引入了非故意的噪声。以 ROME 在 PEAK-CF 上编辑的 LLaMA-2 为例，尽管它在之前的指标评估中表现出色，但它在 PEAK-CF 上的表现却非常差。

在硬负设置中，它们的 AFF 和 ANF 分别为 93.05% 和 82.47%。即使在随机设置下，它们仍然表现不佳，表明邻近知识受到严重破坏。同时，就 AFF 和 ANF 而言，编辑过的模型在硬设定下的表现要比随机设定下的表现差，这表明错误答案和新添加答案之间的语义关系越密切，就越容易受到干扰。值得注意的是，虽然 MEND 在添加性方面表现最佳，但其相对较低的 LS 却表明无关知识受到了严重干扰。我们的研究表明，当前的编辑方法主要关注的是新目标知识的编辑性能，而忽略了对其邻近知识的负面干扰。

数据集之间的比较。比较每种方法在两个数据集上的结果，得出两个结论。(1) 每种方法在 PEAK-T 上的 ES 和 GS 都低于 PEAK-CF 上的 ES 和 GS，这表明 PEAK-T 对现有方法来说，在没有邻近扰动的情况下添加知识更具挑战性。这可能是因为，对于 PEAK-T，新知识来自外部世界，模型从未见过。相比之下，PEAK-CF 已经包含了一些弱的反事实关联，使模型更容易整合反事实。(2) PEAK-T 的 AFF 和 ANF 都低于 PEAK-CF，这表明 PEAK-T 在编辑过程中受到的邻近干扰比 PEAK-CF 少。这可能是由于与模型中的原始反事实知识相比，采样的错误答案与新的外部知识之间的相关性较弱。因此，在 PEAK-T 中添加新知识时的扰动较小。

7.4. APP 的结果

如表 3 和表 4 底下四行所示，APP 结合了四种编辑方法。APP 中使用的错误答案来自硬设置。去掉




图2. 不同编辑方法编辑后 LLaMA-2 的正确答案平均概率 O 和 错误答案平均概率 O_h (硬) 和 O_r (随机)。LLaMA-2 指未经编辑的模型。+ 表示该方法与 APP 相结合。

每种方法的超参数可参见附录 B.2。总体而言, APP 几乎保持了以往编辑指标下添加新知识性能, 并在 硬设置和 随机设置下大大减轻了 AFF 和 ANF 的邻近扰动。尤其是 ROME+APP 和 MEMIT+APP 在添加新知识方面仍然表现出色, 与原始编辑方法相比, 其扰动减少幅度最大。此外, 我们还发现 APP 还提高了 LS 的性能, 保留了无关知识。这些结果有助于得出结论: APP 能有效保持原有正确知识的完整性, 并在添加新知识时防止错误知识的加入。尽管添加性有了显著提高, 但仍远远低于令人满意的水平, 这凸显了所提出的邻近扰动的严重性和复杂性。要应对这一挑战, 需要社会各界的共同努力。

7.5. 答案概率变化

为了进一步分析编辑模型中的邻近扰动和我们提出的 APP 的机制, 图 2 展示了在 PEAK-CF 上用不同方法编辑的 LLaMA-2 模型中正确答案和错误答案的平均概率。这里可以得出两个结论。

现有的编辑方法严重扰乱了概率。与最初的 LLaMA-2 相比, 正确答案的概率大幅下降, 而错误答案 (Hard) 的概率则大幅上升, 尤其是 MEMIT 和 ROME。MEND 显示出最小的差异, 这与其卓越的加法性能是一致的。与错误答案 (Hard) 相比, 错误答案 (Random) 的概率在编辑后的变化明显较小, 这表明与新添加答案更密切相关的错误答案更值得关注。

APP 有效地缓解了概率扰动。




图3. APP 的消融概率和相加性分析。使用 LLaMA-2 在 PEAK-CF 数据集上得出的结果。由于篇幅限制, 其他方法的结果见附录 B.5。

在将现有的编辑方法与所提出的 APP 相结合后, 正确答案和错误答案的概率扰动都得到了显著缓解。这些结果生动地解释了为什么 APP 可以有效地减轻扰动, 从而保留正确的知识, 防止错误知识的加入。

7.6. 消融研究

为了验证其有效性, 我们进行了删除 APP 中每个编辑目标 L_1 、 L_2 或 L_3 的消融测试。图 3 展示了加法的 AFF 和 ANF, 以及正确答案和错误答案 (Hard) 的概率。我们有两个发现。首先, 去除 APP 的任何编辑目标都会导致相加性和概率扰动方面的性能下降, 这表明了它们的有效性。其次, 删除 L_1 会导致最显著的性能下降。这证明了 L_1 在 APP 中的重要性, 因为 APP 的目的是在正确答案和错误答案的概率之间保持一定的余量。

7.7. 获取所有正确答案的影响

提议的方法在编辑过程中可以访问所有正确答案 O , 而基线方法只能访问新的正确答案 o^* 。为了探索访问所有正确答案的效果, 我们让这些基线方法在编辑时也直接使用所有正确答案作为编辑目标。具体来说, 所有基线方法都被扩展为在编辑 LLM 时使用整个 O 集, 以确保比较的公平性。结果如表 5 所示。将这些结果与表 3 中的拟议 APP 方法的结果进行比较, 我们发现, 尽管在获取新知识方面表现相似, 但新基线方法的可加性仍明显高于拟议 APP 方法, 这表明 APP 在维护答案列表完整性方面表现更好。

7.8. 相邻答案数量的影响

图 4 展示了 APP 的性能在 PEAK-CF 和 LLaMA-2 上不同相邻答案数量的变化情况。

表 5. 使用 LLaMA-2 的 PEAK-CF 数据集 (7B) 上更公平基线的评估结果 (%)

。"这里只使用了硬设置中的错误答案。

编辑器	LLaMA-2 (7B)				
	上一页		加法 (硬)		
	es gs↑	↑ ls↑ aff↓	anf ↓		
FT+	97.54	85.93	71.68	74.35	61.83
MEND+	93.26	79.90	50.91	33.92	32.03
MEMIT+	98.29	93.07	94.20	48.10	66.72
ROME+	100.00	93.13	95.48	50.27	64.91

为此，我们扩大了评估范围，考虑在 APP 中使用 k 个正确答案和错误答案。为此，我们扩展了评估范围，考虑在 APP 中使用 k 个正确答案和错误答案，其中 $k \in [0, 1, 3, 5, all]$ 。从这些结果中可以看出，所有与 APP 结合使用的编辑方法的性能都很高。

随着相邻答案数量的增加，该指标也得到了明显改善。这一趋势表明，考虑更多相邻答案以全面描述相邻扰动是有效的。这也表明，即使答案数量较少，AFF 和 ANF 也能得到明显改善，从而证明了所提出的 APP 方法的实用性。

8. 结论与局限性

本研究调查了 LLM 上知识编辑的相邻扰动。研究引入了一个可加性度量，并构建了一个被称为 PEAK 的基准，用于评估相邻知识的扰动程度。此外，还提出了一个即插即用框架 APP，通过最小化知识附加过程中的干扰概率来减轻扰动。对各种知识编辑方法和 LLM 的综合实验表明，它们在编辑过程中不可避免地会对相邻知识产生扰动，而所提出的 APP 方法则在一定程度上有效地减轻了这种扰动。未来，我们将探索扩大邻接知识的范围，以更全面地描述知识编辑的邻接扰动。

此外，我们的工作还存在一些局限性。首先，在实验设置方面，本文采用的编辑方法涉及修改模型参数。但一些保留模型参数的编辑方法仍有待探索。其次，本文以事实知识为基础，如果能将这种方法扩展到不同类型的知识，如常识、逻辑或空间知识，将大有裨益。第三，本文根据概率能力设计了拟议的可加性度量。然而，实际模型产生的结果并不完全取决于概率。因此，虽然这种评估方法大致反映了扰动程度，但可能会在一定程度上偏离实际情况。




图 4. 在 PEAK-CF 上使用 LLaMA-2 的硬设置中的 AFF 和 ANF，在使用 k 个原始正确答案和错误答案的四种编辑方法中都使用了 APP。 $k \in [0, 1, 3, 5, all]$ 。

致谢

我们对匿名观众的宝贵意见表示感谢。本研究由国家科技重大专项（编号：2023ZD0121103）资助。张宁宇得到国家自然科学基金（62206246）、浙江省自然科学基金（LGG22F030011）、甬江人才引进计划（2021A-156-G）、CCF-腾讯犀牛鸟开放研究基金的资助。

影响声明

本文的研究重点是法律硕士的一个重要方面--他们容易因错误或过时的知识而产生非预期的文本。鉴于重新训练 LLMs 需要大量资源，本研究将重点放在新兴的知识编辑领域。它开发了减少扰动以保持事实真实性的技术。就未来的社会影响而言，这项工作有助于减少对全面重新训练的需求，减少计算资源和能源消耗。这符合可持续人工智能的要求，使在资源有限的环境中部署 LLM 更加可行。此外，APP 能够执行有针对性的编辑并减轻邻近的枯燥扰动，这可以提高 LLM 在医疗诊断和法律分析等专业领域的效率，因为在这些领域，精确和最新的知识至关重要。此外，向 LLMs 添加知识的编辑方法可能会被滥用来传播错误信息。此外，如果在没有适当保护措施的情况下添加敏感信息，可能会带来隐私风险。今后，应实施一些策略来降低这些风险。

参考文献

- Bau, D., Liu, S., Wang, T., Zhu, J., and Torralba, A. Rewriting a deep generative model. In Vedaldi, A., Bischof, H., Brox, T., and Frahm, J. (eds.), *Computer Vision - ECCV 2020 - 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part I*, volume 12346 of *Lecture Notes in Computer Science*, pp. doi: 10.1007/978-3-030-58452-8_21. URL https://doi.org/10.1007/978-3-030-58452-8_21.
- Cao, N. D., Aziz, W., and Titov, I. 编辑语言模型中的事实知识。In Moens, M., Huang, X., Specia, L., and Yih, S. W. (eds.), *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 7-11 November, 2021*, pp. doi: 10.18653/v1/2021.emnlp-main.522. URL <https://doi.org/10.18653/v1/2021.emnlp-main.522>.
- Cheng, S., Tian, B., Liu, Q., Chen, X., Wang, Y., Chen, H., and Zhang, N. Can we edit multimodal large language models? In Bouamor, H., Pino, J., and Bali, K. (eds.), *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023*, pp. 计算语言学协会, 2023 年。 URL <https://aclanthology.org/2023.emnlp-main.856>
- Cohen, R., Biran, E., Yoran, O., Globerson, A., and Geva, M. 评估语言模型中知识编辑的连锁反应。 *CoRR*, abs/2307.12976, 2023。 DOI : 10.48550/ARXIV.2307.12976。 URL <https://doi.org/10.48550/arXiv.2307.12976>.
- Dai, D., Dong, L., Hao, Y., Sui, Z., Chang, B., and Wei, F. Knowledge neurons in pretrained transformers. In Muresan, S., Nakov, P., and Villavicencio, A. (eds.), *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2022, Dublin, Ireland, May 22-27, 2022*, pp. doi: 10.18653/v1/2022.acl-long.581. URL <https://doi.org/10.18653/v1/2022.acl-long.581>.
- Gandikota, R., Materzynska, J., Fiotto-Kaufman, J., and Bau, D. Erasing concepts from diffusion models. *CoRR*, abs/2303.07345, 2023. doi: 10.48550/ARXIV.2303.07345. URL <https://doi.org/10.48550/arXiv.2303.07345>.
- Gentile, C. and Warmuth, M. K. Linear hinge loss and average margin. In Kearns, M. J., Solla, S. A., and Cohn, D. A. (eds.), *Advances in Neural Information Processing Systems 11, [NIPS Conference, Denver, Colorado, USA, 1998年11月30日至12月5日]*, 第225-231页。麻省理工学院出版社, 1998 年。
- Ge, M., Schuster, R., Berant, J., and Levy, O. Trans-former feed-forward layers are key-value memories. In Moens, M., Huang, X., Specia, L., and Yih, S. W. (eds.), *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 7-11 November, 2021*, pp. doi: 10.18653/v1/2021.emnlp-main.446。 URL <https://doi.org/10.18653/v1/2021.emnlp-main.446>.
- Geva, M., Caciularu, A., Wang, K. R., and Goldberg, Y. Transformer feed-forward layers build predictions by promoting concepts in the vocabulary space. In Goldberg, Y., Kozareva, Z., and Zhang, Y. (eds.), *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022*, pp. 计算语言学协会, 2022 年。 DOI : 10.18653/v1/2022.emnlp-main.3。 URL <https://doi.org/10.18653/v1/2022.emnlp-main.3>.
- Gu, J., Xu, H., Ma, J., Lu, P., Ling, Z., Chang, K., and Peng, N. Model editing can hurt general abilities of large language models. Doi: 10.48550/ARXIV.2401.04700. URL <https://doi.org/10.48550/arXiv.2401.04700>.
- Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., and Liu, T. 大型语言模型中的幻觉调查：原则、分类、挑战和开放性问题。 *CoRR*, abs/2311.05232, 2023. doi: 10.48550/ARXIV.2311.05232. URL <https://doi.org/10.48550/arXiv.2311.05232>.
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Madotto, A., and Fung, P. Survey of hallucination in natural language generation. *ACM Comput. Surv.*, 55(12):248:1-248:38, 2023. doi: 10.1145/3571730. URL <https://doi.org/10.1145/3571730>.
- Li, Z., Zhang, N., Yao, Y., Wang, M., Chen, X., and Chen, H. 揭示大型语言模型知识编辑的陷阱。 DOI : 10.48550/ARXIV.2310.02129。 URL <https://doi.org/10.48550/arXiv.2310.02129>.
- Ma, J., Chen, B., Gu, J., Ling, Z., Guo, W., Liu, Q., Chen, Z. and Liu, C. Wider & closer: 混合短信道蒸馏器用于零镜头跨语言命名实体识别。 In Goldberg, Y., Kozareva, Z., and Zhang, Y. (eds.), *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Pr.*

- on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022, pp.DOI: 10.18653/v1/2022.emnlp-main.345。URL <https://doi.org/10.18653/v1/2022.emnlp-main.345>.
- Ma, J., Gu, J., Ling, Z., Liu, Q., and Liu, C. Untying the reversal curse via bidirectional language model editing. *CoRR*, abs/2310.10322, 2023. DOI: 10.48550/ARXIV.2310.10322.URL <https://doi.org/10.48550/arXiv.2310.10322>.
- Mahdisoltani, F., Biega, J., and Suchanek, F. M. YAGO3: 来自多语言维基词典的知识库。In *Seventh Biennial Conference on Innovative Data Systems Research, CIDR 2015, Asilomar, CA, USA, January 4-7, 2015, Online Proceedings*. www.cidrdb.org, 2015.URL http://cidrdb.org/cidr2015/Papers/CIDR15_Paper1.pdf.
- Mao, S., Zhang, N., Wang, X., Wang, M., Yao, Y., Jiang, Y., Xie, P., Huang, F., Chen, H. Editing personality for llms.DOI: 10.48550/ARXIV.2310.02168.URL <https://doi.org/10.48550/arXiv.2310.02168>.
- Meng, K., Bau, D., Andonian, A., and Belinkov, Y. 在 GPT 中定位和编辑事实关联。In *NeurIPS*, 2022.URL <https://arxiv.org/abs/2202.05262>.
- Meng, K., Sharma, A. S., Andonian, A. J., Belinkov, Y., and Bau, D. Mass-editing memory in a transformer.In *The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023*. OpenReview.net, 2023.URL <https://openreview.net/pdf?id=MkbcAHYgyS>.
- Mitchell, E., Lin, C., Bosselut, A., Finn, C., and Manning, C.D. 大规模快速模型编辑。In *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022*.OpenReview.net, 2022a.URL <https://openreview.net/forum?id=0DcZxeWfOPT>.
- Mitchell, E., Lin, C., Bosselut, A., Manning, C. D., and Finn, C. Memory-based model editing at scale.In Chaudhuri, K., Jegelka, S., Song, L., Szepesvári, C., Niu, G., and Sabato, S. (eds.), *International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA*, volume 162 of *Proceedings of Machine Learning Research*, pp. 15817-15831.PMLR, 2022b。URL <https://proceedings.mlr.press/v162/mitchell122a.html>.
- OpenAI.GPT-4 技术报告。 *CoRR*, abs/2303.08774, 2023。doi: 10.48550/ARXIV.2303.08774。URL <https://doi.org/10.48550/arXiv.2303.08774>.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C.L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P. F., Leike, J., and Lowe, R. Training language models to follow instructions with human feedback.In *NeurIPS*, 2022.URL <https://arxiv.org/abs/2203.02155>.
- Pearl, J. Direct and indirect effects.In Breese, J. S. and Koller, D. (eds.), *UAI '01: Proceedings of the 17th Conference in Uncertainty in Artificial Intelligence, University of Washington, Seattle, Washington, USA, August 2-5, 2001*, pp.摩根考夫曼, 2001 年。URL https://dslpitt.org/uai/displayArticleDetails.jsp?mmnu=1&smnu=2&article_id=126&proceeding_id=17.
- Peng, B., Galley, M., He, P., Cheng, H., Xie, Y., Hu, Y., Huang, Q., Liden, L., Yu, Z., Chen, W., and Gao, J. Check your facts and try again: 利用外部知识和自动反馈改进大型语言模型。 *CoRR*, abs/2302.12813, 2023。DOI: 10.48550/arXiv.2302.12813.URL <https://doi.org/10.48550/arXiv.2302.12813>.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I., et al. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9, 2019.
- Sinitin, A., Plokhhotnyuk, V., Pyrkov, D. V., Popov, S., and Babenko, A. Editable neural networks.第8届国家间学习表征会议, ICLR 2020, 埃塞俄比亚的斯亚贝巴, 2020 年 4 月 26-30 日。OpenReview.net, 2020.URL <https://openreview.net/forum?id=HJedXaEtvS>.
- Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., Bikel, D., Bikel, D., Blecher, L., Canton-Ferrer, C., Chen, M., Cucurull, G., Esiobu, D., Fernandes, J., Fu, J., Fu, W., Fuller, B., Gao, C., Goswami, V., Goyal, N., Hartshorn, A., Hosseini, S., Hou, R., Inan, H., Kardaş, M., Kerkez, V., Khabsa, M., Kloumann, I., Korenev, A., Koura, P. S., Lachaux, M., Lavril, T., Lee, J., Liskovich, D., Lu, Y., et al. Llama 2: Open foundation and fine-tuned chat models. *CoRR*, abs/2307.09288, 2023。DOI: 10.48550/arXiv.2307.09288。URL <https://doi.org/10.48550/arXiv.2307.09288>.
- Vig, J., Gehrmann, S., Belinkov, Y., Qian, S., Nevo, D., Singer, Y., and Shieber, S. M. Investigating gender bias in language models using causal mediation analysis.In Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., and Lin, H. (eds.), *Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, Neural Information Processing Systems 2020*.

- tion Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual, 2020.
- Vrandečić, D. and Krotzsch, M. Wikidata: a free collaborative knowledgebase. *Commun.ACM*, 57(10):78-85, 2014. doi: 10.1145/2629489. URL <https://doi.org/10.1145/2629489>.
- Wang, B. and Komatsuzaki, A. Gpt-j-6b: A 6 billion parameter autoregressive language model, 2021.
- Wang, P., Zhang, N., Xie, X., Yao, Y., Tian, B., Wang, Easyedit: An easy-to-use knowledge editing framework for large language models. *CoRR*, abs/2308.07269, 2023. DOI: 10.48550/arXiv.2308.07269. URL <https://doi.org/10.48550/arXiv.2308.07269>.
- Wang, Y., Chen, M., Peng, N., and Chang, K.-W. Deepedit: Knowledge editing as decoding with constraints. *ArXiv preprint arXiv:2401.10471*, 2024.
- Wu, X., Li, J., Xu, M., Dong, W., Wu, S., Bian, C., and Xiong, D. DEPN: detecting and editing privacy neurons in pretrained language models. In Bouamor, H., Pino, J., and Bali, K. (eds.), *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023*, pp. 计算语言学协会, 2023 年。 URL <https://aclanthology.org/2023.emnlp-main.174>.
- Robust truncated hinge loss support vector machines. *美国统计协会学报*, 102 (479) : 974-983, 2007 年。
- Yao, Y., Wang, P., Tian, B., Cheng, S., Li, Z., Deng, S., Chen, H., and Zhang, N. Editing large language models: 问题、方法和机遇。 In Bouamor, H., Pino, J., and Bali, K. (eds.), *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023*, pp. 计算语言学协会, 2023 年。 URL <https://aclanthology.org/2023.emnlp-main.632>.
- Yin, X., Jiang, J., Yang, L., and Wan, X. History matters: 大型语言模型中的时态知识编辑。 DOI: 10.48550/ARXIV.2312.05497. URL <https://doi.org/10.48550/arXiv.2312.05497>.
- Zhang, B., Haddow, B., and Birch, A. Prompting large language model for machine translation: 案例研究。 In Krause, A., Brunskill, E., Cho, K., Engelhardt, B., Sabato, S., and Scarlett, J. (eds.), *International Conference on Machine Learning, ICML 2023, 23-29 July 2023, Honolulu, Hawaii, USA*, volume 202 of *Proceedings of Machine Learning Research*, pp. PMLR, 2023a. URL <https://proceedings.mlr.press/v202/zhang23m.html>.
- Zhang, N., Yao, Y., Tian, B., Wang, P., Deng, S., Wang, M., Xi, Z., Mao, S., Zhang, J., Ni, Y., et al. A comprehensive study of knowledge editing for large language models. *ArXiv preprint arXiv:2401.01286*, 2024.
- Zhang, Y., Li, Y., Cui, L., Cai, D., Liu, L., Fu, T., Huang, X., Zhao, E., Zhang, Y., et al, Zhao, E., Zhang, Y., Chen, Y., Wang, L., Luu, A. T., Bi, W., Shi, F., and Shi, S. Siren's song in the AI ocean: A survey on hallucination in large language models. *CoRR*, abs/2309.01219, 2023b. doi: 10.48550/arXiv.2309.01219. URL <https://doi.org/10.48550/arXiv.2309.01219>.
- Zhong, Z., Wu, Z., Manning, C. D., Potts, C., and Chen, D. Mquake: 通过多跳问题评估语言模型中的知识编辑。 In Bouamor, H., Pino, J., and Bali, K. (eds.), *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023*, pp. 计算语言学协会, 2023 年。 URL <https://aclanthology.org/2023.emnlp-main.971>.
- Zhu, C., Rawat, A. S., Zaheer, M., Bhojanapalli, S., Li, D., Yu, F. X., and Kumar, S. Modifying memories in transformer models. *CoRR*, abs/2012.00363, 2020. URL <https://arxiv.org/abs/2012.00363>.

A. 数据集

A.1. 构建错误答案

对于本文提出的 *可加性*，给定编辑 $E = \{s, r, O, o^*, p\}$ ，其中 $t_r(s) = p$ ，同时利用原始正确答案和采样的错误答案。错误答案的采样分为 *硬* 采样和 *随机* 采样两种情况。在 *硬* 设置中，一些对象与新对象 o 建立了直接关系，*。具体来说，将 Wikidata 的三元组表示为 $W(r) = \{(s, r, o)\}$ ，我们首先在 $W(r)$ 中寻找与 o^* （可以是 $(o^*, r^{(')}, *)$, $(*, r^{(')}, o^*)$ 的形式）有链接 $r^{(')}$ 的实体，然后收集这些实体并选择与 o^* 有相同实体类型的实体。例如，如果 o^* 是一个人，那么所选实体也是人。最后，我们抽取一些选定的实体作为错误答案。在 *随机* 设置中，我们寻找与 o^* 没有链接的实体，而其他部分是相同的。这样，*硬* 设置中的错误答案在语义上更接近新添加的对象，而 *随机* 设置中的错误答案在语义上远离新对象。

A.2. 数据集的关系和模板

表 6 和表 7 显示了一些关系及其模板的示例。

表 6. PEAK-CF 中关系 r 的部分模板 $T(r)$ 。实际上，每个关系都有多个模板。这里我们只显示每个关系的一个或两个模板。

关系 (r)	$T(r)$
生产者	"{} 是什么产品的生产者？"， "{} 生产了许多产品，如官方语言 插图 "插图画家 {} 创作了插图"。
写的	"{}，他写过一些类似的书"， "{} 写过哪些书？

表 7. PEAK-T 中关系 r 的部分模板 $T(r)$ 。

关系 (r)	$T(r)$
用于	"这么久以来，{} 在哪些俱乐部效力过？"， "哪些俱乐部聘请过 {} 作为球员？" 创建了 "{} 是负责创建 "的个人
获奖	"{} 是获奖者"， "{} 获得过哪些奖项？

B. 实验设置

B.1. 基准方法

我们选择了五种常用的模型编辑方法作为基线，包括

- **FT** (Zhu 等人, 2020 年)：这种方法只是对编辑内容进行梯度下降，以更新模型参数。它对模型中的一层进行微调，对权重变化进行规范约束，以防止过度拟合。由于原作者没有公布他们的代码，我们按照 Meng 等人 (2022 年) 的研究重新实施了该方法。
- **KN** (Dai 等人, 2022 年)³：它首先通过基于梯度的归因选择与知识表达相关的神经元，然后通过添加缩放嵌入向量修改这些神经元对应的 MLP 层。
- **MEND** (Mitchell 等人, 2022a)⁽⁴⁾：它通过将微调梯度分解成秩-1 形式，学习超网络以产生权重更新。

³ <https://github.com/EleutherAI/knowledge-neurons>.

⁴ <https://github.com/eric-mitchell/mend>

- **ROME** (Meng等人, 2022年)⁵: 它首先将事实知识定位在转换器MLP模块中的特定层, 然后通过MLP模块中直接写入新的键值对来更新知识。
- **MEMIT** (Meng等人, 2023年)⁶: 它对 ROME 进行了扩展, 编辑了大量事实集, 并更新了一系列 MLP 层以更新知识。

这些方法的能力评估基于 EasyEdit (Wang等人, 2023年), 这是一个易于使用的知识编辑框架, 整合了之前方法的发布代码和超参数。

B.2. APP 的超参数

为了设置超参数, 我们还创建了一个小型验证集。表 8 显示了不同 LLM 的超参数设置详情。此外, 保证金 M 设为 2。

表 8. 每种方法在每个模型上的 APP 超参数。

编者	GPT-2 XL (1.5B)			GPT-J (6B)			LLaMA-2 (7B)		
	α	β	γ	α	β	γ	α	β	γ
FT+APP	0.2	0.5	0.2	0.2	0.5	0.2	0.2	0.5	0.2
MEND+APP	0.5	0	0	0.5	0	0	0.3	0	0
MEMIT+APP	0.05	0.05	0.05	0.1	0.3	0.2	0.6	1.0	0.3
ROME+APP	0.2	0.2	0.1	0.2	0.2	0.1	0.5	0.8	0.1

B.3. 以往度量标准示例

下面我们举例说明以前的度量标准的含义。

有效性 给定一个编辑事实 ($s = \text{苹果公司}$, $r = \text{产品}$, $O = \{\text{AirPods 3}, \text{MacBook Air}, \dots, \text{iPhone 14}\}$, $o^* = \text{iPhone 15}$), 如果在相应的问题 $t_r(s)$ "苹果公司的产品有哪些?" 下, 编辑后的模型 F^* 赋予新对象 o^* 的概率高于 O 中的最小概率, 那么这个新知识的添加就是有效的。

泛化 如果经过编辑的模型能够在 "苹果公司生产什么产品?" 这样的转述提示下回忆起新的知识, 那么它就被认为成功泛化了。也就是说, 要确定经过编辑的模型 F^* 分配给新对象 o^* 的概率是否高于在转述提示下 O 的最小概率。

定位 在回答无关或超出编辑范围的提示时, 编辑后的模型应保持不变。例如, "哪家公司开发了 Windows?" 的答案仍应是 "微软"。

B.4. LLaMA-2 (13B) 的结果

LLaMA-2 (13B) 的结果如表 9 所示。与之前的结果相比, 我们可以得出结论: 之前的重要结论仍然有效, 如 "记忆新目标知识的性能良好"、"较大的 LLM 受到的扰动更严重" 和 "APP 显著减轻了扰动"。

B.5. 消融研究

图 5 显示了第 7.6 节中消融研究的其他结果。由于 MEND 只能在 APP 中使用 L_1 , 我们只列出了 FT 的结果。

C. APP 与现有方法结合的实例

这里我们以 ROME 编辑方法为例。

⁵ <https://github.com/kmeng01/rome>

⁶ <https://github.com/kmeng01/memit>

⁷ 以往的研究关注的是概率是否超过原始的 O , 而这里的 O 是一个集合, 因此我们做了些许改动。

表9.使用 LLaMA-2 (13B) 在 PEAK-CF 数据集上的评估结果 (%)。

编辑器	LLaMA-2 (13B)					
	前一个			加性 (硬)		加性 (运行)
	ES ↑	GS ↑	LS ↑	AFF ↓	ANF ↓	AFF ↓ ANF ↓
FT	99.66	84.46	78.16	81.30	57.86	73.45
MEMIT	99.66	98.47	93.50	94.00	85.92	86.10
罗马	100.00	97.90	92.91	93.09	84.93	83.46
FT+APP	97.61	81.07	80.75	71.04	47.30	61.22
MEMIT+APP	97.95	92.26	96.13	51.03	26.20	44.92
罗马+APP	96.59	91.41	94.97	42.08	23.09	35.25




图5 APP 的消融概率和加性分析。LLaMA-2 对 PEAK-CF 数据集进行了分析。

C.1. 梯度模型编辑 (ROME)

ROME (Meng 等人, 2022 年) 应用因果中介分析 (Pearl, 2001 年; Vig 等人, 2020 年) 来定位存储事实的 MLP 模块。

存储事实的 MLP 模块。一个 MLP 模块由两层组成, 第一层和第二层分别表示为 W^l

分别为 $W^{l_{proj}}$ 被视为线性关联存储器和编辑区。一个新事实表示为

键值对 (k_*, v_*) (Geva 等人, 2021 年), 可通过求解约束最小二乘问题将其插入模型的 MLP 模块 (Bau 等人, 2020 年)。剩下的就是选择合适的 k_* 和 v_* 。

将 L 表示编辑过的 MLP 层, F 表示未编辑过的模型, $e = (s, r, o^*)$ 表示编辑事实。密钥 k_* 是通过计算 W^L 输出的主体 s 最后一个标记的平均表示值得到的, 如下所示:

$$k_* = \frac{1}{N} \sum_{j=1}^N k(x_j + s), \quad (11)$$

$$\text{其中 } k(x) = \sigma(W^{(L)}_{fc} \gamma a^{(O(L))}_{[x]_i} h^{(O(L)-1)}_{[x]_i}).$$

这里, x_j 是随机采样序列, i 是句子 x 中主语最后一个标记的位置。 h 是隐藏状态, a 是注意力, γ 是外显规范, σ 是激活函数。

值 v_* 将新知识 (r, o^*) 作为 s 的属性进行编码。为了计算它, ROME 设置 $v_* = \operatorname{argmin}_z L(z)$, 其中目标表示为

$$L_e(o^*, z) = -\log P_{F^{(0)} := z}^{(i)}(o^* | p) + D_{\text{KL}}(P_{F^{(0)} := z}^{(i)}(o^* | p) \| P_{F^{(0)} := z}^{(i)}(x | p)). \quad (12)$$

公式 (12) 中的第一项寻求的是一个向量 z , 将其代入标记 i 处的 MLP 输出 (标记为

$F^{(L)}_{m^{(L)}_i} := z$, 此处 i 是提示 p 中的主语末尾) 时, 将使网络预测目标对象 o^*

例如, p =埃菲尔铁塔位于, o^* =伦敦)。第二项最小化了预测 $p^{(i')}$ (形式为" $\{$ 主语 $\}$ 是 a") 与不变模型的 KL 分歧 (Ma 等人, 2022 年), 这有助于保持模型对主语本质的理解 (i') 是 $p^{(i')}$ 中主语最后一个标记的位置)。

最后, MLP 权重 W^L 进行秩一更新, 以插入新事实:

$$\hat{W} = W + \Lambda C^{-1} k (C^T k)^{-1} \quad (13)$$

其中 C 是一个常数, 是通过估计许多现有密钥的协方差得出的。 $\Lambda = (v^* - Wk) / C^{-1} k^T k$, 表示新密钥-密钥-密钥的残余误差。

新键值对在原始存储矩阵上的残余误差。关于 ROME 的更多细节, 读者可以参考 [Meng 等人](#)

(2022) 的文章。

C.2. 将 APP 应用于 ROME

在 ROME 中, 编辑目标是 $L_e(o^*, z)$, 需要优化的参数是 $v_* = \arg\min_z L(z)$ 的 z 。因此, 建议的 APP 可与 $L_e(o^*, z)$ 结合来优化 z 。

一方面, 编辑目标 $L_{(1)}(O, O_h, z)$ 的目的是在原始正确答案 O 和错误答案 O_h 的概率之间保持一定的余量, 可写成以下形式:

$$L_{(1)}(O, O_h, z) = \frac{1}{NM} \sum_{i=1}^N \sum_{j=1}^M \max\{0, M - \log P_{F(m^{(0)}(z))}(o_i | p) + \log P_{F(m^{(0)}(z))}(o_{hj} | p)\}, \quad (14)$$

N 和 M 分别代表 O 和 O_h 中的元素数。该等式的目的是鼓励正确答案的对数概率至少大于错误答案的对数概率 M 。

另一方面, 在编辑过程中, 既要确保正确答案的绝对概率不降低, 又要控制错误答案的概率不增加, 这可以分别表示为两个目标 $L_{(2)}(O, z)$ 和 $L_{(3)}(O_h, z)$:

$$L_{(2)}(O, z) = \frac{1}{N} \sum_{i=1}^N \max\{0, \log P_{F(m^{(0)}(z))}(o_i | p) - \log P_{F(m^{(0)}(z))}(o_i | p)\}, \quad (15)$$

$$L_{(3)}(O_h, z) = \frac{1}{M} \sum_{i=1}^M \max\{0, \log P_{F(m^{(0)}(z))}(o_{hi} | p) - \log P_{F(m^{(0)}(z))}(o_{hi} | p)\}. \quad (16)$$

$P_{(F)}(o_i | p)$ 指未经编辑的模型输出的概率。 $P_{(F^{(0)}(m^{(0)}(z)))(o_i | p)}$ 指的是经过公式 (12) 中相同操作的模型输出的概率。这两个等式分别追求的目标是: 鼓励正确答案的对数概率不降低, 错误答案的对数概率不增加。最后, 将这些建议目标与编辑目标 $L_e(o^*, z)$ 共同优化, 得到

v_* :

$$v_* = \arg \min_z L_e(o^*, z) + \alpha L_{(1)}(O, O_h, z) + \beta L_{(2)}(O, z) + \gamma L_{(3)}(O_h, z). \quad (17)$$

最后, 利用公式 (13) 更新模型参数。