

如需查看该出版物的讨论、统计资料和作者简介，请访问：<https://www.researchgate.net/publication/380756642>

了解法律硕士代理的规划：一项调查

预印本 - 2024 年 5 月

DOI: 10.48550/arXiv.2402.02716

引文

11

9 位作者，包括



徐煌

中国科学技术大学

26 篇著作 317 次引用

查看简介



王浩

北海道大学

207 篇著作 6,571 次引用

查看简介

阅读

5,776



刘伟文

上海交通大学

117 篇出版物 1 498 次引用

查看简介



德福连

电子科技大学

256 篇出版物 8,511 次引用

查看简介

用户要求增强下载的文件。

在四个基准测试中分析了几种具有代表性的方法。据我们所知，这是第一部从规划能力角度全面分析基于 LLM 的代理的著作。

本文随后的章节安排如下。在第 2，节中我们将作品分为五个主流方向，并分析了它们关于规划能力的观点。第 3 至第 7 节对每个方向进行了详细讨论和分析。最后，第 9 节对本文进行了总结，并对该领域的未来发展方向提出了见解。

2 分类学

随着对基于 LLM 的代理规划能力的研究呈现出蓬勃发展的景象，人们提出了各种方法来开发规划能力的上限。为了更好地了解现有的先进成果，我们挑选了一些具有代表性和影响力的成果，分析其动机和基本思想。为了让大家更好地理解，我们在表 1 中进行。了说明

根据该表，我们为基于 LLM 的代理规划提出了一种新颖、系统的分类法，将现有工作分为五个重要类别，包括任务分解、多计划选择、外部模块辅助规划、反射与细化以及记忆增强规划，如图 1。所示在此，我们对这五个方向简要总结如下。

任务分解。现实生活中的任务通常具有复杂性和多步骤性，给规划带来了极大的困难。这种方法采用分而治之的思想，将复杂的任务分解为若干子任务，然后按顺序对每个子任务进行规划。其过程可表述如下

$$g_0, g_1, \dots, g_n = \text{decompose}(E, g; \Theta, P);$$

$$p'_i = (a^i_0, a^i_1, \dots, a^i_m) = \text{subplan}(E, g_i; \Theta, P).$$

多计划选择。这种方法的重点是引导 LLM 多"思考"，为一项任务生成各种备选计划。然后，与任务相关的搜索算法就会出现。

选择一个计划来执行。这一过程可表述如下

$$P = p_1, p_2, \dots, p_n = \text{plan}(E, g; \Theta, P);$$

$$p^* = \text{select}(E, g, P; \Theta, F).$$

其中， F 代表搜索策略，例如一些树形搜索算法 [Yao 等人, 2023; Zhao 等人, 2023b]。

外部规划师辅助规划。该方法采用外部规划师来提升规划程序，旨在解决所生成计划的效率和可行性问题，而 LLM 主要扮演将任务形式化的角色。具体过程如下：

$$h = \text{formalize}(E, g; \Theta, P);$$

$$p = \text{plan}(E, g, h; \Phi)。$$

其中， Φ 表示外部规划模块， h 表示形式化信息。

反思与完善。这种方法强调通过反思和改进来提高规划能力。

它鼓励 LLM 反思失败，然后完善计划。这一过程可表述如下：

$$p_0 = \text{plan}(E, g; \Theta, P);$$

$$r_i = \text{reflect}(E, g, p_i; \Theta, P);$$

$$p_{i+1} = \text{refine}(E, g, p_i, r_i; \Theta, P);$$

记忆增强规划。这种方法通过额外的记忆模块来实现规划，其中存储了一些有价值的信息，如常识性知识、过去的经验、特定领域的知识等。这一过程可表述如下

$$m = \text{retrieve}(E, g; M);$$

$$p = \text{plan}(E, g, m; \Theta, P)。$$

其中 M 代表内存模块。

这五个方向相互关联而非相互排斥，通常涉及同时采用多种技术。在接下来的章节中，我们将深入探讨有关 LLM-代理规划的五个研究方向，阐明它们的动机，提出表征解决方案，并解决固有的局限性。

3 任务分解

在现实世界中，环境往往具有复杂性和多变性的特点，因此通过一步到位的规划流程来完成复杂的任务是一项艰巨的挑战。




图 2：任务分解方式类型。

对复杂任务进行简化是人类的一项杰出能力，这体现在将一项任务分解为多个更简单的子任务上[Schraagen 等, 2000人]，这类类似于著名的"分解与征服"算法策略，如公式 (1) 所示。任务分解一般包括两个关键步骤：首先是分解复杂任务，称为"分解"步骤；其次是规划子任务，称为"子计划步骤"。目前在这一领域进行任务分解的方法一般分为两类：先分解和后分解，如图 2 所示。

3.1 分解优先法

分解优先法首先将任务分解为多个子目标，然后依次对每个子目标进行规划，如图 2 (a) 所示。具有代表性的方法包括

表 1: 现有 LLM-Agent规划工作的分类法。

方法	想法	法律硕士的任务	配方	代表作品
任务分解	分而治之	任务分解 分任务规划	$[g] = \text{decompose}(E, g; \Theta, P);$ $p = \text{subplan}(E, g; \Theta, P)$	CoT[2022], ReAct[2022]、 HuggingGPT [2023]
多计划 选择	生成多个计划 并选择最佳	生成计划 计划评估	$P = \text{plan}(E, g; \Theta, P);$ $p = \text{select}(E, g, P; \Theta, F)$	ToT [2023], GoT [2023]、 反恐委员会 [2022b]
外部 规划师辅助	将任务和 利用外部规划人员	任务正规化	$h = \text{formalize}(E, g; \Theta, P);$ $p = \text{plan}(E, g, h; \Phi)$	LLM+P [2023a]、 LEM+PDDL [2023]
反思与改进	反思经验, 完善计划	生成计划 反思改进	$p_0 = \text{plan}(E, g; \Theta, P);$ $r_i = \text{reflect}(E, g, p_i; \Theta, P);$ $p_{i+1} = \text{refine}(E, g, p_i, r_i; \Theta, P)$	Reflexion [2023]、 评论家 [2023]、 自我定义 [2023]
记忆辅助 规划	利用记忆 帮助规划	生成计划 内存提取	$m = \text{retrieve}(E, g; M);$ $p = \text{plan}(E, g, m; \Theta, P)$	记住 [2023a]、 记忆库 [2023]

HuggingGPT [Shen 等, 2023人]、Plan-and-Solve [Wang 等, 2023b人]、ProgPrompt [Singh 等人, 2023]等。

HuggingGPT[Shen等人, 2023年]利用Huggingface Hub中的各种多模态模型构建了一个用于多模态任务的智能代理。为了促进不同模型之间的协作, LLM 充当了控制器的角色, 负责分解人类提出的任务、选择模型并生成最终响应。最关键的阶段是初始任务分解, HuggingGPT 会明确指示 LLM 将给定任务分解为子任务, 并提供任务间的依赖关系。Plan-and-Solve [Wang 等人, 2023b] 在 Zero-shot Chain-of-Thought [Kojima 等人, 2022] 的基础上进行了改进, 将原来的 "让我们一步一步地思考" 转化为两步提示指令: "让我们先制定一个计划" 和 "让我们执行这个计划"。这种 "0-shot" 方法提高了数学推理、常识推理和符号推理的能力。ProgPrompt [Singh 等人, 2023] 将任务的自然语言描述转化为编码问题。它通过代码将代理的行动空间和环境中的对象符号化, 将每个行动形式化为一个函数, 将每个对象表示为一个变量。因此, 任务规划自然就转化为函数生成。在执行任务时, 代理首先以函数调用的形式生成计划, 然后逐步执行。

3.2 交错分解法

交错分解涉及交错任务分解和子任务规划, 每次分解只显示当前状态下的一个或两个子任务, 如图 2 (b)。所示这类方法的代表包括思维链 (CoT) 系列[Wei 等人, 2022 年; Kojima 等人, 2022 Yao 等年]、ReAct [人, 等2023 年人2022人, Chen 等, 2022 年年]、PAL [Gao]、思维程序 (PoT) []、Visual ChatGPT [Wu 等人, 2023 年]等。

引入思维链 (CoT) [Wei *et al.*, 2022]揭示了 LLM 的少量学习能力。CoT 引导 LLM 通过一些构建的轨迹对复杂问题进行推理, 利用 LLM 的

任务分解的推理能力。随后, Zero-shot CoT [Kojima *et al.*, 2022]通过 "让我们逐步思考" 这一神奇指令, 释放了 LLM 的零射推理能力。与将推理嵌入计划过程的 CoT 不同, ReAct [Yao 等人, 2022] 将推理与计划分离开来。它在推理 (思考步骤) 和规划 (行动步骤) 之间交替进行, 显著提高了规划能力。Visual ChatGPT [Wu 等人, 2023] 利用 ReAct 的机制, 将 LLM 用作配备一系列视觉模型的代理大脑, 从而产生了一个具有图像处理能力的代理。PAL [Gao 等人, 2023] 利用 LLM 的编码能力改进了 CoT, 在推理过程中引导 LLM 生成代码。最后, 使用代码解释器 (如 Python) 对代码进行综合演算, 从而获得解决方案。事实证明, 这种方法有助于代理解决数学和符号推理问题。思维程序 (Program-of-Thought, Chen 等人PoT) [, 2022] 将推理过程完全形式化为编程。作者还利用在代码相关数据上训练的 CodeX [Chen 等, 人2021b] 模型, 提高了数学和金融问题的处理能力。

3.3 讨论

分解优先法的优势在于子任务与原始任务之间的关联性更强, 从而降低了任务遗忘和遗漏的风险[Touvron 等人, 2023]。不过, 由于子任务在一开始就已预先确定, 因此需要额外的调整机制, 否则某个步骤的错误就会导致失败, 这将在第 6. 节中讨论另一方面, 交错分解和子规划可根据环境反馈动态调整分解, 从而提高容错性。不过, 对于复杂的任务, 过长的轨迹可能会导致 LLM 出现幻觉, 在后续的子任务和子规划中偏离最初的目标。

尽管任务分解大大增强了 LLM-Agent 解决复杂任务的能力, 但挑战依然存在。第一个挑战是任务分解带来的额外开销。将任务分解为多个子任务需要更多的推理和生成、

这需要额外的时间和计算成本。另一方面，对于分解成数十个子任务的高度复杂任务，规划会受到 LLM 上下文长度的限制，从而导致规划轨迹的遗忘。

4 多计划选择

由于任务的复杂性和 LLM 固有的不确定性，LLM-Agent 为特定任务生成的计划可能多种多样。即使 LLM 拥有强大的推理能力，由 LLM 生成的单一计划也很可能是次优的，甚至是不可行的。更自然的方法是多计划选择，包括两个主要步骤：多计划生成和最优计划选择。

4.1 多计划生成

多计划生成包括生成十几条计划路径，组成候选计划集。主流方法考虑在生成模型的解码过程中采用不确定性。

自治性[Wang 等人, 2022b]采用了一种简单的直觉：复杂问题的解决方案很少是唯一的。与产生单一路径的 CoT 不同，自治性通过解码过程中体现的采样策略，如温度采样、顶 k 采样等，获得多条不同的推理路径。思维树 (ToT) [Yao 等人, 2023]提出了两种生成计划（即思维）的策略：采样和提议。采样策略与自治性一致，即 LLM 会在解码过程中对多个计划进行采样。提议策略明确指示 LLM 通过提示中的少量示例生成各种计划。思想图 (Graph-of-Thought, Besta 等2023GoT) [人,]通过添加思想转换扩展了 ToT，支持任意思想聚合。LLM-MCTS [Zhao 等人, 2023b] 和 RAP [Hao 等人, 2023] 利用 LLM 作为蒙特卡洛树搜索 (Monte Carlo Tree Search, MCTS) 的启发式策略函数，通过多次调用获得多个潜在行动。

4.2 最佳计划选择

为了从候选计划中选出最优计划，我们采用了多种策略作为启发式搜索算法。

自一致性[Wang 等, 2022b人]应用了天真的多数票策略，将得票最多的计划视为最优选择。得益于树形结构，思维树 (ToT) [Yao 等人, 2023] 支持树形搜索算法，如传统的 BFS 和 DFS。在选择一个节点进行扩展时，它会使用 LLM 评估多个操作，并选择最优操作。与 ToT 类似，LLM-MCTS [Zhao 等人, 2023b] 和 RAP [Hao 等人, 2023] 也采用树形结构来辅助多计划搜索。与 ToT 不同，它们采用蒙特卡洛树搜索 (MCTS) 算法进行搜索。LLM A* [Xiao and Wang, 2023] 利用人工智能中的经典 A* 算法来辅助 LLM 进行搜索。从当前位置到目标位置的切比雪夫距离是选择最优路径的启发式成本函数。

4.3 讨论

多计划选择的可扩展性具有显著优势，可以在广阔的搜索空间中对潜在解决方案进行更广泛的探索。然而，这一优势也伴随着固有的权衡。计算需求的增加，尤其是对于具有大量标记数或计算量的模型，带来了实际挑战。这种成本考虑变得至关重要，尤其是在资源限制是一个重要因素的情况下，如在线服务。此外，依赖 LLM 评估计划也带来了新的挑战。由于 LLM 在排序任务中的性能仍在审查之中，因此需要进一步验证和微调其在这种特定情况下的能力。LLM 的随机性增加了搜索的随机性，可能会影响所选计划的一致性和可靠性。

5 外部规划师辅助规划

尽管大型语言模型 (LLMs) 具有强大的推理和任务分解能力，但在面对具有复杂约束条件的环境（如数学问题解决或生成可接受的行动）时，仍会出现难题。为了应对挑战，许多方法都将 LLM 与外部规划器相结合。根据引入的规划器，这些方法可分为符号规划器和神经规划器。

5.1 符号规划器

几十年来，符号规划器一直是自动规划领域的基本组成部分。这些方法基于成熟的符号形式化模型，如 PDDL 模型 [Aeronautiques 等人, 1998 年; Haslum 等人, 2019 年]，采用符号推理来确定从初始状态到期望目标状态的最优路径。

LLM+P [Liu 等人, 2023a] 通过整合基于 PDDL 的符号规划器，增强了 LLM 的规划能力。利用 LLM 的语义理解和编码能力，作者将问题组织成文字语言提示输入 LLM。这促使 LLM 将环境中的操作和指定任务组织成 PDDL 语言格式。随后，在获得形式化描述后，作者在规划过程中使用了快速向下¹求解器。在 LLM+P 的基础上，LLM-DP [Dagan 等人, 2023] 专为动态交互环境而设计。接收到环境反馈后，LLM 会处理信息，将其形式化为 PDDL 语言，然后利用 BFS [Lipovetzky 等人, 2014] 求解器生成计划。LLM+PDDL [Guan 等, 2023人] 也是利用 PDDL 语言将任务形式化，并增加了一个人工验证步骤，以检查 LLM 生成的 PDDL 模型中是否存在潜在问题。在规划过程中，作者建议使用 LLM 生成的规划作为初始启发式解决方案，以加速局部搜索规划器的搜索过程，如 LPG [Gerevini and Se- rina, 2002]。LLM+ASP [Yang 等人, 2023b] 将 LLM 用自然语言描述的问题转化为原子事实、

¹ <https://github.com/aibasell/downward/tree/release-22.12.0>

将任务转化为 ASP 问题。随后，利用 ASP 解算器 CLINGO 生成计划。

5.2 神经规划器

神经规划器是利用强化学习或模仿学习技术对收集的规划数据进行训练的深度学习模型，在特定领域内显示出有效的规划能力。例如，DRRN[He 等人, 2015] 通过强化学习将规划过程建模为马尔可夫决策过程，训练策略网络以获得深度决策模型。决策转换器（DT）[Chen 等, 2021a] 赋予转换器模型能力，利用规划数据克隆人类决策行为。

训练有素的神经规划器在各自的领域内表现出卓越的规划能力，并因其较小的参数规模而显示出卓越的规划效率。然而，在面对复杂且不常遇到的问题时，由于训练数据稀缺，这些小型模型往往会因泛化能力不足而表现不佳。因此，有几项研究探索将 LLM 与轻量级神经规划器相结合，以进一步提高规划能力。CALM[Yao 等, 2020a] 提出了一种将语言模型与基于 RL 的神经规划器相结合的早期方法。一个语言模型处理文本环境信息，根据环境信息生成一组候选行动作为先验。然后使用 DRRN 策略网络对这些候选行动进行重新排序，最终选出最优行动。SwiftSage[Liu 等人, 2023] 利用认知心理学中的双重过程理论，将规划过程分为慢速思考和快速思考。慢速思维过程涉及复杂的推理和理性的深思熟虑，而快速思维则类似于通过长期训练形成的本能反应。作者利用通过模仿学习训练的 DT 模型作为快速思维模型，用于快速生成计划。当计划执行过程中出现错误，表明出现了更复杂的问题时，代理就会切换到慢速思维过程，此时 LLM 会根据当前状态进行推理和规划。事实证明，这种快慢结合的思维方式在效率方面非常有效。

5.3 讨论

对于那些需要额外规划人员协助的策略，LLM 主要起辅助作用。它的主要功能包括解析文本反馈和提供辅助推理信息，以协助规划，尤其是在处理复杂问题时。具体来说，增强 LLM 在代码生成方面的能力，可以为处理更广泛的交叉人工智能任务提供动力。事实上，传统的符号人工智能系统的一个重要缺点是复杂，而且在构建符号模型时严重依赖人类专家，而 LLM 可以加速这一过程，促进更快、更优地建立符号模型。符号系统带来的优势包括理论完整性、稳定性和可解释性。统计人工智能与 LLM 的结合将成为未来人工智能发展的主要趋势。

6 反思与完善

反思和改进是规划过程中不可或缺的组成部分。它们增强了 LLM-Agent 规划的容错和纠错能力。由于存在幻觉问题以及对复杂问题的推理能力不足，LLM-代理在规划过程中可能会由于反馈有限而犯错并陷入“思维循环”。对失败进行反思和总结有助于代理纠正错误，并在以后的尝试中摆脱这种循环。

自我完善[Madaan 等人, 2023] 采用的是生成、反馈和完善的迭代过程。每次生成后，LLM 都会为计划生成反馈，以便根据反馈进行调整。Reflexion[Shinn 等人, 2023] 对 ReAct 进行了扩展，加入了一个评估器来评估轨迹。LLM 在发现错误后会产生自我反思，从而帮助纠错。CRITIC[Gou 等人, 2023] 使用知识库和搜索引擎等外部工具来验证 LLM 生成的行动。然后，它利用外部知识进行自我纠错，大大减少了事实错误。InteRecAgent[Huang 等人, 2023b] 采用一种名为 ReChain 的机制进行自我纠正。LLM 用于评估由主动推荐代理生成的响应和工具使用计划，总结错误反馈，并决定是否重新启动计划。LEMA[An 等人, 2023] 首先收集错误的规划样本，然后利用更强大的 GPT-4 进行修正。然后利用这些经过修正的样本对 LLM-Agent 进行微调，从而在 LLaMA 模型的各种规模上显著提高性能。

特别是，自我反思策略与以下方面有相似之处。根据强化学习原理，代理扮演决策者的角色，如策略网络。环境反馈会触发策略网络的更新。不过，与通过修改模型参数实现更新的深度强化学习不同，在 LLM 代理中，这种更新是通过 LLM 自身的自我反思实现的，最终形成文字语言反馈。这些文字反馈既可作为长期记忆，也可作为短期记忆，通过提示影响代理的后续规划输出。然而，这种文本更新形式的收敛性目前还缺乏可靠的证明，表明无法证明持续的反思能够最终引导 LLM 代理达到指定的目标。

7 基于记忆的规划

对于代理人来说，记忆是提高规划能力和成长潜力的重要途径。关于 LLM-代理的记忆机制，目前主要有两种通过记忆增强规划能力的方法：基于 RAG 的记忆和具身记忆。

7.1 基于 RAG 的存储器

Retrieval Augmented Generation (RAG) [Lewis 等人, 2020; Mao 等人, 2020; 等Cai 人, 2022] 技术被提出来利用检索信息帮助文本生成。它能够利用最新知识增强 LLM，例如

如新必应²和谷歌巴德³。对于 LLM 代理来说，过去的经验可以存储在内存中，并在需要进行检索。这类方法的核心理念是在任务规划时从内存中检索与任务相关的经验。在这些方法中，记忆通常存储在附加存储中，形式也多种多样，如文本[Park 等人；人，Packer 人2023；2023Liu 等2023b；等，Wang 等2023c；人，Zhong 等，2023人]、表格形式[Zhang 等，2023a人]、知识图谱[Pan 等人，2024]等。

生成式代理（Generative Park 等2023年Agents）[人，]以文本形式存储类人代理的日常经历，并根据与当前情况的相关性和再现性的综合得分检索记忆。同样，MemoryBank [Zhong 等，人2023]、TiM [Liu 等，2023b人Wang 等人，]和 RecMind [2023c] 使用文本编码模型将每段记忆编码成向量，并建立索引结构，如 FAISS library [Johnson 等人，2019]。在检索过程中，对当前状态的描述被用作从记忆库中检索记忆的查询。三者的区别在于记忆更新的方式。MemGPT [Packer 等人，2023] 利用计算机架构中的多级存储概念，将 LLM 的上下文抽象为 RAM，并将额外的存储结构视为磁盘。LLM 可以自发决定是检索历史记忆还是将当前上下文保存到存储中。REMEM-BER [Zhang 等人，2023a] 以 Q 值表的形式存储历史记忆，其中每条记录都是（环境、任务、操作、Q 值）元组。在检索过程中，会同时检索正面和负面记忆，以便 LLM 根据环境和任务的相似性生成计划。

7.2 化身记忆

嵌入式记忆包括利用代理的历史经验样本对 LLM 进行微调，将记忆嵌入模型参数中。经验样本通常是从代理与环境的交互中收集的，其中可能包括有关环境的常识、与任务相关的先验知识以及成功或失败的经验。训练一个拥有数十亿参数的语言模型成本巨大，而参数高效微调（PEFT）技术只需训练一小部分参数即可降低成本并加快速度，如 LoRA、QLoRA、P-tuning 等。

CALM [Yao 等人，2020b] 利用从文本世界环境中收集的地面实况行动轨迹，通过下一个标记预测任务对 GPT-2 进行微调，使其能够记忆规划相关信息，并在规划任务中很好地泛化。同样，TDT [Wang 等人，2022a] 使用收集到的马尔可夫决策过程数据来微调文本决策转换器（TDT）。它在更具挑战性的科学世界 [Wang 等人，2022a]任务中取得了更好的成功率。AgentTuning [Zeng 等，2023人] 将来自不同任务的计划轨迹组织成对话形式，对 LLaMA 模型进行微调，结果显示，在未见过的计划任务上，该模型的性能有了显著提高。

² <https://www.bing.com/> ³<https://bard.google.com>

表 2：基于提示的代表性方法在四个互动基准上的评估。SR、AR 和 EX 分别是成功率、平均奖励和支出的缩写。支出是根据通过 OpenAI 的 API 消耗的代币数量计算的。Z-CoT 和 F-CoT 分别代表 Zeroshot-CoT 和 Fewshot-CoT。

衡量标准	AlfWorld		科学世界		火锅QA		发烧	
	SR(%)	EX(\$)	AR	EX(\$)	SR(%)	EX(\$)	SR(%)	EX(\$)
Z-CoT	不适用	不适用	不适用	不适用	0.01	0.95	0.39	1.07
F-CoT	0.43	98.60	16.58	272.22	0.32	5.73	0.61	2.25
CoT-SC	0.57	105.37	15.24	274.33	0.33	7.86	0.62	3.21
SayCan	0.60	113.61	12.36	125.71	不适用	不适用	不适用	不适用
再行动	0.57	152.18	15.05	356.03	0.34	66.00	0.63	22.20
反思	0.71	220.17	19.39	724.48	0.39	112.49	0.68	37.26

7.3 讨论

基于 RAG 的记忆方法和基于微调的记忆方法可增强 LLM-Agent 的规划能力，这两种方法各有不同的优势和局限性。基于 RAG 的方法主要通过自然语言文本提供实时、低成本的外部记忆更新，但依赖于检索算法的准确性。微调法通过修改参数提供了更大的记忆容量，但记忆更新成本较高，且难以保留细粒度细节。

内存增强型 LLM-代理在规划中表现出更强的成长性和容错性，但内存的生成在很大程度上取决于 LLM 的生成能力。通过自生成内存来证明较弱的 LLM 代理仍然是一个具有挑战性的探索领域。

8 评估

评估代理的规划能力是研究领域的一个关键问题。在此，我们研究了几种主流基准测试方法，并将其分为以下几类。

交互式游戏环境：游戏环境可根据代理的行动提供实时多模式反馈，包括文字和视觉反馈。目前，应用最广泛的游戏环境是 Minecraft⁴，代理需要收集材料来制作工具，以获得更多奖励。代理创建工具的数量通常被用作评估指标。另一个流行的类别是基于文本的交互环境，如 ALFWorld [Shridhar 等人，2020]、ScienceWorld [Wang 等，2022a人] 等，其中代理在一个用自然语言描述的环境中定位，行动和位置有限。成功率或获得的奖励通常被用作评价指标。与 Minecraft 相比，这些基于文本的交互环境通常较为简单，反馈直接，可行的操作较少。

交互式检索环境：交互式检索环境模拟人类在现实生活中进行信息检索和推理的过程。在这些环境中，通常允许代理与搜索引擎和其他网络服务进行交互，使用诸如搜索关键词或执行点击、前进和后退操作等操作来获取更多信息，从而获得信息。

⁴ <https://www.minecraft.net/>

回答问题或完成信息检索任务。常用的检索环境包括基于维基百科的问题解答任务[YaoYang 等, 2018, 等人, 2022] (如 HotPotQA[人Thorne 等人2018]和Fever[]), 以及查找特定信息的网页浏览任务, 包括WebShop、Mind2Web[Deng 等人Zhou人2023, 2023 等,]和WebArena[]。任务成功率通常被用作衡量标准。

交互式编程环境: 交互式编程环境模拟程序员与计算机之间的交互, 测试代理在解决计算机相关问题时的规划能力。在这些环境中, 代理需要与计算机互动, 通过编写代码或指令来解决问题。他们会收到各种反馈, 包括编译和运行时的错误信息, 以及执行结果。流行的交互式编程环境涉及操作系统、数据库等相关问题, 如 Agent Bench [Liu 等人, Kim 等人, 20232023c]、MiniWoB++ []。

现有的这些交互式环境大多缺乏精细评估, 主要通过最终成功率来评估性能。此外, 与现实世界中完成一项任务通常有多种路径的情况不同, 由于注释成本较高, 大多数模拟环境中通常只有一条 "黄金" 路径。

实验我们在四个基准上进行了实验, 以验证代表性作品的性能, 如表 2。所示由于预算有限, 我们采用了六种基于提示的方法, 包括任务去组成、多路径选择和反射。在基准测试方面, 我们采用了 ALFWorld、ScienceWorld、HotPotQA 和 FEVER 等涉及互动游戏和问题解答的基准测试。由于《ALFWorld》和《ScienceWorld》涉及较大的行动空间, 零点射击法 (即 ZeroShot-CoT) 因不了解行动空间而不适用。SayCan 通过将输出动作与具有值函数的动作空间间接地来改进 CoT, 但这不适用于质量保证任务, 因为只有两个动作: 搜索[关键字]和查找[关键字]。而且我们将值函数设定为文本嵌入模型 *bge-small-en-v1.5* [Xiao 等人, 2023]。对于 CoT-SC 的游戏任务和 QA 任务, 我们每一步分别获得 3 个操作和 5 个答案。Reflexion 的重试次数设为 1。我们使用 OpenAI 中 *text-davinci-003* 的 API 作为 LLM。

(i) **性能随着费用的增加而提高。** 由于 CoT-SC、ReAct 和 Reflexion 分别涉及多个计划、补充思考和反思, 因此它们的支出比主干方法要多。直观地说, 更多的 "节点" 代表更细致的思考, 从而提高性能。

(ii) **对于复杂的任务, 建议使用少量的示例。** 尽管 "让我们一步步思考" 这一神奇指令可以引导更多推理, 但 ZeroShot-CoT 在两个质量保证基准测试中表现出严重的性能下降, 这表明 LLM 有必要使用示例来进一步理解任务。

(iii) **反思在提高成功率, 尤其是复杂任务的成功率方面发挥着至关重要的作用。** 尽管 Reflexion

与 ReAct 相比, LLM 在复杂任务 (如 ALF-World 和 ScienceWorld) 中的效果令人满意, 这表明 LLM 具备纠错能力。

9 结论和未来方向

由于 LLM 显示了智能的出现, 人们越来越关注利用 LLM 增强代理的规划能力。图 1 总结了研究的主要方向, 第 3 至第 7 部分对各种方法进行了详细的比较和分析。我们还在四个基准上进行了实验, 比较了几种代表性方法的有效性, 结果表明性能会随着费用的增加而提高。尽管这些工作提高了规划能力, 但仍存在一些重大挑战。

幻觉。在计划过程中, LLM 经常出现幻觉, 导致计划不合理、不忠实于任务提示或无法遵循复杂的结构。例如, 计划中可能包括与环境中不存在的物品相互影响的行动。虽然这些问题可以通过精心的提示工程得到缓解, 但它们反映了 LLM 的根本缺陷[Zhang 等人, 2023b; Huang 等人, 2023a]。

生成计划的可行性。LLM 以统计学习为基础, 通过海量数据优化下一个词的概率。与符号人工智能相比, 这种方法很难服从复杂的约束条件, 尤其是在处理 LLM 训练过程中遇到的不太常见的约束条件时。因此, 如果不考虑充分的前提条件, LLM 生成的计划可能缺乏可行性。在不改变 LLM 本身的情况下, 将 LLM 与符号规划模型连接起来, 是一个很有前景的未来方向。

生成计划的效率。生成高效计划是规划中的一个关键问题。然而, 在现有的 LLM 代理中, 规划都是贪婪地基于 LLM 输出的生成计划, 而不考虑生成计划的效率。因此, 未来的发展可能需要引入额外的效率评估模块, 与 LLM 结合使用, 以获得更高效的计划。

多模态环境反馈。LLM 最初是为处理文本输入而设计的, 但现实世界中的环境反馈往往是多模态的, 包括图像、音频等, 用自然语言描述这些反馈具有挑战性。因此, LLM 代理在处理此类场景时面临着限制。未来的考虑因素可能包括综合开发多模态大型模型和重新审视相关规划策略。

细粒度评估。如第 8, 节所述现有的基准大多依赖于任务的最终完成状态, 缺乏细粒度的分步评估。此外, 环境反馈通常是基于规则的、简单化的, 与真实世界的场景相去甚远。未来可能采取的措施是利用 LLM 等高智能模型来设计更逼真的评估环境。

参考资料

- [Aeronautiques 等人, 1998 年] Constructions Aeronautiques、Adele Howe 等人, Pddl--规划领域定义语言。《技术报告, Tech.Rep.》, 1998.
- [安等, 2023] 安胜男, 马泽雄, 等: 从错误中学习让 llm 成为更好的推理者。arXiv 预印本 arXiv:2310.20689, 2023。
- [Besta 等人, 2023] Maciej Besta、Nils Blach 等人.思想之图.用大型语言模型解决复杂问题.arXiv preprint arXiv:2308.09687, 2023: 用大型语言模型解决复杂问题。arXiv 预印本 arXiv:2308.09687, 2023.
- [Cai 等人, 2022 年] Deng Cai、Yan Wang、Lemao Liu 和 Shuming Shi.检索增强文本生成的最新进展。见 SIGIR, 第 3417-3419 页, 2022 年。
- [陈莉莉、陆凯文等人, 决策转换器: 通过序列修改进行强化学习。NeurIPS, 34:15084-15097, 2021.
- [Mark Chen, Jerry Tworek, et al.
- [陈文虎等, 2022] 陈文虎, 马学光, 等.思想提示的临界点.数字推理任务中计算与推理的分离.arXiv preprint arXiv:2211.12588, 2022: ArXiv preprint arXiv:2211.12588, 2022.
- [Dagan et al., 2023] Gautier Dagan, Frank Keller, and Alex Lascarides.arXiv preprint arXiv:2308.06391, 2023.
- [Deng 等人, 2023] Xiang Deng, Yu Gu, et al. Mind2web: ArXiv preprint arXiv:2306.06070, 2023.
- [Luyu Gao, Aman Madaan, et al. Pal: 程序辅助语言模型。In ICML, pages 10764- 10799, 2023.
- [Gerevini and Serina, 2002] Alfonso Gerevini and Ivan Serina.Lpg: 基于局部搜索的带行动代价规划图规划器。In Aips, volume 2, pages 281- 290, 2002.
- [Ghallab 等人, 2004 年] Malik Ghallab、Dana Nau 等人, 《自动匹配规划: 理论与实践》。爱思唯尔, 2004 年。
- [Gou 等人, 2023] Zhibin Gou, Zhihong Shao, et al: arXiv preprint arXiv:2305.11738, 2023.
- [Guan 等人, 2023] Lin Guan、Karthik Valmeekam 等人.利用预训练的大型语言模型构建和利用世界模型进行基于模型的任务规划.arXiv 预印本 arXiv:2305.14909, 2023.
- [郝等, 2023] 郝世波, 顾毅, 等.用语言模型推理就是用世界模型规划.arXiv 预印本 arXiv:2305.14992, 2023.
- [Haslum 等人, 2019] Patrik Haslum、Nir Lipovetzky 等人.规划领域定义语言导论, 第13卷.Springer, 2019.
- [He et al., 2015] Ji He, Jianshu Chen, et al. Deep reinforcement learning with a natural language action space. ArXiv preprint arXiv:1511.04636, 2015.
- [黄磊等, 2023a] 黄磊, 于伟江, 等. 大型语言模型中的幻觉研究: ArXiv preprint arXiv:2311.05232, 2023.
- [黄旭等, 2023b] 黄旭, 连建勋, 等. Recommender ai agent: ArXiv preprint arXiv:2308.16505, 2023.
- [Johnson 等人, 2019] Jeff Johnson、Matthijs Douze 和 Herve' Jegou.使用 GPU 进行亿级规模的相似性搜索。IEEE Transactions on Big Data, 7 (3): 535-547, 2019.
- [Kim 等人, 2023] Geunwoo Kim 等人.语言模型可解决计算机任务.arXiv 预印本 arXiv:2303.17491, 2023.
- [Kojima et al.NeurIPS, 35: 22199-22213, 2022。
- [Patrick Lewis, Ethan Perez, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks.NeurIPS, 33:9459-9474, 2020.
- [Bill Yuchen Lin, Yicheng Fu, et al: ArXiv preprint arXiv:2305.17390, 2023.
- [基于宽度和推理的规划器: Siw、bfs (f) 和 probe。IPC, 第 43 页, 2014 年。
- [Liu et al: ArXiv preprint arXiv:2304.11477, 2023.
- [刘磊等人, 2023b] 刘磊、杨晓燕等人.Think-in-memory: ArXiv preprint arXiv:2311.08719, 2023.
- [Liu et al., 2023c] Xiao Liu, Hao Yu, et al. Agent- bench: ArXiv preprint arXiv:2308.03688, 2023.
- [Aman Madaan, Niket Tandon, et al. Self-refine: arXiv preprint arXiv:2303.17651, 2023.
- [毛宇宁等, 2020] 毛宇宁、何鹏程、刘等.开放域问题解答的生成增强检索.arXiv 预印本 arXiv:2009.08553, 2020.
- [Charles Packer, Vivian Fang, et al. Memgpt: ArXiv preprint arXiv:2310.08560, 2023.
- [Pan 等人, 2024 年] Shirui Pan、Linhao Luo 等人.统一大型语言模型和知识图谱: 路线图。TKDE, 2024。

- [Joon Sung Park, Joseph O'Brien, et al: 人类行为的交互式模拟. In *SUIST*, pages 1-22, 2023.
- [Qin et al.
- [Schraagen et al., 2000] Jan Maarten Schraagen, Susan F Chipman, et al. *认知任务分析*. 心理学出版社, 2000 年.
- [沈永亮等, 2023] 沈永亮、宋开涛等, 《拥抱--Gingpt: *arXiv preprint arXiv:2303.17580*, 2023.
- [Shinn 等人, 2023 年] Noah Shinn、Federico Cassano 等人, Reflexion: 具有语言强化学习功能的语言代理. 在 2023 年的 *NeurIPS* 上.
- [Shridhar 等人, 2020] Mohit Shridhar、Xingdi Yuan 等人, Alfworld: *ArXiv preprint arXiv:2010.03768*, 2020.
- [Singh 等人, 2023 年] Ishika Singh、Valts Blukis 等人, Prog-prompt: 使用大型语言模型生成情景机器人任务计划. In *ICRA 2023*, pages 11523-11530.IEEE, 2023.
- [孙等, 2023] 孙建凯, 郑传洋, 等.基础模型推理研究.*arXiv 预印本 arXiv:2312.11562*, 2023.
- [Thorne et al., 2018] James Thorne, Andreas Vlachos, et al. Fever: a large-scale dataset for fact extraction and verification. *arXiv preprint arXiv:1803.05355*, 2018.
- [乌戈-图夫龙等人, 2023] 乌戈-图夫龙、路易斯-马丁等人, 《Llama 2: 开放基础与微调聊天模型》, *arXiv 预印本 arXiv:2307.09288*, 2023.
- [王若尧等, 2022a] 王若尧、彼得-扬森等, 科学世界: *ArXiv preprint arXiv:2203.07540*, 2022.
- [王学智等, 2022b] 王学智, 魏杰等.自一致性改进语言模型中的思维链推理.*arXiv预印本 arXiv:2203.11171*, 2022.
- [王磊等, 2023a] 王磊, 马晨, 等.基于大型语言模型的自主代理研究.*arXiv 预印本 arXiv:2308.11432*, 2023.
- [王磊等, 2023b] 王磊, 徐文宇, 等. 计划-求解提示: *arXiv preprint arXiv:2305.04091*, 2023.
- [Recmind: *arXiv preprint arXiv:2308.14296*, 2023.
- [Wei 等, 2022] Jason Wei, Xuezhi Wang, et al. Chain-of-thought prompting elicits reasoning in large language models.*NeurIPS*, 35:24824-24837, 2022.
- [Wu 等人, 2023] 吴晨飞、尹胜明等.视觉聊天: 使用视觉基础模型进行对话、绘图和编辑. *arXiv 预印本 arXiv:2303.04671*, 2023.
- [肖世涛等, C-pack: 推进通用中文嵌入的打包资源, 2023.
- [Xiao and Wang, 2023] Hengjia Xiao and Peng Wang.Llm a*: *arXiv preprint arXiv:2312.01797*, 2023.
- [杨志林等, 2018] 杨志林、彭琦等: 《Hotpotqa: A dataset for diverse, explainable multi-hop question answering. *arXiv preprint arXiv:1809.09600*, 2018.
- [Sherry Yang, Nachum Ofir, et al: *ArXiv preprint arXiv:2303.04129*, 2023.
- [杨等人, 2023b] 杨准、亚当-伊沙伊和李祖兴.将大型语言模型与逻辑编程耦合, 实现稳健的通用文本推理. *arXiv 预印本 arXiv:2307.07696*, 2023.
- [姚舜宇等, 2020a] 姚舜宇、饶若翰等.保持冷静, 勇于探索.基于文本的游戏中行动生成的语言模型. *arXiv preprint arXiv:2010.02903*, 2020: 基于文本的游戏中行动生成的语言模型. *arXiv 预印本 arXiv:2010.02903*, 2020.
- [姚舜宇等, 2020b] 姚舜宇、饶若翰等.保持冷静与探索.基于文本的游戏中行动生成的语言模型. *arXiv preprint arXiv:2010.02903*, 2020: 基于文本的游戏中行动生成的语言模型. *arXiv 预印本 arXiv:2010.02903*, 2020.
- [Re-act: *arXiv preprint arXiv:2210.03629*, 2022.
- [姚舜宇等, 2023] 姚舜宇、于滇等.思想之树.用大型语言模型慎重解决问题. *arXiv preprint arXiv:2305.10601*, 2023: 用大型语言模型慎重解决问题. *arXiv preprint arXiv:2305.10601*, 2023.
- [Agent-tuning: *arXiv preprint arXiv:2310.12823*, 2023.
- [张等, 2023a] 张丹阳、陈璐等: 大语言模型是半参数强化学习代理. *arXiv 预印本 arXiv:2306.07929*, 2023.
- [Zhang et al: *arXiv preprint arXiv:2309.01219*, 2023.
- [赵等, 2023a] Wayne Xin Zhao, Kun Zhou, et al. A survey of large language models. *ArXiv preprint arXiv:2303.18223*, 2023.
- [Zirui Zhao, Wee Sun Lee, and David Hsu.大型语言模型作为大规模任务规划的常识性知识[*ArXiv preprint arXiv:2305.14078*, 2023.
- [钟万钧、郭良红、高琦琦、王彦林.记忆库: *ArXiv preprint arXiv:2305.10250*, 2023.
- [Zhou 等人, 2023] Shuyan Zhou、Frank F Xu 等人, We-barena: *ArXiv preprint arXiv:2307.13854*, 2023.