

思维链提示激发大型语言模型的推理能力

魏杰

王学智

Dale Schuurmans Maarten Bosma Brian Ichter

夏飞

Ed H. Chi

Quoc V. Le

Denny Zhou

谷歌研究，大脑团队

{jasonwei,dennyzhou}@google.com

摘要

我们探讨了生成思维链——一系列中间推理步骤——如何显著提高大型语言模型执行复杂推理的能力。我们特别展示了这种推理能力是如何通过一种称为思维链提示的简单方法在足够大的语言模型中自然出现的。

在三个大型语言模型上进行的实验表明，思维链提示可以提高一系列算术、常识和符号推理任务的成绩。实证结果令人震惊。例如，在数学单词问题 GSM8K 基准测试中，仅用 8 个思维链示例来提示 PaLM 540B 就达到了最先进的准确度，甚至超过了带有验证器的经过微调的 GPT-3。




图 1：思维链提示使大型语言模型能够处理复杂的算术、常识和符号推理任务。图中突出显示了思维链推理过程。

1 引言

最近，语言模型给 NLP 领域带来了一场革命 (Peters 等人, 2018 年; Devlin 等人, 2019 年; Brown 等人, 2020 年等)。扩大语言模型的规模已被证明能带来一系列好处，如提高性能和样本效率 (Kaplan 等人, 2020 年; Brown 等人, 2020 年等)。然而，在具有挑战性的任务 (如算术、常识和符号推理) 中，仅扩大模型规模还不足以实现高性能 (Rae 等人, 2021 年)。

这项工作探讨了如何通过一种简单的方法来释放大语言模型的推理能力，这种方法有两个动机。首先，算术推理技术可以从生成自然语言推理中获益，从而得出最终答案。除了使用形式语言而非自然语言的神经符号方法 (Roy and Roth, 2015; Chiang and Chen, 2019; Amini et al. 其次，大型语言模型提供了令人兴奋的




图 2: PaLM 540B 采用思维链提示，在数学单词问题 GSM8K 基准测试中取得了最新性能。经过微调的 GPT-3 和之前的最佳成绩来自 Cobbe 等人 (2021 年)。

通过“提示”在语境中进行少量学习的前景。也就是说，无需为每项新任务单独微调语言模型检查点，只需用一些演示任务的输入-输出示例“提示”模型即可。值得注意的是，这在一系列简单的问题解答任务中都取得了成功 (Brown 等人, 2020 年)。

然而，上述两种想法都有很大的局限性。对于推理增强训练和微调方法来说，创建一大批高质量的推理需要花费大量成本，这比普通机器学习中的简单输入输出对复杂得多。对于 Brown 等人 (2020) 所使用的传统几枪提示方法，它在需要推理能力的任务中效果不佳，而且往往不会随着语言模型规模的扩大而有实质性的改善 (Rae 等人, 2021)。在本文中，我们结合了这两种观点的优势，避免了它们的局限性。具体来说，我们探索了语言模型在推理任务中进行少量提示的能力，给定的提示由三元组组成：输入、思维链、输出。思维链是一系列导致最终输出的中间自然语言推理步骤，我们将这种方法称为思维链提示。图 1 是一个提示示例。

我们对算术、常识和符号推理基准进行了实证评估，结果表明思维链提示优于标准提示，有时甚至达到惊人的程度。图 2 展示了这样一个结果：在数学单词问题的 GSM8K 基准 (Cobbe 等人, 2021 年) 上，使用 PaLM 540B 的思维链提示法大大优于标准提示法，达到了新的一流水平。只进行提示的方法之所以重要，是因为它不需要大量的训练数据集，而且单个模型检查点可以执行许多任务，而不会丧失通用性。这项工作强调了大型语言模型如何通过几个例子和任务的自然语言数据进行学习 (例如，通过大型训练数据集自动学习输入和输出的基本模式)。

2 思维链提示

在解决复杂的推理任务 (如多步骤数学单词问题) 时，考虑一下自己的思维过程。典型的做法是将问题分解成中间步骤，并在给出最终答案前解决每个步骤：“简给妈妈送 2 朵花后，她有 10 朵花.....然后她给爸爸送 3 朵花后，她将有 7 朵花.....所以答案是 7。本文的目标是赋予语言模型生成类似思维链的能力--一系列连贯的中间推理步骤，最终得出问题的最终答案。我们将证明，足够大的

如果在少许提示的示例中提供思维链推理的示范，语言模型就能产生思维链。

图 1 显示了一个例子，模型通过思维链解决了一道数学单词题，否则它就会出错。本例中的思维链类似于解题思路，可以被解释为解题思路，但我们仍然选择将其称为思维链，以更好地体现它模仿了一步步得出答案的思维过程（此外，解题思路/解释通常出现在最终答案之后（Narang 等人，2020 年；Wiegreffe 等人，2022 年；Lampinen 等人，2022 年等））。

作为一种促进语言模型推理的方法，思维链提示有几个吸引人的特性。

1. 首先，思维链原则上允许模型将多步骤问题分解为中间步骤，这意味着可以将额外的计算分配给需要更多推理步骤的问题。
2. 其次，思维链为了解模型的行为提供了一个可解释的窗口，表明它可能是如何得出特定答案的，并为调试推理路径出错的地方提供了机会（尽管完全描述支持答案的模型计算仍是一个未决问题）。
3. 第三，思维链推理可用于数学文字题、常识推理和符号操作等任务，而且有可能（至少在原则上）适用于人类可以通过语言解决的任何任务。
4. 最后，在足够大的现成语言模型中，只需将思维链序列的示例纳入少量提示的示例中，就能很容易地激发思维链推理。

在实证实验中，我们将观察思维链提示对算术推理（第 3 节）、常识推理（第 4 节）和符号推理（第 5 节）的作用。

3 算术推理

我们首先考虑图 1 所示的数学单词问题，它可以测量语言模型的算术推理能力。虽然算术推理对人类来说很简单，但却是语言模型经常遇到的困难（Hendrycks 等人，2021 年；Patel 等人，2021 年等）。令人吃惊的是，当与 540B 参数语言模型一起使用时，思维链提示在几项任务上的表现可与特定任务的微调模型相媲美，甚至在具有挑战性的 GSM8K 基准上达到了新的技术水平（Cobbe 等人，2021 年）。

3.1 实验装置

我们在多个基准上探索了各种语言模型的思维链提示。

基准。我们考虑了以下五个数学单词问题基准：(1) GSM8K 数学单词问题基准（Cobbe 等人，2021 年 2021 年 2020 年），(2) SVAMP 数据集（Patel 等人，等），(3) ASDiv 数据集（Miao 人，），(4) AQuA 数据集（代数单词问题）、2021 年），(3) ASDiv 数据集中的各种数学单词问题（Miao 等人，2020 年），(4) AQuA 数据集中的代数单词问题，以及 (5) MAWPS 基准（Koncel-Kedziorski 等人，2016 年）。例题见附录表 12。

标准提示。在基线中，我们考虑的是布朗等人（2020 年）推广的标准“少量提示”，即在为测试时间示例输出预测之前，给语言模型提供输入-输出对的上下文示例。示例的格式为问题和答案。模型直接给出答案，如图 1（左）所示。

思维链提示。如图 1（右）所示，我们提出的方法是在寥寥数语提示中为每个示例添加相关答案的思维链。由于大多数数据集都只有一个评估分集，因此我们手工制作了一组 8 个带有思维链提示的 few-shot 示例--图 1（右）显示了其中一个思维链示例，附录表 20 给出了所有示例。（这些示例没有经过提示工程；稳健性在第 3.4 节和附录 A.2 中进行了研究）。为了研究这种形式的思维链提示是否能成功地诱导出一系列成功的推理，我们将在第 3.4 节和附录 A.2 中进行研究。



图 3：算术、常识和符号推理基准的输入、思维链、输出三元组示例。思维链突出显示。完整提示见附录 G。

对于数学单词问题，除了 AQuA（多选而非自由回答）以外，我们在所有基准测试中都使用了这套由八个思维链组成的示例。对于 AQuA，我们使用了训练集中的四个示例和解决方案，如附录表 21 所示。

语言模型。我们评估了五个大型语言模型。第一个是 GPT-3 (Brown 等人, 2020 年)，我们使用了 text-ada-001、text-babbage-001、text-curie-001 和 text-davinci-002，它们大概对应于 InstructGPT 模型的 350M、1.3B、6.7B 和 175B 参数 (Ouyang 等人, 2022 年)。第二个是 LaMDA (Thoppilan 等人, 2022 年)，它有 422M、2B、8B、68B 和 137B 参数的模型。第三个是 PaLM，它有 8B、62B 和 540B 参数模型。第四个是 UL2 20B (Tay 等人, 2022 年)，第五个是 Codex (Chen 等人, 2021 年, OpenAI API 中的代码-davinci-002)。我们通过贪婪解码从模型中采样 (尽管后续工作表明，通过在许多采样代中提取多数最终答案，可以改进思维链提示 (Wang 等, 2022a))。对于 LaMDA，我们报告了五个随机种子的平均结果，每个种子都有不同的随机洗牌示例顺序。由于 LaMDA 的实验没有显示出不同种子间的巨大差异，为了节省计算，我们报告了所有其他模型的单一示例顺序的结果。

3.2 成果

图 4 总结了思维链提示的最强结果，附录中表 2 显示了每个模型集合、模型大小和基准的所有实验结果。其中有三个重要启示。首先，图 4 显示思维链提示是模型规模的一种新兴能力 (Wei 等人, 2022b)。也就是说，思维链提示对小型模型的性能没有积极影响，只有在对大型模型使用时才会提高性能。

~100B 参数。我们定性地发现，规模较小的模型会产生流畅但不合逻辑的思维链，导致成绩低于标准提示。

其次，对于更复杂的问题，思维链提示的性能提升更大。例如，对于 GSM8K（基线性能最低的数据集），最大的 GPT 和 PaLM 模型的性能提高了一倍多。另一方面，对于 Sin- gleOp（MAWPS 中最简单的子集，只需一步即可求解），性能提升要么为负，要么非常小（见附录表 3）。

第三，通过 GPT-3 175B 和 PaLM 540B 进行的思维链提示与先前的技术水平相比更胜一筹，先前的技术水平通常是在标注的训练数据集上对特定任务模型进行微调。图 4 显示了 PaLM 540B 是如何利用思维链提示在 GSM8K、SVAMP 和 MAWPS 上达到新的技术水平的（但要注意的是，标准提示在 SVAMP 上已经超过了先前的最佳水平）。在另外两个数据集 AQuA 和 ASDiv 上，使用思维链提示的 PaLM 达到了最新技术水平的 2% 以内（附录表 2）。

为了更好地理解思维链提示发挥作用的原因，我们通过 LaMDA 137B 手动检查了模型生成的思维链

为 GSM8K。在模型返回正确最终答案的 50 个随机例子中，所有的

除了两个巧合地得出了正确答案之外，其他生成的思维链在对数和数学上都是正确的（模型生成的正确思维链示例见附录 D.1 和表 8）。我们还随机抽查了 50 个模型给出错误答案的样本。分析结果表明，46% 的思维链几乎是正确的，除了一些小错误（计算器错误、符号图

而其他 54% 的思维链在语义理解或连贯性方面存在重大错误（见附录 D.2）。为了略微了解为什么缩放能提高思维链推理能力，我们对 PaLM 62B 所犯的错误以及这些错误是否能通过缩放至 PaLM 540B 而得到修正进行了类似的分析。总之，将 PaLM 放大到 540B 可以修复 62B 模型中的大部分一步缺失和语义理解错误（见附录 A.1）。

3.3 消融研究

观察到使用思维链提示的好处，自然会产生一个问题，即通过其他类型的提示是否也能带来同样的性能改进。图 5 显示的是一项消融研究，采用了下文所述的三种不同的思维链。

仅等式思维链提示可能有帮助的一个原因是，它可以生成要评估的数学公式，因此我们测试了一种变体，即在给出答案之前只提示模型输出数学公式。图 5 显示，只提示方程对 GSM8K 没有多大帮助，这意味着 GSM8K 中问题的语义太具有挑战性，无法在没有思维链中的自然语言推理步骤的情况下直接转化为方程。然而，对于一步或两步问题的数据集，我们发现只用等式提示确实能提高成绩，因为等式可以很容易地从问题中推导出来（见附录表 6）。




图 4：思维链提示使大型语言模型能够解决具有挑战性的数学问题。值得注意的是，思维链推理是随着模型规模扩大而出现的。之前的最佳数据来自 Cobbe 等人（2021 年）的 GSM8K、Jie 等人（2022 年）的 SVAMP 和 Lan 等人（2021 年）的 MAWPS。

只计算变量。另一种直觉是，思维链允许模型在较难的问题上花费更多的计算量（即中间代币）。为了从思维链推理中分离出变量计算的影响，我们测试了一种配置，即只提示模型输出与解题所需的等式字符数相等的点序列（.....）。这一变体的表现与基线大致相同，这表明变量计算本身并不是思维链提示成功的原因，而通过自然语言表达中间步骤似乎更有用。

回答后的思维链。思维链提示的另一个潜在好处可能是，这种提示能让模型更好地获取在预训练中获得的相关知识。因此，我们测试了另一种配置，即仅在答案之后才给出思维链提示，以确定模型是否真正依赖于产生的思维链给出最终答案。这一变体的表现与基线大致相同，这表明思维链所体现的顺序推理的作用不仅仅在于激活知识。




图 5：使用 LaMDA 137B 和 PaLM 540B 对不同提示变化进行的消融研究。其他数据集的结果见附表 6 和表 7。

3.4 思维链的稳健性

对示例的敏感性是提示方法的一个关键考量因素--例如，改变几发示例的排列方式，可以使 SST-2 上的 GPT-3 的准确率从接近偶然性 (54.3%) 到接近最先进水平 (93.4%) 不等 (Zhao 等人, 2021 年)。在最后一个小节中，我们评估了对不同注释者所写的思维链的鲁棒性。除了上述结果外，我们还使用了由注释者撰写的思维链。

A、本文的另外两位共同作者（注释者 B 和 C）独立撰写相同的思维链
少量镜头示例（如附录 H 所示）。注释器 A 还写了另一个更简洁的思维链
与原版相比，采用的是
科布等人 (2021 年) ⁽¹⁾

图 6 显示了 LaMDA 137B 在 GSM8K 上的这些结果。和 MAWPS（其他数据集的消融结果见下表见附录表 6/表 7）。尽管存在




图 6：对于不同的提示实例，思维链提示法存在差异（如预期），但对于不同的注释者和不同的示例，思维链提示法的表现优于标准提示法。

在不同的思维链注释之间，正如在使用基于范例的提示时所预期的那样 (Le Scao

和 Rush, 2021 年; Reynolds 和 McDonell, 2021 年; Zhao 等人, 2021 年)，所有的思维链提示都远远超过了标准基线。这一结果表明，思维链的成功使用并不取决于特定的语言风格。

为了证实成功的思维链提示对其他示例集也有效，我们还进行了以下实验
使用从 GSM8K 训练集中随机抽取的三组 8 个示例、一个独立的

¹ 例如，原文的思维链用了几个短句（“原来有 9 台计算机。每 4 天增加 5 台。因此， $5 * 4 =$ 增加了 20 台计算机。9 + 20 是 29。”），简洁的思维链则是 “ $5 * 4 = 20$ 台新电脑。因此，现在机房里有 $9 + 20 = 29$ 台新电脑”。

图 6 显示，这些提示与我们人工编写的示例表现相当，也大大优于标准提示。

除了对注释者、独立编写的思维链、不同的示例和各种语言模型具有鲁棒性之外，我们还发现用于算术推理的思维链提示对不同的示例顺序和不同数量的示例具有鲁棒性（见附录 A.2）。

4 常识推理

虽然思维链特别适用于数学文字问题，但思维链基于语言的特性实际上使其适用于广泛的常识推理问题，这些问题涉及在一般背景知识假设下对物理和人类互动的推理。常识推理是与世界互动的关键，但目前的自然语言理解系统仍无法做到这一点（Talmor 等人，2021 年）。

基准。我们考虑了涵盖各种常识推理类型的五个数据集。流行的 CSQA（Talmor 等人，2019 年）提出了关于世界的常识性问题，这些问题涉及复杂的语义，通常需要先验知识。StrategyQA（Geva 等人，2021 年）要求模型推断出回答问题的多跳策略。我们从 BIG-bench（BIG-bench 协作，2021 年）中选择了两个专门的评估集：日期理解（涉及从给定上下文中推断日期）和体育理解（涉及判断与体育有关的句子是可信还是不可信）。最后，SayCan 数据集（Ahn 等人，2022 年）涉及将自然语言指令映射到离散集中的机器人动作序列。图 3 显示了所有数据集中带有思维链注释的示例。

提示。我们的实验设置与上一节相同。对于 CSQA 和 StrategyQA，我们从训练集中随机选取示例，并手动为它们组成思维链，作为少量示例。两个 BIG-bench 任务没有训练集，因此我们选择了评估集中的前十个示例作为 few-shot 示例，并报告了评估集其余部分的数字。在 SayCan 中，我们使用了 Ahn 等人（2022 年）使用的训练集中的六个示例，同时还使用了人工组成的思维链。

结果图 7 着重显示了 PaLM 的这些结果（LaMDA、GPT-3 和不同模型规模的全部结果见表 4）。在所有任务中，扩大模型规模都提高了标准提示的性能；思维链提示则进一步提高了性能，其中 PaLM 540B 的提高幅度最大。有了思维链提示，PaLM 540B 的性能相对于基线有了很大提高，在 StrategyQA（75.6% 对 69.4%）上超过了先前的技术水平，在体育理解（95.4% 对 84%）上超过了无辅助的体育爱好者。这些结果表明，在需要一系列常识推理能力的任务中，思维链提示也能提高成绩（但要注意的是，在 CSQA 上的收益微乎其微）。




图 7：思维链提示也提高了语言模型的常识推理能力。此处显示的语言模型是 PaLM。之前的最佳数据来自 CSQA（Talmor 等人，2019 年）和 StrategyQA（Geva 等人，2021 年）的排行榜（截至 2022 年 5 月 5 日，仅有单一模型）。使用不同大小的 LaMDA、GPT-3 和 PaLM 得出的其他结果见表 4。

² 60 个标记，以适应我们的输入上下文窗口，并将示例限制在这些步骤的目的是与我们制作的八个范例进行公平的比较。

5 符号推理

我们最后的实验评估考虑的是符号再现。

这对人类来说很简单，但对语言模型来说却很困难。我们的研究表明，思维链提示不仅能让语言模型完成在标准提示设置下具有挑战性的符号推理任务，而且还能促进长度泛化，使推理时间输入比在寥寥几例中看到的时间输入更长。

任务。 我们使用以下两个玩具任务。

- **最后字母连接。** 这项任务要求模型将名字中单词的最后一个字母连接起来（例如，"Amy Brown" → "yn"）。³我们从姓名普查数据（<https://namecensus.com/>）中的前一千个姓氏和名字中随机拼接出全名。
- **掷硬币。** 这项任务要求模型回答

在人们掷硬币或不掷硬币后，硬币仍是正面朝上（例如：“一枚硬币正面朝上。菲比掷硬币。奥斯瓦尔多没有掷硬币。硬币还是正面朝上吗？” → “不是”）。

由于这些符号推理任务的构造是明确定义的，因此对于每项任务，我们都会考虑一个域内测试集，在这个测试集中，示例的步数与符号推理任务的步数相同。

我们还使用了一个域外（OOD）测试集，该测试集的评估示例比示例中的步骤更多。对于最后一个字母的连接，模型只看到两个单词的名称示例，然后对 3 个和 4 个单词的名称执行最后一个字母的连接⁴。我们的实验设置采用了与前两节相同的方法和模型。我们再次为每项任务中的少量示例手动构建思维链，如图 3 所示。

结果图 8 显示了 PaLM 的域内和 OOD 评估结果，附录表 5 显示了 LaMDA 的结果。对于 PaLM 540B，思维链提示的解率几乎达到了 100%（注意，标准提示已经解决了 PaLM 540 的掷硬币问题，但对于 LaMDA 137B 则没有）。请注意，这些域内评估都是“玩具任务”，因为少许示例中的思维链已经提供了完美的解法结构；模型所要做的就是用测试时间示例中的新符号重复同样的步骤。然而，小模型仍然会失败——只有在模型参数达到 100B 时，才有能力对这三个任务中未见的符号进行抽象处理。

至于 OOD 评估，标准提示在这两项任务中都失败了。在思维链提示下，语言模型实现了向上扩展曲线（尽管性能比域内设置要低）。因此，对于规模足够大的语言模型而言，思维链提示有助于超越所见思维链的长度泛化。

6 讨论

我们将思维链提示作为一种简单的机制来激发大型语言模型中的多步骤推理行为，并对此进行了探索。我们首先看到，思维链提示在算术推理上的性能提高幅度很大，其改进效果比消融强得多，而且对不同的注释者、示例和语言模型都很稳健（第 3 节）。下一页

³ 我们使用 GPT-3 davinci 测试了 10 个常用地名，除一个外全部正确。

⁴ 对于长度超过 2 个字的姓名，我们会将多个姓和名连接在一起。




图 8：在两项符号再认任务中，使用思维链提示可促进对较长序列的归纳。

常识推理实验强调了思维链推理的语言性质如何使其普遍适用（第 4 节）。最后，我们表明，对于符号推理，思维链提示有助于将 OOD 推广到更长的序列长度（第 5 节）。在所有实验中，思维链推理都是通过提示现成的语言模型来激发的。在撰写本文的过程中，没有对任何语言模型进行微调。

思维链推理的出现是模型规模的结果，这一直是一个普遍的主题（Wei 等人，2022b）。在许多推理任务中，标准提示的缩放曲线是平的，而思维链提示则会导致缩放曲线急剧上升。思维链提示似乎扩大了大型语言模型可以成功执行的任务集--换句话说，我们的工作强调了标准提示只提供了大型语言模型能力的下限。这一观察结果提出的问题可能多于回答的问题--例如，随着模型规模的进一步扩大，我们还能期望推理能力提高多少？还有哪些提示方法可以扩大语言模型可以解决的任务范围？

至于局限性，我们首先要说明的是，虽然思维链模拟了人类推理者的思维过程，但这并不能回答神经网络是否真的在“推理”，这还是一个未决问题。其次，虽然在少镜头设置中，用思维链手动增强示例的成本极低，但这种注释成本可能会让微调工作望而却步（不过这有可能通过合成数据生成或零镜头泛化来克服）。第三，无法保证推理路径的正确性，这可能会导致正确答案和错误答案；改进语言模型的事实生成是未来工作的一个开放方向（Rashkin 等人，2021 年；Ye 和 Durrett，2022 年；Wiegrefe 等人，2022 年等）。最后，由于思维链推理只在大型模型中出现，因此在实际应用中成本较高；进一步的研究可以探索如何在较小的模型中诱导推理。

7 相关工作

这项工作受到许多研究领域的启发，我们将在扩展的相关工作部分（附录 C）中详细介绍。在此，我们将介绍两个方向和相关论文，它们可能是最相关的。

第一个相关方向是利用中间步骤解决推理问题。Ling 等人（2017）率先提出了通过一系列中间步骤使用自然语言推理解决数学文字问题的想法。他们的工作与使用形式语言进行推理的文献（Roy 等人，2015；Chiang 和 Chen，2019；Amini 等人，2019；Chen 等人，2019）形成了鲜明的对比。Cobbe 等人（2021 年）扩展了 Ling 等人（2017 年）的研究，创建了一个更大的数据集，并利用它对预训练的语言模型进行微调，而不是从头开始训练一个模型。在程序合成领域，Nye 等人（2021）利用语言模型，通过逐行预测中间计算结果来预测 Python 程序的最终输出，结果表明他们的逐步预测法比直接预测最终输出效果更好。

当然，本文也与近期有关提示的大量研究密切相关。自从布朗等人（2020）提出的“少量提示”（few-shot prompting）得到普及以来，已有几种通用方法提高了模型的提示能力，例如自动学习提示（莱斯特等人魏等等，2021）或给模型提供描述任务的指令（人桑人人，2022a；，2022；欧阳等，2022）。这些方法改进或增强了提示的输入部分（如输入前的指令），而我们的工作则采取了正交方向，即用思维链增强语言模型的输出。

8 结论

我们将思维链提示作为一种简单而广泛适用的方法，用于增强语言模型的推理能力。通过对算术推理、符号推理和常识推理的实验，我们发现思维链推理是模型规模的一个新兴属性，它允许足够大的语言模型执行推理任务，而这些推理任务的规模曲线本来是平的。扩大语言模型所能执行的推理任务范围，有望进一步激发基于语言的推理方法的研究。

致谢

我们感谢 Jacob Devlin、Claire Cui、Andrew Dai 和 Ellie Pavlick 对论文提供的反馈意见。感谢 Jacob Austin、Yuhuai Wu、Henryk Michalewski、Aitor Lewkowycz、Charles Sutton 和 Aakanksha Chowdhery 的讨论。感谢 Sid Maxwell 告知我们原稿中手动误差分析的错误。

参考资料

- Michael Ahn、Anthony Brohan、Noah Brown、Yevgen Chebotar、Omar Cortes、Byron David、Chelsea Finn、Keerthana Gopalakrishnan、Karol Hausman、Alex Herzog 等，2022 年。[做我能做的，而不是我说的](#)：ArXiv preprint arXiv:2204.01691.
- Aida Amini、Saadia Gabriel、Shanchuan Lin、Rik Koncel-Kedziorski、Yejin Choi 和 Hannaneh Hajishirzi。2019。[MathQA：利用运算的实现可解释的数学单词问题求解基于形式主义](#)。In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics：人类语言技术，第 1 卷（长篇论文和短篇论文）*，明尼苏达州明尼阿波利斯。计算语言学协会。
- 丹尼尔-安道尔、何鲁恒、肯顿-李和艾米莉-皮特勒。2019。[给BERT一个计算器：查找通过阅读理解操作和参数](#)。EMNLP.
- 雅各布-安德烈亚斯、丹-克莱因、谢尔盖-莱文。2018。[潜语言学习](#)。NAACL.
- Jacob Austin, Augustus Odena, Maxwell Nye, Maarten Bosma, Henryk Michalewski, David Dohan, Ellen Jiang, Carrie Cai, Michael Terry, Quoc Le, et al.[使用大型语言程序合成模型的](#)。arXiv 预印本 arXiv:2108.07732.
- BIG-bench 合作。2021。[超越模仿游戏：测量和推断语言模型的能力](#)。[准备中](#)。
- Kaj Bostrom, Xinyu Zhao, Swarat Chaudhuri, and Greg Durrett.2021。[自然语言演绎的灵活生成](#)。EMNLP.
- 汤姆-布朗、本杰明-曼、尼克-莱德、梅兰妮-苏比亚、贾里德-D-卡普兰、普拉富拉-达里瓦尔、阿尔文德-尼拉坎坦、普拉纳夫-希亚姆、吉里什-萨斯特里、阿曼达-阿斯凯尔、桑迪尼-阿加瓦尔、阿里埃尔-赫伯特-沃斯、格雷琴-克鲁格、汤姆-亨根根、雷旺-查尔德Aditya Ramesh、Daniel Ziegler、Jeffrey Wu、Clemens Winter、Chris Hesse、Mark Chen、Eric Sigler、Mateusz Litwin、Scott Gray、Benjamin Chess、Jack Clark、Christopher Berner、Sam McCandlish、Alec Radford、Ilya Sutskever 和 Dario Amodei。2020。[语言模型是少数学习者](#)。NeurIPS。
- Jonathon Cai、Richard Shin 和 Dawn Song。2017。[通过递归通用化使神经编程架构](#)。ICLR.
- Oana-Maria Camburu、Tim Rocktäschel、Thomas Lukasiewicz 和 Phil Blunsom。2018。[e-SNLI：使用自然语言解释的自然语言推理](#)。NeurIPS.
- Howard Chen, Jacqueline He, Karthik Narasimhan, and Danqi Chen.2022。[合理化能提高稳健性吗？](#) NAACL.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al.[评估在代码上训练的大型语言模型](#)。arXiv preprint arXiv:2107.03374.
- Xinyun Chen, Chen Liang, Adams Wei Yu, Denny Zhou, Dawn Song, and Quoc V. Le.2019。[神经符号阅读器：用于阅读分布式和符号表征的可扩展集成理解的](#)。ICLR.
- Ting-Rui Chiang and Yun-Nung Chen.2019。[用于求解的语义对齐方程生成和推理数学单词问题](#)。In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics：Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 2656-2668, Minneapolis, Minnesota. 计算语言学协会。

- Peter Clark, Oyvind Tafjord 和 Kyle Richardson. 2020. [作为软推理器的变换器语言](#)。 *IJCAI*.
- 卡尔-科布、维尼特-科萨拉朱、穆罕默德-巴伐利亚、雅各布-希尔顿、中野礼一郎、克里斯托弗-赫塞和约翰-舒尔曼。 2021. [训练验证器解决数学文字问题](#)。 *arXiv 预印本 arXiv:2110.14168*.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee 和 Kristina Toutanova. 2019. [BERT: 的预训练用于语言理解深度双向变换器](#)。 *NAACL*.
- 董红华、毛嘉媛、林天、王冲、李丽红和周丹妮。 2019. [神经逻辑机](#) *IJCLR*.
- Dheeru Dua, Sameer Singh 和 Matt Gardner. 2020. [阅读中中间注释的好处理解](#)。 *ACL*.
- Mor Geva, Daniel Khashabi, Elad Segal, Tushar Khot, Dan Roth 和 Jonathan Berant. 2021. [亚里士多德用笔记本电脑吗? 隐含推理策略的问题解答基准](#)。 *TACL*.
- Yuling Gu, Bhavana Dalvi Mishra, and Peter Clark. 2022. [DREAM: 揭示心理模型语言模型背后的](#)。 *NAACL*.
- Braden Hancock, Paroma Varma, Stephanie Wang, Martin Bringmann, Percy Liang 和 Christopher Ré. 2018. [用自然语言解释训练分类器](#)。 *ACL*.
- Peter Hase 和 Mohit Bansal. 2022. [理解解释数据作用的正式框架](#)。 *ACL*.
- Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song 和 Jacob Steinhardt. 2021. [用数学数据集测量数学问题的解决](#)。 *arXiv 预印本 arXiv:2103.03874*.
- Mohammad Javad Hosseini, Hannaneh Hajishirzi, Oren Etzioni 和 Nate Kushman. 2014. [通过动词分类解决算术单词问题学习](#)。 *EMNLP*.
- Zhanming Jie, Jierui Li, and Wei Lu. 2022. [学习演绎推理: 数学单词问题作为复杂关系提取的求解](#)。 *arXiv 预印本 arXiv:2203.10316*.
- 贾里德-卡普兰、萨姆-麦坎德利什、汤姆-亨尼根、汤姆-B-布朗、本杰明-切斯、雷旺-柴尔德、斯科特-格雷、亚历克-拉德福德、杰弗里-吴和达里奥-阿莫代。 2020. [神经语言的缩放定律模型](#)。 *arXiv 预印本 arXiv:2001.08361*.
- Rik Koncel-Kedziorski, Subhro Roy, Aida Amini, Nate Kushman 和 Hannaneh Hajishirzi. 2016. [MAWPS: 数学单词问题库](#)。 *NAACL*.
- Andrew K. Lampinen, Ishita Dasgupta, Stephanie C.Y. Chan, Kory Matthewson, Michael Henry Tessler, Antonia Creswell, James L. McClelland, Jane X. Wang, and Felix Hill. 2022. [语言能模型从上下文解释中学习吗?](#) *arXiv preprint arXiv:2204.02329*.
- 兰义怀、王磊、张启元、兰云石、戴炳田、王艳、张东祥和林奕鹏。 2021. [MWPToolkit: 基于深度学习的数学开源框架单词问题求解器的](#)。 *arXiv preprint arXiv:2109.00799*.
- Teven Le Scao 和 Alexander Rush. 2021. [一个提示值多少数据点?](#) *NAACL*.
- Brian Lester, Rami Al-Rfou 和 Noah Constant. 2021. [参数高效规模力量及时调整的](#)。 *EMNLP*.
- Iddo Lev, Bill MacCartney, Christopher Manning 和 Roger Levy. 2004. [解决逻辑难题: 从稳健处理到精确语义](#)。 *第二届文本意义与解释研讨会论文集*。
- Xiang Lisa Li 和 Percy Liang. 2021. [前缀调整: 优化连续提示生成](#)。 *ACL*.

- Zhengzhong Liang, Steven Bethard, and Mihai Surdeanu.2021.通过内部独白实现推理可解释的多跳语言。 *NAACL*.
- Wang Ling, Dani Yogatama, Chris Dyer, and Phil Blunsom.2017.通过理由进行程序归纳生成：学习解决和解释代数文字问题。 *ACL*.
- Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi, and Graham Neubig.2021.预训练、提示和预测：自然语言中的提示方法系统调查》处理。 *ArXiv 预印本 arXiv:2107.13586*.
- Bodhisattwa Prasad Majumder、Oana-Maria Camburu、Thomas Lukasiewicz 和 Julian McAuley。2021.理性启发的常识性自然语言解释。 *arXiv预印本 arXiv:2106.13876*.
- Ana Marasovic, Iz Beltagy, Doug Downey, and Matthew E Peters.2022.自然语言提示下的少量自我合理化。 *NAACL 研究成果*.
- Joshua Maynez、Shashi Narayan、Bernd Bohnet 和 Ryan McDonald。2020.论忠实性和抽象概括中的事实性。 In *ACL*.
- Shen Yun Miao, Chao Chun Liang, and Keh Yih Su.2020.用于评估和的多样化语料库开发英语数学单词问题求解器。 *ACL*.
- Sewon Min、Xinxi Lyu、Ari Holtzman、Mikel Artetxe、Mike Lewis、Hannaneh Hajishirzi 和 Luke Zettlemoyer。2022.反思演示的作用： *arXiv preprint arXiv:2202.12837*.
- Sharan Narang、Colin Raffel、Katherine Lee、Adam Roberts、Noah Fiedel 和 Karishma Malkan。2020.WT5?训练文本到文本模型以解释其预测。 *arXiv preprint arXiv:2004.14546*.
- Maxwell Nye, Anders Johan Andreassen, Guy Gur-Ari, Henryk Michalewski, Jacob Austin, David Bieber, David Dohan, Aitor Lewkowycz, Maarten Bosma, David Luan, et al.展示您的作品用语言模型进行中间计算的 Scratchpads。 *arXiv 预印本 arXiv:2112.00114*.
- Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al.训练语言模型以遵循人类反馈的指令。 *arXiv preprint arXiv:2203.02155*.
- Arkil Patel、Satwik Bhattamishra 和 Navin Goyal。2021.NLP模型真的能够解决简单的数学文字问题吗？ *NAACL*.
- Matthew E. Peters、Mark Neumann、Mohit Iyyer、Matt Gardner、Christopher Clark、Kenton Lee 和 Luke Zettlemoyer。2018.深度语境化单词表征。 *NAACL*.
- 皮新宇、刘倩、陈蓓、莫尔塔扎-齐亚迪、林泽奇、高艳、傅强、楼建光、陈伟柱。2022. *ArXiv preprint arXiv:2201.11473*.
- Piotr Piekos, Mateusz Malinowski, and Henryk Michalewski.2021.通过预测推理顺序BERT的数学能力》。测量和提高 *ACL*.
- Jack W. Rae, Sebastian Borgeaud, Trevor Cai, Katie Millican, Jordan Hoffmann, Francis Song, John Aslanides, Sarah Henderson, Roman Ring, Susannah Young, et al.扩展语言模型：方法、分析及训练 Gopher 的启示。 *arXiv 预印本 arXiv:2112.11446*.
- Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li 和 Peter J Liu。2020.用统一的探索迁移学习的极限文本到文本转换器》。 *机器学习研究期刊*，21:1-67.
- Dheeraj Rajagopal、Vidhisha Balachandran、Eduard H. Hovy 和 Yulia Tsvetkov。2021.SelfExplain：神经文本分类器的自解释架构。 *EMNLP*.
- Nazneen Fatema Rajani、Bryan McCann、Caiming Xiong 和 Richard Socher。2019.解释你自己！利用语言模型进行常识推理。 *ACL*.

- Qiu Ran, Yankai Lin, Peng Li, Jie Zhou, and Zhiyuan Liu. 2019. NumNet: 机器阅读数字推理的理解。 *EMNLP*.
- Hannah Rashkin, Vitaly Nikolaev, Matthew Lamm, Michael Collins, Dipanjan Das, Slav Petrov, Gaurav Singh Tomar, Iulia Turc 和 David Reitter. 2021. 自然语言中的归因测量生成模型。 *arXiv 预印本 arXiv:2112.12870*.
- 加布里埃尔-雷奇亚. 2021. 通过演示教授自回归语言模型复杂任务的 *arXiv preprint arXiv:2109.02102*.
- Emily Reif, Daphne Ippolito, Ann Yuan, Andy Coenen, Chris Callison-Burch, Jason Wei. 2022. 用大型语言模型实现任意文本风格转换的秘诀。 *ACL*.
- Laria Reynolds 和 Kyle McDonell. 2021. 大型语言模型的提示编程：超越几枪范式。 2021 年计算机系统的人为因素 CHI 会议扩展摘要。
- Subhro Roy and Dan Roth. 2015. 解决一般算术文字问题。 *EMNLP*.
- Subhro Roy, Tim Vieira 和 Dan Roth. 2015. 自然语言中的数量推理。 *TACL*.
- Mohammed Saeed, Naser Ahmadi, Preslav Nakov, and Paolo Papotti. 2021. RuleBERT: 教授向预训练语言模型软规则。 *EMNLP*.
- Victor Sanh, Albert Webson, Colin Raffel, Stephen H. Bach, Lintang Sutawika, Zaid Alyafeai, Antoine Chaffin, Arnaud Stiegler, Teven Le Scao, Arun Raja, et al. 多任务提示训练实现零镜头任务泛化。 *ICLR*.
- Jianhao Shen, Yichun Yin, Lin Li, Lifeng Shang, Xin Jiang, Ming Zhang, and Qun Liu. 2021. 生成与排序：数学单词问题的多任务框架。 计算语言学协会论文集: *EMNLP 2021*.
- Alon Talmor, Jonathan Herzig, Nicholas Lourie 和 Jonathan Berant. 2019. 常识问答：以常识性知识为目标的答题挑战。 *NAACL*.
- Alon Talmor, Oyvind Tafjord, Peter Clark, Yoav Goldberg 和 Jonathan Berant. 2020. 思维：教预训练模型系统推理隐含知识飞跃。 *NeurIPS*.
- Alon Talmor, Ori Yoran, Ronan Le Bras, Chandra Bhagavatula, Yoav Goldberg, Yejin Choi 和 Jonathan Berant. 2021. CommonsenseQA 2.0: 通过游戏化揭示人工智能的极限。 *NeurIPS 数据集和基准赛道*.
- Yi Tay, Mostafa Dehghani, Vinh Q Tran, Xavier Garcia, Dara Bahri, Tal Schuster, Huaixiu Steven Zheng, Neil Houlsby 和 Donald Metzler. 2022. *ArXiv preprint arXiv:2205.05131*.
- Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, et al. LaMDA: 的语言模型对话应用。 *arXiv 预印本 arXiv:2201.08239*.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, and Denny Zhou. 2022a. 自洽性改善语言模型中的思维链推理。 *arXiv 预印本 arXiv:2203.11171*.
- Yizhong Wang, Swaroop Mishra, Pegah Alipoormolabashi, Yeganeh Kordi, Amirreza Mirzaei, Anjana Arunkumar, Arjun Ashok, Arut Selvan Dhanasekaran, Atharva Naik, David Stap, et al. 在 1600 多项语言任务中通过上下文指令进行泛化的基准测试。 *arXiv 预印本 arXiv:2204.07705*.
- Jason Wei, Maarten Bosma, Vincent Y. Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M. Dai, and Quoc V. Le. 2022a. 微调语言模型是零点学习者。 *ICLR*.

- Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, et al. 2022b. [大型语言的新兴能力模型](#)。《*机器学习研究论文集*》。
- Sarah Wiegrefe, Jack Hessel, Swabha Swayamdipta, Mark Riedl 和 Yejin Choi. 2022. [重构人机协作，生成自由文本解释](#)。 *NAACL*.
- Sarah Wiegrefe 和 Ana Marasovic'. 2021. [教我解释：可解释数据集回顾NLP](#)。 *NeurIPS*.
- Sarah Wiegrefe, Ana Marasovic', and Noah A. Smith. 2021. [测量标签之间的关联与自由文本理由](#)。 *EMNLP*.
- Wu Tongshuang, Ellen Jiang, Aaron Donsbach, Jeff Gray, Alejandra Molina, Michael Terry 和 Carrie J Cai. 2022a. [PromptChainer：通过可视化连锁大型语言模型提示编程](#)。 *CHI Extended Abstracts*.
- 吴同双、Michael Terry 和 Carrie Jun Cai. 2022b. [人工智能链：透明可控的通过连锁大型语言模型提示实现人机交互](#)。 *CHI*.
- Yujun Yan, Kevin Swersky, Danai Koutra, Parthasarathy Ranganathan, and Milad Hashemi. 2020. [神经执行引擎：学习执行子程序](#)。 *NeurIPS*.
- Huihan Yao, Ying Chen, Qinyuan Ye, Xisen Jin, and Xiang Ren. 2021. [用构成解释完善语言模型](#)。 *NeurIPS*.
- Xi Ye 和 Greg Durrett. 2022. [情境学习中解释的不可靠](#)。 *arXiv preprint arXiv:2205.03401*.
- Yordan Yordanov, Vid Kocijan, Thomas Lukasiewicz, and Oana-Maria Camburu. 2021. [自然语言解释的域外迁移学习（out-of-domain transfer learning of natural language explanationsFew-shot）](#)。 *arXiv预印本arXiv:2112.06204*。
- Omar Zaidan, Jason Eisner, and Christine Piatko. 2007. [使用 "注释者理由" 改进文本分类的机器学习](#)。 *NAACL*.
- Wojciech Zaremba 和 Ilya Sutskever. 2014. *ArXiv preprint arXiv:1410.4615*.
- Eric Zelikman, Yuhuai Wu 和 Noah D. Goodman. 2022. [STaR: Bootstrapping reasoning with reasoning](#). *arXiv preprint arXiv:2203.14465*.
- Tony Z. Zhao, Eric Wallace, Shi Feng, Dan Klein, and Sameer Singh. 2021. [先校准后使用：提高语言模型的少拍性能](#)。 *ICML*.
- Wangchunshu Zhou, Jinyi Hu, Hanlin Zhang, Xiaodan Liang, Maosong Sun, Chenyan Xiong, and Jian Tang. 2020. [以解释为潜在，实现可解释的自然语言理解变量](#)。 *NeurIPS*.