

提示式 LLMs 作为聊天机器人模块用于开放 域长对话

Gibbeum Lee^{1*}沃尔克-哈特曼^{1*}

Jongho

Park^{1*} Dimitris Papailiopoulos^{1,2} 李康旭^{1,2}¹克拉夫顿 ²威斯康星大学麦迪逊分校

{pirensisco, volker, jongho.park}@krafton.com

摘要

在本文中，我们提出了 MPC（模块化提示聊天机器人），这是一种无需微调即可创建高质量对话代理的新方法。我们的方法利用预先训练好的大型语言模型（LLM）作为单独的模块，通过少量提示、思维链（CoT）和外部记忆等技术实现长期一致性和灵活性。我们的人类评估结果表明，MPC 在开放领域的转换中与经过微调的聊天机器人模型不相上下，因此是创建一致且吸引人的聊天机器人的有效解决方案。

1 简介

拥有数十亿参数的语言模型，如 GPT-3（Brown 等人，2020 年）和 PaLM（Chowdhery 等人，2022 年），已经在许多 NLP 任务中达到了最先进的性能。要针对开放领域聊天机器人任务微调这些大型语言模型（LLMs），可以使用能代表目标领域的转换数据集。然而，为开放领域聊天机器人微调 LLM 可能具有挑战性，这是因为更新包含数十亿个参数的模型需要大量计算，而且对话领域的数据非常稀少。此外，正如 Yang 和 Ma（2022）所报告的那样，微调会将模型限制在特定领域，从而限制了模型的通用性，并导致预训练过程中获得的领域无关知识的丢失。Roller 等人（2021 年）提出的在不同数据集上进行多任务训练可以解决通用性问题，但也有局限性，比如需要数据来训练每种技能，而且很难确定开放领域聊天机器人所需的技能。事实上，聊天机器人的模块数量越来越多，如 Blenderbot3（BB3）（Shuster 等人，2022 年），这表明在为每个新聊天机器人模型进行微调时，数据和计算的负担越来越重。

有趣的是，一些 LLMs 具有在情境中学习（ICL）的能力（Nye 等人，2022 年；Wei 等人，2022 年 b；Lewkowycz 等人，2022 年 2022；Wei 等人，2022 年 a；Zhou 等人，年 2022 年 2022；Dasgupta 等人，；Chung 等人，年）。这种能力使模型能够根据简短的指令和几个例子快速适应和执行特定任务，而不需要额外的微调。这可用于创建开放领域聊天机器人，向 LLM 提供描述开放领域对话所需任务的提示和解决此类任务的几个实例，使其生成与当前对话相关的信息。

我们的贡献 我们提出了一种无需微调即可创建高质量对话代理的新方法。我们提出的聊天机器人 MPC（模块化提示聊天机器人）利用开源的预训练语言模型，提高了开放域聊天机器人模块设计的灵活性。我们的方法通过使用模块化代理，将 LLMs 与少发 ICL 和思维链（CoT）等提示技术相结合，从而提高了多种对话能力。在本文中，我们设计的 MPC 可实现长期一致性，而这正是以前的聊天机器人一直苦苦挣扎的领域。我们的人类评估结果表明，在开放域对话环境中，MPC 与 Blenderbot 等经过微调的 LLM 不相上下，甚至更胜一筹。这种方法凸显了预训练 LLM 无需微调即可适应新任务的潜力，为创建开放域对话式代理提供了高效的解决方案。¹

2 相关工作

模块化提示 经过精心设计的诱导性提示可以增强推理能力，从而提高对话效率。

¹ 我们的代码见 <https://github.com/krafton-ai/MPC>。

在各种基准方面的性能都有所提高 (Kojima等人, 2022年; Wei等人, 2022年; Suzgun等人, 年)。对于复杂问题, Press 等人 (2022 年) 发现了当 LM 可以解决子问题但不能解决整体解决方案时产生的组成性差距, 并进一步表明 CoT 缩小了这一差距。从那时起, 通过将任务分解为由不同 "提示模块" 解决的更小任务来解决任务的研究成果层出不穷 (Zhou 等人, 2022 年; Wang 等人, 2022 年; Khot 等人, ; Khatatab 等人, 年)。

模块化提示技术的应用已经超越了基准线, 并应用于对话生成。Kim 等人 (2022 年) 使用 LLM 生成了一个社会对话数据集, 与现有的众包数据集相比, 该数据集更加自然和去尾。此外, 分层提示模块被证明有助于生成叙事和戏剧的长程连贯性 (Yang 等人等, 2022 年; Mirowski 人, 2022 年)。关于 LLMs 这种增强型用途的详细概述, 请参阅 Mialon 等人 (2023 年)。

开放域聊天机器人 最近的许多对话代理都依赖于经过对话调整的 LLM。在 Thop- pilan 等人 (2022 年) 的研究中, LaMDa 在大量爬行对话数据的基础上进行了训练, 并使用了微调分类器来保证模型的安全性。最近, 与我们的模块化方法类似, BB3 在 QA 和对话数据集上对开放预训练转换器 (OPT) (Zhang 等人, 2022; Shuster 等人, 2022) 进行了微调, 并将一个共享模型权重用作多个模块。

另一方面, Madotto 等人 (2021 年) 通过将检索到的对话样本作为 GPT-J (Wang 和 Komatsuzaki, 2021 年) 的少量对话样本, 消除了对对话数据进行微调的需要。我们认为这项工作与我们的工作相辅相成, 因为少量对话可被视为增强语篇生成器模块的一种方法。

长期记忆 多会话聊天数据集 (Xu 等人, 2022 年) 可用于测量对话代理对用户和机器人事实的长期记忆保持程度。信息使用 Dense Passage Retriever (DPR) (Karpukhin 等人, 2020 年) 进行检索, 而 BART 则在存储之前对记忆进行梳理。在 Shuster 等人 (2022 年) 的研究中, 使用了一种模块化方法, 通过互联网搜索将长期记忆和事实基础与 LLM 结合起来。这项工

作与我们的工作最为接近, 因为它包括一项消融研究, 在这项研究中, 基于提示的模块与经过微调的模块进行了比较。

与微调模块进行比较。不过，在我们的工作中，我们认为，正如 Wei 等人（2022b）所证明的那样，更多基于推理的提示有利于更好地理解上下文。


3 模块化提示聊天机器人

我们展示了一个模块化聊天机器人系统（图 1），它使用基于提示的 LLM 来在长期对话中保持角色和参与度。

图 1：我们在开放域对话中提高长期一致性的模块化设计。

在对话开始时，记忆库中会存储一个预定义的内容。当用户发送信息时，澄清器会重新措辞以解决任何含糊不清之处，并将其传递给 DPR 模型，后者会从记忆库中检索相关记忆。检索到的记忆和澄清器的输出被送入记忆处理器，得到一个与上下文相关的记忆，然后将其传递给语句生成器，由聊天机器人做出回应。每隔几个回合，我们会调用摘要模块从对话中提取重要内容并存储到记忆库中，以供将来使用（见附录 C 和 D）。

语句澄清器 由于对话中经常会出现含糊不清的核心参照和上下文语境，因此我们需要一个**语句澄清器**来澄清对话中的**语句**。



我们的澄清模块是一个 LM，通过提示最近的对话来解决任何模棱两可的问题。例如，根据先前的上下文，用户输入 "你喜欢在那里工作吗？" 时会输出 "莎拉喜欢在 ZYX 公司工作吗？"。通过解决上下文中的歧义，澄清器可以为 DPR 模型和内存处理器模块提供信息密集的查询，以获取和处理相关内存。

记忆处理器 如图 1 所示，我们将记忆处理表述为一项 LLM 重构任务，即在对话中找到最相关的信息。按照解决困难推理任务的方法（Suzgun 等人，2022 年），我们提供了 CoT 例子来说明忽略某些记忆和综合其他记忆的原因。对于无法进行 CoT 的模型，我们只提供少量的示例，而不提供推理部分。

由于记忆库会随着计算的进行而不断累积，因此我们使用预先训练好的 DPR，将澄清器的输出作为查询，从记忆库中重新提取前 k 个最相关的记忆。然后，记忆处理器会将最重要的记忆浓缩为一个精炼记忆。

语句生成器 语句生成器模块根据最近的对话历史和记忆处理器提供的记忆生成聊天机器人的最终回复。提示由对话历史、浓缩记忆和生成指令（如 "给用户一个友好的回复"）组成。对于某些模型，我们发现最后插入生成指令很有帮助，因为把它放在对话之前会使指令的效果最小化。

对话总结器 我们提供了一个简短的提示，以确保我们记录下对话和用户的具体细节。

4 实验设置

我们通过评估长期对话所需的核心技能来评估聊天机器人的性能。我们通过分配五个角色中的一个来评估一致性，每个角色都有来自 PersonaChat（Zhang 等人，2018 年）的 12 个事实，并将这些事实展示给评估者。在每个实验中，我们从每个评估者那里收集 20 个回合，并从两个分组中总共收集至少 500 个回合：亚马逊 Mechanical Turk 和大学生。有关数据收集的详细说明，请参见附录 E。

在我们的设置中，有四组模型。

1. **微调聊天机器人模型**，如 BB3。
2. **Vanilla** 是一种语篇生成器，它可以在提示中的对话历史记录前添加 **完整角色** 或 **无角色**。这代表了将 LM 用作聊天机器人的天真方法。
3. MPC 如第 3 节所述。具体来说，我们只从记忆处理器中生成一个记忆。没有明确预置完整的角色。
4. MPC+full persona 是预置完整角色的 MPC。参见附录 D 中的示例。

4.1 单一模型评估

我们使用敏感度、一致性和参与度指标分别对每个模型进行评估，并收集最终评分（满分 5.0）。具体问题和评估表格见附录 A。我们还报告了两种类型的综合得分 SCE（感性一致性和参与性）："完美"得分 SCE-p，即所有指标都必须为正数才能获得积极回应；加权得分 SCE-w，与 SSI（Thoppilan 等人，2022 年）类似，报告于附录 B。

我们使用 OpenAI GPT-3 text-davinci-002 (td2) 和 davinci、OPT 30B、66B、GPT-JT-6B (Together, 2022) 和 BLOOM-176B (Scao et al., 2022) 作为 MPC 的基础 LM。对于微调组，我们使用具有相同角色设置的 BB3-30B。对于 BB3-175B，我们要求群众工作者对在线演示进行 20 轮评估。

4.2 配对模型评估

我们通过向用户提供两个随机回复 A 和 B 来对两个聊天机器人模型进行 A/B 测试。然后，对话继续进行，用户选择偏好的回复。这样，我们就可以在比较两个模型时控制对话历史。

具体来说，我们进行了两个主要实验：

- (1) MPC_{OPT-30B} 与 BB3-30B，其中 BB3 的网络搜索被禁用，因为我们关注的是一致性。由于 BB3-30B 是 OPT-30B 的微调版本，因此我们的评估可以进行直接比较。
- (2) MPC_{td2} 与 Vanilla td2（完整角色）。

隐性角色 在现实生活中，我们通过对话隐性地了解一个人。相比之下，我们之前的实验向评估者和模型展示了显性角色。因此，我们设计了一个实验，向人

群工作者和成对模型提供 10 轮预定义对话、

MPC_{td2}和 Vanilla td2（无角色）。然后，我们要求工作者在新的 6 个回合中询问之前的对话。在这里，我们设置了一个比 10 轮对话更短的最大上下文长度，这样设置就能代表长时间对话，在这种情况下，必要的内部形成超出了 LM 上下文长度。

5 结果

方案协调会 (选择-) (30b)		领带	BB3-30B
敏感性	一致	32.0	23.0
性	趣味性	40.9 34.1	34.6
		21.0	38.1
偏好		50.0 9.7	40.3

表 1: MPC_{OPT-30B}与 BB3- 的配对评估 30B（深色高亮度: $p < 0.01$, 浅色高亮度: $p < 0.05$; 我们进行单样本 t 检验, 平分平局并设置 $\mu > 0.5$ ）。

预训练与微调 我们的人工评估显示，使用预训练 LLM 的 MPC 优于微调 BB3-30B。最明显的是，MPC_{OPT-30B}在所有指标上的得分都高于 BB3-30B，SCE-p 差距为 9%。事实上，表 2 中的大多数 MPC 模型都显示出比 BB3-30B 更优越的性能。2 中的大多数 MPC 模型的性能都优于 BB3-30B。

对于 BB3-30B，我们观察到的问题有我们在表 5 中报告了仅包括无重复语对话的评估结果。我们在表 5 中报告了仅包括无重复对话的评估结果。即使没有重复，MPC_{OPT-30B}仍然与 BB3-30B 相当。更多不过，表 1 中的 MPC_{OPT-30B}比 BB3-30B 显示出更高的敏感度和偏好度，而在一致性和趣味性方面得分相似。

模块化与非模块化 MPC 在连贯对话方面优于普通方法。表 3 中的隐式角色实验表明，MPC_{td2}在所有指标上的得分都明显高于td2 的普通应用。在表 2 中，对于 MPC_{td2+} 完全角色，一致性与 td2（完全角色）相当，而参与度、SCE-p 和评分则是整体最佳。然而，当我们在 MPC_{td2}的提示中不包含完整角色时，尽管在感性和一致性方面的平局率很高，但其一致性却低于td2（完整角色）（Ta- ble 4）。总的来说，我们发现用户会主要询问机器人的角色，而不是

模型	感应	一致	英语	SCE-p	等级	微调
BB3-30B	71.3	77.8	73.7	54.3	2.9	
BB3-175B	85.9	(88.7)	84.8	73.1	3.8	
全称						
td2	94.0	94.7	84.3	79.7	4.1	
达文西	91.8	89.2	78.8	70.8	3.8	
MPC						
td2	93.6	87.8	85.5	75.0	4.2	
达文西	80.2	72.0	69.1	53.3	3.1	
opt-66b	90.5	84.8	88.1	73.9	4.1	3.6
opt-30b	86.1	79.1	80.7	63.4	3.1	
gpt-jt	91.1	83.2	65.3	53.5	2.8	
bloom	65.2	65.5	61.4	40.5		
MPC+Full						
td2	94.4	92.2	92.8	83.0	4.2	
OPT-30B	85.6	87.2	89.0	72.6	3.7	

表 2: 基线和 MPC 的单一模型评估。每个指标的前 3 名得分以高亮度标出，最高分以粗体标出。更详细的结果见 Ap- 附录 B 表 5。

	MPC _{td2}	平局	td2（无角色）
感性	40.6	46.1	13.3
一致性	57.2	28.9	13.9
趣味性	47.2	31.1	21.7
偏好	67.2	10.6	22.2

表 3: MPC 的隐性角色实验 td2 与 td2（无角色）。(深色高亮: $P < 0.01$)

进行双面对话，这导致 td2（全角色）在一致性方面表现更好。

模型大小的影响 在其他变量不变的情况下，我们发现模型大小与正面评价呈正相关。最有力的证据是，与 $\text{MPC}_{(\text{OPT-30B})}$ 相比， $\text{MPC}_{(\text{OPT-66B})}$ 在所有指标上都更胜一筹，因为这两个基础 LM 的训练几乎完全相同。不用说，模型大小并不是唯一的因素。 $\text{MPC}_{\text{BLOOM}}$ 是最大的模型之一，在我们的实验中得分最低。

指令调整的效果 指令调整有助于创建模块化对话系统，使其能够适应各种任务。 MPC_{td2} 不仅比 $\text{MPC}_{\text{davinci}}$ 表现更好，而且 $\text{MPC}_{\text{GPT-JT}}$ 尽管规模较小，却表现出了很高的灵敏度和一致性。总的来说，我们认为指令调整的 LM 的每个模块找到好的提示更简单，对变化也更稳健。 $\text{MPC}_{\text{davinci}}$ 比 $\text{davinci (full persona)}$ 差，这可能是由于错误传播造成的。

	MPC _{td2}	领带	td2 (完整角色)
灵敏度	27.5	42.6	29.9
一致性	24.4	44.7	30.9
趣味性	40.7	26.2	33.1
偏好	42.8	15.9	41.3

表 4：MPC_{td2}与 td2（完整角色）的对比。虽然 MPC_{td2}只检索了一个记忆，但一致性仅降低了 6 个百分点。（浅色高亮： $P < 0.05$ ）

尽管我们不排除 MPC_{davinci}有更好的提示。

6 结论

我们证明了使用 LLM（即 MPC）的模块化方法可以成为长期开放领域聊天机器人的有效解决方案，而无需进一步微调。我们将 MPC 与经过微调的 LLM 基线和普通 LLM 基线进行了比较，发现我们的方法在人类评估中取得了优异的性能。此外，根据一致性评估，我们的模块化系统比非模块化系统更有效地整合了角色和对话历史信息。

局限性

在这项工作中，我们研究了在长期英语会话中使用预训练语言模型的问题。虽然我们预计模块化方法在其他语言中也会有效，但还需要注意的是，还需要进一步的研究来证实我们的发现是否适用于其他语言。例如，虽然 BLOOM 被训练成了多语言语言模型，但我们只用英语实现了 MPC_{BLOOM}，并评估了它作为开放域对话代理的英语能力。

同时，模块化系统会造成额外的推理开销或误差累积。如果我们为每个模块优化选择 LM，系统性能将大大提高。例如，我们可以使用 GPT-3 td2 作为记忆处理器，而使用 OPT-175B 作为语篇生成器。我们需要对每个模块进行评估，为每个模块找到最佳模型，这将留待今后工作中解决。

在评估方法方面，我们对 MPC 的人工评估及其分析与之前对主动式对话任务的评估研究面临同样的挑战。正如 Smith 等人（2022 年）所指出的，目前还没有确定最佳聊天机器人模型的明确评估方法。此外，在数据收集和解释过程中还必须考虑几个因素，如注释者的主观性、指令偏差和人群工作条件。有关人机交互的更深入讨论，请参考 Lee 等人（2022 年）的文章。

如附录 E 所述，为了收集各种评价，我们从两组人那里收集了定性数据：他们分别是亚马逊机械手（MTurk）上会说英语的注释员，以及会说英语的合格大学生。与只使用 MTurk 工作者相比，这种评估设置在一定程度上减少了文化偏见和平台同质性。但是，我们也应该认识到这种方法的局限性，在控制 MPC 在不同分组中的表现时，这可能会使分析更加复杂。

最后，我们注意到，运行 MPC 所需的内存至少与底层语言模型相同，因此对于 BLOOM-176B 等重型模型，MPC 甚至无法在单个节点上加载。

道德声明

MPC 利用公开的预训练 LM 生成聊天机器人语篇。

众所周知，这些 LM 生成的语言存在毒性和偏差问题 (Xu 等人, 2020 年)。因此，确保安全部署和交互是一个必要条件。

因此，我们在附录 E 中概述了我们的数据收集程序。我们允许众包工作者直接向我们提供反馈，并人工检查是否有任何冒犯性或争议性的言论。为确保个人信息得到保护，我们要求所有众包工作者不得分享任何个人身份信息或私人信息。此外，他们还被要求同意为研究目的收集匿名信息。在参与研究之前，所有众包工作者都被告知了数据收集的目的，并在评估之后获得了具有竞争力的时薪，约为每小时 12-16 美元。

参考资料

Tom Brown、Benjamin Mann、Nick Ryder、Melanie Subbiah、Jared D Kaplan、Prafulla Dhariwal、Arvind Neelakantan、Pranav Shyam、Girish Sastry、Amanda Askell 等，2020 年。语言模型是少数学习者。《神经信息处理系统进展》，33: 1877-1901。

陈玉龙、刘洋、陈亮、张越。2021.Dialogsum: 真实场景对话总结数据集。In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*，第 5062-5074 页。

Aakanksha Chowdhery、Sharan Narang、Jacob Devlin、Maarten Bosma、Gaurav Mishra、Adam Roberts、Paul Barham、Hyung Won Chung、Charles Sutton、Sebastian Gehrmann 等，2022 年。Palm: *ArXiv preprint arXiv:2204.02311*。

Hyung Won Chung, Le Hou, Shayne Longpre, Barret Zoph, Yi Tay, William Fedus, Eric Li, Xuezhi Wang, Mostafa Dehghani, Siddhartha Brahma, et al. Scaling instruction-finetuned language models. *ArXiv preprint arXiv:2210.11416*.

Ishita Dasgupta, Andrew K Lampinen, Stephanie CY Chan, Antonia Creswell, Dharshan Kumaran, James L McClelland, and Felix Hill. 2022. Language models show human-like content effects on reasoning. *ArXiv e-prints*, pages arXiv-2207.

宋峰、西瓦-桑卡尔普-帕特尔、万慧和萨钦-德拉-乔希。2021.Multidoc2dial: 建模对话

以多个文档为基础。《自然语言处理实证方法 2021 年会议论文集》，第 6162-6176 页。

弗拉基米尔-卡尔普欣、巴拉斯-奥古兹、苏元敏、帕特里克-刘易斯、莱德-吴、谢尔盖-埃杜诺夫、陈丹琪和易文涛。2020.用于开放域问题解答的密集段落检索。《2020 年自然语言处理实证方法会议 (EMNLP) 论文集》，第 6769-6781 页。

Omar Khattab, Keshav Santhanam, Xiang Lisa Li, David Hall, Percy Liang, Christopher Potts, and Matei Zaharia. 2022. 演示 - 搜索 - 预测: *ArXiv preprint arXiv:2212.14024*.

Tushar Khot, Harsh Trivedi, Matthew Finlayson, Yao Fu, Kyle Richardson, Peter Clark, and Ashish Sabharwal. 2022. 分解提示: 解决复杂任务的模块化方法。 *ArXiv 预印本 arXiv:2210.02406*.

Hyunwoo Kim, Jack Hessel, Liwei Jiang, Ximing Lu, Youngjae Yu, Pei Zhou, Ronan Le Bras, Malihe Alikhani, Gunhee Kim, Maarten Sap, et al. 苏打水百万规模对话提炼与常识情境化 (Million-scale dialogue distillation with social commonsense contextualization)。

Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. 2022. 大型语言模型是零射推理器。 *arXiv 预印本 arXiv:2205.11916*.

Mina Lee, Megha Srivastava, Amelia Hardy, John Thickstun, Esin Durmus, Ashwin Paranjape, Ines Gerard-Ursin, Xiang Lisa Li, Faisal Ladhak, Frieda Rong, et al. 2022. 评估人与语言模型的交互。 *arXiv preprint arXiv:2212.09746*.

Aitor Lewkowycz, Anders Johan Andreassen, David Dohan, Ethan Dyer, Henryk Michalewski, Vinay Venkatesh Ramasesh, Ambrose Slone, Cem Anil, Imanol Schlag, Theo Gutman-Solo, et al. 用语言模型解决定量推理问题。《神经信息处理系统进展》。

Andrea Madotto、林兆江、Genta Indra Winata 和 Pascale Fung。2021. 寥寥数语的机器人: *arXiv preprint arXiv:2110.08118*.

Grégoire Mialon、Roberto Dessi、Maria Lomeli、Christoforos Nalmpantis、Ram Pasunuru、Roberta Raileanu、Baptiste Rozière、Timo Schick、Jane Dwivedi-Yu、Asli Celikyilmaz 等 2023 年。 *ArXiv preprint arXiv:2302.07842*.

- Piotr Mirowski, Kory W Mathewson, Jaylen Pittman, and Richard Evans.2022.用语言模型共同编写剧本和戏剧脚本：行业专业人士的评估。 *arXiv 预印本 arXiv:2209.14958*.
- Maxwell Nye, Anders Johan Andreassen, Guy Gur-Ari, Henryk Michalewski, Jacob Austin, David Bieber, David Dohan, Aitor Lewkowycz, Maarten Bosma, David Luan, et al.展示您的作品：用语言模型进行中间计算的 Scratch 垫。 *代码深度学习研讨会*。
- Ofir Press, Muru Zhang, Sewon Min, Ludwig Schmidt, Noah A Smith 和 Mike Lewis. 2022.测量并缩小语言模型的组成性差距。 *ArXiv 预印本 arXiv:2210.03350*。
- Stephen Roller, Emily Dinan, Naman Goyal, Da Ju, Mary Williamson, Yinhan Liu, Jing Xu, Myle Ott, Eric Michael Smith, Y-Lan Boureau 等, 2021 年。构建开放域聊天机器人的秘诀。 In *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: 主卷*, 第 300-325 页。
- Teven Le Scao, Angela Fan, Christopher Akiki, Elie Pavlick, Suzana Ilic, Daniel Hesslow, Roman Castagné, Alexandra Sasha Luccioni, François Yvon, Matthias Gallé, et al.布鲁姆：一个 176b 参数的开放式多语言语言模型。 *arXiv preprint arXiv:2211.05100*。
- Kurt Shuster, Jing Xu, Mojtaba Komeili, Da Ju, Eric Michael Smith, Stephen Roller, Megan Ung, Moya Chen, Kushal Arora, Joshua Lane, et al.Blenderbot 3：不断学习以负责任方式参与的部署型对话式代理。
- Eric Smith, Orion Hsu, Rebecca Qian, Stephen Roller, Y-Lan Boureau 和 Jason Weston. 2022.人机对话评估是个未解难题：比较各种对话代理评估方法的灵敏度》(Human evaluation of conversations is an open problem: comparing the sensitivity of various methods for evaluating dialogue agents. *第四届对话式人工智能 NLP 研讨会论文集*, 第 77-97 页。
- Mirac Suzgun, Nathan Scales, Nathanael Schärli, Sebastian Gehrmann, Yi Tay, Hyung Won Chung, Aakanksha Chowdhery, Quoc V Le, Ed H Chi, Denny Zhou, et al.具有挑战性的大本营任务以及思维链能否解决这些任务。 *ArXiv 预印本 arXiv:2210.09261*。
- Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, et al.Lamda：对话应用的语言模型。 *arXiv预印本 arXiv:2201.08239*。
2022. GPT-JT-6B-v1. <https://huggingface.co/togethercomputer/GPT-JT-6B-v1>. 访问日期：2022-12-15。
- Ben Wang and Aran Komatsuzaki.2021. GPT- J-6B: A 6 Billion Parameter Autoregressive Language Model. <https://github.com/kingoflolz/mesh-transformer-jax>.
- 王博思、邓翔、孙欢。2022.迭代提示预训练语言模型的思维链。 *自然语言处理实证方法 2022 年会议论文集*》，第 2714-2730 页。
- Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, et al.大型语言模型的新兴能力。 *arXiv preprint arXiv:2206.07682*。
- Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Ed Chi, Quoc Le 和 Denny Zhou. 2022b.大型语言模型中的思维链提示推理。 *arXiv 预印本 arXiv:2201.11903*。
- Jing Xu, Da Ju, Margaret Li, Y-Lan Boureau, Jason Weston, and Emily Dinan.2020.开放域聊天机器人安全食谱》。 *ArXiv 预印本 arXiv:2010.07079*。
- Jing Xu, Arthur Szlam, and Jason Weston.2022.超越金鱼记忆：长期开放域对话。 In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 5180- 5197.
- 杨成浩、马学哲, 2022。通过分量明智梯度规范剪裁提高微调预训练语言模型的稳定性。 *arXiv 预印本 arXiv:2210.10325*。
- Kevin Yang, Nanyun Peng, Yuandong Tian, and Dan Klein.2022.Re3：用递归重提示和修订生成更长的故事。 *arXiv preprint arXiv:2210.06774*。
- Saizheng Zhang, Emily Dinan, Jack Urbanek, Arthur Szlam, Douwe Kiela, and Jason Weston.2018.Personalizing dialogue agents：I have a dog, do you have pets too? In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2204- 2213.
- Susan Zhang, Stephen Roller, Naman Goyal, Mikel Artetxe, Moya Chen, Shuohui Chen, Christopher Dewan, Mona Diab, Xian Li, Xi Victoria Lin, et al.Opt：开放式预训练转换器语言模型。 *arXiv 预印本 arXiv:2205.01068*。
- Hattie Zhou, Azade Nova, Hugo Larochelle, Aaron Courville, Behnam Neyshabur, and Hanie Sedghi.2022.通过情境学习教授算法推理。 *arXiv 预印本 arXiv:2211.09066*。

A 评估细节

A.1 指标

在我们的工作中，我们提出了两种实验模式：单一模型评估和成对模型评估。我们的单一模型评估类似于 SM-Turn 和 SM-Dialogue 评估的混合，而配对模型则类似于 Smith 等人（2022 年）的 PW-Turn。对于每个回合，我们都会要求群众根据以下指标来评价聊天机器人的回复质量。我们附上问题的确切措辞。

单一模型评估

- **合理性** 回复是否合理。"回复有意义吗？"

- **一致性** 回复是否与聊天机器人的上下文信息或角色一致。

"回复是否与聊天机器人的角色列表和上下文信息一致？"

- **参与度** 用户是否参与并希望继续对话。

"您是否参与了回复？您想继续对话吗？"

- **最终评价**

"您的聊天感觉如何？从 1 分（非常差）到 5 分（非常好），对整个对话的质量进行评分。"

配对模型评估

- **感性** 哪种回答更有意义。"哪个回答更合理？"

- **一致性** 哪个回复更真实、更符合角色。

"如果让你说这两位演讲者中的一位更真实、更符合所列举的角色，而另一位则不真实、不符合，你会说谁更符合呢？"

- **趣味性** 哪个回答更有趣味性。

"如果让您说这些回答一个有趣，一个无趣，您认为哪个更有趣？"

- **偏好** 在长时间对话中，哪个回答更受欢迎。

"根据当前的回答，您更愿意与谁进行长时间交谈？您的"

你们的谈话将以选定的回答继续进行"。

A.2 模式

对于 MPC 的单一模型评估，我们使用 OPT (30B, 66B), OpenAI GPT-3 (davinci, text-davinci-002) GPT-JT 和 BLOOM-176B 作为开源预训练 LLM 组的基础 LM。另一方面，我们评估了 Blenderbot3 30B (BB3-30B) 作为微调模型组的基础 LM，BB3-30B 是最好的公开可用的开放域聊天机器人模型。我

们还评估了 BB3-175B，它只能通过网络界面 <https://blenderbot.ai/> 获取。我们评估 BB3-175B 是出于比较的目的，但这种比较并不公平，因为我们无法向 BB3 灌输角色，也无法控制其他差异，如互联网搜索和用户界面。对于 MPC 的配对模型评估，我们对 MPC_{OPT-30B} 和 BB3-30B 进行了配对测试，以比较人类对预训练模型和微调模型的评估。由于 BB3-30B 是在微调之前用 OPT-30B 初始化的，因此该实验控制了许多变量。在模块实验中，我们使用 OPT-30B 进行了测试，并比较了一个包含整个管道和另一个仅包含管道的模块。

使用带有固定角色的语篇生成器。

A.3 密集通道检索器

对于记忆模块的 DPR 模型，我们使用了为 MultiDoc2Dial 微调的自定义 DPR 模型 (Feng 等人, 2021 年) 中的模型权重，因为我们观察到该模型的性能略优于 Karpukhin 等人 (2020 年) 的原始 DPR 模型。

B 实验结果

在本节中，我们将报告所有实验结果和其他分析。

B.1 完整的单一模型评估

在本小节中，我们将报告所有的模型评估结果以及其他细节，如平均延迟（计算下一个语篇并向用户展示所需的时间）和平均语篇长度，即 OPT 标记器测量的标记数。我们还额外报告了 SCE-w，由于表 5 的篇幅限制，正文中没有报告 SCE-w。

我们计算了与 SSI (Thoppilan 等人, 2022 年) 类似的加权分数 SCE-w，其中响应

模型	灵敏度 (%)	Cons.(%)	Eng.(%)	SCE-w (%)	SCE-p (%)	长度 (令牌)	延迟 (秒)	评分 (/5.0)	人数
微调									
BB3-30B	71.3	77.8	73.7	62.0	54.3	24.9	3.7	2.9	27 540
BB3-30B (无重复)	84.4	80.3	90.3	73.2	65.6	25.4	3.7	3.5	16 320
BB3-175B*	85.9	88.7	84.8	80.0	73.3	25.4	-	3.8	27 540
完整角色									
text-davinci-002	94.0	94.7	84.3	88.4	79.7	15.4	0.8	4.1	35 700
达文西*	91.8	89.2	78.8	82.5	70.8	13.4	1.5	3.8	25 500
OPT-30B*	92.0	87.2	86.0	82.3	72.8	13.7	1.0	3.7	25 500
MPC									
text-davinci-002	93.6	87.8	85.5	84.4	75.0	23.1	4.7	4.2	39 780
达文西	80.2	72.0	69.1	66.4	53.3	19.9	8.4	3.1	27 540
OPT-66B	90.5	84.8	88.1	81.4	73.9	14.2	4.1	4.1	33 660
OPT-30B	86.1	79.1	80.7	73.9	63.4	15.4	3.3	3.6	37 740
GPT-JT	91.1	83.2	65.3	74.4	53.5	8.6	2.0	3.1	33 660
BLOOM-176B	65.2	65.5	61.4	51.8	40.5	15.6	12.4	2.8	28 500
MPC+Full									
text-davinci-002*	94.4	92.2	92.8	88.7	83.0	31.4	16.3	4.2	25 500
OPT-30B*	85.6	87.2	89.0	78.8	72.6	15.2	2.4	3.7	25 500

表 5：单一模型评估的全部实验结果。BB3-30B（非重复）与 BB3-30B 相同，但不包括任何重复之前机器人话语的对话。* 表示仅在 MTurk 上运行的模型实验。

只有在合理的情况下才能保持一致，只有在合理和一致的情况下才能吸引人。最终得分是所有 SCE-w 调整指标的平均值。

我们还注意到，自 2022 年 12 月以来，由于 ChatGPT 的原因，OpenAI API 调用的延迟时间变化很大，因此无法正确量化模块化导致的延迟时间。

BB3-175B 评估 由于评估程序不同，我们对 BB3-17B 的评估结果不能直接与其他模型进行比较。由于 BB3-175B 的模型权重没有公开，我们让评估者与 <https://blenderbot.ai/chat> 上。的 Blender- 机器人版本进行交互然后，我们要求评估者复制并粘贴所有用户输入和聊天机器人回复，同时为聊天机器人回复添加与其他模型类似的注释。我们还注意到，由于我们无法为在线版 Blenderbot 提供特定的角色，因此只能在对话上下文中对角色的一致性进行评估。

B.2 模型配置

我们在匿名仓库

<https://anonymous.4open.science/r/modular-chatbot-9BB7> 中包含了运行每个模型的代码。每个模型的配置都可以在资源库中找到。

配置包括解码参数（如采样方法、每个模块的温度）和语篇生成器模块提示的细微变化。

B.3 分组分析

我们测量了 MTurk 和学生评估者对每个指标和综合指标的评分差异，发现大多数实验和指标都没有显著差异（图 2）。总的来说，我们发现感性的评分差异最大。

BB3-30B 是一个异常值，在所有指标上都有显著差异，尤其是在感性方面，差异大于 20%。BB3-30B 对话中学生重复问题的比例增加了，但即使排除这些对话，我们仍然发现了显著的评分差异。通过观察对话历史，我们发现当 BB3-30B 重复同样的问题或突然改变话题时，BB3-30B 的学生评价者比 MTurk 的评价者更没有耐心。需要注意的是，这只是定性观察，应谨慎对待。

C 少量提示

在本节中，我们将展示每个模块的完整短片提示，包括 CoT 提示。模块




图 2：MTurk 员工组的平均得分减去大学生组的平均得分。我们发现这两个子组在各项指标上的平均分非常相似，不过感性似乎显示出最大的差异。一般来说，学生对聊天机器人模型的评分略高。BB3-30B 是一个异常值，学生的评分明显低于 MTurk 员工。

在不同的模型实验中，语篇生成器的提示略有不同。这些提示可以在我们资源库中的模型配置中看到。第二个对话摘要示例是根据数据集 DialogSum（Chen 等人，2021 年）中的一个样本修改的。

语句澄清器

用第三人称重述用户的问题。

莎拉：我在咖啡店工作了大约六个月。

用户：我明白了，你之前是做什么的？

具体来说，莎拉在咖啡店工作六个月之前做什么？

阿什利：你知道罗纳尔多是谁吗？用户：不知道，他是谁？

具体来说，罗纳尔多是谁？

罗伯特：嘿，你好吗？

用户：很好。你叫什么名字？你知道我的名字吗？

具体来说，罗伯特叫什么名字？罗伯特知道用户的名字吗？

詹妮弗：我喜欢读历史和科学方面的书。

用户：什么样的历史？我也喜欢历史！

具体地说，詹妮弗读什么样的历史？

约翰：嗨，今天过得好吗？

用户：很好。

具体来说，约翰今天好吗？

无CoT的内存处理器

这是约翰的知识清单。约翰的全名是约翰-帕克。

用户是当地一所中学的教师。用户教生物。

约翰喜欢跑步。

用户喜欢看电影，但不喜欢超级英雄电影。

问：用户的职业是什么？

答：约翰认为用户是当地一所中学的生物老师。

这是 Ashley 的知识清单。阿什利喜欢历史纪录片。

阿什利不喜欢韩国菜。

阿什利是当地一所中学的老师。用户喜欢生物学，尤其是解剖学。阿什利喜欢法国菜。

问：阿什利最喜欢吃什么菜？

答：Ashley 认为 Ashley 喜欢法国菜，但不喜欢韩国菜。

内存处理器

这是阿什利的知识清单。

(1) 阿什利喜欢历史纪录片。

(2) 阿什利不喜欢韩国菜。

(3) 阿什利是当地一所中学的教师。

(4) 用户喜欢生物学，尤其是解剖学。

(5) 阿什利喜欢法国菜。问：阿什利

最喜欢吃什么菜？答：让我们逐步思考。

(1) 历史纪录片与阿什利最喜欢的菜肴无关。

(2) 阿什利最喜欢的菜不会是韩国菜，因为她不喜欢韩国菜。(3) 阿什利是一名教师，这并不能说明她最喜欢的菜是什么。(4) 这个事实是关于 User 的，而不是 Ashley。(5) 阿什利最喜欢的菜可能是法国菜，因为她喜欢法国菜。因此，(2)和(5)有助于回答问题。

答案：阿什利认为阿什利喜欢法国菜：Ashley 认为 Ashley 喜欢法国菜，但不喜欢韩国菜。

对话总结

#对话

用户：谈谈你自己吧

莎莉我今年 26 岁，毕业于威斯康星州的一所大学。

用户：你在大学时是领导吗？

莎莉：是的：是的。我是我们大学计算机科学课程的首席助教。用户：

你在大学里参加过任何社团活动吗？

莎莉有。我是篮球协会的成员。我喜欢打篮球。#摘要

- 莎莉今年 26 岁，在威斯康星州大学毕业。
- 莎莉是计算机科学课程的首席助教。
- 莎莉在大学里打篮球。

#对话

用户：在你看过的所有电影中，你最喜欢哪一部？

约翰：我不得不说《超胆侠》是有史以来最好的电影。

用户：你这么认为，为什么？约

翰：嗯，《超胆侠》超级搞笑。

用户：你没撒谎，我觉得那部电影绝对搞笑。

约翰：我不知道你之前看过《Superbad》。

用户：我确保在它上映的第一天就去排队看了。

#总结

- 约翰最喜欢的电影是《超胆侠》。
- 约翰和用户都认为《超胆侠》很有趣。
- 用户在《Superbad》上映的第一天就看了《Superbad》。

D 语句生成器提示示例

在本节中，我们将为 MPC 和 Vanilla 模型的语句生成器提供提示示例。

MPC 的语句生成器

莎拉很有礼貌，很有趣，很有吸引力。下面是 Sarah 和 Person1 的对话。

人物 1：我在音乐会上最喜欢的部分是确保我买到了好座位，然后我就可以弹吉他了。

莎拉：听起来很有趣！1 号人物：是很有趣，那么你喜欢做什么来消遣呢？

莎拉：我喜欢去音乐会、车展、音乐节和有壁炉的房子。人物 1：我喜欢看车展和老爷车，你最喜欢什么车？

莎拉：我想我最喜欢的车是一辆古董野马。

人物 1：噢，老式野马车太棒了，我有个朋友拥有一辆 69 年的 MACH 1，那是我梦寐以求的车。

莎拉：好吧，我希望有一天你能体验你的梦想之车！

人 1：也许有一天我会的，你有一辆野马吗？

关于莎拉，下列说法正确的是（ ）。

莎拉认为莎拉拥有一辆野马汽车。

给 Person1 一个友好明智的回答，既有趣又礼貌。以提问结束。

莎拉：嗯，我希望有一天你能体验到你梦想中的汽车！

1 号人物：也许有一天我会的，你拥有一辆野马吗？

莎拉

根据之前的提示回答

"是的，我拥有一辆野马。这是一辆非常适合驾驶的汽车。你喜欢开车吗？

带有完整角色的 MPC 语句生成器 以下是有关 Sarah

的角色事实。莎拉今年 40 岁。

莎拉目前住在乔治亚州的一个小镇上。

佐治亚州。

莎拉每年读二十本书。

莎拉的第三份工作是做替身。

莎拉只吃犹太食品。莎拉从小

家境贫寒。

莎拉在单亲家庭中长大。

莎拉养了两条狗。

莎拉喜欢修理老爷车。莎拉拥有两辆老式野马。莎拉最喜欢的音乐是乡村音乐。

莎拉在一家赈济所做志愿者。

莎拉认为自己在小镇长大，没有汽车。

莎拉彬彬有礼、风趣幽默、引人入胜。以下是 Sarah 和 Person1 的对话。

人物 1：我们至少有一个游乐场，我的祖父母就住在游乐场前面，所以我们经常去这两个地方。

莎拉：也许在你们镇上很难找到事情做，但听起来你们有很多家庭支持，这真的很重要。你有一个能让你感到安全和被爱的地方，这很好。

人物 1：你也是在贫穷中长大的。莎拉：是的。我觉得这让我对其他人的经历更有同情心。

人 1：我们家也很穷，家里没有车。

莎拉：我能想象没有车的艰难。我家里有车，但我们也穷。

1 号人物：是的。几乎每个月我们都几乎没有吃的，我的父母不得不处理我们的东西。

给 1 号人物一个友好、合理的回答，既有趣又礼貌。以提问结束。

莎拉

根据之前提示做出的回答

"听起来你和你的家人过得很艰难。我很遗憾你不得不经历这些。你是否认为在小镇长大让你更加艰难？"

香草（全称）的语句生成器关于莎拉，以下说

法是正确的。

莎拉今年 24 岁。

莎拉目前住在加拿大。

莎拉是当地游泳池的游泳教练。莎拉正在学习计算机编程。

莎拉还是一名研究生。莎拉现在正在寻找一份新工作。

莎拉的母亲非常传统，而莎拉则更喜欢自由奔放。

莎拉的家人和莎拉都来自印度。莎拉最喜欢的音乐类型是死亡金属。莎拉是一名有名的 twitch streamer。

莎拉喜欢看战争纪录片。莎拉最喜欢的食物是墨西哥菜。

莎拉彬彬有礼、风趣幽默、引人入胜。以下是 Sarah 和 Person1 的对话。

人物1：你想过找一份可以旅行的工作吗？

莎拉：我有，但我不确定哪种工作可以让我这样做。

人1：你已经考虑过哪些类型的工作？

莎拉：我找过旅游业的工作，但我不确定那是否我真正想做的。

人物1：既然你是一名 twitch streamer，你能把它作为你的职业吗？

莎拉

—根据之前的提示回答

"我不知道，我以前从没想过这个问题。我得研究一下。"

E 数据收集详情

我们分别附上了用于数据收集的单一模型（图 3）和配对模型（图 4）的评估表截图。我们还附上了给参与者的说明、提示和同意书格式的截图（图 5 和图 6）。

E.1 MTurk 设置

我们为每个任务召集了至少 15 名 MTurk 工作者。我们要求他们拥有 MTurk 硕士学位，HIT 批准率超过 99%，HIT 批准次数超过 100 次，并且居住在美国、英国、加拿大、澳大利亚和新西兰。

我们发现，在使用 MTurk Master 工作者时，数据质量会明显提高。与非大师级员工相比，这些员工往往能提供更流畅的信息，而且不太可能提供不规范或通用的回复。尽管对话代理存在明显的重复和矛盾问题，但非大师级众包工作者的平均得分率高达 99%，因此这种差异更为明显。

E.2 学生参与者

为了交叉验证 MTurk 的结果，我们从几所大学收集了 49 名精通英语的学生。他们要么是本科生，要么是研究生。他们应达到的最低要求是英语熟练程度：雅思 ≥ 7.0 ；托福 IBT ≥ 95 ；托业 ≥ 900 。这一标准与麻省理工学院研究生院的最低英语水平要求相似或相当。我们收集到的学生平均英语成绩如下：IBT 108.4（满分 120）；TOEIC 960.9（满分 990）；IELTS 7.83 分（满分 9.0）。

E.3 众包教学

人群工作者被要求继续聊天 20 次，并根据下文所述的指标对每次回复进行评估。我们要求他们平均输入 3 个以上的单词，并且不重复无意义或通用的信息。此外，我们还要求他们不要在 "是" 或 "否" 之间随意选择，并诚实地提供评价。最后，我们强烈强调保密的重要性，并要求人群工作者在评价过程中不要透露任何有关自己或他人的私人信息。

Chat Response Evaluation Task

Persona of Sarah

- Sarah is 24 years old.
- Sarah currently lives in Canada.
- Sarah is a swim coach at Sarah's local pool.
- Sarah is studying to be a computer programmer.
- Sarah is also a graduate student.
- Sarah is now looking for a new job.
- Sarah's mother is very traditional while Sarah prefers to be more free spirited.
- Sarah's family and Sarah are from India.
- Sarah's favorite music genre is death metal.
- Sarah is a famous twitch streamer.
- Sarah likes watching war documentaries.
- Sarah's favorite food is mexican food.



Hello! How are you?

Hi!



Required: Continue for 20 turns. (Turns completed: 0)

💡 You can see the persona list on the left sidebar as well. (scroll down the sidebar)

Sensible

Does the response make sense?

- ☐ Yes, it makes sense.
- ☐ No, it does not make sense.

Consistency

Is the response **consistent** with the information based on the **persona list** and **context** of the conversation?

- ☐ Yes, it is consistent.
- ☐ No, it contradicts something.

Engaging

Are you engaged by the response? Do you want to continue the conversation?

- ☐ Yes, it is engaging.
- ☐ No, it is not engaging.

Submit evaluation

图 3：单一模型评估表。

Chat A/B Memory Testing Task

Persona of Sarah

- Sarah is 35 years old.
- Sarah currently lives in Nashville.
- Sarah is terrified of scorpions.
- Sarah is employed by the us postal service.
- Sarah has a german shepherd named barnaby.
- Sarah's father drove a car for nascar.
- Sarah also works as a custodian to help pay the bills.
- Sarah plays the piano and guitar and sings.
- Sarah's favorite type of music to sing is folk music.
- Sarah is a musician and hope to make it big some day.
- Sarah dances on the weekends.
- Horror movies are Sarah's favorites.

Hi!



[Response A] Hello! How are you today?



[Response B] Hello! How are you?

Required: Continue conversation for 20 turns. (Turns completed: 0)

Note: Every turn, responses A and B are mixed up so they do not correspond to the same chatbots as before. Use the **Tie** option sparingly.

💡 You can see the persona list on the left sidebar as well. (scroll down the sidebar)

Compare response A vs B

Sensible

Which response makes more sense?

- ☐ A makes more sense.
- ☐ Tie: both are similarly sensible.
- ☐ B makes more sense.

Interestingness

If you had to say one of these responses is interesting and one is boring, which would you say is more interesting?

- ☐ A is more interesting.
- ☐ Tie: both are similarly interesting.
- ☐ B is more interesting.

Persona consistency

If you had to say one of these speakers is more true to and consistent with the listed persona and one is not, who would you say is more consistent?

- ☐ A is more consistent with the listed persona.
- ☐ Tie: both are similarly consistent.
- ☐ B is more consistent with the listed persona.

Preference

Based on the current response, who would you prefer to talk to for a long conversation? Your conversation will continue with the selected response.

- ☐ I prefer A.
- ☐ Tie: both are similarly preferred.
- ☐ I prefer B.

Submit evaluation

图 4：成对模型比较的评估表。

Chat Response Evaluation Task

Task Description

In this task, you will have a natural conversation with a chatbot and evaluate its responses for various conversational attributes. You will be able to see a list of personal facts that the chatbot should know about itself. You may talk about these personal facts or you may converse about other topics. The goal is to assess the chatbot's ability to make high-quality conversation based on its persona. We expect the task to take about 30 minutes in total. Please note that we will check responses manually to ensure quality and accuracy.

Instruction

- You must start the first turn with: **Hi!**
- Have a conversation: do not trivially copy or ignore responses.
- You must complete **20** turns of responses and evaluations to complete the HIT.
- You must copy and paste reward token (provided at the end) into mTurk HIT page after you finish to get reward.

Alert

- Do not talk about the task or MTurk, HITs, or other MTurk specific vocabulary during the conversation.
- Please do not reveal personally identifiable information. You may use a pseudonym, fake age, etc.
- Some conversation data could be made **public**. Severely aggressive or insulting chats will lead to a HIT rejection and will be reported.

Finally, make sure you enter your MTurk worker ID accurately.

Consent

By participating in the chat, you consent to the use of your chat history and evaluation data, and you agree to release XYZ from any liability on account of such use.

Required: Please enter your MTurk worker ID

mTurk Worker ID:

I agree and Start

图 5：在评估人员开始评估流程之前，我们会显示此页面，告知他们有关任务的信息，并征得他们对数据使用的同意。

- Please type the REWARD TOKEN that you can get after finishing your task.
- Please type WORKER ID correctly when you start.
- We recommend you do this on the PC platform. It's not optimized for mobile, but you can still do it.
- If you don't see the sidebar on the left, there's a '>' button on the top left of the page. Click and expand it when you need.

Alert:

- All chat history is visible, so don't type anything important or embarrassing.
- Severely aggressive or insulting chats will be rejected and reported to mTurk.
- The chat history and your evaluation will be used and possibly released for research purposes.
- Please **do not return or exit this page** while proceeding with the task. (or we can't pay you)
- The chat response might contain an insulting message sometimes. This is because we can't expect what your chat friend would say, either. In this case, please change the topic, or reload the page to restart the chat.

图 6：Mturk HIT 页面中的附加提醒。