

编辑语言模型中的事实知识

Nicola De Cao^{1,2}, Wilker Aziz¹, Ivan Titov^(1,2)

¹阿姆斯特丹大学, ²爱丁堡大学

{ nicola.decao, w.aziz, titov }@uva.nl

摘要

在预训练过程中获得并存储在车道模型 (LM) 参数中的事实知识在下游任务 (如问题解答或文本推理) 中非常有用。然而, 有些事实可能会被错误地诱导出来, 或者随着时间的推移而变得过时。我们介绍的知识编辑器 (KNOWLEDGEEDITOR) 是一种可用于编辑这些知识的方法, 从而修复 "错误" 或意外的预判定, 而无需进行昂贵的再训练或微调。KNOWLEDGEEDITOR 不仅在理论上高效, 而且无需对 LM 预训练进行任何修改 (例如使用元学习)。在我们的方法中, 我们通过有条件的优化训练超网络, 在不影响其他知识的情况下修改一个事实; 然后利用训练好的超网络预测测试时的权重更新。我们用两种流行的体系结构和知识密集型任务展示了 KNOWLEDGEEDITOR 的功效: i) 为事实检查而微调的 BERT 模型, 以及 ii) 为知识密集型任务而微调的 KNOWLEDGEEDITOR 模型。

ii) 用于问题解答的序列到序列 BART 模型。使用我们的方法, 改变对查询的具体措辞的预测往往会导致对其转述的预测也发生一致的变化。我们的研究表明, 在训练过程中利用 (例如自动生成的) 副词可以进一步促进这种变化。有趣的是, 我们的超网络可以被看作是一个 "探针", 它可以重新确定哪些组件需要更改以操作事实知识; 我们的分析表明, 更新往往集中在一小部分组件上。

1 引言

使用预先训练好的基于转换器的语言模型 (LMs; Vaswani 等人, 2017; Devlin 等人 Radford, 2019; 等人 Lewis 等, 2019; 人 Brown 等人, 2020; Raf-fel 等人, 2020; , 2020) 最近取得了一些进展。

¹源代码见 <https://github.com/nicola-decao/KnowledgeEditor>




图 1: **左图:** 参数为 θ 的模型 f 更倾向于预测输入 x 的 y (例如, y 是以 $f(x; \theta)$ 为参数的离散分布的模式/最大值)。 **右图:** 我们的方法使用超网络 g 将 f 的参数更新为 θ' , 从而使 $f(x; \theta')$ 优先选择替代预测 a , 而不影响任何其他输入 $x' \neq x$ 的预测 y' 。我们的模型会编辑 f 参数中存储的有关 x 的知识。

已成为 NLP 的标准做法。在预训练过程中获得的事实知识可以帮助完成下游任务, 但也可能不正确或随着时间的推移而过时 (例如, 不能反映国家元首或国家人口的变化)。开发可靠且计算效率高的方法来修正模型的错误, 而不需要昂贵的重新训练, 将是非常有益的。图 2 举例说明了如何修改最初记错纳米比亚首都的模型记忆。

传统的知识库 (KB) 明确存储事实知识, 而神经模式则不同, 它们在参数中隐含着对事实的记忆。人们无法轻松访问和解释它们的组合和记忆 (Ribeiro 等人, 2016 年; Be-linkov 和 Glass, 2019 年 2019 年; Voita 等人, ; De Cao 等人, 2020 年), 因此, 修改它们的知识是一个具有挑战性的问题。出于实际考虑, 我们为旨在解决这一问题的方法提出了以下要求 (更正式的处理方法见第 2 节):

- **通用性:** 能够修改未经过专门训练的可编辑模型 (无需对 LM 进行特殊的预训练, 如使用元学习);




图 2: 针对闭卷答题进行微调的预训练语言 BART 模型的预测结果。**左图:** 来自 Beam Search 的模型 top-k 预测值。**右图:** 使用我们的方法将 "纳米比亚的首都是什么?" 从 "纳米比亚" (错误) 改为 "温得和克" (正确预测) 后的 top-k 预测。改变一个事实也会改变一个语义等同的问题, 并保持其他事实的预测结果不变。

- **可靠性:** 能够成功地更新特定事实, 而不影响其他已掌握的知识;
- **一致性:** 在对某一事实进行等效表述时, 所做的改动应是一致的 (例如, 当被要求对某一问题的答案进行更新时, 其解析的答案也应随之改变)。

Zhu 等 (2020) 和 Sinitin 等 (2020) 已经解决了这个问题, 第 3 节将详细讨论。然而, 这两种方法都不能确保编辑后的模型 "可靠", 即其他知识不会受到严重影响, 也不能确保在同等输入条件下的变化 "一致"。此外, Sinitin 等人 (2020 年) 的方法需要对原始网络进行昂贵的专门训练。虽然在他们的应用 (如机器翻译) 中, 重新训练原始网络是可行的, 但当网络是预先训练的 LM 时, 就会出现问题。我们提出了一种能克服这些限制的新方法。

我们将编辑神经模型的记忆视为 **学习更新** 问题。我们使用了一种高效的超网络参数化方法, 该方法经过训练, 可在获得需要修改的单一事实时更新 LM 参数。我们不需要元学习、重新训练或微调原始网络。我们在训练中采用了约束优化: 无论原始模型和更新模型在参数空间中的距离有多大, 我们都会约束编辑后的模型保持与原始模型相同的预测结果。我们展示了如何扩展这一框架, 以便在训练中纳入 (例如自动生成的) 转述, 从而进一步提高一致性。图 1 显示了我们的方法概要。

与前两种方法不同的是, 我们不

我们无需选择要更新的参数子集, 因为我们让模型自己学习。事实上, 我们的超网络可以被看作是一个 "探针", 它重新确定了网络的哪些组成部分需要改变, 以操作事实知识, 揭示 "因果调解机制" (Vig 等人, 2020 年)。我们观察到, 尽管我们并不鼓励任何形式的稀疏性, 但更新最终都集中在一组有限的模型组件中。有趣的是, 更新最多的部分与获得较大梯度的参数组不同 (见图 4)。

贡献 我们的贡献如下:

- 我们定义了知识编辑任务, 并提出了一套评估指标;
- 我们提出的 KNOWLEDGEEDITOR 可以高效可靠地学习修改 LM 的记忆, 同时对语义等同的输入保持一致的预测;
- 我们验证了我们提出的方法在很大程度上满足了我们的期望--而其他基于微调的基线方法在知识密集型任务 (如事实检查和开放域问题解答) 中使用不同的 LM 架构进行测试时却失败了;
- 我们分析了 KNOWLEDGEEDITOR 和其他方法的更新情况。

2 任务

我们希望编辑神经语言模型的记忆, 以便在输入时, 其输出能反映出经过修改的事实集合。幸运的是, 语言模型的知识对我们来说通常是不透明的, 它们被非本地地存储在大量的参数和架构组件中。因此, 具体来说, 为了操作

我们需要改变模型的参数，使其只影响模型对特定输入的预测。对于给定的输入 x ，只有当 x 受到其中一个修订事实的影响时，编辑后的模型所做的预测 a 才应与原始模型所做的预测 y 有所不同。

2.1 定义

更具体地说，我们有一个模型 $x \mapsto f(x; \theta)$ ，其训练参数为 θ ，以及一个修订数据集

$(x, y, a) \in \mathcal{D}$ ，即 x 是输入， y 是 $f(x; \theta)$ 所偏好的预测， a 是我们希望编辑后的模型偏好的替代预测。具体来说，我们将模型架构 f 固定不变，并寻找替代参数 θ^r ，这样对于 x ， $f(x; \theta^r)$ 将偏好预测 a 而不是 y ，同时保持所有其他预测不变。在实践中，我们使用一个有限的数据集 $\mathcal{E}(x)$ 来近似 "所有其他预测" 的集合，该数据集由 $(x^r, y^{(r)})$ 组成，其中 $x^r \neq x$ 。此外，预测不一定是连续的，也不一定是模型的可微分输出；相反，它们可能来自基于 $f(x; \theta)$ 的任意决策规则。例如，当 $f(x; \theta)$ 参数化了输出空间上的离散分布 $p_{Y|X}$ 时，最可能的结果是标准决策规则是输出分布的模式

分布： $y = \arg \max_{(c) \in Y} p_{Y|X}(c | x, \theta)$ 。²

语义等同输入 可以选择，对于某些修订 $(x, y, a) \in \mathcal{D}$ ，我们也可以有一组与 x 语义等同的输入 $P(x)$ （例如自动生成的解析）。这样的集合至少有两种用途：i) 明确监督应与 (x, y, a) 同时实现的变化；ii) 评估编辑过的模型是否能对语义等同的输入做出一致的预测。请注意，在这项工作中，我们从未在测试时使用过转述，只是在训练和评估我们的方法时才使用；在测试时生成转述虽然可能有帮助，但会影响效率。

2.2 评估

要测试一个方法 g 是否能生成经过编辑的参数 θ^r 符合我们的要求，我们对其进行衡量：

1. **成功率**: g 对 θ^r 中知识的成功更新程度，用对

²在文本分类求解中，这是直接可行的（因为 Y 很小），而在序列到序列求解中，我们则需要光束搜索来近似模式（ Y 过大或无约束时）。

$\mathcal{D}$ 输入的修正预测的准确性；

2. **保留准确性**: θ^r 保留 f 最初预测的程度，以集合 $\mathcal{E}(x)$ 中输入输出对的准确度衡量；
3. **等价准确性**: 修正模型 θ^r 对等价输入的预判的一致性，以修正预测对所有 $P(x)$ 的准确性来衡量；
4. **性能恶化**: 更新模型的测试性能恶化程度³。

这些值是通过比较不同输入子集（如 $\mathcal{D}$ 、 $\mathcal{E}(x)$ 、 $P(x)$ ）的 $f(-; \theta)$ 和 $f(-; \theta^r)$ 预测值，并与不同焦距（如黄金标准、原始预测或替代预测）进行比较而获得的。虽然这些指标原则上可以直接计算，但有些指标对计算要求很高。例如，重新保持准确性取决于我们所能获得的所有输入的预测结果，而这可能是下游任务的全部验证/测试数据⁴。

以往的研究对这项任务的类似版本进行了不同的评估。Sinitin 等人（2020 年）测量了性能劣化和成功率，但没有测量 **保留准确性** 或 **等效准确性**。较小的性能劣化并不能保证较高的等价准确性，因为前者对原始模型做出错误决策时的变化非常敏感。Zhu 等人（2020 年）也根据旧的或修改过的事实来评估准确性，但这无助于衡量保留准确性。我们认为，在生产环境中，保留模型对不在 $\mathcal{D}$ 中的输入的预测至关重要，因为在生产环境中，模型预测可能已被广泛分析和测试。对于 $x^r \in \mathcal{D}$ ，我们的目标是保留所有原始预测以及模型得分 $f(x^r; \theta^r)$ 本身，从而有效避免重新校准模型的需要（例如，在下游使用概率估计的应用中）。

3 相关工作

修改转换器 编辑模型知识的最直接策略是在新的数据集上重新训练模型，增加、修改或删除事实。这通常是不可行的，因为 LM 需要进行大规模的昂贵训练，而这是最难复制的。

³ $1 - \frac{\text{的精确度 } f(-; \theta^r)}{f(-; \theta) \text{ 的精度}}$

⁴ 不过，在 g 的训练过程中，我们可以使用子采样（即迷你批次）来近似度量。

Sinitstin 等人 (2020 年) 提出了一种元学习方法 (Finn 等人, 2017 年) 用于模型修改, 该方法学习的参数在测试时很容易编辑 (例如, 更新模型知识只需根据这些学习到的参数进行几步 SGD)。为了获得可靠的方法, 他们采用了正则化目标, 迫使更新后的模型不偏离原始模型。这种技术有三大局限性: i) 需要昂贵而专业的预训练; ii) 对许多超参数 (正则化器的权重和要更新的参数子集) 很敏感; iii) 他们的多任务目标不能保证可靠性 (模型会因偏离原始模型而受到惩罚, 而不是受限于不偏离原始模型)。

Zhu 等人 (2020 年) 使用约束优化, 而不是对偏离原始模型的更新模型进行惩罚。他们使用的是一种成本较低的程序, 因为他们根据特定的下游任务 (数据有所改变) 进行了重新微调。他们的方法在原始模型的参数和编辑后的参数之间采用 L_2 或 L_∞ 约束。然而, 基于规范的参数约束忽略了 LM 的高度非线性性质, 也忽略了参数是如何决定模型输出的。事实上, 参数空间的微小变化可能会对许多数据点产生完全不同的输出, 从而导致一种潜在的不可靠方法。此外, 他们还指出需要选择需要更新的参数子集, 这需要额外的开发工作。Zhu 等人 (2020 年) 的方法与 Elastic Weight Consolidation (Kirkpatrick 等人, 2017 年) 相似, 后者是为防止神经网络模型中的灾难性遗忘而开发的一种技术。

语言模型中的知识 Petroni 等人 (2019) 的研究表明, 预先训练好的语言模型可以在不进行微调的情况下重新调用事实知识, 而这是通过向 LMs 输送特定提示来实现的。人们发现, 手工制作的提示语并不是从 LMs 中提取知识的最佳选择, 为了解 LMs "知道" 什么, 人们提出了各种解决方案 (Jiang 等人, 2020 年; Shin 等人, 2020 年; Liu 等人, 2021 年)。此外, 罗伯茨等人 (2020) 的研究表明, 可以对大型模型进行微调, 使其能够访问内部记忆, 在没有任何额外语境的情况下回答自然语言问题, 而且准确率出奇地高--他们将这种情况称为闭卷答题。尽管这些模型的表现相当出色, 但它们不能

与重新获取和使用上下文的替代方法相比, 这些方法的预测质量并不高。激励记忆事实知识的方法对许多下游任务都有好处, 这表明研究有效编辑模型记忆的方法确实很重要 (Zhang 等人, 2019 年; Sun 等人, 2019 年年, 2020)。最近一些同时使用内隐和外显记忆的hy-brid方法显示出对问题解答的一些益处 (Férvy 等人, 2020; Verga 等人, 2020)。值得注意的是, 仅依赖内部隐记忆的语言模型在 (多语言) Entity Linking 方面是最先进的 (De Cao 等人, 2021a,b)。编辑 LM 内隐记忆的有效机制可能适用于所有这些情况。

在解释神经网络的研究中, 已经对识别实现某种行为所需的神经网络最小变化进行了研究 (Lakretz 等人, 2019 年; Vig 等人, 2020 年; Elazar 等人, 2021 年; Csordás 等人, 2021 年)。需要更新的成分可被解释为控制或编码相应的现象 (如主谓一致)。这些研究大多集中于修改神经元激活而非权重, 以及稀疏干预 (如修改一个或少数几个神经元)。虽然与我们的目标相去甚远, 但我们的工作与之有着有趣的联系。例如, 我们在第 6.4 节中对更新的分析虽然非常有限, 但可能会对如何将事实知识编码到模型参数中有所启发。

4 方法

我们建议将编辑神经模型记忆的任务视为一个学习问题。与其定义一种手工算法来计算新参数 θ' , 我们不如学习一个 "知识编辑器" (KNOWLEDGEEDITOR): 一个根据我们想要修改的原子事实来预测 $\theta^{(r)}$ 的模型。具体来说, KNOWLEDGEEDITOR 是一个超级网络 (Ha 等人, 2017 年), 即一个预测另一个网络参数的神经网络。由于这项任务要求所有其他预测都保持不变, 只有我们希望改变的预测除外, 因此我们将学习任务视为一个约束优化问题。

优化 对于输入 x , 将一个模型 $f(-; \theta)$ 的预测值改为 a , 相当于最小化 a 为输入时所产生的损失 $L(\theta; x, a)$ 。

目标。保留知识的其余部分，就是限制更新参数 θ^r ，使模型输出 $f(\cdot; \theta^r)$ 在 $x^r \in \mathcal{X}$ 时不发生变化。我们的编辑器 g 是一个以 φ 为参数的神经网络，我们通过优化每个数据点 $(x, y, a) \in \mathcal{D}$ 的目标来选择 φ ：

$$\begin{aligned} & \min_{\varphi} \sum_{x^r \in \mathcal{X}} L(\theta^r; x^r, a) \\ \text{s.t. } & C(\theta, \theta^r, f; \mathcal{X}) \leq m, \end{aligned} \quad (1)$$

其中， $\mathcal{P}$ 是与 x 语义等价的输入集合（为方便起见，我们假设它至少包含 x ）， $\theta^r = \theta + g(x, y, a; \varphi)$ ， C 是更新的约束条件，边际 $m \in \mathbb{R}_{>0}$ 是一个参数。该约束用于表达我们希望在 $x^r \neq x$ 的情况下保持模型输出不变的愿望。请注意，只有 x ，而不是 $\mathcal{P}$ 的其余部分作为输入提供给编辑器，因为这些在测试时是不可用的。在我们的模型中， $f(x; \theta)$ 参数化了输出样本空间 $\mathcal{Y}$ 上的离散分布 $p_{Y|X}$ ，因此我们选择用从更新模型到原始模型的库尔贝克-莱布勒（KL）发散之和来计算更新： $C_{(KL)}(\theta, \theta^r, f; \mathcal{X}) =$

$$\sum_{x^r \in \mathcal{X}} \sum_{c \in \mathcal{Y}} p_{Y|X}(c | x^r, \theta) \log \left(\frac{p_{Y|X}(c | x^r, \theta^r)}{p_{Y|X}(c | x^r, \theta)} \right) \quad (2)$$

对于所有 $x^r \neq x$ ，该约束将推动更新模型预设与原始模型相同的输出分布。我们可以采用的另一种约束是参数 L_p 准则。

更新，从而优化 g ，使其对原始模型参数的更新最小：

$C_L(\theta, \theta^r, f; \mathcal{X}) = \sum_i | \theta_i - \theta_i^r |^{p(1)/p}$ 。这意味着 Zhu 等人（2020 年）曾使用过。

然而，这种约束纯粹是在参数空间中表达的，与模型结构 f 无关，并不能直接促使模型输出接近函数空间中的原始输出（即两个函数相似）。神经模型是高度非线性的函数，因此我们预计这种约束不会有效。这一点将在第 6 节中得到验证。

可实现的近似方法 非线性约束优化通常难以实现，因此我们采用拉格朗日松弛法（Boyd 等人，2004 年）来代替。由于需要在每个训练步骤中评估数据集中所有数据点的 KL，因此该约束本身就对计算提出了挑战。为了提高可操作性，我们对约束条件进行了评估

近似地通过蒙特卡罗（Monte Carlo, MC）采样（详见附录 A）。最后，在序列到序列模型中，由于样本空间 $\mathcal{Y}$ 是无界的，即使对单个数据点评估 KL 也是难以实现的。在这种情况下，我们在一个子集上近似计算通过波束搜索获得的样本空间。

结构 而不是直接预测 θ^r 、

我们的超网络会预测一个移动 $\Delta\theta$ ，从而使 $\theta^r = \theta + \Delta\theta$ 。简单的超网络实现可能会参数过多，因为它需要的参数数量是目标网络规模的二次方。因此，我们采用了与 Krueger 等人（2017）类似的技巧，使 g 能够轻松预测现代大型深度神经网络（如 BERT）的编辑。也就是说， g 利用梯度信息 $\nabla_{\theta} L(\theta; x, a)$ ，因为它携带了关于 f 如何访问存储在 θ 中的知识的丰富信息（即在给定 a 的情况下，更新哪些参数以提高模型的似然）⁵。

我们首先对 (x, y, a) 进行编码，用特殊的分隔符串联文本，然后将其输入双向 LSTM（Hochreiter 和 Schmidhuber, 1997 年）。然后，我们将最后一个 LSTM 隐藏状态输出一个单一向量 h ，该向量包含

为进一步计算提供条件。要预测 $n \times m \times$

权重矩阵 $W \in \theta$ ，我们使用

五个以 h 为条件的 FFNN，预测 vectors

$\alpha, \beta \in \mathbb{R}^m, \gamma, \delta \in \mathbb{R}^n$ 和一个标量 $\eta \in \mathbb{R}$ 。则

$$\Delta W = \sigma(\eta) \cdot \alpha \odot \nabla L(W; x, a) + \beta^T, \quad (3)$$

与 $\alpha = \sigma(\alpha) \gamma^T$ 和 $\beta = \sigma(\beta) \delta^T$ 、

其中 σ 是 Sigmoid 函数 $\sigma(x) = \frac{1}{1 + \exp(-x)}$ ， σ 表示 Softmax 函数 $\sigma_i = \frac{\exp(x_i)}{\sum_j \exp(x_j)}$ 。

根据这一公式，超网络 φ 的参数与 θ 的大小成线性关系。对等式 3 的一种解释是，更新 ΔW 是目标梯度和偏置项之和。梯度和偏置的比例是通过外向量积产生的，因为这样可以有效地对一个只有三个向量的矩阵进行参数化。该门使模型的某些参数保持不变。

边际退火 边际 m 是一个超参数，因此是固定的。但是，i）它很难选择，因为它与任务有关，ii）它应该

⁵不使用梯度信息的超网络收敛速度太慢。

尽可能小。但是，如果边际太小，我们就有可能得到一个很小的可行集，而且模型可能永远不会收敛。为了解决这两个问题，我们会为边际值选择一个初始值，并在训练过程中根据预测结果对边际值进行退火：当模型成功改变 > 90% 的预测结果时，我们会将边际值乘以 0.8。一旦边际值达到一个理想的小值，我们就停止降低边际值。退火过程可以防止模型发散，同时不断收紧约束条件。

5 实验设置

我们的目标是评估 KNOWL-EDGEEDITOR 在知识密集型任务中与基线相比的有效性。然后，我们将利用第 2.2 节中提出的指标，在闭卷事实核查和闭卷问题解答中测试我们的方法。

5.1 基线

我们将其与两种基准进行比较：i) 微调；ii) Zhu 等人（2020 年）提出的方法。微调相当于使用标准梯度下降法，使我们想要修正的事实/预测的损失最小化。为此，我们效仿 Sinitisin 等人（2020）的方法，采用 RMSProp（Tieleman 和 Hinton，2012）。⁶我们将学习率设置为 $10^{(-)}$ ⁵，并在成功改变模型输出或达到最大 100 梯度步数后停止学习。Zhu 等人（2020）的方法扩展了微调范围，对参数施加了 L_∞ 约束。⁷按照 Sinitisin 等人（2020）和 Zhu 等人（2020）的方法，我们报告了对所有参数或仅对参数子集进行微调的基线。我们将搜索限制为选择整个层，并根据验证集的子集来决定性能。需要注意的是，选择参数子集进行更新需要进行大量搜索，而 KNOWLEDGEEDITOR 通过自动学习，省去了这一过程。

5.2 模型和数据

我们在 KILT（Petroni 等人等 Devlin 人，2021 年）的二进制 FEVER 数据集（Thorne 人，2018 年）上对闭卷事实检查（FC）微调 BERT 基础模型（，2019 年）进行了评估。我们还评估了

⁶我们尝试了各种替代方案，其中 RMSProp 是最有效的。

⁷我们搜索惩罚的超参数 $m \in \{10^{-3}, 5 \times 10^{-4}, 10^{-4}, 5 \times 10^{-5}, 10^{-5}\}$ 根据成功率和保留准确率之和选择最佳值。

在一项具有更复杂输出空间的任務上：闭卷问题解答（QA）。为此，我们在 Levy 等人等人（2017）的零点关系提取（zsRE）数据集上，用标准 seq2seq 目标对 BART 基础模型（Lewis，2020 年）进行了微调。我们之所以在这个数据集上进行评估，是因为它注释了人类生成的问题解析，我们可以用它来衡量模型对语义等同输入的鲁棒性。对于 FC，我们只需翻转标签即可创建替代预测；而对于 QA，我们则会选取通过波束搜索枚举出的所有假设，但前 1 个假设除外。后者确保了模型分布下的高概率结果。我们通过反向翻译生成语义等同的输入。有关模型和数据收集的技术细节，请参见附录 B。

6 研究结果

表 1 报告了事实检查和问题解答的主要结果。总体而言，KNOWL-EDGEEDITOR 在所有指标上都取得了很高的性能。其他一些方法也在某些指标上取得了较高的性能，但总是牺牲了其他指标（从未同时满足我们的所有要求）。我们根据不同的指标（而不是单一指标）对各种方法进行比较，因为我们无法精确地确定每个指标的重要性。为了收集更多信息，我们计算了从 Dirichlet 分布（ $\alpha=1$ 以确保组合的多样性）中采样系数的随机凸组合，并在附录 C 图 6 中报告了一个系统在 1,000 个此类组合中优于另一个系统的概率估计值。对于 FC 和 QA，我们的完整方法优于所有基线的概率非常高（分别为 $\approx 97\%$ 和 $\approx 88\%$ ）。在附录 C 的图 5 中，我们展示了综合得分的分布（即图 6 中报告的近似值的原始数据）。然后，我们分析了我们的方法和基线。

6.1 成功率

每种方法在事实检查方面都能达到几乎完美的成功率。除我们的方法外，其他所有方法都是循环更新，要么在新模型更新成功后停止，要么在达到最大迭代次数后停止。KNOWLEDGEEDITOR 的成功率不是 100%，因为即使在失败的情况下，我们也不会进行一次以上的更新。为此，我们还展示了一个实验

方法	事实检查				问题解答			
	成功率 $\uparrow$	保留准 确性 $\uparrow$	等效准 确率 $\uparrow$	执行解题 $\downarrow$	成功率 $\uparrow$	保留认 证 $\uparrow$	等效 acc $\uparrow$	执行检测 $\downarrow$
微调（第一层）	100.0	99.44	42.24	0.00	98.68	91.43	89.86 / 93.59	0.41
微调（所有层）	100.0	86.95	95.58	2.25	100.0	67.55	97.77 / 98.84	4.50
Zhu 等人（第一层）	100.0	99.44	40.30	0.00	81.44	92.86	72.63 / 78.21	0.32
Zhu 等人（所有层）	100.0	94.07	83.30	0.10	80.65	95.56	76.41 / 79.38	0.35
我们的 C_{L_2}	99.10	45.10	99.01	35.29	99.10	46.66	97.16 / 99.24	9.22
知识编辑器	98.80	98.14	82.69	0.10	94.65	98.73	86.50 / 92.06	0.11
+循环 [†]	100.0	97.78	81.57	0.59	99.23	97.79	89.51 / 96.81	0.50
+ $P^{(x)}$ ($\neq$)	98.50	98.55	95.25	0.24	94.12	98.56	91.20 / 94.53	0.17
+ P^x + loop [‡]	100.0	98.46	94.65	0.47	99.55	97.68	93.46 / 97.10	0.95

表 1：第 2.2 节所述指标在事实核查和问题解答方面的准确度得分。*[†]循环更新，当更新成功或达到最大迭代次数时停止（仅在测试时）。

[‡]使用转述（语义等同的输入）作为额外的监督（仅在训练时）。

我们的方法在一个循环中进行多次更新，并采用与基线相同的停止标准。请注意，我们只在测试时采用这种方法（*即*不进行多次更新训练）。当采用多重更新时，我们的方法在事实检查方面的成功率也达到了 100%，在质量保证方面几乎达到了完美的准确率 ($> 99\%$)^(*)。

闭卷质量检测是一项更具挑战性的任务，因为输出空间是文本，而不仅仅是一个双元标签。在这种情况下，KNOWLEDGEEDITOR 的准确率很高 ($\approx 95\%$ 或 $> 99\%$)。在所有方法中，KNOWLEDGEEDITOR 的成功率最高，同时保留准确率也最高。在质量保证方面，Zhu 等人（2020 年）的方法没有达到很好的成功率 ($\approx 80\%$)。我们搜索了超参数，希望他们的方法也能获得较高的保留准确率，而且确实比常规微调方法要高。然而，与事实检查不同的是，用于质量保证的常规微调可以获得最多的满分，但却牺牲了保留准确率。序列到序列模型对轻微的参数变化更为敏感。这是因为微小的变化可能会完全改变从波束搜索（QA 的情况）中得到的 top-k 预测结果。与此不同的是，在二元分类器（FC 的情况）中，预测的概率可以在不跨越决策边界（未校准时通常设置为 0.5）的情况下发生重大变化。

6.2 保留以前的知识

KNOWLEDGEEDITOR 几乎完美地保留了验证集中的预测结果（保留准确率）。

^{*}即使我们不对多次后续更新进行训练，它的成功也为在训练时添加后续更新提供了可能。我们将在今后的工作中探索这一技术。

$\approx 98\%$)。相反，我们使用 C_{L_2} 的方法的保留准确率非常低（始终为 $< 50\%$ ）。 $C_{(L_1)_2}$ 存在营养遗忘的问题，因为它并不强制要求更新后的模型在函数空间上接近原始模型（*即*两个函数相似），而只是在参数空间上。

对所有层进行微调是成功的，但会对之前获得的知识产生负面影响：FC 和 QA 的精度分别为 $\approx 87\%$ 和 $\approx 68\%$ ，而 $\approx$ 和 $\approx$ 的性能分别下降 2% 和 4%。对单层进行微调更有效，因为这样可以防止过度拟合（在 FC 和 QA 中，最佳模型都会更新第一层）。然而，在 FC 中，更新后的模型并不能生成语义等效的输入：转述的准确率甚至远低于我们在训练中不使用转述的方法（42% vs. $> 81\%$ ），而与使用转述的方法相比 ($> 94\%$)，准确率则更低。

使用 Zhu 等人（2020 年）的方法进行微调对 FC 的性能影响不大，这并不奇怪，因为标准微调已经获得了几乎满分。不同的是，在 QA 设置中，使用他们的约束优化提高了保留准确率（比普通微调提高了 4%），但代价是成功率较低 ($\approx 80\%$ ，而微调可获得满分)。

6.3 转述的准确性

我们在评估我们的方法时，同时考虑了和不考虑额外的转述监督以提高泛化效果--这分别对应于等式 1 中的 P^x 作为 x 的转述集或 $P^x = \{x\}$ 。没有这种额外的监督、




图 3：原始模型和更新模型在 FEVER 上的对数分布。对所有层进行微调 (a) 会导致许多错误，即使预测结果没有跨越决策边界，预测概率也不会保持不变。 $C_{(L)}^{(2)}$ (b) 成功地翻转了标签，但并没有迫使预测结果保持不变。对于我们的完整方法，即带 P^x 的 $C_{(KL)}^{(c)}$ ，误差主要集中在模型不确定的原点附近，小的扰动会使对数越过决策边界。用颜色更直观。

KNOWLEDGEEDITOR 在等价准确性方面已经很有竞争力。不过，采用这种额外的监督显然对这两项任务都有好处：我们获得了相同的成功率和再训练准确率，但等价准确率分别提高了

>在 FC 中提高了 70%，在 QA 中提高了 >30%（针对生成的转述）。在 FC 中，虽然对单层进行微调在成功率和保留准确率方面被证明是最佳的，但它在转述方面的表现却很差。也就是说，该模型成功地更新了对特定数据点的预测，但没有更新对词组的预测。这表明，通过微调来编辑模型的知识并不能很好地推广，而且会过度适应特定的输入。在 QA 方面，Zhu 等人（2020 年）的表现也比我们或其他方法差。

当其他方法在转述方面的表现与我们的方法相当或更好时，它们并不能很好地保持准确性（例如，见表 1 中的 QA 微调）。对 QA 进行微调似乎比对 FC 进行微调的通用性更好，但不能保留以前的知识。在表 1 中，我们还报告了生成的和人工生成的转述集的准确率。令人惊讶的是，人工生成的转述短语得分更高。我们推测，出现这种情况是因为自动转述有时在语义上并不等同或不流畅。

6.4 模型更新分析

在图 3 中，我们绘制了不同方法下原始模型和更新模型在 FC 上的对数分布。

方法。在理想的方法中，更新前后的所有对数都必须保持不变（我们想要改变的对数除外）。从图中，我们可以看到不同类型误差的分布，如预测被错误翻转（从真到假或相反）的数据点。这些误差主要集中在原点附近，小的扰动会使对数越过决策边界。在对所有层进行微调时，我们可以看到对数受到了明显的影响，它们发生了很大的变化（即点不再集中在对角线附近）。事实上，微调使得许多数据点越过了决策边界，其概率也从原来的概率发生了变化。图 3b 显示了 $C_{(L)}^{(2)}$ 的失败，因为这种方法几乎没有保留之前的预测结果。相反，KNOWLEDGEEDITOR 几乎保留了所有预测标签及其概率（图 3c 中的大部分数据点都保持在对角线上）。

我们还在图 4 中报告了 QA 实验的平均权重更新可视化情况。我们报告的是由转述提供额外监督的设置（但没有转述时的热图也类似）。从图中可以观察到三个主要现象。首先，梯度主要集中在第一个编码器层和最后一个解码器层。梯度解释了为什么第一层是需要更新的最佳参数子集。其次，微调不会保留梯度大小，而是几乎均匀地更新整个模型。这是因为优化器的自适应




图 4: QA 实验中各层权重矩阵更新的平均归一化幅度。微调会均匀更新所有层，而我们的更新更为稀疏。

学习速度最初会抹去梯度方向。梯度方向只有在几个梯度步骤后才起作用，但在大多数情况下，该方法只需要一个步骤就能修改其知识。最后，我们的更新比较稀疏，而且与改变预测的梯度不一致。这表明我们的方法学会了有意义地使用梯度（即忽略某些方向或操纵其大小）。令人惊讶的是，知识操纵似乎主要是通过修改影响注意力分布形状的参数来实现的。

W^K (自和 Q), 而不是值等。 (W^V) 。正如我们所讨论的，超网络可能会将其视为一个探针，提供有关模型用于编码知识边缘的机制的见解（Vig 等人，2020 年）。例如，对底层的关注已经很耐人寻味，因为它与图像分类模型顶层发生记忆的说法（Stephenson 等人，2021 年）相矛盾，暗示了 NLP 和视觉中底层记忆机制的本质区别。不过，适当的调查不在本研究范围之内。更多分析见附录 C。

7 结论

在这项工作中，我们探讨了编辑隐含在语言模型参数中的实际知识的任务。对于这项任务，我们正式定义了需求、目标和一套衡量标准，以衡量不同方法的功效。我们在基于闭卷事实检查和问题解答的两个基准上对其进行了具体评估。我们提出了 KNOWLEDGEEDITOR 方法（KNOWLEDGEEDITOR

该模型基于一个超网络，能够高效可靠地学习修改存储在 LM 参数中的隐含知识。我们针对不同的微调变量对我们的模型进行了全面评估，证明了我们方法的优势。我们的方法所预设的更新幅度可能会揭示 LM 用来编码事实知识的机制；我们将此类研究留待今后的工作中进行。

伦理考虑

基于预训练 LM 的技术继承了部分或全部的潜在危害（本德尔等人年），2006、2021)。我们编辑 LM 知识的技术不会加剧 LM 的潜在危害，事实上还可以用来减轻危害，因为一旦发现问题，就可以对其进行修正。不过，我们注意到，恶意使用我们的知识边缘编辑器是可能的。例如，恶意代理可能会使用本工作中介绍的技术向 LMs 中注入不正确的知识。

致谢

作者感谢 Michael Schlichtkrull、Lena Voita 和 Luisa Quarta 的讨论和支持。本项目得到了 SAP 创新中心网络、欧洲研究理事会启动基金 BroadSem (678254)、荷兰科学研究组织 (NWO) VIDI 639.022.518 和欧盟地平线 2020 研究与创新计划第 825299 号赠款协议 (Gourmet) 的支持。

参考文献

- Yonatan Belinkov 和 James Glass.2019.神经语言处理中的分析方法: A survey.《计算语言学协会论文集》, 7:49-72.
- Emily M. Bender, Timnit Gebru, Angelina McMillan- Major, and Shmargaret Shmitchell.2021.论随机鹦鹉的危险: 语言模型会太大吗? In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, FAccT '21, page 610-623, New York, NY, USA.美国计算机协会。
- Stephen Boyd, Stephen P Boyd, and Lieven Vandenberghe.2004.《凸优化》。剑桥大学出版社。
- Tom B. Brown、Benjamin Mann、Nick Ryder、Melanie Subbiah、Jared Kaplan、Prafulla Dhariwal、Arvind Neelakantan、Pranav Shyam、Girish Sastry、Amanda Askell、Sandhini Agarwal、Ariel Herbert-Voss、Gretchen Krueger、Tom Henighan、Rewon Child、Aditya Ramesh、Daniel M.Ziegler、Jeffrey Wu、Clemens Winter、Christopher Hesse、Mark Chen、Eric Sigler、Mateusz Litwin、Scott Gray、Benjamin Chess、Jack Clark、Christopher Berner、Sam McCandlish、Alec Radford、Ilya Sutskever, and Dario Amodei.2020.语言模型是少量学习者。《神经信息处理系统进展 33: 2020 年神经信息处理系统年会, NeurIPS 2020, 2020 年 9 月 6-12 日, 虚拟》。
- Róbert Csordás, Sjoerd van Steenkiste, and Jürgen Schmidhuber.2021.通过检验功能可加权掩码模块化》。提交给国际学习表征会议。
- Nicola De Cao、Gautier Izacard、Sebastian Riedel 和 Fabio Petroni. 2021a.自回归实体再三元。在《学习表征国际会议上》。
- Nicola De Cao、Michael Sejr Schlichtkrull、Wilker Aziz 和 Ivan Titov. 2020.神经模型中的跨层出现? 决策是如何的 In *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3243-3255, Online.计算语言学协会。
- Nicola De Cao, Ledell Wu, Kashyap Popat, Mikel Artetxe, Naman Goyal, Mikhail Plekhanov, Luke Zettlemoyer, Nicola Cancedda, Sebastian Riedel, and Fabio Petroni.2021b.多语言自回归实体链接。arXiv 预印本 arXiv:2103.12528.
- Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova. 2019.BERT: 的预训练语言理解深度双向变换器。2019 年美国语言学会北美分会会议论文集
- 计算语言学协会北美分会 2019 年会议论文集: 人类语言技术》第 1 卷 (长篇论文和短篇论文), 第 4171-4186 页, 明尼苏达州明尼阿波利斯市。计算语言学协会。
- Yanai Elazar, Shauli Ravfogel, Alon Jacovi, and Yoav Goldberg.2021.失忆探测: 失忆反事实行为分析。Transactions of the Association for Computational Linguistics, 9:160-175.
- Thibault Févry, Livio Baldini Soares, Nicholas FitzGerald, Eunsol Choi, and Tom Kwiatkowski.2020.实体专家: 具有实体功能的稀疏内存访问即监督。In *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4937-4951, Online.计算语言学协会。
- Chelsea Finn、Pieter Abbeel 和 Sergey Levine. 2017.用于快速适应的模型识别元学习深度网络。In *Proceedings of the 34th International Conference on Machine Learning, ICML 2017, Sydney, NSW, Australia, 6-11 August 2017*, volume 70 of *Proceedings of Machine Learning Research*, pages 1126-1135.PMLR.
- David Ha, Andrew M. Dai, and Quoc V. Le.2017.超网络。In *5th International Conference on Learning Representations, ICLR 2017, Toulon, France, April 24-26, 2017, Conference Track Proceedings*.OpenReview.net.
- Sepp Hochreiter and Jürgen Schmidhuber.1997.Long short-term memory.《神经计算》, 9 (8): 1735-1780。
- Zhengbao Jiang, Frank F. Xu, Jun Araki, and Graham Neubig.2020.我们如何才能知道语言什么模型知道? 《计算语言学协会论文集》, 8:423-438.
- Mandar Joshi, Eunsol Choi, Daniel Weld, and Luke Zettlemoyer.2017.TriviaQA: 大规模用于阅读有监督挑战数据集理解的。In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1601-1611, Vancouver, Canada.计算语言学协会。
- Marcin Junczys-Dowmunt、Roman Grundkiewicz、Tomasz Dwojak、Hieu Hoang、Kenneth Heafield、Tom Neckermann、Frank Seide、Ulrich Germann、Alham Fikri Aji、Nikolay Bogoychev、André F. T. Martins 和 Alexandra Birch. 2018.玛丽安: 快速C++ 中的神经机器翻译。澳大利亚墨尔本, ACL 2018 系统演示论文集, 第 116-121 页。计算语言学协会。
- Diederik P. Kingma and Jimmy Ba.2015.亚当: 随机优化方法。第三届国家间学习表征会议。

- ICLR 2015, 美国加利福尼亚州圣地亚哥, 2015 年 5 月 7-9 日, 会议论文集。
- J.Kirkpatrick, Razvan Pascanu, Neil C. Rabinowitz, J.Veness, G. Desjardins, Andrei A. Rusu, K. Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, Demis Hassabis, C. Clopath, D. Ku-mar, and Raia Hadsell. 2017. 克服神经网络中的营养遗忘。《美国国家科学院院刊》, 114: 3521 - 3526。
- David Krueger, Chin-Wei Huang, Riashat Islam, Ryan Turner, Alexandre Lacoste, and Aaron Courville. 2017. *ArXiv preprint arXiv:1710.04759*.
- Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Jacob Devlin, Kenton Lee, Kristina Toutanova, Llion Jones, Matthew Kelcey, Ming-Wei Chang, Andrew M. Dai, Jakob Uszkoreit, Quoc Le and Slav Petrov. 2019. 自然语言处理: 问题基准分词研究的。《计算语言学协会论文集》, 7:453-466。
- Yair Laktretz, German Kruszewski, Theo Desbordes, Dieuwke Hupkes, Stanislas Dehaene and Marco Baroni. 2019. LSTM 语言模型中分类单元的数字和同步出现。In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 36-41, Online. 计算语言学协会。
- Nayeon Lee, Belinda Z. Li, Sinong Wang, Wen-tau Yih, Hao Ma, and Madihan Khabza. 2020. 作为事实核查者的模型? 语言 In *Proceedings of the Third Workshop on Fact Extraction and VERification (FEVER)*, pages 36-41, Online. 计算语言学协会。
- Omer Levy, Minjoon Seo, Eunsol Choi, and Luke Zettlemoyer. 2017. 通过提取零点关系阅读理解。第 21 届计算自然语言学习大会 (CoNLL 2017) 论文集, 第 333-342 页, 加拿大温哥华。计算语言学协会。
- 迈克-刘易斯 (Mike Lewis)、刘银汉 (Yinhan Liu)、纳曼-戈亚尔 (Naman Goyal)、马尔-詹-加兹维尼内贾德 (Marjan Ghazvininejad)、阿卜杜勒拉赫曼-穆罕默德 (Abdelrahman Mohamed)、奥马尔-利维 (Omer Levy)、韦塞林-斯托扬诺夫 (Veselin Stoyanov) 和卢克-泽特勒莫耶 (Luke Zettlemoyer)。2020. BART: 去噪序列到序列预用于自然语言生成、翻译训练和理解的。In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7871-7880, Online. 计算语言学协会。
- Xiao Liu, Yanan Zheng, Zhengxiao Du, Ming Ding, Yujie Qian, Zhilin Yang, and Jie Tang. 2021. GPT也能理解。 *arXiv preprint arXiv:2103.10385*.
- Fabio Petroni, Aleksandra Piktus, Angela Fan, Patrick Lewis, Majid Yazdani, Nicola De Cao, James Thorne, Yacine Jernite, Vladimir Karpukhin, Jean Maillard, Vassilis Plachouras, Tim Rocktäschel, and Sebastian Riedel. 2021. KILT: 的基准知识密集型语言任务。In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2523-2544, Online. 计算语言学协会。
- Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, and Alexander Miller. 2019. 语言模型作为知识库? 自然语言处理实证方法会议暨第九届自然语言处理国际联合会会议 (EMNLP-IJCNLP) 论文集, 第2463-2473页, 中国香港。计算语言学协会。
- Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei and Ilya Sutskever. 2019. 语言模型是无监督的多任务学习者。 *OpenAI 博客*, 1 (8) : 9。
- Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li and Peter J. Liu. 2020. 用统一的文本到迁移学习的极限文本转换器探索。 *机器学习再搜索期刊*, 21 (140) : 1-67。
- Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev and Percy Liang. 2016. SQuAD: 用于100,000+ 个问题文本机器理解的。 *自然语言处理实证方法 2016 年会议论文集*, 第 2383-2392 页, 德克萨斯州奥斯汀。计算语言学协会。
- Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. 机器学习的模型可解释性 (Model-agnostic interpretability of machine learning)。 *国际机器学习大会 (ICML) 机器学习中的可解释性研讨会*。
- 亚当-罗伯茨、科林-拉斐尔和诺姆-沙泽尔。2020. 语言模型的? 参数能包含多少知识 自然语言处理实证方法 (EMNLP) 2020 年会议论文集, 第 5418-5426 页, 在线。计算语言学协会。
- Rico Sennrich, Barry Haddow, and Alexandra Birch. 2016. 用单语数据改进神经机器翻译模式。In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 86-96, Berlin, Germany. 计算语言学协会。

- Taylor Shin、Yasaman Razeghi、Robert L. Logan IV、Eric Wallace 和 Sameer Singh. 2020. [自动提示：通过从语言模型中获取知识自动生成的提示](#). In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4222-4235, Online. 计算语言学协会。
- Anton Sinitsin, Vsevolod Plohotnyuk, Dmitriy Pyrkin, Sergei Popov, and Artem Babenko. 2020. [可编辑神经网络](#). 第8届学习表征国际会议, ICLR 2020, 埃塞俄比亚的斯亚贝巴, 2020年4月26-30日. OpenReview.net.
- Nitish Srivastava、Geoffrey Hinton、Alex Krizhevsky、Ilya Sutskever 和 Ruslan Salakhutdinov. 2014. [辍学：防止神经网络简单方法过度拟合的](#). *机器学习再搜索期刊*, 15 (56) : 1929-1958。
- Cory Stephenson, Suchismita Padhy, Abhinav Ganesh, Yue Hui, Hanlin Tang, and SueYeon Chung. 2021. 论深度神经网络中泛化和记忆的几何学. *国家间学习表征会议 (ICLR) 论文集*。
- 孙宇、王硕恒、李玉坤、冯世坤、陈旭怡、张晗、田昕、朱丹香、田浩和吴华。2019. *ArXiv preprint arXiv:1904.09223*.
- Yu Sun, Shuohuan Wang, Yukun Li, Shikun Feng, Hao Tian, Hua Wu, and Haifeng Wang. 2020. [Ernie 2.0：语言持续预训练框架理解的](#). *美国人工智能学会会议论文集*, 34 (05) : 8968-8975。
- Ilya Sutskever, James Martens, and Geoffrey E. Hinton. 2011. [用递归生成文本神经网络](#). 第28届国家间机器学习大会论文集, ICML 2011, 美国华盛顿州贝尔维尤, 2011年6月28日至7月2日, 第1017-1024页, 2011年, 第1017-1024页. Omnipress.
- Ilya Sutskever, Oriol Vinyals, and Quoc V. Le. 2014. [神经网络的序列到序列学习](#). In *Advances in Neural Information Processing Systems 27: Annual Conference on Neural Information Processing Systems 2014, December 8-13 2014, Montreal, Quebec, Canada*, pages 3104-3112.
- Christian Szegedy、Vincent Vanhoucke、Sergey Ioffe、Jonathon Shlens 和 Zbigniew Wojna. 2016. [重新思考计算机视觉的初始架构识别](#). In *2016 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2016, Las Vegas, NV, USA, June 27-30, 2016*, pages 2818-2826. IEEE 计算机协会。
- James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. 2018. [FEVER: a large-scale dataset for fact extraction and verification](#). In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: 人类语言技术》第1卷 (长篇论文)*, 第 809-819 页, 路易斯安那州新奥尔良. 计算语言学协会。
- Tijmen Tieleman and Geoffrey Hinton. 2012. 讲座 6.5-RmsProp：将梯度除以其最近幅度的运行平均值. *COURSERA：机器学习的神经网络*, 4 (2) : 26-31。
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. [注意力就是一切你所需要的](#). *神经信息处理系统进展 30：2017 年神经信息处理系统年会*, 2017 年 12 月 4-9, 2017, Long Beach, CA, USA, pages 5998-6008.
- Pat Verga、Haitian Sun、Livio Baldini Soares 和 William W Cohen. 2020. [事实即专家：适应性对符号和可解释性神经记忆知识的](#). *arXiv 预印本 arXiv:2007.00849*.
- Jesse Vig, Sebastian Gehrmann, Yonatan Belinkov, Sharon Qian, Daniel Nevo, Yaron Singer, and Stuart Shieber. 2020. 解释神经 NLP 的因果中介分析：性别偏见案例. *NeurIPS*.
- Elena Voita、Rico Sennrich 和 Ivan Titov. 2019. [跨语言表征自下而上进化的：机器翻译和研究语言建模目标](#). In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 4396-4406, Hong Kong, China. 计算语言学协会。
- John Wieting and Kevin Gimpel. 2018. [ParaNMT-50M：挑战仿拟句子极限用数百万机器翻译的](#). In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 451-462, Melbourne, Australia. 计算语言学协会。
- Thomas Wolf、Lysandre Debut、Victor Sanh、Julien Chaumond、Clement Delangue、Anthony Moi、Pierric Cistac、Tim Rault、Remi Louf、Morgan Funtowicz、Joe Davison、Sam Shleifer、Patrick von Platen、Clara Ma、Yacine Jernite、Julien Plu、Canwen Xu、Teven Le Scao、Sylvain Gugger、Mariama Drame、Quentin Lhoest 和 Alexander Rush. 2020. [Trans-formers：最先进的自然语言处理技术](#). *自然语言处理实证方法 2020 年会议论文集：系统演示*, 第 38-45 页, 在线. 计算语言学协会。
- Zhengyan Zhang, Xu Han, Zhiyuan Liu, Xin Jiang, Maosong Sun, and Qun Liu. 2019. [ERNIE: Enhanced language representation with informative en-](#)

[titles](#). In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 1441-1451, Florence, Italy. 计算语言学协会。

Chen Zhu, Ankit Singh Rawat, Manzil Zaheer, Sri-nadh Bhojanapalli, Daliang Li, Felix Yu, and Sanjiv Kumar. 2020. [修改变压器中的记忆模型](#)。 *arXiv 预印本* *arXiv:2012.00363*.

A 约束优化的放松与逼近

给定一个最小化目标，其形式为

$$\begin{aligned} \min_{\theta} \quad & \mathbb{E}_{x \sim p(x)} [f(x, \theta)] \\ \text{s.t.} \quad & \frac{1}{|Y|} \sum_{y \in Y} C(y, \theta) \leq m, \end{aligned} \quad (4)$$

可以用乘法器 $\alpha \in \mathbb{R}_{\geq 0}$ 进行拉格朗日松弛求解 (Boyd 等人, 2004 年), 并通过采样 $y \sim p(y)$ 近似到

$$\min_{\theta} \max_{\alpha} f(x, \theta) + \alpha \cdot (C(y, \theta) - m). \quad (5)$$

等式 5 可通过自动差分进行评估, 并通过梯度下降进行优化。

B 实验设置

B.1 事实检查

我们使用 KILT (Petroni 等人, 2021 年) 的二元 FEVER 数据集 (Thorne, 2018 年) 对闭卷事实检查 (FC) 进行了评估。FEVER 分别有 104,966 个训练实例和 10,444 个验证实例。对于每一个输入索赔 x , 模型都会预测其可能为真的概率 $f(x; \theta)$ 。这与 Lee 等人 (2020 年) 利用掩码 LMs 研究闭卷和零镜头 FC 相似。具体来说, 我们要求 LM 执行二元分类。我们对 BERT 基础模型 (Devlin 等人, 2019 年) 进行了微调, 并在其顶部增加了一个线性层, 该层将对 BOS (句子开头) 标记做出响应的隐藏状态映射为阳性标签的概率。考虑到可用的监督, 我们对架构进行了训练, 以通过正则化和权重衰减使模型可能性最大化。最终模型的准确率为 77.1%⁹。

B.2 问题解答

我们还对一个样本空间更为复杂的任务进行了评估: 闭卷答题。(QA)。这里 QA 被视为序列到从问题到答案的顺序问题, 既不检索也不提供任何证据 (Roberts et al.) 这与在 FC 中的情况一样, 都强调了 "唤醒" 的作用。

⁹这与 Petroni 等人 (2021 年) 报告的更大型 BART 模型的结果相当。

在预训练中获得的知识, 并将其编码到模型参数中。在这项任务中, 我们使用了 Levy 等人 (2017 年) 的 "零镜头关系提取 (zsRE) " 数据集 ()。

将 zsRE 与其他流行的质量保证数据集 (如 SQuAD (Rajpurkar 等人, 2016 年)、Natural Ques-

zsRE 是专门为训练和测试之间不存在关系重叠而构建的 (即它是 "0-shot")。我们重新拆分了数据集使其在训练和测试中具有相同的分布

拆分--我们对零点特异性不感兴趣。

因此, 我们避免了其带来的额外复杂性。原始的 zsRE 数据集分别有 147909 个训练实例和 3724 个验证实例。在重新拆分并使用所有转述后, 我们分别有 244,173 个训练实例和 27,644 个验证实例。对于这项任务, 我们使用标准 seq2seq 目标对 BART 基础模型 (Lewis 等人, 2020 年) 进行了微调, 即在观察到输出序列的情况下最大化模型似然 (Sutskever 等人, 2011 年、2014 年), 并使用 dropout (Srivastava 等人, 2014 年) 和标签平滑 (Szegedy 等人, 2016 年) 进行了调整。最终模型的准确率 (模型预测与黄金标准完全匹配) 为 22.1%¹⁰。

B.3 生成替代预测

替代预测的生成与任务有关, 因为它要求为给定输入生成一个可信的替代目标, 例如, 如果我们需要编辑关于一国元首的知识, 那么可信的替代标签应该是一个人, 而不是一个字符串 (即使格式很好)。事实检查很简单: 我们只需翻转标签, 因为它是二元分类。对于质量保证, 我们利用模型分布下的高概率结果作为可信修订的代表。特别是, 我们会选取通过波束搜索枚举出的所有假设, 但前 1¹¹ 假设除外。

¹⁰这比 Petroni 等人 (2021 年) 报告的对 zsRE 的原始拆分要多。这是因为最初的拆分旨在进行零次评估, 而我们在训练集和验证集之间有关系类型的重叠。

¹¹这并不总能保证备选预设与原始预设具有相同的语义类型, 但很有可能, 因为模型赋予了它们很高的概率。

B.4 语义等同的输入

我们希望更新后的模型能够与语义等同的输入（见第 2 章和第 4 章中的 P^x ）保持一致，而不仅仅是学习一个新的特定和孤立的数据点。这种一致性说明编辑机制是有效的，可以利用模型中存储的知识。然而，并非所有数据集都附带有输入的解析（例如，在我们的案例中，FEVER 没有附带解析，而 zsRE 只附带了 30% 数据集的解析）。为此，我们使用往返翻译（Sennrich 等人，2016 年；Wieting 和 Gimpel，2018 年）生成语义等同的输入。我们采用由 Hug- gingface Transformers（Wolf 等人，2020 年）提供的 Marian Neural Machine Translation（MarianNMT；Junczys-Dowmunt 等，2018 年）中的英译德和德译英 Transformer 模型。我们使用波束搜索（波束大小为 5）获得 25 个词组。从这一集合中，我们排除了任何由 $f(\hat{x}; \theta)$ 支持的预测 $\hat{y}$ 与 $f(x; \theta)$ 支持的预测 y 不匹配的 $\hat{x}$ 的候选转述 $\hat{x}$ 。这种过滤方法可以确保，根据当前模型，所有转述都具有完全相同的预测。

B.5 架构细节

我们要修改的原始模型是 BERT 基础模型（Devlin 等人，2019 年）和 BART 基础模型（Lewis 等人，2020 年），分别用于事实检查和问题解答。它们都是基于 Transformer 的模型，各有 12 层，隐藏大小为 768。BERT 有 12 个头，而 BART 有 16 个头。它们的参数分别为 1.1 亿和 1.39 亿。BERT 的词汇量为 30522 个，而 BART 为 50265 个。

KNOWLEDGEEDITOR 有一个小型单层双向 LSTM，输入大小为 768，隐藏大小为 128。压缩 LSTM 状态的 FFNN 采用 [256, tanh, 1024] 架构，而 5 个 FFNN 均采用 [1024, tanh, d] 架构，其中 d 取决于要修改的权重。在我们的实验中，我们没有使用我们的模型来修改 LM 的偏置、层规范、单词和位置嵌入。总体而言，KNOWLEDGEEDITOR 的 BERT 和 BART 参数分别为 5400 万和 6700 万。

B.6 训练细节

我们要修改的原始模型的训练批量为 256 个，使用了

Adam（Kingma 和 Ba，2015 年）（学习率为 $3e-5$ ）、权重衰减（ $1e-2$ ）和带热身的线性调度（总更新次数为 50k，热身更新次数为 500）。我们最多训练了 20 个历元，并使用验证集上的准确率进行模型选择¹²。

KNOWLEDGEEDITOR 模型在 FC 和 QA 中的训练批量分别为 1024 和 256，训练时使用了 Adam（参数学习率为 $3e-4$ ，拉格朗日乘数为 $1e-1$ ）、权重去除（ $1e-2$ ）和带热身的线性时间表（总更新次数为 200k，热身日期为 1k）。¹³对于事实检查模型， C_{KL} 的余量在 $1e-1$ 和 $1e-3$ 之间退火；对于 BART 问题解答模型， C_{KL} 的余量在 $1e-3$ 和 $1e-5$ 之间退火。对于序列到序列损失，我们采用了标签平滑度为 0.1 的交叉熵损失。

C 其他结果

更新分析 在初步实验中，我们研究了不利用梯度信息的超网络版本（见等式 3）。在没有梯度信息的情况下，模型的收敛速度≈ 要慢 10 倍才能达到相同的准确率，而且在质量保证方面没有收敛（ θ 模型无法获得 > 75% 的成功率和 > 50% 的保留准确率）。这表明梯度对我们的超网络是有帮助的，也是可以实际使用的，但在没有修改的情况下不应该直接使用。为了更好地说明这一点，我们在表 2 中用更新之间的余弦相似度来报告不同更新方法与梯度之间的相关性。当然，微调与梯度的相关性很高，但我们的方法（无论是否有额外的意译监督）与其他方法的相关性很低。余弦相似度低可能有两个原因，一是模型确实将梯度投射到了不同的、更“知识保护”的方向上，二是参数空间太大，余弦相似度很快就归零，无法揭示真正的低相似度。

¹²我们使用 4 台 Nvidia Titan X 12GB 进行训练，FC 大约需要 10 分钟，QA 需要 3 小时。

¹³我们使用 4 台 Nvidia Titan X 12GB 进行训练，FC 大约需要 1 天，QA 需要 3 天。

	$\nabla_{\theta} \mathcal{L}$	微调	C_{KL}	$C_{KL} + P^x$
$\nabla_{\theta} \mathcal{L}$	1.000	0.451	-0.018	-0.025
微调	0.451	1.000	-0.010	-0.011
C_{KL}	-0.017	-0.010	1.000	0.183
$C_{KL} + P^x$	-0.021	-0.011	0.183	1.000

表 2：不同更新方法之间的平均余弦相似度以及更新梯度。
微调适用于所有层。




图 5：根据从 Dirichlet 分布 ($\alpha=1$ -见表 1 中的所有值) 中抽取的 1k 个随机分配的指标加权和的概率分布。抽样权重允许以概率方式解释得分。KNOWLEDGEEDITOR (有不同变体) 的分布更偏向于高分 (100)，这表明在给指标分配权重时，加权总和很有可能有利于我们的方法。用颜色更直观。

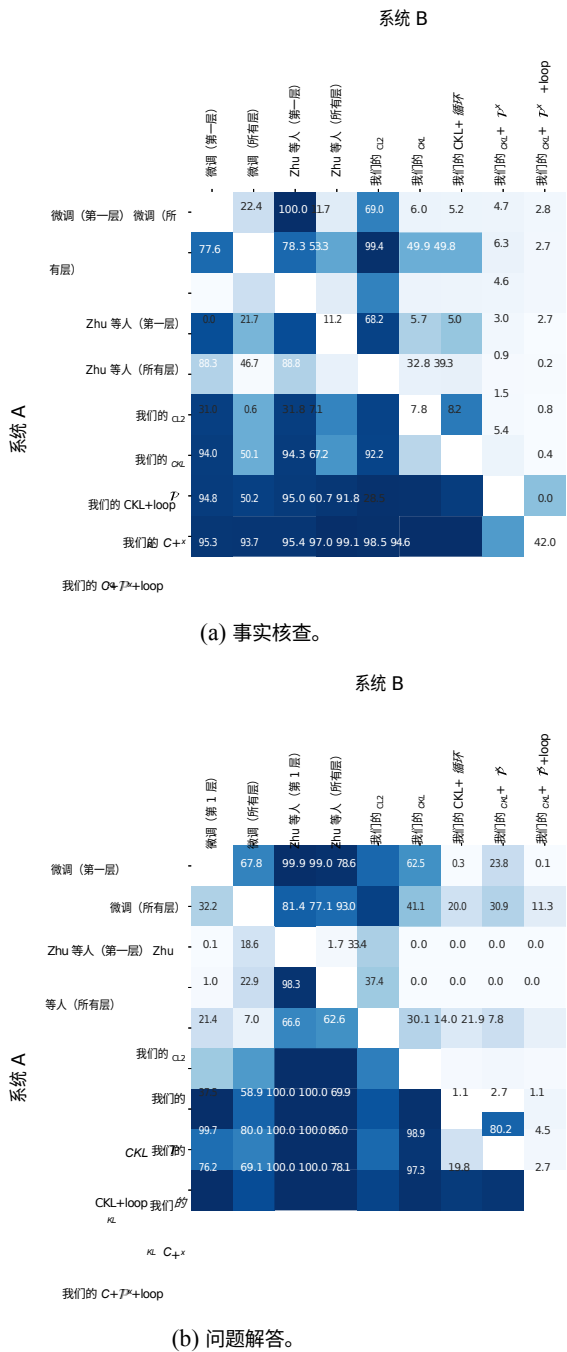


图 6：根据指标加权和 (见表 1 中的独立值) 抽样混合系数，系统 A 优于系统 B 的概率
从 Dirichlet 分布 ($\alpha=1$ ，以涵盖各种度量组合) 中提取 1000 次。KNOWLEDGEEDITOR ($C_{KL} + P^x + \text{loop}$) 优于竞争系统的概率很高 (FC 为 $> 97\%$ ，QA 为 $> 88\%$)，这表明在对指标分配一定权重时，加权总和极有可能有利于我们的方法。用颜色显示更佳视图。